

分类号: _____

学校代号: 11847

UDC: _____

密级: _____

学号: _____

佛山大学

硕士学位论文

(理学硕士)

基于改进 YOLOv11 的地下排水管道
缺陷智能检测方法研究

作者姓名: _____

学科专业: _____

导师姓名: _____

完成时间: _____

Foshan University

A dissertation for master's degree

**Research on Intelligent Defect Detection Method
for Underground Drainage Pipelines Based on
Improved YOLOv11**

Author: _____

Speciality: _____

Supervisor: _____

Finished time: _____

学位论文独创性声明

本人郑重声明：所呈交的学位论文是在导师指导下独立完成的研究成果。除文中已经明确注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律后果由本人承担。

论文作者签名：_____

日期：_____

学位论文版权使用授权声明

本人完全了解佛山大学关于保存、使用学位论文的有关规定，同意学校保留并按规定向有关部门或机构送交论文的印刷本和电子版，允许论文被查阅和借阅；同意学校将本论文的全部或部分内容编入有关数据库进行检索，并采用影印、缩印、扫描或数字化等方式保存、汇编和使用。本授权声明适用于涉密论文解密后以及非涉密论文。

保密情况：☐ 公开 ☐ 保密（_____ 年）

论文作者签名：_____

日期：_____

指导教师签名：_____

日期：_____

摘要

地下排水管网是城市基础设施体系中的重要组成部分，其运行状态直接影响城市排涝安全、道路运行秩序与生态环境质量。当前，基于闭路电视图像的排水管道检测已成为管网运维中的重要技术手段，但传统人工判读方式仍存在效率低、主观性强以及漏判误判率高等问题。与此同时，地下排水管道缺陷图像普遍具有缺陷目标尺度小、边界模糊、背景干扰强、正常样本占比高以及源域与目标域分布差异明显等特点，导致现有通用目标检测方法在该场景中的检测精度、鲁棒性和跨域泛化能力仍然受限。

针对上述问题，本文围绕地下排水管道 CCTV 图像缺陷检测任务，构建了“前级高召回预筛 + 后级精确检测”的总体框架。首先，结合公开 SewerML 数据与目标域巡检数据，构建源域单标签分类数据集和目标域六类结构性缺陷检测数据集；其次，面向复杂背景和小目标场景，提出一种基于改进 YOLOv11 的缺陷检测方法，从注意力机制、检测头和损失函数三个层面提升模型对细粒度缺陷和难样本的识别能力；再次，针对目标域样本有限和域差明显的问题，设计源域分类预训练与目标域微调相结合的跨域迁移策略，以增强模型的目标域适应性。

本文后续将通过前级预筛实验、检测对比实验、消融实验、迁移实验和可视化分析，对所提方法在精度、召回、误报控制和跨域泛化方面的有效性进行验证。研究目标是形成一条兼顾检测性能、标注成本与工程可部署性的地下排水管道缺陷智能识别技术路线，为城市排水管网智能巡检提供方法支撑。

关键词：地下排水管道；缺陷检测；YOLOv11；迁移学习；跨域适应；CCTV 图像

Abstract

Urban underground drainage pipelines are critical components of municipal infrastructure, and their operating conditions directly affect urban flood control, traffic safety, and environmental governance. CCTV-based inspection has become an important technical approach for drainage pipeline maintenance. However, conventional manual inspection still suffers from low efficiency, strong subjectivity, and high rates of missed and false judgments. In addition, CCTV images of drainage pipelines usually contain small defect targets, blurred boundaries, complex background noise, a high proportion of normal samples, and obvious distribution gaps caused by different devices, lighting conditions, and regional environments. These factors limit the accuracy, robustness, and cross-domain generalization of existing generic detection methods in real sewer inspection scenarios.

To address these challenges, this thesis constructs a two-stage framework that combines high-recall pre-screening with precise downstream detection for underground drainage pipeline defects. A source-domain single-label classification dataset and a target-domain six-class structural-defect detection dataset are organized to support progressive learning from source representation modeling to target-domain detection. On this basis, an improved YOLOv11-based detector is developed by enhancing attention modeling, redesigning the detection head, and refining the loss function, while a cross-domain transfer strategy is introduced through source-domain classification pretraining and target-domain fine-tuning.

The proposed framework will be further validated through pre-screening experiments, comparative detection experiments, ablation studies, transfer experiments, and qualitative analysis. The overall goal is to provide a practical and engineering-oriented technical route for intelligent CCTV inspection of underground drainage pipelines under limited annotations and domain shift.

Key words: underground drainage pipeline, defect detection, YOLOv11, transfer learning, cross-domain adaptation, CCTV image

目录

摘要	I
Abstract	II
第 1 章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.2.1 排水管道缺陷视觉检测研究	2
1.2.2 基于 YOLO 的缺陷检测研究	2
1.2.3 弱监督定位与低标注增强研究	2
1.2.4 迁移学习与跨域适应研究	2
1.3 现有研究存在的问题	3
1.4 研究内容与技术路线	4
1.5 本文主要创新点	5
1.6 论文结构安排	5
第 2 章 理论基础与关键技术	6
2.1 地下排水管道缺陷类型与图像特征	6
2.1.1 地下排水管道缺陷类型	6
2.1.2 缺陷图像特征分析	6
2.2 图像分类与目标检测评价指标	7
2.2.1 目标检测任务定义	7
2.2.2 目标检测方法演进	8
2.2.3 常用评价指标	9
2.3 YOLO 系列与 YOLOv11 原理	10
2.3.1 YOLO 系列的基本思想	10
2.3.2 YOLOv11 结构概述	10
2.3.3 分类模型与检测模型的区别	11

2.3.4	YOLOv11 作为本文基线的工程理由	11
2.4	注意力机制理论	12
2.4.1	注意力机制的作用机理	12
2.4.2	注意力机制与 sewer 场景的匹配性	12
2.5	损失函数与框回归相关理论	13
2.5.1	分类损失与定位损失的协同作用	13
2.5.2	损失设计与 Precision/Recall 折中	13
2.6	迁移学习与域适应理论	14
2.6.1	源域、目标域与域差定义	14
2.6.2	地下排水管道场景中的主要域差来源	15
2.6.3	渐进式迁移路线的理论依据	15
2.7	CAM / Grad-CAM 与弱监督定位理论	16
2.7.1	CAM / Grad-CAM 的基本思想	16
2.7.2	监督粒度连续体与低标注学习启示	17
2.7.3	人机协同闭环与工程意义	17
2.7.4	候选区域与伪标签的角色定位	18
2.8	本章小结	19
第 3 章	数据集构建与总体研究框架	21
3.1	数据来源与总体说明	21
3.1.1	源域数据	21
3.1.2	目标域数据	21
3.2	源域分类数据集构建	21
3.2.1	单标签化原则	21
3.2.2	源域六类与样本规模	22
3.2.3	源域数据的任务定位	22
3.3	目标域六类缺陷定义与标签映射	23
3.3.1	目标域最终检测类别	23
3.3.2	源域与目标域的关系	23
3.4	第一阶段与第二阶段任务定义	24
3.5	数据预处理与划分协议	25
3.5.1	预处理与增强	25
3.5.2	划分协议与运行型验证集	25

3.6	总体系统框架设计	26
3.7	评价协议与实验规范	27
3.8	本章小结	27
第 4 章	前级高召回预筛与弱监督标注增强策略	28
4.1	前级高召回预筛问题定义	28
4.2	基于同源图像重标注的二分类 gate 构建	28
4.3	YOLO11-cls 五尺度基线扫描	28
4.4	阈值校准与 operating point 选择	29
4.5	Hard Negative Mining 策略	31
4.6	CAM/Grad-CAM 伪框生成与质量控制	31
4.7	本章小结	32
第 5 章	基于改进 YOLOv11 的管道缺陷检测与跨域迁移策略	33
5.1	基线检测模型与问题分析	33
5.2	注意力机制改进	33
5.2.1	改进动机	33
5.2.2	模块设计与嵌入方式	33
5.3	检测头改进	34
5.3.1	原始检测头局限性	34
5.3.2	改进思路	34
5.4	损失函数改进	34
5.4.1	优化目标	34
5.4.2	形式化表达	34
5.5	改进 YOLOv11 总体结构	35
5.6	跨域迁移适应训练策略	35
5.6.1	跨域问题分析	35
5.6.2	迁移路径设计	36
5.7	训练流程与实现细节	36
5.8	本章小结	37
第 6 章	实验结果与分析	38
6.1	实验设置	38
6.1.1	实验平台与训练配置	38

目录

6.2	第一阶段前级预筛基线与结果分析	38
6.3	第一阶段关键消融实验	39
6.4	第二阶段检测 baseline 对比实验	40
6.5	创新点一消融实验	40
6.6	创新点二迁移学习对比实验	41
6.7	系统级对比实验	41
6.8	可视化与错误分析	42
6.9	本章小结	43
第 7 章	结论与展望	44
7.1	研究结论	44
7.2	不足之处	44
7.3	展望	45
	参考文献	46
	致谢	53
	在读期间发表的学术论文与取得的其他成果	54
	补充图表规划	55
	补充说明	56

第 1 章 绪论

1.1 研究背景与意义

地下排水管网是城市基础设施体系的重要组成部分，其运行状态直接关系到城市防涝、污水输送、水环境治理和道路运行安全。由于排水管道长期处于封闭、潮湿和腐蚀环境中，裂缝、破损、错口、变形、渗漏和侵入等缺陷会在长期服役过程中逐步累积，并可能进一步引发排水能力衰减、污染泄漏甚至地面塌陷等安全问题^{[26][7]}。因此，建立高效、可靠的地下排水管道缺陷智能识别方法，具有明确的工程价值和现实意义。

当前工程场景仍以 CCTV 巡检为主。CCTV 技术能够在非开挖条件下获取连续图像和视频，但后续的缺陷识别、分类和复核仍大量依赖人工判读。随着巡检规模扩大，海量正常帧和高重复度图像使人工复核成本显著上升，误判、漏判和效率下降问题逐渐突出^{[24][23]}。因此，如何利用计算机视觉方法实现对排水管道缺陷的辅助识别，已成为 sewer inspection 研究的核心任务。

从技术发展看，该方向经历了由传统图像处理与机器学习，到深度分类和目标检测，再到弱监督定位、迁移学习和系统级优化的演进过程。早期工作主要依赖人工特征和经典分类器，近年则逐步转向以 CNN 和 YOLO 为代表的深度学习模型，并开始关注公开数据、低标注增强和跨域适应等更贴近真实部署的问题^{[30][1]}。本文即在这一演进背景下，围绕改进 YOLOv11 与跨域迁移展开研究。




图 1.1 地下排水管道缺陷智能识别研究发展脉络

注：根据文献^{[30][1]} 整理与改绘。

1.2 国内外研究现状

1.2.1 排水管道缺陷视觉检测研究

排水管道缺陷自动识别最初建立在传统图像处理和人工特征设计基础上。这类方法通常围绕边缘、纹理和候选区域规则展开，能够在局部场景中形成初步自动判别能力，但对光照变化、背景噪声和成像设备差异较为敏感，泛化能力有限^{[30][29]}。随着深度学习的发展，研究重心逐渐转向数据驱动的特征学习，排水管道缺陷识别开始由“特征设计问题”转变为“特征学习与任务适配问题”^{[27][15]}。

1.2.2 基于 YOLO 的缺陷检测研究

近年来，YOLO 系列因具有较好的实时性和工程生态，已成为 sewer defect detection 中最常见的检测路线之一。现有工作多围绕注意力机制、特征融合、检测头和轻量化设计展开改进，以适应 sewer 图像中小目标、弱纹理和复杂背景等特点^{[9][10]}。但已有研究也表明，单纯套用通用 detector 往往难以兼顾高召回、低误报和跨域稳定性，场景化改造仍然必要^{[47][2]}。

1.2.3 弱监督定位与低标注增强研究

Sewer-ML 的公开发布使该方向首次具备较统一的 benchmark 条件，也使图像级分类、CAM/Grad-CAM 候选区域生成和弱监督定位研究成为可能^[6]。在此基础上，研究者开始关注类别不均衡、标签质量和低标注增强等问题。相关研究表明，图像级标签可以辅助生成候选区域，但伪框质量仍高度依赖分类模型稳定性和后续质量控制^{[13][3]}。

1.2.4 迁移学习与跨域适应研究

公开数据与本地巡检数据之间在设备、照明、管材纹理和标签口径上普遍存在明显差异，导致模型跨域泛化能力受限。现有 sewer transfer learning 研究已经证明，源域预训练和目标域微调能够缓解目标域样本不足问题，但如何把迁移学习与 detector 改进、弱监督增强和系统级误报控制整合为完整技术链条，仍缺少较系统的研究^{[8][14]}。

表 1.1 现有研究路线对比与本文定位

路线类型	代表文献	监督粒度	主要优点	主要问题	与本文关系
传统图像处理与机器学习	[30][29]	图 像 级/候 选 区域级	解释性较强、实现简单	泛化能力弱、对场景变化敏感	作为发展起点与背景对照
深度分类与层次分类	[16][17]	图像级	适合筛查与长尾类别建模	难以直接输出精确位置	支撑前级 gate 与源域预训练
改进 YOLO 检测	[9][10]	框级监督	工程实现成熟、部署方便	依赖目标域检测框标注	对应本文创新点 1
WSOL/CAM 与伪框增强	[3][20]	图 像 级/弱 监 督	可降低初始标注成本	伪框质量波动较大	支撑本文低标注增强链路
迁移学习与跨域适应	[8][42]	预训练 + 微调	缓解样本不足与域差	迁移收益依赖源域相关性	对应本文创新点 2

1.3 现有研究存在的问题

综合已有研究，当前排水管道缺陷智能识别仍面临四类核心问题：其一，正常帧占比高，直接检测容易带来误报累积和较高复核成本；其二，缺陷多为小目标、细长目标或弱纹理异常，通用 **detector** 难以稳定兼顾召回率与精度；其三，目标域高质量检测框标注代价高，限制了模型快速构建与迭代；其四，源域与目标域之间存在明显 **domain gap**，现有研究对“源域预训练、目标域微调、弱监督增强和系统级验证”的统一组织仍然不足^{[11][3]}。

基于这些问题，本文将研究重点组织为一条完整技术路线：先利用源域分类学习建立 **sewer-specific** 表征，再通过高召回预筛和弱监督候选区域生成降低标注与误报压力，最后在改进 YOLOv11 与跨域迁移策略上完成目标域缺陷检测。




图 1.2 地下排水管道缺陷检测的问题链及本文技术路线

注：根据文献^{[24][3]} 整理与改绘。

1.4 研究内容与技术路线

围绕上述问题，本文主要开展以下工作：构建源域单标签六类分类数据与目标域六类结构性缺陷检测数据，建立高召回预筛与弱监督伪框增强链路，提出改进 YOLOv11 检测模型，并构建源域预训练、目标域微调 and 检测微调相衔接的跨域迁移训练策略。整体上，论文按照“问题背景、前级支撑链、改进 detector、跨域适应与系统级验证”的顺序逐步展开。

表 1.2 本文研究内容与章节对应关系

研究问题	对应章节	主要目标
RQ1: 高召回 gate 是否能够有效降低误报	第 3 章、第 4 章、第 6 章	验证前级筛查在高召回约束下的减负效果
RQ2: 改进 YOLOv11 是否提升复杂场景检测性能	第 5 章、第 6 章	验证注意力、检测头和损失函数的协同增益
RQ3: 跨域迁移是否缓解样本不足与域差问题	第 5 章、第 6 章	验证源域预训练与目标域微调的迁移价值
RQ4: 两阶段系统是否优于单阶段直接检测	第 4 章、第 6 章	验证系统级误报控制与工程适配性

1.5 本文主要创新点

1. 提出一种面向地下排水管道缺陷场景的改进 YOLOv11 检测方法，通过注意力机制、检测头和损失函数协同优化，提升复杂背景和小目标条件下的检测能力。
2. 提出一种源域预训练与目标域微调相结合的跨域迁移适应训练策略，利用公开 Sewer-ML 数据和少量目标域样本提升目标域检测模型的初始化质量与泛化能力。

需要说明的是，前级高召回预筛、CAM 热力图和伪框构建不单独作为创新点，而是服务于上述两个核心创新点落地的支撑链条。

1.6 论文结构安排

全文共分为七章：第 1 章为绪论；第 2 章介绍理论基础与关键技术；第 3 章介绍数据集构建与总体研究框架；第 4 章阐述前级高召回预筛与弱监督标注增强策略；第 5 章介绍改进 YOLOv11 检测方法与跨域迁移策略；第 6 章给出实验结果与分析；第 7 章总结全文并展望后续研究方向。

第2章 理论基础与关键技术

2.1 地下排水管道缺陷类型与图像特征

2.1.1 地下排水管道缺陷类型

地下排水管道缺陷并不是标准自然图像中的显著目标，而是与管壁纹理、接口结构、照明条件和运行工况耦合的一类工程视觉对象。结合本文目标域任务，最终检测类别固定为CrackBreak、SurfaceDamage、Deformation、JointDislocation、Intrusion 和 Infiltration 六类，其中既包含局部纹理破坏，也包含接口异常和整体几何形变^{[26][7]}。这种类别冻结并不是简单删减 Sewer 场景中的病害种类，而是围绕最终检测任务的可实施性、类别语义稳定性以及目标域标注条件进行的任务化选择。

从工程属性看，结构性病害通常与管道安全、维修优先级和后续养护决策直接相关，因此更适合作为检测主任务。相较之下，部分功能性缺陷、构造信息和工况标签更适合出现在预筛、分类辅助或附录说明中，而不宜与最终检测类别混合建模^{[24][6]}。这一点决定了本文后续不会把源域类别体系与目标域检测类别做机械一一对应，而是采用“源域较粗、目标域冻结”的映射思路，以支撑后续跨域训练和实验对比。

从视觉表现上看，六类结构性缺陷又具有明显差异。裂缝与破损更依赖于局部细纹理和细长轮廓感知；表面损伤与腐蚀更接近区域性异常，边界往往模糊；变形强调整体几何变化；错口与侵入则与接口结构关系紧密相关；渗漏通常表现为低对比度拖尾或局部湿痕^{[11][9]}。因此，后续模型设计必须同时考虑局部细节保持、上下文建模和复杂背景抑制，不能把所有缺陷当作视觉属性一致的普通目标。

2.1.2 缺陷图像特征分析

这类图像的主要难点体现在四个方面：一是缺陷目标通常尺度较小，局部有效像素占比低；二是缺陷边界模糊，许多病害只表现为弱纹理或低对比异常；三是背景干扰强，反光、水膜、污渍和沉积物会造成明显伪激活；四是类别之间存在视觉相似性，易出现类间混淆^{[11][4]}。对于长视频巡检场景而言，摄像头自带光

源造成的中心高亮、边缘衰减和局部曝光过强等现象，也会进一步放大模型对背景纹理的误响应。

除静态图像特征外，排水管道巡检数据还具有明显的分布不均衡特征。正常帧通常远多于缺陷帧，且不同缺陷类别样本数量差异很大，少数类往往具有更高工程风险却更难获得稳定标注^{[13][16]}。这意味着模型若只优化总体准确率，往往会偏向背景和多数类，从而在真实部署中表现为“总体指标尚可，但关键缺陷漏检较多”。

从方法论角度看，上述视觉难点直接约束后续研究路线：如果任务核心问题来自小目标与弱纹理，则需要在特征表达阶段尽量保留细粒度信息；如果误报主要来自污渍、反光和沉积干扰，则需要在前级预筛和后级 detector 中同时关注背景抑制；如果目标域高质量框标注有限，则必须通过迁移学习和弱监督定位去降低监督构建成本。也正因为如此，第 4 章和第 5 章中的模型改进与跨域迁移，并不是相互独立的附加操作，而是对同一组任务困难的分层回应。




图 2.1 地下排水管道缺陷检测的关键理论支撑关系

注：根据本文理论框架整理与改绘。

2.2 图像分类与目标检测评价指标

2.2.1 目标检测任务定义

目标检测任务要求模型同时完成类别判定与空间定位。与图像分类仅回答“图像中是否存在某类目标”不同，检测模型还需要给出候选边界框、类别标签及相应置信度，因此更适合服务于排水管道巡检中的“哪里有缺陷、属于什么类

型、需要优先复核哪些区域”等实际需求^{[15][12]}。对 sewer 场景而言，这种能力尤其重要，因为同一张图像中可能同时包含多个异常区域，且异常边界往往并不清晰。

按照候选区域生成方式和预测组织形式的不同，现有检测方法大致可以分为两阶段方法、一阶段方法和端到端集合预测方法。两阶段方法以 R-CNN 系列为代表，先生成候选区域再分类回归，具有较强的精细识别能力；一阶段方法以 SSD 和 YOLO 系列为代表，将分类和回归整合到同一网络中，兼顾速度与精度；基于 Transformer 的 DETR 路线则从集合匹配角度重构了检测流程^{[31][32][44]}。考虑到本文面向的是海量巡检图像和长视频场景，一阶段检测器在工程部署上更具优势，因此成为后续模型设计的主要基础。

2.2.2 目标检测方法演进

从发展脉络看，地下排水管道缺陷检测并不是一开始就建立在深度目标检测基础之上的。早期工作更多依赖传统图像处理、边缘纹理特征和机器学习分类器，在局部规则明确的场景下能够形成初步自动筛查能力，但对设备差异、光照变化和背景噪声极为敏感^{[30][29]}。随着 CNN 的引入，研究重点逐渐转向深度特征学习，缺陷识别开始从“人工设计特征”转变为“以数据驱动的特征学习”为核心。

在此基础上，一阶段 detector 尤其是 YOLO 路线逐渐成为 sewer defect detection 的主流工程方案。其原因并不只是速度快，更在于该路线生态成熟、训练流程稳定、易于与分类模型、迁移学习和部署工具衔接^{[9][10]}。但已有研究同时指出，直接采用通用 detector 往往难以同时兼顾高召回、低误报和跨域稳定性，这也是本文后续要从注意力机制、检测头与损失函数三个层面进行场景化改进的直接动因。

表 2.1 典型检测范式比较表

检测范式	代表方法	主要优点	主要局限	与本文关系
两阶段检测	R-CNN 系列	候选区域精细，识别能力较强	推理较慢，部署成本较高	作为理论参照，不作为主路线
一阶段检测	SSD、YOLO 系列	速度快，工程实现成熟	小目标和复杂背景下易受干扰	作为本文主路线
端到端集合预测	DETR 系列	结构统一，后处理依赖较弱	收敛与部署成本较高	作为强基线参考

2.2.3 常用评价指标

本文后续同时涉及源域分类、前级高召回预筛和目标域目标检测三个层次，因此评价指标不能只依赖单一准确率。对于前级预筛，更重要的是在尽量不漏掉异常样本的前提下过滤正常样本；对于检测模型，则需要同时关注识别精度、定位质量与误报水平。基于这一考虑，本文不追求在理论基础章节中罗列过多指标，而是只保留后续实验中会反复使用、且能直接支撑研究问题回答的六个核心指标。

其中，Precision、Recall 与 F1-score 用于描述识别准确性与漏检之间的折中关系，Specificity 与 Gate Recall 用于服务第一阶段预筛在高召回约束下的误报控制分析，mAP@0.5 与 mAP@0.5:0.95 则用于评价第二阶段 detector 的检测与定位质量。上述指标既覆盖了分类与检测的主要评价需求，也能对应后续章节中的系统级实验结论。为便于全文统一引用，表 2.2 对这六个核心指标进行集中定义。

表 2.2 评价指标定义与说明

指标	计算方式说明	主要含义	本文中的使用场景
Precision	预测为正的样本中，真实为正的的比例	预测结果的准确性	反映误报控制能力，直接影响人工复核成本。
Recall	真实正样本中，被模型成功检出的比例	对真实缺陷的覆盖能力	对缺陷检测尤其关键，漏检会直接削弱维护决策可靠性。
Specificity	真实负样本中，被模型正确排除的比例	对正常样本的过滤能力	是第一阶段 gate 的核心指标，反映正常帧过滤能力。
F1-score	Precision 与 Recall 的调和平均	识别效果的综合折中	适合用于概括模型总体识别能力，但仍需配合 Precision 与 Recall 同时分析。
Gate Recall	前级预筛保留下来的异常样本占全部异常样本的比例	前级 gate 对异常样本的保留能力	是第一阶段的硬约束指标，用于保证真正异常样本尽可能不被误滤除。
mAP@0.5	在 IoU 阈值为 0.5 时统计平均精度	模型是否大致检出目标	是第二阶段 detector 的主评价指标之一，更贴近工程中“能否发现缺陷”的需求。
mAP@0.5:0.95	在多个 IoU 阈值下统计平均精度并取平均	同时反映检测与定位质量	适合用于正式实验对比，能够更严格地衡量定位边界是否稳定。

需要说明的是，本文并未在第二章保留 AUROC、AUPRC、NRR、PTR 和

FP/image 等其他指标，并不代表这些指标不重要，而是因为这些指标更适合在对应实验章节中结合具体任务视图解释。例如，第 4 章讨论第一阶段 operating point 时会重点引入 NRR 与 PTR；第 6 章讨论系统级结果时会引入 FP/image 和更多误报控制指标。这样安排能够避免理论基础章节过早堆积大量符号，同时使每个指标都在最合适的实验语境下被解释。

此外，还需要强调一点：评价指标的选择本身就体现了论文对任务目标的理解。若只强调某一单点精度指标，容易掩盖高召回条件下的误报成本；若只强调系统级过滤能力，又可能忽略 detector 的定位质量。因此，本文把六个核心指标放在理论基础章节统一定义，目的并不是追求指标完整，而是提前给出后续实验比较的逻辑坐标系，使第 4 章和第 6 章中的所有对比都能围绕同一套评价语义展开。

2.3 YOLO 系列与 YOLOv11 原理

2.3.1 YOLO 系列的基本思想

YOLO 系列将目标检测统一建模为单阶段回归问题，能够在单个网络中同时完成类别判断和边界框预测，因此兼具较好的速度与工程可部署性^[33]。这一范式的关键优势在于训练和推理流程相对统一，便于在同一工程框架内完成数据准备、模型迭代和结果部署。对排水管道场景而言，这一路线更适合长视频、大批量图片和快速迭代训练流程。

从方法发展上看，YOLO 的优势不只体现在实时性，更体现在其逐步形成了成熟的特征提取、多尺度融合和检测头组织范式。随着不同版本持续迭代，YOLO 家族逐渐在工业缺陷检测、基础设施巡检和嵌入式部署场景中形成较强工程竞争力。这也是本文选择在 YOLO 路线而不是完全另起炉灶的端到端方案上做改进的主要原因。

2.3.2 YOLOv11 结构概述

YOLOv11 在工程实现中延续了主干特征提取、颈部多尺度融合和检测头预测的基本结构，同时保留了较成熟的训练与部署接口。本文选择 YOLOv11 作为基线，原因在于其工程生态稳定、改造接口清晰，便于在同一平台上完成前级分类、后级检测和跨域迁移实验。




图 2.2 YOLOv11 检测模型结构示意图

注：根据官方公开结构关系整理与改绘^[57]。

2.3.3 分类模型与检测模型的区别

需要指出的是，YOLOv11 的分类模型与检测模型虽然共享部分工程接口，但两者面向的监督粒度和输出目标并不相同。分类模型更适合学习“图像中是否存在某类异常”的判别边界，因此非常适合作为源域表征学习和前级 gate 的工具；检测模型则负责完成类别识别与空间定位，因而更适合承担最终缺陷检测任务。这一区分正是本文采用“源域分类预训练 → 目标域分类微调 → 目标域检测训练”渐进路线的理论基础。

与此同时，YOLOv11 在 sewer 场景中的局限也很明确：面对小目标、弱纹理和复杂背景时，通用结构往往难以同时兼顾召回率与误报控制，因此需要在特征表达、检测头设计和训练目标三个层面做针对性改进^{[9][10]}。也就是说，YOLOv11 在本文中既是一个成熟的工程起点，也是一个必须被场景化改造的基线平台。

2.3.4 YOLOv11 作为本文基线的工程理由

本文最终选择 YOLOv11 而不是直接转向完全不同的检测体系，主要出于三点考虑。第一，YOLO 路线在排水管道缺陷研究中已经有较多成功实践，具备较强的同领域可迁移性，因此能够与本文的 SewerML 源域预训练、目标域 detector 训练形成自然衔接^{[9][8]}。第二，YOLOv11 在工程实现上具备较成熟的训练、验证和推理接口，适合与本文当前的数据组织方式和运行环境对接。第三，YOLOv11 仍保留了足够清晰的 backbone、neck、head 分层结构，便于后续在注意力、检测头和损失函数层面开展可解释的改进。

从论文写作角度看，基线模型的选择还决定了后续消融实验是否具有说服力。若基线平台本身过于冷门或改造接口不清晰，则很难把注意力模块、检测头

改进和迁移策略放到同一张实验矩阵里进行公平比较。YOLOv11 恰好能够提供统一的平台，使本文后续的所有改进都可以围绕同一基线展开，从而保证实验设计的可读性和结论的可归因性。

2.4 注意力机制理论

2.4.1 注意力机制的作用机理

注意力机制的核心作用是强化关键区域和关键通道响应，抑制背景噪声对特征学习的干扰。对于 sewer defect detection 而言，注意力模块的价值主要体现在两个方面：一是提升模型对细小裂缝、接口异常和局部渗漏等弱显著目标的聚焦能力；二是降低反光、污渍和壁面纹理带来的伪激活^[11]。

现有研究中常见的轻量级注意力模块包括 SE、CBAM 和 ECA。它们分别强调通道重标定、通道与空间联合建模以及低开销的局部跨通道交互。对本文而言，注意力模块选择的原则不是“越复杂越好”，而是是否能在 sewer 场景中以较低代价带来稳定增益。若一个模块虽然理论表达能力更强，却显著增加参数量、推理时延或训练不稳定性，那么其工程价值可能并不高。

因此，第二章对注意力模块的讨论重点并不是罗列所有变体，而是建立一个清晰的筛选准则：是否能增强关键缺陷区域响应、是否有助于抑制背景噪声、是否能够自然嵌入 YOLOv11 的 backbone/neck 结构，以及是否适合后续消融实验进行公平比较。第 5 章的注意力设计选择将严格围绕这些原则展开。

2.4.2 注意力机制与 sewer 场景的匹配性

对于地下排水管道场景，注意力机制的意义并不只是“提高特征表达能力”这一抽象说法，而是与具体误差来源直接相关。若模型在反光、水膜或污渍区域持续产生高响应，则说明其显著性分配已经偏离真实缺陷区域；若模型对细小裂缝和接口异常的响应被大面积背景纹理淹没，则说明其在关键区域聚焦方面存在不足。注意力模块正是在这一层面介入，通过对通道和空间信息进行重加权，使模型把更多表征能力集中到与缺陷有关的局部区域。

不过，注意力机制并非一定越强越好。对于需要长期运行的工程系统而言，任何结构改动都必须考虑复杂度、稳定性和后续部署成本。也正因为如此，本文把注意力模块定位为“有明确任务指向的增强组件”，而不是单纯为了提升指标而叠加的装饰性模块。后续消融实验将围绕这一点展开，即既比较它是否有效，

也比较它是否值得。

表 2.3 典型注意力模块比较表

模块	机制类型	参数/计算开销	优点	是否适合本文
SE	通道重标定	低到中等	结构简单，易集成	适合作为轻量基线
CBAM	通道 + 空间联合注意力	中等	对关键区域建模更直接	适合复杂背景场景
ECA	局部跨通道交互	低	代价较小，部署友好	适合作为低开销候选

2.5 损失函数与框回归相关理论

2.5.1 分类损失与定位损失的协同作用

检测模型的训练效果不仅取决于网络结构，也取决于训练目标的组织方式。对于 sewer 缺陷检测，损失函数需要同时面对类别不均衡、难样本区分不足和边界模糊等问题。分类侧常见损失包括 BCE、CE 和 Focal Loss；定位侧通常依赖 IoU、GIoU 等框回归损失^{[34][43]}。

从任务角度看，Focal Loss 更适合抑制大量易分类样本对梯度的主导，IoU 类损失则有助于提高边界回归质量。本文后续对损失函数的改进，核心并不是机械替换公式，而是围绕“如何在保持召回率的同时抑制误报，并改善 hardest positive / hardest negative 区分”展开。对于排水管道场景而言，这种优化尤其关键，因为真实任务不仅要求检出缺陷，还要求减少大量正常背景中的误报。

换言之，损失函数设计在本文中承担的是“把视觉难点转化为训练偏好”的角色。如果任务最难点是少数类与弱纹理目标，则损失函数应尽量突出难样本；如果后续系统更看重高召回下的误报抑制，则损失函数也应避免过度偏向易样本和多数类。正因为存在这种任务依赖性，第 5 章不会简单照搬通用损失设置，而是把损失函数作为与注意力模块、检测头并列的核心改进项。

2.5.2 损失设计与 Precision/Recall 折中

在工程检测任务中，损失函数选择还会直接影响 Precision 与 Recall 的平衡关系。若训练目标更强调容易区分的样本，模型可能在验证集上表现出较高 Precision，却牺牲了对弱显著目标和边界模糊目标的 Recall；反之，若训练目标过

于强调正样本召回，又可能在复杂背景中引入更多误报。这种折中关系在 sewer defect detection 中尤为突出，因为正常背景占比高、异常边界不稳定且类间相似度高。

因此，本文并不把损失函数视为单一公式替换问题，而是把它理解为“如何将研究目标写入训练过程”的方式。后续改进若能在高召回条件下抑制误报，并改善 hardest normal 与 hardest positive 的区分能力，就说明损失函数设计真正契合了本文任务需求，而不是仅仅在某个单点指标上取得偶然提升。

表 2.4 典型损失函数与适用问题比较表

损失函数	主要解决问题	适合场景	与本文关系
BCE / CE	基础分类训练	常规分类与检测分类支路	作为基础对照
Focal Loss	类别不均衡、易样本主导	正负样本数量差距大时	适合作为候选改进项
IoU / GIoU 类损失	提升边界框回归质量	需要更稳定定位时	支撑后续定位优化分析
组合损失	同时兼顾分类与定位目标	场景化检测任务	对应本文损失设计主线

2.6 迁移学习与域适应理论

2.6.1 源域、目标域与域差定义

迁移学习的基本思想是在源域学习通用或同领域先验，再迁移到目标域进行微调，以缓解目标域标注不足问题^{[40][41]}。对本文而言，源域是公开 Sewer-ML 数据，目标域是本地巡检数据。两者在设备、纹理、照明和标签口径上存在差异，因此模型不能只依赖公开数据训练结果直接部署。

在工程实现上，本文采用的不是高复杂度对抗式域适应，而是“源域分类预训练 → 目标域分类微调 → 目标域检测微调”的渐进路线。该路线实现成本较低、解释性较强，也更适合与低标注增强流程结合。选择这一方案的一个重要原因在于，地下排水管道场景的 domain gap 不仅来自图像风格差异，还来自缺陷定义、标注口径和设备条件差异，因此过于抽象的端到端对抗式适配未必能带来最稳的收益。

更进一步地，迁移学习在本文中并不只是“训练技巧”，而是连接公开数据与本地任务的核心桥梁。若没有源域预训练，目标域 detector 只能在有限样本

下从零开始学习，容易出现训练不稳定和类间混淆；若没有目标域微调，源域模型又难以适应本地场景中的成像条件与标签口径。这也是后续实验必须设置 from-scratch、official pretrained、source pretrain 和 source+target finetune 多组对比的理论原因。

2.6.2 地下排水管道场景中的主要域差来源

对排水管道场景而言，域差并不是抽象的统计概念，而是由具体采集条件和标注条件共同形成的。不同地区在管材、接口形式、积水程度和照明环境上往往存在明显差异；不同巡检设备在分辨率、曝光方式、移动速度和畸变控制上也存在差别；不同数据集甚至可能对相同缺陷给出不同的标签口径^{[8][1]}。这些因素叠加后，会导致源域模型即便在公开数据上表现良好，也未必能直接迁移到本地目标域。




图 2.3 地下排水管道检测任务中的主要域差来源

注：根据相关 sewer detection 与 transfer learning 文献整理与改绘。

2.6.3 渐进式迁移路线的理论依据

在这一前提下，本文采用渐进式迁移路线具有明确理论合理性。源域分类预训练负责学习同领域缺陷表征，目标域分类微调负责建立对本地图像分布的初步适应，目标域检测微调则进一步把这种表征转化为位置级监督能力。相较于直接采用重对抗式域适应，渐进式路线更易解释、训练代价更低，也更符合目前工程侧“少量标注、逐步增强”的现实条件。

这一路线的另一个优势在于能够与第一阶段 gate 和弱监督定位自然衔接。因为分类模型本身就是前级预筛与 CAM 热力图生成的基础，所以源域分类预训

练不会成为独立于全文的旁支实验，而是同时服务于迁移学习、低标注增强和两阶段系统构建。这正是本文将迁移策略写成核心创新点之一的原因。

表 2.5 迁移学习与域适应策略比较表

方法类型	是否需要目标域标签	是否需要对抗训练	工程复杂度	本文采用情况
通用预训练 + 微调	需要	否	低	作为基础对照
同领域源域预训练 + 微调	需要少量标签	否	低到中等	本文主路线
对抗式域适应	可弱依赖标签	是	高	仅作理论参考
伪标签/自训练	需要少量标签或高置信预测	否	中等	作为扩展备选

2.7 CAM / Grad-CAM 与弱监督定位理论

2.7.1 CAM / Grad-CAM 的基本思想

CAM 和 Grad-CAM 通过分析分类模型的响应分布，给出图像中对当前类别判别最关键的区域，是图像级监督向候选区域监督过渡的重要工具^{[38][39]}。在本文中，热力图不直接作为最终真值，而是作为候选区域生成和低标注增强的中间监督信号。

这一路线的意义在于把人工工作从“全量从零标注”转变为“针对候选区域进行抽检与快修”。对于目标域样本有限的 sewer 场景，这种做法能够在控制标注成本的同时，为 detector 训练提供更具针对性的初始监督。也正因如此，本文在后续章节中会把 CAM / Grad-CAM 明确界定为低标注增强支撑链的一部分，而不是把它们误写成最终 detector 的替代品。

从监督粒度角度看，CAM / Grad-CAM 的理论价值在于说明图像级标签并不必然止步于分类任务。只要分类模型能够学到稳定的类别响应区域，热力图就可以转化为候选框、候选区域或人工抽检线索，从而为检测任务提供中间层监督^{[3][58]}。这也是本文后续从源域分类预训练逐步过渡到目标域检测训练的重要理论支点。

2.7.2 监督粒度连续体与低标注学习启示

在低标注视觉任务中，监督信息不应被简单理解为“有标注”与“无标注”两种状态，而更应被看作从图像级标签、候选区域、少量精确框到充分检测标注之间连续变化的监督粒度谱系。对 sewer defect detection 而言，这一点尤其重要，因为目标域真正稀缺的往往不是图像本身，而是高质量、口径稳定且可用于 detector 训练的框级标注^{[3][58]}。

把监督粒度理解为连续体有两个直接启示：其一，源域分类预训练、目标域分类微调、CAM 候选区域生成和少量人工精框并不是互斥资源，而是可以顺序衔接、相互补充的监督层级；其二，低标注训练的关键不是单纯减少标注数量，而是先建立可靠先验，再把有限标注投入到最值得的样本和阶段上。本文后续采用的技术路线，正是基于这一思路构建。

这也意味着，本文后续的实验顺序本身具有理论基础，而不是“先做什么方便就先做什么”。源域分类实验之所以排在前面，是为了先验证同领域表征是否稳定；目标域分类微调之所以作为中间步骤，是为了把公开数据的先验压缩到本地场景；CAM 候选区域与少量人工快修之所以位于 detector 训练之前，则是为了在不大规模追加框标注成本的前提下，为检测模型建立第一版可用监督。这样的顺序安排，恰恰体现了监督粒度连续体在工程任务中的实际落地方式。

2.7.3 人机协同闭环与工程意义

从更高层次看，地下排水管道智能巡检并不是“模型完全替代人工”的单向过程，而更像是“模型与人工分工重组”的协同闭环。模型擅长的是在海量图像和长视频中快速筛出疑似异常区域，人工擅长的是利用工程经验判断复杂边界、确认疑难样本和完成最终维护决策^{[23][22]}。因此，一个真正可用的系统应当把模型视为人工能力的放大器，而不是孤立的最终判决器。

本文把前级预筛、CAM 候选区域和 detector 训练放在同一条链路中讨论，目的正是为了把“分类能否减少人工逐帧查看”“热力图能否降低初始标注成本”“检测器能否提高最终识别质量”这些问题统一到同一个工程闭环里解释。这样，后续第 6 章的实验就不仅是在报告某个模型指标更高，而是在回答整套技术路线是否真的更适合地下排水管道的真实巡检流程。

2.7.4 候选区域与伪标签的角色定位

在低标注检测任务中，伪标签并不应被理解为“替代真值”的廉价近似，而更适合作为一种中间层监督资源。对 sewer defect detection 而言，CAM / Grad-CAM 产生的候选区域本质上反映了分类模型认为最能支持当前类别判断的区域，因此它更适合承担“提示人工关注哪里”“为 detector 提供第一版粗监督”的角色，而不宜直接等同于精确边界框^{[39][3]}。这一定位能够解释为什么本文后续会把 CAM 输出、抽检规则和人工快修放在同一实验链条中分析。

进一步说，候选区域的真正价值在于重构标注流程。传统做法通常要求标注者从零开始浏览所有图像并绘制框标注，而基于候选区域的流程则先由模型给出“最值得看的地方”，再由人工进行确认、修正或否决。对于正常样本占比极高、专家标注成本较高的排水管道场景，这种重构意味着同样的人工时间可以更集中地投入到高价值样本上。因此，本文在理论上把伪标签视为“监督增强接口”，而不是单纯的临时补丁。

表 2.6 监督粒度与训练目标对应关系表

监督粒度	典型监督形式	主要训练目标	在本文中的角色
图像级监督	单标签/多标签分类标签	学习类别存在性与粗粒度判别边界	服务于源域预训练、目标域分类微调与前级 gate
候选区域监督	CAM 热力图、伪框、人工抽检结果	提供候选位置先验，降低精框构建成本	服务于弱监督增强与 detector 初始监督
框级监督	人工精修边界框	学习类别识别与空间定位	服务于最终 detector 训练与正式评测




图 2.4 从图像级监督到检测级监督的连续体

注：根据文献^{[39][3]} 整理与改绘。

2.8 本章小结

本章围绕后续研究真正需要使用的理论进行了系统梳理。首先，明确了排水管道缺陷图像在尺度、纹理、背景和类别分布上的任务难点，并说明了为何需要把目标域任务冻结为六类结构性缺陷；其次，从目标检测任务定义、YOLO 路线发展和 YOLOv11 结构特点出发，解释了本文为何选择一阶段 **detector** 作为工程基础；再次，从注意力机制、损失函数与迁移学习角度建立了第 5 章模型改进与跨域训练的理论依据；最后，阐明了 CAM / Grad-CAM 在低标注增强链路中的角色定位。上述内容共同构成第 3 章数据组织、第 4 章前级预筛以及第 5 章改进检测与跨域迁移策略的理论前提。

为了避免后续章节出现“理论讲了一套，实验做的是另一套”的割裂问题，本文还需要把本章内容进一步压缩为可执行的研究问题映射关系。也就是说，第二章不仅回答“相关概念是什么”，还回答“这些概念分别支撑后续哪一类实验、哪一个研究问题以及哪一条技术路线”。表 2.7 对这一关系进行集中总结。

表 2.7 研究问题与理论基础映射表

研究问题	对应理论基础	直接支撑章节	主要回答内容
RQ1	缺陷图像特征、核心评价指标、监督粒度连续体	第 4 章、第 6.2–6.3 节	高召回 gate 是否能有效降低误报与正常样本流入
RQ2	YOLOv11 原理、注意力机制、损失函数与框回归	第 5 章、第 6.4–6.5 节	改进 detector 是否能提升复杂场景下的检测性能
RQ3	迁移学习、域差来源、渐进式迁移路线	第 5 章、第 6.6 节	源域预训练与目标域微调是否能缓解样本不足和域差问题
RQ4	CAM/Grad-CAM、候选区域、两阶段协同与人机闭环	第 4 章、第 6.7 节	两阶段系统是否优于单阶段直接检测并更适合工程应用

从论文整体结构看，表 2.7 还承担一个更深层次的作用，即把公开文献中的分散结论压缩为本文可执行的研究路线。已有 **sewer detection** 文献分别证明了公开数据集的价值、YOLO 路线的工程优势、迁移学习在同领域任务中的潜力以及 CAM / WSOL 在低标注定位中的可行性，但这些结论往往聚焦单一环节，尚未自动汇聚为一条能够直接解决本文目标任务的完整方法链^{[6][9][8][3]}。第二章通过理论梳理所完成的，正是把这些分散结论重新组织为统一的问题图景：为什么

sewer 缺陷检测需要关注小目标与复杂背景，为什么一阶段 detector 虽适合工程落地却仍需场景化改进，为什么目标域少标注条件下必须引入源域预训练、目标域微调和候选区域增强，以及为什么这些环节必须被视作一条连续的研究链而不是若干互不相干的技术拼接。只有在这一图景被明确建立后，后续第 3 章的数据组织、第 4 章的前级预筛、第 5 章的模型改进与迁移策略以及第 6 章的系统级实验，才能形成真正首尾一致的论文闭环。

第3章 数据集构建与总体研究框架

3.1 数据来源与总体说明

3.1.1 源域数据

本文源域数据来自公开 Sewer-ML 数据集。考虑到 Sewer-ML 原始发布形态为多标签分类数据,而本文的前级预筛、CAM 热力图和迁移分类实验均需要稳定的单标签监督信号,因此本文在不改变原始数据来源的前提下,对原始标签进行了任务化重构,形成适用于分类预训练的单标签六类平衡数据集。将 Sewer-ML 选为源域的原因主要有三点:其一,数据规模较大且类别覆盖较广,能够为模型提供较强的 sewer scene prior;其二,数据来源公开、口径明确,适合在论文中形成可复现的源域背景;其三,已有研究已经证明 Sewer-ML 及其衍生任务可有效支撑 sewer-specific classification、transfer learning 与 weakly supervised localization 研究^{[6][13][3]}。

3.1.2 目标域数据

目标域数据来自本地或合作区域的地下排水管道巡检图像,包括图像级标签、少量检测框标注以及后续人工复核样本。目标域是本文最终检测任务的真实落点,其类别口径、误报约束和评价方式均以本地工程任务为准。与源域数据相比,目标域数据在拍摄设备、视角、照明条件、管材背景、污渍分布和缺陷表达方式等方面更具工程性,也更能体现真实 deployment 条件下的 domain gap。因此,本文并不追求让源域标签体系严格等价于目标域检测类别,而是通过层次化标签对齐和迁移训练,使源域数据主要承担“先学会看懂 sewer scene”的任务,目标域数据承担“完成本地检测任务定义”的任务。

3.2 源域分类数据集构建

3.2.1 单标签化原则

为适应分类预训练、二分类 gate 构建和 CAM 热力图生成流程,本文将 Sewer-ML 原始样本重构为单标签分类数据,并采用固定优先级将多标签样本映射到唯

一主类。这样处理的目的是不是否定 Sewer-ML 的原始多标签语义，而是在当前实验框架中尽可能减弱标签重叠对分类训练稳定性的影响，使分类模型输出更适合作为候选区域生成的中间监督信号。与此同时，本文保留 **Normal** 类别，使模型在源域阶段就具备明确的正常/异常判别能力，为后续第一阶段高召回预筛任务提供基础。

3.2.2 源域六类与样本规模

当前构建的源域单标签数据集为 `sewerml_cls6_train7200`，共 7200 张图片，按类别均衡组织，每类 1200 张，其中训练集每类 1080 张、验证集每类 120 张。源域六类分别为 **Normal**、**Deformation**、**Roots**、**JointAnomaly**、**WallDamage** 和 **DepositAttachment**。该数据集既是后续 source pretrain 的输入，也是第一阶段 gate 扫描和 CAM 候选区域生成的基础。选择 7200 张作为首版正式实验规模，主要是综合考虑了类别平衡、训练成本、3090 显卡平台上的迭代效率以及前级预筛研究对稳定表征的需求。

表 3.1 源域单标签六类分类数据集分布

类别	训练集数量	验证集数量	总数量
Normal	1080	120	1200
Deformation	1080	120	1200
Roots	1080	120	1200
JointAnomaly	1080	120	1200
WallDamage	1080	120	1200
DepositAttachment	1080	120	1200
合计	6480	720	7200

同样地，图 6.6 用于展示不同初始化与微调路径带来的迁移收益差异。

图 3.1 源域六类样本示例图

3.2.3 源域数据的任务定位

需要强调的是，源域分类数据集并不直接承担最终检测任务，而是同时服务于三个中间目标：第一，为 **Normal/Abnormal** 高召回预筛提供统一的初始特征表征；第二，为 CAM/Grad-CAM 候选区域生成提供稳定的类响应基础；第三，为后续目标域检测提供更贴近 sewer inspection 场景的初始化权重。也就是说，源

域数据的角色是“可迁移缺陷表征学习平台”，而不是“目标域检测任务的直接替代品”。

3.3 目标域六类缺陷定义与标签映射

3.3.1 目标域最终检测类别

本文将目标域最终检测任务固定为六类结构性缺陷:CrackBreak、SurfaceDamage、Deformation、JointDislocation、Intrusion 和 Infiltration。该定义兼顾了中国排水管道检测评估口径、目标域图像表现特点以及后续检测模型的可训练性。与源域分类类别不同，目标域类别必须为最终检测任务服务，因此一经确定便不再随实验中途变动。

表 3.2 目标域六类缺陷与任务定义

编号	类别名称	说明
0	CrackBreak	对应破裂、裂缝、坍塌等管壁破坏性缺陷
1	SurfaceDamage	对应表面损伤、腐蚀样损伤及相关施工/制造缺陷
2	Deformation	对应管道几何形态变化、变形等缺陷
3	JointDislocation	对应接口错位、脱节、错口等接口异常
4	Intrusion	对应接口侵入、材料侵入或局部异物侵入
5	Infiltration	对应渗漏、渗入水等渗漏类异常

从系统层面看，图 6.7 将单阶段与两阶段方案的关键指标并列展示，以突出整体路线的工程价值。

图 3.2 目标域六类样本示例图

3.3.2 源域与目标域的关系

源域分类类别与目标域检测类别并非严格一一对应。源域更强调稳定表征与预筛能力，目标域更强调最终缺陷位置与类别判定。本文采用“源域预训练较粗、目标域检测类冻结”的层次化标签对齐思路，使迁移学习服务于最终检测目标而不是反过来受制于源域原始标签体系。这种处理能够在避免语义硬映射冲突的同时，最大化公开 sewer 数据对本地任务的可迁移价值^{[6][8][53]}。

表 3.3 源域任务视图与目标域任务视图的关系

任务层级	类别视图	主要作用
源域分类预训练	Normal / Deformation / Roots / JointAnomaly / WallDamage / DepositAttachment	学习 sewer scene 通用表征，支撑 gate 与 CAM
第一阶段预筛	Normal / Abnormal	在高召回约束下最大化正常样本过滤率
第二阶段检测	CrackBreak / SurfaceDamage / Deformation / JointDislocation / Intrusion / Infiltration	完成最终缺陷定位与类别判定

为避免总体指标掩盖类别差异，图 6.8 对各类别 AP 表现进行细化对比。

图 3.3 源域类别到目标域类别的映射关系图

3.4 第一阶段与第二阶段任务定义

本文将总体任务拆分为两个紧密衔接但职责不同的阶段。第一阶段是 Normal/Abnormal 高召回预筛，其目标不是给出最终缺陷类别，而是在“尽量不过漏异常”的约束下，尽可能过滤明显正常样本，从而降低第二阶段检测器的输入规模与误报传播风险。第二阶段是目标域六类结构性缺陷检测，它负责完成最终类别和位置判定，并输出可直接用于工程复核和维护决策的结果。这样的任务分解既符合 hierarchical classification 在 sewer inspection 中的已有经验^{[16][17]}，也更适合本文后续围绕误报控制、低标注增强与跨域迁移开展系统实验。

此外，图 6.9 进一步对照展示第一阶段 CAM 关注区域与第二阶段 detector 输出框的关系。

图 3.4 第一阶段与第二阶段任务定义示意图

3.5 数据预处理与划分协议

3.5.1 预处理与增强

分类阶段以轻量增强为主，包括尺度变换、随机翻转和颜色扰动，以避免过强增强破坏缺陷语义；检测阶段则根据实验需要进一步引入 Mosaic、随机裁剪、几何变换等策略，以增强模型对复杂场景的鲁棒性。对于目标域图像，本文还将结合图像质量、重复帧比例和标注置信度进行筛选，以减轻低质量样本对检测器收敛稳定性的干扰^[14]。

3.5.2 划分协议与运行型验证集

除常规 train/val/test 划分外，本文在第一阶段预筛实验中强调“运行型验证集”的概念，即验证集尽量接近真实巡检流程中正常样本占比较高的分布条件。这样设计的目的在于避免仅在均衡样本上评价 gate 模块，而忽略其在真实运维场景中对误报和复核成本的影响。对于第二阶段检测任务，本文则保持目标域类别定义、训练配置和评价阈值的一致性，以确保不同 baseline、消融实验与迁移实验之间具有严格可比性。

为增强结论章节的收束性，表 7.1 将主要结论、对应章节和关键证据图表进行统一对应。

表 3.4 数据来源与划分协议

数据层级	当前状态	主要用途
源域分类数据	已构建 source pretrain、gate 扫描、sewerml_cls6_train 生成含 train/val	
目标域图像级数据	按六类检测任务持续补充	target cls finetune、候选区域生成
目标域检测框数据	少量人工框与后续 reviewed box	detector baseline、改进模型与迁移实验
运行型验证集	以高 normal 占比组织	gate operating point 与系统级误报分析

为避免正文过度臃肿而又保留充分原始材料，表 2 对后续附录中建议补充的图表内容进行统一规划。

表 3.5 图像尺寸与长宽比分布统计表

数据层级	典型尺寸范围	长宽比分布特点	主要作用
源域分类数据	—	—	支撑 source pretrain 与 gate 实验
目标域图像级数据	—	—	支撑 target cls finetune 与 CAM 生成
目标域检测数据	—	—	支撑 detector baseline 与改进实验

表 3.6 数据质量与清洗规则表

问题类型	判定标准	是否剔除	后续用途
严重模糊/不可辨识	缺陷区域无法人工确认	是	不进入训练与验证
重复或近重复帧	连续多帧信息增量极低	部分剔除	保留少量代表帧构建运行型验证集
低质量但可判读样本	噪声较大但缺陷可辨认	否	用于增强真实场景鲁棒性
标注口径不一致样本	类别边界存在明显争议	暂缓使用	人工复核或进入附录分析
CAM 明显偏移样本	热力图无法覆盖主体区域	否	作为伪框抽检与人工快修重点对象

图 3.5 数据划分与运行型验证集构建流程图

3.6 总体系统框架设计

围绕“公开源域可用、目标域框标注昂贵、正常帧占比高、域差显著”这些现实约束，本文构建了“源域分类预训练 → 前级高召回预筛 → CAM/伪框辅助 → 改进 YOLOv11 检测 → 目标域迁移适应”的总体系统框架。该框架的核心思想是让不同子模块分别承担最擅长的职责：源域分类负责学习通用缺陷表征，前级 gate 负责削减正常样本流量并控制误报传播，CAM/伪框流程负责降低检测标注成本，改进 YOLOv11 负责完成最终高精度缺陷检测，而跨域迁移策略则负责把源域知识稳定转化为目标域性能。这样组织的目的不是“模块堆砌”，而是围绕工程问题把不同研究路径编排成一条可执行的完整技术链。

图 3.6 地下排水管道缺陷检测总体系统框架

3.7 评价协议与实验规范

为保证后续实验具有统一口径，本文将评价协议分为三层：第一阶段预筛层主要采用 Accuracy、Macro-F1、AUPRC、AUROC、Spec@Recall、Prec@Recall、PTR 和 NRR 等指标；第二阶段检测层采用 Precision、Recall、F1、 $mAP@0.5$ 和 $mAP@0.5 : 0.95$ 等指标；系统级验证层则关注单图误报率、单视频误报率、门控召回率和整体复核效率。与此同时，本文统一记录实验环境、模型初始化方式、输入尺寸、阈值选择、数据划分和结果导出位置，以保证训练机推送回来的结果可以无歧义地接入论文写作过程。

3.8 本章小结

本章从数据来源、源域单标签分类数据构建、目标域任务定义、两阶段任务划分、数据划分协议和系统总体框架等方面，对本文后续研究所依赖的数据与任务组织方式进行了说明。与单纯介绍“用了什么数据”相比，本章更重要的作用是回答“为什么本文必须用这样的数据组织方式来支撑后续检测与迁移实验”。在此基础上，第 4 章将进一步聚焦前级高召回预筛与弱监督标注增强策略，第 5 章则聚焦改进 YOLOv11 检测方法与跨域迁移策略本体。

第 4 章 前级高召回预筛与弱监督标注增强策略

4.1 前级高召回预筛问题定义

真实巡检场景中，正常图像通常显著多于缺陷图像。如果将全部帧直接输入后级检测器，不仅会带来较高推理开销，也会因背景复杂和正常帧海量存在而放大误报累积。因此，本文将第一阶段任务明确重定义为 **Normal/Abnormal** 高召回 **gate**，其目标是在尽量不过漏异常图像的约束下，最大化对正常图像的过滤能力。更具体地说，第一阶段的优化目标可以概括为：在保证门控召回率不低于预设阈值的前提下，尽可能提高正常样本过滤率。这里的预设异常召回率通常取 99.0% 或 99.5%。在这一任务中，第一阶段并不承担最终类别输出责任，而是承担“高召回、低漏放”的门控角色，这一点与最终六类检测任务的目标存在本质差异。

4.2 基于同源图像重标注的二分类 gate 构建

本文第一阶段 **gate** 并未引入新的图像来源，而是在源域单标签六类分类数据上进行任务重映射：将 **Normal** 保留为负类，将其余五类合并为 **Abnormal** 正类。这样的设计具有两方面优势。其一，它保证第一阶段与源域六类分类实验在同一图像来源和同一 **split** 上比较，从而避免由于数据源变化带来的干扰。其二，它使 **gate** 任务与后续 CAM 生成、**target finetune** 和 **detector** 初始化天然衔接，形成统一的 **source-side learning chain**。已有 **hierarchical classification** 研究也表明，在 **sewer inspection** 中先建立 **defect/non-defect** 或 **normal/abnormal** 的高层判别，再进入更细粒度识别，是一种合理且工程上可解释的任务组织方式^{[16][17]}。

4.3 YOLO11-cls 五尺度基线扫描

为确定第一阶段最合适的分类容量，本文以 YOLO11-cls 系列的 **n/s/m/l/x** 五个尺度作为统一候选，在相同数据集、相同训练协议和相同 **operating point** 评价方式下进行容量扫描。当前五组 **source baseline** 结果均已完成汇总，表 4.1 同时给出六类分类视图与 **gate** 视图下的关键指标，其中“在 Recall 不低于 99.5% 时

的 Specificity”与“在 Recall 不低于 99.0% 时的 Specificity”更直接反映了高召回约束下的正常样本过滤能力。

表 4.1 YOLO11-cls 五尺度容量扫描表

模型	任务视图	Top1/Acc	Macro-F1	AUPRC	Recall 不低于 99.5% 时的 Specificity	Recall 不低于 99.0% 时的 Specificity
yolo11n-cls	六类分类	0.6792	0.6800	0.9813	—	—
yolo11n-cls	二分类 gate	—	—	0.9813	未达到	0.4083
yolo11s-cls	六类分类	0.6681	0.6708	0.9794	—	—
yolo11s-cls	二分类 gate	—	—	0.9794	0.4417	0.5500
yolo11m-cls	六类分类	0.7083	0.7095	0.9843	—	—
yolo11m-cls	二分类 gate	—	—	0.9843	0.4833	0.6167
yolo11l-cls	六类分类	0.7139	0.7151	0.9879	—	—
yolo11l-cls	二分类 gate	—	—	0.9879	0.4417	0.4667
yolo11x-cls	六类分类	0.6736	0.6762	0.9868	—	—
yolo11x-cls	二分类 gate	—	—	0.9868	0.4333	0.4917

从当前结果看，yolo11l-cls 在六类分类视图下取得最高的 Top1 Accuracy、Macro-F1 与 AUPRC，说明较大的分类容量有利于提升源域表征质量；但在高召回 gate 视图下，yolo11m-cls 在 Recall 不低于 99.5% 与 Recall 不低于 99.0% 两个锚点上分别取得 0.4833 和 0.6167 的 Specificity，优于其余尺度。这表明“分类更强”并不必然等价于“高召回过滤更优”，第一阶段模型选型仍需同时兼顾分类判别能力与 operating point 下的过滤收益。

4.4 阈值校准与 operating point 选择

第一阶段 gate 的有效性不能只通过默认阈值下的准确率判断，更需要关注在高召回约束下的 specificity、precision 和过滤比例。因此，本文采用 threshold sweep 的方式扫描不同 operating point，并重点记录“Recall 不低于 99.5%”“Recall 不低于 99.0%”“Specificity 不低于 60%”“Specificity 不低于 70%”等锚点。五组 source baseline 的结果表明，m 模型在保持高召回的同时可显著提升 specificity 与 gate F1，而 l 模型虽然分类精度更高，但在高召回锚点上的过滤收益反而下降，说明更大的分类容量并不会自动转化为更优的 gate operating point。

表 4.2 第一阶段 operating point 对比表

模型	阈值策略	Gate Recall	Specificity	Precision	F1	PTR
yolo11n-cls	默认阈值 0.50	0.9717	0.7000	0.9418	0.9565	0.8597
yolo11n-cls	Recall 不低于 99.0%	0.9900	0.4083	0.8932	0.9391	0.9236
yolo11s-cls	默认阈值 0.50	0.9817	0.6000	0.9246	0.9523	0.8847
yolo11s-cls	Recall 不低于 99.5%	0.9950	0.4417	0.8991	0.9446	0.9222
yolo11s-cls	Recall 不低于 99.0%	0.9900	0.5500	0.9167	0.9519	0.9000
yolo11m-cls	默认阈值 0.50	0.9750	0.7333	0.9481	0.9614	0.8569
yolo11m-cls	Recall 不低于 99.5%	0.9950	0.4833	0.9059	0.9484	0.9153
yolo11m-cls	Recall 不低于 99.0%	0.9900	0.6167	0.9281	0.9581	0.8889
yolo11l-cls	默认阈值 0.50	0.9700	0.7167	0.9448	0.9572	0.8556
yolo11l-cls	Recall 不低于 99.5%	0.9950	0.4417	0.8991	0.9446	0.9222
yolo11l-cls	Recall 不低于 99.0%	0.9900	0.4667	0.9027	0.9444	0.9139
yolo11x-cls	默认阈值 0.50	0.9633	0.6667	0.9353	0.9491	0.8583
yolo11x-cls	Recall 不低于 99.5%	0.9967	0.4333	0.8979	0.9447	0.9250
yolo11x-cls	Recall 不低于 99.0%	0.9900	0.4917	0.9069	0.9466	0.9097

表4.2 进一步说明了不同尺度在 operating point 层面的差异。具体而言，n 模型在默认阈值下的 specificity 达到 0.7000，但其最大召回率仅为 0.9933，因此在 Recall 不低于 99.5% 的约束下无法找到可行点；s 模型虽然分类视图最弱，但已经能够在 Recall 不低于 99.5% 与 Recall 不低于 99.0% 的约束下分别保持 0.4417 和 0.5500 的 specificity；m 模型在两个高召回锚点上均取得最佳 specificity，同时在 precision 与 F1 上也保持领先；l 模型的默认阈值表现与 m 接近，但在高召回约束下 specificity 明显回落；x 模型则呈现出较为平衡但不突出的特征。综合来看，m 模型最适合作为第一阶段 gate 的主基线，而 l 模型更适合作为高质量 source 表征的上界参考。

图 4.1 第一阶段预筛 PR 曲线

图 4.2 第一阶段 Recall-Specificity 曲线

图 4.3 第一阶段阈值扫描曲线

图 4.4 第一阶段校准前后可靠性曲线

图 4.5 第一阶段最佳模型混淆矩阵

4.5 Hard Negative Mining 策略

仅依赖均衡的源域训练集，往往仍不足以覆盖真实巡检场景中的 **hardest normal** 样本，例如受污渍、反光、水膜和局部结构变化影响而呈现异常外观的正常图像。因此，本文将 **Hard Negative Mining** 作为第一阶段的重要增强策略之一，即在高召回 **gate** 模型基础上，将置信度高但最终被人工确认或规则确认的误报 **normal** 样本重新回流到训练集，用于提升 **gate** 对复杂背景的抑制能力。该策略的目标并不是单纯提高整体准确率，而是在既定召回锚点附近提高 **specificity** 与 **precision**，从而为两阶段系统争取更大的误报控制收益。

表 4.3 第一阶段关键消融表

组别	任务定义	Calibration	Hard Negative	Loss	Spec@R=99.5%	Spec@R=99.0%
G0	六类间接 gate	否	否	CE	—	—
G1	二分类 gate	否	否	BCE/CE	—	—
G2	二分类 gate	是	否	BCE/CE	—	—
G3	二分类 gate	是	是	BCE/CE	—	—
G4	二分类 gate	是	是	Weighted BCE/Focal	—	—
G5	二分类 gate	是	是	Best Loss + Attention	—	—

图 4.6 Hard Negative Mining 中的典型 **hardest normal** 样本

4.6 CAM/Grad-CAM 伪框生成与质量控制

第一阶段分类模型并不直接输出检测框，但其热力图响应可以作为弱监督定位的中间信号。本文基于源域预训练与目标域微调后的分类模型，生成 **CAM/Grad-CAM** 热力图，并通过阈值分割、连通域筛选与外接矩形拟合得到初始伪框。该流程的作用主要有两点：一是为后续 **detector** 训练提供低成本初始框；二是帮助识别哪些类别更适合走 **CAM** 主路线、哪些类别必须尽早切换到人工框支撑。伪框并不被视为最终真值，而是位于“自动生成 → 抽检评估 → 轻量快修”的中间层资源^{[39][3]}。

图 4.7 CAM/Grad-CAM 典型可视化结果

表 4.4 CAM 伪框抽检与后续处理模板

类别	抽检数量	可直接用	轻改可用	不可用	可用率	建议路线
CrackBreak	—	—	—	—	—	—
SurfaceDamage	—	—	—	—	—	—
Deformation	—	—	—	—	—	—
JointDislocation	—	—	—	—	—	—
Intrusion	—	—	—	—	—	—
Infiltration	—	—	—	—	—	—

4.7 本章小结

本章围绕第一阶段高召回预筛和弱监督标注增强，完成了任务定义、二分类 gate 组织方式、容量扫描、阈值选择、hard negative 思路和 CAM 伪框流程的结构化说明。需要再次强调的是，本章并非本文的主创新章，而是支撑后续改进 detector 与跨域迁移落地的工程链条章节。第 5 章将在此基础上转入本文的核心方法设计，即改进 YOLOv11 检测方法与跨域迁移训练策略。

第5章 基于改进 YOLOv11 的管道缺陷检测与跨域迁移策略

5.1 基线检测模型与问题分析

本文以 YOLOv11 作为地下排水管道缺陷检测的 baseline。一方面，YOLO 路线具有较高的实时性与较成熟的工程实现，便于与实际巡检系统衔接；另一方面，YOLOv11 在通用检测任务中的性能平衡较好，适合作为本文开展场景化改进的基础模型。然而，直接将原始 YOLOv11 detector 用于排水管道缺陷检测时，仍会遭遇小目标漏检、细长缺陷边界表达不足、复杂背景误报偏高以及类间混淆明显等问题。因此，本文不把模型改进理解为简单替换某个模块，而是围绕“特征表达、预测组织和训练目标”三条主线展开协同优化^{[9][47][45]}。

5.2 注意力机制改进

5.2.1 改进动机

针对 sewer defect detection 中小目标弱纹理、边界模糊和背景干扰强的特点，本文在 YOLOv11 baseline 中引入注意力机制，以增强对关键区域和关键通道的聚焦能力。注意力机制的作用不仅在于提高总体精度，更重要的是帮助模型在反光、水膜、污渍和管壁纹理干扰下，稳定提取与缺陷结构真正相关的判别信息。

5.2.2 模块设计与嵌入方式

本文后续仅选择一个主注意力模块作为正式方案，其余候选模块作为消融对比或附录补充。设计原则是：优先选择参数开销可控、对多尺度特征融合有直接增益、且在复杂背景场景下能稳定提升 recall/precision 平衡的模块。注意力模块的插入位置主要考虑 backbone 后部和 neck 融合层，以兼顾高层语义与中低层细节信息。

图 5.1 注意力模块插入位置示意图

5.3 检测头改进

5.3.1 原始检测头局限性

在排水管道缺陷场景中，原始检测头在处理细粒度结构异常、低对比目标以及多尺度小目标时，存在边界表达能力不足和类别判别不稳定的问题。尤其对于 CrackBreak、JointDislocation 和 Infiltration 等类别，局部显著区域小而背景干扰强，容易导致分类支路与定位支路同时受噪声影响。

5.3.2 改进思路

检测头改进的核心思路是在保持整体推理效率可控的前提下，增强对多尺度结构异常的表达能力，并改善分类与定位分支对困难样本的响应组织方式。具体实现将在后续实验定型后给出，包括预测层组织方式、特征融合路径、额外监督分支或结构轻量化约束等内容。已有 sewer defect detection 文献表明，head-side 改造对于兼顾局部纹理破坏和整体结构异常往往是必要的^{[9][10][11]}。

图 5.2 检测头改进示意图

5.4 损失函数改进

5.4.1 优化目标

考虑到目标域检测样本存在类别不均衡、易混类别边界模糊以及 hardest positive/hardest negative 区分不足等问题，本文进一步对损失函数进行场景化设计。其优化目标是同时改善召回与误报控制，使模型在复杂背景下更稳定地区分正常纹理与真实缺陷响应。

5.4.2 形式化表达

本文在基线损失框架上保留定位项、分类项和分布聚焦项，并根据实验结果引入针对难样本或类别不均衡的补充项。换言之，最终总损失由边界框回归项、分类项、分布聚焦项以及可选的辅助项共同组成。其中，辅助项主要用于难样本补偿或类别重加权。最终采用哪一种组合方式，将以实验效果与复杂度控制结果为依据确定。

图 5.3 改进损失函数组成与优化信号流图

5.5 改进 YOLOv11 总体结构

结合注意力机制、检测头改进和损失函数优化，本文构建用于地下排水管道缺陷检测的改进 YOLOv11 模型。该模型的设计目标不是单一维度地追求最高精度，而是在复杂背景、小目标、低对比度缺陷和工程部署可行性之间取得更合理的平衡。整体结构将在后续实验中通过模块消融表和复杂度对比表进行验证。

图 5.4 改进 YOLOv11 总体结构

表 5.1 改进模块设计说明表

模块	设计目的
注意力机制	强化关键区域与关键通道响应，抑制复杂背景干扰
检测头改进	提升多尺度与细粒度缺陷的分类与定位组织能力
损失函数改进	缓解类别不均衡与难样本学习不足问题，优化 recall/precision 折中

表 5.2 模块插入位置与复杂度变化表

模块	插入层位置	Params 变化	FLOPs 变化	设计目的
注意力模块	—	—	—	增强关键区域与关键通道响应
改进检测头	—	—	—	提升多尺度与细粒度目标表达能力
损失函数优化	训练目标层	无显式参数变化	无显式 FLOPs 变化	改善长尾类别与难样本学习

5.6 跨域迁移适应训练策略

5.6.1 跨域问题分析

公开 Sewer-ML 数据与本地巡检数据在设备、视角、照明条件、管材纹理和标签口径等方面存在明显差异。若仅依赖目标域有限框标注从零训练 detector，模型往往难以获得足够稳定的初始化，且更容易出现过拟合与类间边界漂移。已有 transfer learning 研究已经表明，在 sewer defect detection 中，领域相关的预训练能够有效改善模型初始性能和收敛稳定性^[8]。

5.6.2 迁移路径设计

本文采用“源域分类预训练 → 目标域分类微调 / gate 迁移 → 目标域检测微调”的渐进式迁移路径。首先，在源域六类分类数据上学习 sewer-specific 通用表征；其次，在目标域图像级标签上进行分类微调，使特征分布更贴近本地巡检场景；最后，将上述表征迁移到 detector 训练中，并与少量人工框或伪框增强策略结合。这一路径的优点在于无需引入额外复杂的域对齐损失，却能够以较低的实现成本充分利用同领域源数据。

图 5.5 跨域迁移训练流程图

5.7 训练流程与实现细节

在训练流程上，本文遵循“先前级、后后级；先源域、后目标域；先分类、后检测”的组织原则。具体而言，先完成 source cls 六类预训练与 gate 扫描，再进行 target cls 微调与 CAM 伪框生成，最后进入 detector baseline、改进模型与迁移对比实验。对于不同训练阶段，输入尺寸、batch size、冻结策略、学习率和阈值选择均记录为可复现实验配置，以便后续将训练机推回来的结果直接映射到论文表格中。

表 5.3 迁移策略设置表

方案编号	训练策略说明
T0	目标域随机初始化，从零开始训练检测器
T1	使用官方 YOLOv11 通用预训练权重直接在目标域检测任务上微调
T2	使用源域分类预训练权重初始化，再迁移至目标域检测任务
T3	源域分类预训练 + 目标域分类微调 + 目标域检测微调
T4	—

表 5.4 训练阶段组织与冻结/解冻策略表

阶段	初始化方式	冻结层设置	学习率	训练轮数	输出结果
Source cls	官方分类权重	不冻结或轻冻结	—	—	source 预训练权重
Target cls / gate	source cls 迁移	视实验设定部分冻结	—	—	target 分类权重与 gate 模型
CAM/ 伪框生成	target cls 权重	不涉及	—	—	热力图与伪框候选
Detector baseline	官方或迁移权重	—	—	—	baseline 检测模型
Improved detector	最优初始化方案	—	—	—	改进检测模型与迁移结果

5.8 本章小结

本章给出了本文的核心方法设计：一方面，通过注意力机制、检测头和损失函数三个层面的协同优化，构建改进 YOLOv11 检测模型；另一方面，通过源域分类预训练、目标域分类微调与检测微调组成跨域迁移适应训练策略。与第 4 章作为支撑链不同，本章构成本文真正的两项核心创新内容，后续第 6 章将围绕这两项创新展开系统实验验证。

第 6 章 实验结果与分析

6.1 实验设置

6.1.1 实验平台与训练配置

本文实验在单卡 GPU 工作站上完成，硬件平台采用 NVIDIA GeForce RTX 3090（24GB 显存）。实验软件环境以 Python 3.11.15 为基础，深度学习框架采用 PyTorch 2.11.0+cu128、TorchVision 0.26.0+cu128、CUDA 12.8 与 Ultralytics 8.3.0。对于当前已完成的第一阶段 source 实验，统一使用 sewerml_cls6_train7200 数据集，在相同输入尺寸、训练轮数和批大小设置下完成 YOLO11-cls 五个尺度的基线扫描，以保证不同容量模型之间的比较具有可比性。

表 6.1 实验参数设置表

项目	配置
硬件平台	NVIDIA GeForce RTX 3090, 24GB 显存
软件环境	Python 3.11.15, CUDA 12.8, PyTorch 2.11.0+cu128, Ultralytics 8.3.0
Source 数据集	sewerml_cls6_train7200
Source 基线模型	YOLO11n/s/m/l/x-cls
输入尺寸	640×640
训练轮数	200
批大小	32
数据加载线程数	2
主要评价指标	Accuracy、Macro-F1、AUROC、AUPRC、Gate Recall、Specificity

6.2 第一阶段前级预筛基线与结果分析

本节首先比较五个 YOLO11-cls 尺度在源域任务上的容量差异。结果显示，在相同源域数据与训练协议下，l 尺度模型在 Top1、Macro-F1、AUROC 与 AUPRC 等分类判别指标上整体领先，而 m 尺度模型在高召回 gate 的过滤指标上更优。其中，m 尺度模型在默认阈值 0.50 下取得 0.7083 的 Top1 Accuracy、0.7095 的 Macro-F1、0.9750 的 Gate Recall 和 0.7333 的 Specificity；在 Recall 不低于 99.0% 的锚点下，其 Specificity 达到 0.6167，优于 n、s、l、x 其余各尺度。该结果表明，

第一阶段模型的最优选择不能只看分类精度，还需要结合 **operating point** 下的正常样本过滤收益进行综合判断。

表 6.2 第一阶段容量扫描结果表

模型	Top1/Acc	Macro-F1	AUROC	AUPRC	默认阈值下的 Gate Recall	默认阈值下的 Specificity	Recall 不低于 99.0% 时的 Specificity
yolo11n-cls	0.6792	0.6800	0.9288	0.9813	0.9717	0.7000	0.4083
yolo11s-cls	0.6681	0.6708	0.9215	0.9794	0.9817	0.6000	0.5500
yolo11m-cls	0.7083	0.7095	0.9367	0.9843	0.9750	0.7333	0.6167
yolo11l-cls	0.7139	0.7151	0.9488	0.9879	0.9700	0.7167	0.4667
yolo11x-cls	0.6736	0.6762	0.9430	0.9868	0.9633	0.6667	0.4917

从整体趋势看，五个尺度并没有呈现“容量越大、第一阶段效果越好”的单调关系。若仅看六类分类指标，**l** 与 **m** 组成第一梯队，其中 **l** 略优于 **m**；若转到高召回 **gate** 视角，则 **m** 的优势更加明显。相比之下，**s** 与 **x** 虽然在高召回条件下均能给出可用的 **operating point**，但整体过滤收益仍低于 **m**；**n** 则表现出“默认阈值较稳、极高召回扩展性不足”的特征。由此可见，第一阶段容量选择应以高召回 **operating point** 下的综合收益为核心，而不是简单沿用分类精度最高的模型。

图 6.1 第一阶段不同模型容量的关键指标对比

图 6.2 第一阶段 PR 曲线组图

图 6.3 第一阶段 Recall-Specificity 曲线组图

6.3 第一阶段关键消融实验

围绕第一阶段 **gate**，本文后续重点开展四类消融：任务重映射（六类间接 **gate** 与二分类 **gate** 对比）、校准策略、**hard negative** 回流策略以及损失函数设计。与第二阶段 **detector** 不同，第一阶段消融不追求复杂模块堆叠，而是优先回答“哪种低成本策略最有效地提升高召回约束下的正常样本过滤率”这一核心问题。需要强调的是，本节表格和图形均属于第一阶段前级预筛实验，其数据来源应为分类模型与 **gate** 阈值扫描结果，而不是目标检测结果。

表 6.3 第一阶段关键消融表

组别	任务定义	Calibration	Hard Negative	Loss	Recall 不低于 99.5% 时的 Specificity	Recall 不低于 99.0% 时的 Specificity
G0	六类间接 gate	否	否	CE	—	—
G1	二分类 gate	否	否	BCE/CE	—	—
G2	二分类 gate	是	否	BCE/CE	—	—
G3	二分类 gate	是	是	BCE/CE	—	—
G4	二分类 gate	是	是	Weighted BCE/Focal	—	—
G5	二分类 gate	是	是	Best Loss	—	—

6.4 第二阶段检测 baseline 对比实验

第二阶段检测 baseline 主要用于回答“原始 detector 在当前目标域任务中的起点水平如何”。本文计划选取原始 YOLOv11 baseline、2–3 个强 baseline 以及后续改进模型进行对比，重点关注 Precision、Recall、F1、mAP@0.5、mAP@0.5:0.95 和 FP/image 等指标。该部分实验将构成后续创新点一消融和创新点二迁移实验的统一比较底盘。自本节开始，后续表格默认均属于第二阶段目标检测或系统级实验，不能使用第一阶段分类/gate 指标直接替代填写。

表 6.4 第二阶段 baseline 对比表

模型	Params	FLOPs	Precision	Recall	F1	mAP@0.5	FP/image
YOLOv11 Baseline	—	—	—	—	—	—	—
YOLOv8-s	—	—	—	—	—	—	—
YOLOv10-s	—	—	—	—	—	—	—
RT-DETR-R18	—	—	—	—	—	—	—

图 6.4 第二阶段 baseline 对比柱状图

6.5 创新点一消融实验

创新点一对应的是改进 YOLOv11 检测方法，因此消融实验必须围绕注意力机制、检测头和损失函数三部分展开，回答每个模块是否真正产生增益，以及三者协同后是否形成可解释的性能提升。该表是本文答辩时最关键的实验表之一，因此字段在当前阶段先完全固定。特别说明：表6.5 中的 **B0** 表示第二阶段未引入任何改进模块的原始 YOLOv11 detector baseline，而不是第一阶段的分类或 gate 基线。

表 6.5 创新点一消融表

组别	Attention	Head	Loss	Params	FLOPs	Precision	Recall	mAP@0.5
B0	否	否	否	—	—	—	—	—
B1	是	否	否	—	—	—	—	—
B2	否	是	否	—	—	—	—	—
B3	否	否	是	—	—	—	—	—
B4	是	是	否	—	—	—	—	—
B5	是	否	是	—	—	—	—	—
B6	否	是	是	—	—	—	—	—
B7	是	是	是	—	—	—	—	—

图 6.5 创新点一消融收益图

6.6 创新点二迁移学习对比实验

创新点二对应“源域预训练到目标域微调”的跨域迁移适应策略。该部分实验重点回答：仅使用官方通用预训练权重是否足够；加入同领域 `source cls pretrain` 后能否提升 `detector` 初始化质量；进一步加入 `target cls finetune` 是否还能带来额外收益。该实验将直接决定本文第二个创新点能否成立。需要说明的是，本节虽会调用第一阶段 `source cls` 结果作为初始化来源，但表6.6 的评价对象仍然是第二阶段 `detector` 的最终检测性能。

表 6.6 创新点二迁移对比表

组别	初始化方式	源域预训练	目标域分类微调	Precision	Recall	mAP@0.5	FP/image
T0	From scratch	否	否	—	—	—	—
T1	Official pretrained	否	否	—	—	—	—
T2	Source cls pretrain	是	否	—	—	—	—
T3	Source cls pretrain + target cls finetune	是	是	—	—	—	—
T4	Best transfer strategy	是	是	—	—	—	—

图 6.6 创新点二迁移收益图

6.7 系统级对比实验

仅比较 `detector` 精度并不足以反映本文路线的真实价值，系统级实验还需要回答“两阶段系统是否比单阶段直接检测更适合排水管道 CCTV 场景”。因此，

本文将比较单阶段直接检测、两阶段 baseline、两阶段 + 改进 detector、两阶段 + 改进 detector + transfer 等系统版本，重点从 Gate Recall、NRR、PTR、Precision、Recall 和 FP/image 等角度评价整体方案。该部分表格同时涉及第一阶段与第二阶段输出，但评价对象已经从单一模块扩展为整体系统。

表 6.7 两阶段系统对比表

系统	第一阶段	第二阶段	Gate Recall	NRR	PTR	Precision	Recall	FP/image
S0	无	单阶段直接检测	—	—	—	—	—	—
S1	原版 gate	原版 detector	—	—	—	—	—	—
S2	改进 gate	原版 detector	—	—	—	—	—	—
S3	改进 gate	改进 YOLOv11	—	—	—	—	—	—
S4	改进 gate	改进 YOLOv11 + transfer	—	—	—	—	—	—

图 6.7 两阶段系统对比图

6.8 可视化与错误分析

为了更直观地说明模型在真实巡检场景中的表现，本文将在本节通过典型检测结果、误检样例、漏检样例、hardest normal 样例以及 CAM/Detector 可视化结果，对模型行为进行系统分析。重点关注三类现象：一是哪些类别或哪些背景纹理最容易引发误报；二是哪些缺陷在不同训练策略下最容易漏检；三是迁移学习和两阶段系统是否改变了这些错误的分布结构。

表 6.8 各类别检测结果表

类别	Precision	Recall	F1	AP50	AP50-95	主要错误类型
CrackBreak	—	—	—	—	—	—
SurfaceDamage	—	—	—	—	—	—
Deformation	—	—	—	—	—	—
JointDislocation	—	—	—	—	—	—
Intrusion	—	—	—	—	—	—
Infiltration	—	—	—	—	—	—

图 6.8 各类别 AP 柱状图

图 6.9 CAM 与 detector 对照可视化图

图 6.10 第二阶段检测可视化结果

图 6.11 典型误检与漏检案例

6.9 本章小结

本章重新组织了全文实验矩阵：先验证第一阶段 **gate** 的容量选择与关键增强，再比较第二阶段 **baseline**，随后分别检验创新点一和创新点二，最后从系统级角度比较单阶段与两阶段路线。当前五个 **YOLO11-cls** 尺度的 **source baseline** 结果已经补齐，后续将继续把 **detector**、迁移和系统级实验结果按本章表格字段同步写入，以形成完整的实验闭环。

第 7 章 结论与展望

7.1 研究结论

本文围绕地下排水管道 CCTV 图像缺陷检测中的小目标难识别、背景干扰强、正常样本占比高、目标域标注不足以及跨域泛化能力不足等问题展开研究，构建了面向地下排水管道智能巡检的检测方法与实验体系。论文的主要工作包括源域单标签分类数据集构建、目标域缺陷类别体系设计、高召回预筛与后级精检总体框架构建、改进 YOLOv11 检测模型设计以及源域预训练与目标域微调相结合的跨域迁移训练策略设计。

从本文研究路线来看，后续实验预期将验证以下结论：其一，改进 YOLOv11 模型能够提升地下排水管道缺陷检测的精度、召回能力与复杂背景鲁棒性；其二，源域预训练与目标域微调相结合的跨域迁移策略能够在目标域标注不足条件下提升模型性能和收敛效率；其三，高召回预筛与后级精检相结合的系统设计能够在工程层面降低误报并提升整体运行效率。

表 7.1 本文主要结论与证据对应表

主要结论	对应章节	关键证据图表	工程意义
第一阶段高召回 gate 能在高召回约束下有效降低正常样本流量	第 4 章、第 6 章	表 4.1、表 4.2、图 4.1–图 4.3、表 6.2	降低复核压力,减少后级计算负担
改进 YOLOv11 能提升复杂背景与小目标场景下的检测表现	第 5 章、第 6 章	表 5.1、图 5.1–图 5.3、表 6.4、表 6.5	提升目标域检测精度与稳定性
源域预训练与目标域微调的迁移策略能缓解目标域样本不足问题	第 5 章、第 6 章	图 5.4、表 5.2、表 6.6	降低对大量框标注的依赖
两阶段系统整体优于单阶段直接检测的工程运行方式	第 3 章、第 6 章	图 3.2、表 6.7、图 6.9	提升系统可部署性与误报控制能力

7.2 不足之处

尽管本文构建了较为完整的研究链条，但仍存在一些不足。首先，目标域高质量检测框标注规模仍然有限，模型最终性能仍受目标域数据规模约束。其次，

部分复杂缺陷类别在图像表现上存在较强相似性，容易引发误检和类别混淆。再次，本文采用的跨域迁移方法以源域预训练和目标域微调为主，尚未引入更复杂的域对齐机制。最后，本文更多侧重于图像级与目标检测级实验，尚未充分利用长视频的时序信息。

7.3 展望

未来可从以下几个方向进一步开展研究：

1. 继续扩充目标域高质量检测数据，完善类别分布与场景覆盖范围；
2. 探索更加稳健的跨域泛化方法，如特征对齐、半监督学习或自训练策略；
3. 结合视频时序信息，研究基于连续帧上下文的缺陷识别与误报抑制方法；
4. 面向实际巡检系统，进一步开展模型压缩、部署优化和在线辅助判读研究。

参考文献

参考文献

- [1] Ma D, Fang H, Wang N, et al. The state-of-the-art in pipe defect inspection with computer vision-based methods[J]. Measurement, 2026, 257: 118431.
- [2] Oğurlu M, Bayram B, Kulavuz B, et al. Deep Learning for Automated Sewer Defect Detection: Benchmarking YOLO and RT-DETR on the Istanbul Dataset[J]. Applied Sciences, 2025, 15(20): 11096.
- [3] Yin J, Yin X, Pan M, et al. Scalable and transparent automated sewer defect detection using weakly supervised object localization[J]. Automation in Construction, 2025, 174: 106152.
- [4] Goharinezhad S, Hadi A, Mirzaei S, et al. Automated defect classification and localization in sewer pipelines using hybrid ResNet50–Swin transformer and modified YOLOv8 on CCTV inspection images[J]. Scientific Reports, 2025, 15(1).
- [5] Yang C, Zheng F, Kapelan Z, et al. Automated quantification of sewage pipe cracks using deep learning for urban water environment management[J]. Tunnelling and Underground Space Technology, 2025, 155: 106195.
- [6] Haurum J B, Moeslund T B. Sewer-ML: A Multi-Label Sewer Defect Classification Dataset and Benchmark[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 13451-13462.
- [7] Sun L, Zhu J, Tan J, et al. Deep learning-assisted automated sewage pipe defect detection for urban water environment management[J]. Science of the Total Environment, 2023, 882: 163562.
- [8] Situ Z, Teng S, Feng W, et al. A transfer learning-based YOLO network for sewer defect detection in comparison to classic object detection methods[J]. Developments in the Built Environment, 2023, 15: 100191.
- [9] Wang T, Li Y, Zhai Y, et al. A Sewer Pipeline Defect Detection Method Based on Improved YOLOv5[J]. Processes, 2023, 11(8): 2508.

参考文献

- [10] Zhao X, Xiao N, Cai Z, et al. YOLOv5-Sewer: Lightweight Sewer Defect Detection Model[J]. Applied Sciences, 2024, 14(5): 1869.
- [11] Li D, Xie Q, Yu Z, et al. Sewer pipe defect detection via deep learning with local and global feature fusion[J]. Automation in Construction, 2021, 129: 103823.
- [12] Zhang J, Liu X, Zhang X, et al. Automatic Detection Method of Sewer Pipe Defects Using Deep Learning Techniques[J]. Applied Sciences, 2023, 13(7): 4589.
- [13] Dang L M, Kyeong S J, Li Y, et al. Deep learning-based sewer defect classification for highly imbalanced dataset[J]. Computers & Industrial Engineering, 2021, 161: 107630.
- [14] Jang S, Kim D. Impact of Data Quality on CNN-Based Sewer Defect Detection[J]. Water, 2025, 17(13): 2028.
- [15] Cheng J C P, Wang M. Automated detection of sewer pipe defects in CCTV images using deep learning techniques[J]. Automation in Construction, 2018, 95: 155-171.
- [16] Li D, Cong A, Guo S, et al. Sewer damage detection from imbalanced CCTV inspection data using deep convolutional neural networks with hierarchical classification[J]. Automation in Construction, 2019, 101: 199-208.
- [17] Meijer D, Scholten L, Clemens F, et al. A defect classification methodology for sewer image sets with convolutional neural networks[J]. Automation in Construction, 2019, 104: 281-298.
- [18] He J, Wang Z, Yong Z, et al. An automatic defect detection and localization method using imaging geometric features for sewer pipes[J]. Measurement, 2025, 243: 116367.
- [19] Taormina R, van der Werf J A, et al. Interpretable Sewer Defect Detection with Large Multimodal Models[C]//The 3rd International Joint Conference on Water Distribution Systems Analysis & Computing and Control for the Water Industry (WDSA/CCWI 2024). 2024: 158.

- [20] Yang Y, Yang S, Zhao Q, et al. Weakly supervised collaborative localization learning method for sewer pipe defect detection[J]. Machine Vision and Applications, 2024, 35(5).
- [21] Oh C, Dang L M, Han D, et al. Robust Sewer Defect Detection With Text Analysis Based on Deep Learning[J]. IEEE Access, 2022, 10: 46224-46237.
- [22] Wang M, Kumar S S, Cheng J C P, et al. Automated sewer pipe defect tracking in CCTV videos based on defect detection and metric learning[J]. Automation in Construction, 2021, 121: 103438.
- [23] Yin X, Ma T, Bouferguene A, et al. Automation for sewer pipe assessment: CCTV video interpretation algorithm and sewer pipe video assessment (SPVA) system development[J]. Automation in Construction, 2021, 125: 103622.
- [24] Haurum J B, Moeslund T B. A Survey on Image-Based Automation of CCTV and SSET Sewer Inspections[J]. Automation in Construction, 2020, 111: 103061.
- [25] Yin X, Chen Y, Bouferguene A, et al. A deep learning-based framework for an automated defect detection system for sewer pipes[J]. Automation in Construction, 2020, 109: 102967.
- [26] Moradi S, Zayed T, Golkhoo F. Review on Computer Aided Sewer Pipeline Defect Detection and Condition Assessment[J]. Infrastructures, 2019, 4(1): 10.
- [27] Kumar S S, Abraham D M, Jahanshahi M R, et al. Automated defect classification in sewer closed circuit television inspections using deep convolutional neural networks[J]. Automation in Construction, 2018, 91: 273-283.
- [28] Myrans J, Everson R, Kapelan Z, et al. Automated detection of faults in sewers using CCTV image sequences[J]. Automation in Construction, 2018, 95: 64-71.
- [29] Hawari A, Alamin M, Alkadour F, et al. Automated defect detection tool for closed circuit television (CCTV) inspected sewer pipelines[J]. Automation in Construction, 2018, 89: 99-109.

- [30] Halfawy M R, Hengmeechai J. Automated defect detection in sewer closed circuit television images using histograms of oriented gradients and support vector machine[J]. Automation in Construction, 2014, 38: 1-13.
- [31] Girshick R, Donahue J, Darrell T, et al. Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation[C]//2014 IEEE Conference on Computer Vision and Pattern Recognition. 2014: 580-587.
- [32] Liu W, Anguelov D, Erhan D, et al. SSD: Single Shot MultiBox Detector[C]//Computer Vision–ECCV 2016. Cham: Springer, 2016: 21-37.
- [33] Redmon J, Divvala S, Girshick R, et al. You Only Look Once: Unified, Real-Time Object Detection[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 779-788.
- [34] Lin T Y, Goyal P, Girshick R, et al. Focal Loss for Dense Object Detection[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 42(2): 318-327.
- [35] Hu J, Shen L, Sun G. Squeeze-and-Excitation Networks[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018: 7132-7141.
- [36] Woo S, Park J, Lee J Y, et al. CBAM: Convolutional Block Attention Module[C]//Computer Vision–ECCV 2018. Cham: Springer, 2018: 3-19.
- [37] Wang Q, Wu B, Zhu P, et al. ECA-Net: Efficient Channel Attention for Deep Convolutional Neural Networks[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 11531-11539.
- [38] Zhou B, Khosla A, Lapedriza A, et al. Learning Deep Features for Discriminative Localization[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 2921-2929.
- [39] Selvaraju R R, Cogswell M, Das A, et al. Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization[C]//2017 IEEE International Conference on Computer Vision (ICCV). 2017: 618-626.
- [40] Pan S J, Yang Q. A Survey on Transfer Learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2010, 22(10): 1345-1359.

- [41] Weiss K, Khoshgoftaar T M, Wang D. A survey of transfer learning[J]. Journal of Big Data, 2016, 3(1).
- [42] Wang M, Deng W. Deep visual domain adaptation: A survey[J]. Neurocomputing, 2018, 312: 135-153.
- [43] Rezatofighi H, Tsoi N, Gwak J Y, et al. Generalized Intersection Over Union: A Metric and a Loss for Bounding Box Regression[C]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 658-666.
- [44] Carion N, Massa F, Synnaeve G, et al. End-to-End Object Detection with Transformers[C]//Computer Vision–ECCV 2020. Cham: Springer, 2020: 213-229.
- [45] Cheng X, Wang Y. Pipeline Defect Detection Based on Improved YOLOv11[J]. Processes, 2026, 14(3): 530.
- [46] Jung J T, Reiterer A. Improving Sewer Damage Inspection: Development of a Deep Learning Integration Concept for a Multi-Sensor System[J]. Sensors, 2024, 24(23): 7786.
- [47] Huang J, Kang H. Automatic Defect Detection in Sewer Pipe Closed-Circuit Television Images via Improved You Only Look Once Version 5 Object Detection Network[J]. IEEE Access, 2024, 12: 92797-92825.
- [48] Lu J, Song W, Zhang Y, et al. Real-time defect detection in underground sewage pipelines using an improved YOLOv5 model[J]. Automation in Construction, 2025, 173: 106068.
- [49] Yu H, Liu J, Lin M. A Comprehensive Literature Review on YOLO-Based Small Object Detection: Methods, Challenges, and Future Trends[J]. Computers, Materials & Continua, 2026, 87(1).
- [50] Jing R, Zhang W, Li Y, et al. Dynamic Feature Focusing Network for small object detection[J]. Information Processing & Management, 2024, 61(6): 103858.
- [51] Ma Y, Yin J, Huang F, et al. Surface defect inspection of industrial products with object detection deep networks: a systematic review[J]. Artificial Intelligence Review, 2024, 57(12): 333.

- [52] Fu G, Zhang Z, Li J, et al. An evaluation method for model transfer learning performance in industrial surface defect detection tasks[J]. Expert Systems with Applications, 2025, 293: 128680.
- [53] Ye B, Lai J, Xie X, et al. Prototype-guided domain adaptive one-stage object detector for defect detection[J]. Advanced Engineering Informatics, 2024, 62: 102618.
- [54] Lv Z, Dong S, He J, et al. Lightweight Sewer Pipe Crack Detection Method Based on Amphibious Robot and Improved YOLOv8n[J]. Sensors, 2024, 24(18): 6112.
- [55] Wang H, Feng Z, Jiang M, et al. RDLK-YOLO enhanced pipeline defect detection in uneven illumination[J]. Scientific Reports, 2025, 15: 43594.
- [56] Lee S, Uh Y, Choe J, et al. Discovering an inference recipe for weakly-supervised object localization[J]. Pattern Recognition, 2024, 157: 110838.
- [57] Farrugia M. YOLO11 Architecture Diagram: Visual Representation of the YOLO11 Object Detection Model[EB/OL]. Zenodo, 2025.
- [58] Božič J, Tabernik D, Skočaj D. Mixed supervision for surface-defect detection: From weakly to fully supervised learning[J]. Computers in Industry, 2021, 129: 103459.
- [59] Ameri R, Hsu C C, Band S S. A systematic review of deep learning approaches for surface defect detection in industrial applications[J]. Engineering Applications of Artificial Intelligence, 2024, 130: 107717.
- [60] Wang H, Li Z, Wang H. Few-Shot Steel Surface Defect Detection[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-12.

致谢

在本论文的选题、数据整理、方法设计、实验推进和写作过程中，指导教师、课题组同学以及相关协作人员都给予了大量帮助。在此谨向所有关心、支持和帮助过本研究工作的老师、同学、家人和朋友致以诚挚谢意。论文从问题凝练到章节重构，再到实验方案设计与结果分析，均得益于导师在研究方向把握、技术路线梳理和论文写作规范方面的持续指导。课题组同学在数据整理、实验讨论和阶段性汇报中提供了大量建设性意见，也为本文顺利推进创造了良好条件。与此同时，家人对本人学习与生活的理解、支持与包容，也是完成本论文的重要保障。

在读期间发表的学术论文与取得的其他成果

1. 与本论文相关的学术论文、专利、项目与竞赛成果将在终稿提交前据实补录，并统一按照学校要求进行格式化整理。

补充图表规划

为避免正文过度臃肿而又保留充分原始材料，本附录对后续建议补充的图表内容进行统一规划。附录部分主要用于安置全量 **threshold sweep** 结果、完整 **baseline** 指标表、更多样本示例、额外 **CAM/Grad-CAM** 可视化、训练曲线以及错误样本画廊等材料，以增强实验过程的可复核性与材料完整性。

表 2 附录补充图表规划表

附录编号	建议内容	主要作用
表 A.1–表 A.2	全量 threshold sweep 表、五尺度完整 baseline 指标表	补充正文未展开的原始数值
表 A.3–表 A.6	全量 run config 、混淆矩阵明细、伪框抽检记录、错误样本统计表	展示实验原材料的完整性
图 A.1–图 A.2	更多 source/target 样本图	增强数据集展示的直观性
图 A.3–图 A.4	更多 CAM/Grad-CAM 与 calibration 图	支撑第一阶段支撑链分析
图 A.5–图 A.8	全量训练曲线、每类 PR 曲线、更多误检/漏检画廊、资源监控图	支撑实验充分性与可复核性

补充说明

本附录用于安置最终定稿时不宜在正文中大篇幅展示、但对答辩和归档具有支撑意义的辅助材料，包括：详细网络结构图、迁移训练阶段配置表、类别映射细则、伪框生成规则、数据清洗口径、实验日志样例及更多定性可视化图件。若后续实验中产生新的系统级图表，也将在本附录中按学校规范继续补充。