

分类号: _____

学校代号: 11847

UDC: _____

密级: _____

学号: _____

佛山大学

硕士学位论文

(理学硕士)

基于改进 YOLO_{v11} 的地下排水管道
缺陷智能检测方法研究

作者姓名: _____

学科专业: _____

导师姓名: _____

完成时间: _____

Foshan University

A dissertation for master's degree

**Research on Intelligent Defect Detection
Method for Underground Drainage
Pipelines Based on Improved YOLOv11**

Author: _____

Speciality: _____

Supervisor: _____

Finished time: _____

学位论文独创性声明

本人郑重声明：所呈交的学位论文是在导师指导下独立完成的研究成果。除文中已经明确注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律后果由本人承担。

论文作者签名：_____

日期：_____

学位论文版权使用授权声明

本人完全了解佛山大学关于保存、使用学位论文的有关规定，同意学校保留并按规定向有关部门或机构送交论文的印刷本和电子版，允许论文被查阅和借阅；同意学校将本论文的全部或部分内容编入有关数据库进行检索，并采用影印、缩印、扫描或数字化等方式保存、汇编和使用。本授权声明适用于涉密论文解密后以及非涉密论文。

保密情况： 公开 保密（_____ 年）

论文作者签名：_____

日期：_____

指导教师签名：_____

日期：_____

摘要

地下排水管网是城市基础设施体系中的重要组成部分，其运行状态直接影响城市排涝安全、道路运行秩序与生态环境质量。当前，基于闭路电视图像的排水管道检测已成为管网运维中的重要技术手段，但传统人工判读方式仍存在效率低、主观性强以及漏判误判率高等问题。与此同时，地下排水管道缺陷图像普遍具有缺陷目标尺度小、边界模糊、背景干扰强、正常样本占比高以及源域与目标域分布差异明显等特点，导致现有通用目标检测方法在该场景中的检测精度、鲁棒性和跨域泛化能力仍然受限。

针对上述问题，本文围绕地下排水管道 CCTV 图像缺陷检测任务，构建前级高召回预筛与后级精确检测相结合的总体框架。首先，结合公开 SewerML 数据与目标域巡检数据，构建源域单标签分类数据集和目标域六类结构性缺陷检测数据集；其次，面向复杂背景和小目标场景，提出一种基于改进 YOLOv11 的缺陷检测方法，从注意力机制、检测头和损失函数三个层面提升模型对细粒度缺陷和难样本的识别能力；再次，针对目标域样本有限和域差明显的问题，设计源域分类预训练与目标域微调相结合的跨域迁移策略，以增强模型的目标域适应性。

本文后续将通过前级预筛实验、检测对比实验、消融实验、迁移实验和可视化分析，对所提方法在精度、召回、误报控制和跨域泛化方面的有效性进行验证。研究目标是形成一条兼顾检测性能、标注成本与工程可部署性的地下排水管道缺陷智能识别技术路线，为城市排水管网智能巡检提供方法支撑。

关键词：地下排水管道；缺陷检测；YOLOv11；迁移学习；跨域适应；CCTV 图像

Abstract

Urban underground drainage pipelines are critical components of municipal infrastructure, and their operating conditions directly affect urban flood control, traffic safety, and environmental governance. CCTV-based inspection has become an important technical approach for drainage pipeline maintenance. However, conventional manual inspection still suffers from low efficiency, strong subjectivity, and high rates of missed and false judgments. In addition, CCTV images of drainage pipelines usually contain small defect targets, blurred boundaries, complex background noise, a high proportion of normal samples, and obvious distribution gaps caused by different devices, lighting conditions, and regional environments. These factors limit the accuracy, robustness, and cross-domain generalization of existing generic detection methods in real sewer inspection scenarios.

To address these challenges, this thesis constructs a two-stage framework that combines high-recall pre-screening with precise downstream detection for underground drainage pipeline defects. A source-domain single-label classification dataset and a target-domain six-class structural-defect detection dataset are organized to support progressive learning from source representation modeling to target-domain detection. On this basis, an improved YOLOv11-based detector is developed by enhancing attention modeling, redesigning the detection head, and refining the loss function, while a cross-domain transfer strategy is introduced through source-domain classification pretraining and target-domain fine-tuning.

The proposed framework will be further validated through pre-screening experiments, comparative detection experiments, ablation studies, transfer experiments, and qualitative analysis. The overall goal is to provide a practical and engineering-oriented technical route for intelligent CCTV inspection of underground drainage pipelines under limited annotations and domain shift.

Key words: underground drainage pipeline, defect detection, YOLOv11, transfer learning, cross-domain adaptation, CCTV image

目录

摘要	I
Abstract	II
第 1 章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.2.1 排水管道缺陷视觉检测研究	2
1.2.2 基于 YOLO 的缺陷检测研究	2
1.2.3 弱监督定位与低标注增强研究	2
1.2.4 迁移学习与跨域适应研究	2
1.3 现有研究存在的问题	3
1.4 研究内容与技术路线	4
1.5 本文主要创新点	5
1.6 论文结构安排	5
第 2 章 理论基础与关键技术	6
2.1 地下排水管道缺陷类型与图像特征	6
2.1.1 地下排水管道缺陷类型	6
2.1.2 缺陷图像特征分析	6
2.2 图像分类与目标检测评价指标	7
2.2.1 常用评价指标	7
2.3 YOLO 系列与 YOLOv11 原理	9
2.3.1 YOLO 系列的基本思想	9
2.3.2 YOLOv11 结构概述	9
2.3.3 分类模型与检测模型的区别	10
2.3.4 YOLOv11 作为本文基线的工程理由	10
2.4 注意力机制理论	10
2.4.1 注意力机制的作用机理	10
2.4.2 注意力机制与 sewer 场景的匹配性	11
2.5 损失函数与框回归相关理论	11

2.5.1	分类损失与定位损失的协同作用	11
2.5.2	损失设计与 Precision/Recall 折中	12
2.6	迁移学习与域适应理论	13
2.6.1	源域、目标域与域差定义	13
2.6.2	地下排水管道场景中的主要域差来源	13
2.6.3	渐进式迁移路线的理论依据	14
2.7	CAM / Grad-CAM 与弱监督定位理论	15
2.7.1	CAM / Grad-CAM 的基本思想	15
2.7.2	监督粒度连续体与低标注学习启示	15
2.7.3	人机协同闭环与工程意义	16
2.7.4	候选区域与伪标签的角色定位	16
2.8	本章小结	17
第 3 章	数据集构建与总体研究框架	19
3.1	数据来源与总体说明	19
3.1.1	源域数据	19
3.1.2	目标域数据	19
3.2	源域分类数据集构建	19
3.2.1	单标签化原则	19
3.2.2	源域六类与样本规模	20
3.2.3	源域数据的任务定位	20
3.3	目标域六类缺陷定义与标签映射	21
3.3.1	目标域最终检测类别	21
3.3.2	源域与目标域的关系	21
3.4	第一阶段与第二阶段任务定义	22
3.5	数据预处理与划分协议	22
3.5.1	预处理与增强	22
3.5.2	划分协议与运行型验证集	23
3.6	总体系统框架设计	24
3.7	评价协议与实验规范	24
3.8	本章小结	25
第 4 章	前级高召回预筛与弱监督标注增强策略	26
4.1	前级高召回预筛问题定义	26
4.2	基于同源图像重标注的二分类 gate 构建	26
4.3	YOLO11-cls 源域分类基线扫描	26
4.4	阈值校准与 operating point 选择	29

4.5	Hard Negative Mining 策略	31
4.6	CAM 与 Grad-CAM 伪框生成与质量控制	35
4.7	本章小结	36
第 5 章	基于改进 YOLOv11 的管道缺陷检测与跨域迁移策略	37
5.1	基线检测模型与问题分析	37
5.2	注意力机制改进	37
5.2.1	改进动机	37
5.2.2	模块设计与嵌入方式	37
5.3	检测头改进	38
5.3.1	原始检测头局限性	38
5.3.2	改进思路	38
5.4	损失函数改进	38
5.4.1	优化目标	38
5.4.2	形式化表达	38
5.5	改进 YOLOv11 总体结构	39
5.6	跨域迁移适应训练策略	39
5.6.1	跨域问题分析	39
5.6.2	迁移路径设计	40
5.7	训练流程与实现细节	40
5.8	本章小结	41
第 6 章	实验结果与分析	42
6.1	实验设置	42
6.1.1	实验平台与训练配置	42
6.2	第一阶段六类分类与二分类 gate 基线结果分析	43
6.3	第一阶段 calibration 结果分析	44
6.4	第二阶段检测 baseline 对比实验	47
6.5	创新点一消融实验	48
6.6	创新点二迁移学习对比实验	49
6.7	系统级对比实验	49
6.8	可视化与错误分析	50
6.9	本章小结	51
第 7 章	结论与展望	52
7.1	研究结论	52
7.2	不足之处	53
7.3	展望	53

参考文献	54
致谢	61
在读期间发表的学术论文与取得的其他成果	62
补充图表规划	63
补充说明	64
.1 六类间接 gate 的统一 calibration 补充结果	64
.2 第一阶段 HN 回流比例扫描补充结果	65

第 1 章 绪论

1.1 研究背景与意义

地下排水管网是城市基础设施体系的重要组成部分，其运行状态直接关联城市防涝、污水输送、水环境治理和道路运行安全。排水管道长期处于封闭、潮湿和腐蚀环境中，裂缝、破损、错口、变形、渗漏和侵入等病害会在服役过程中持续累积，并可能进一步诱发排水能力衰减、污染泄漏乃至地面塌陷等安全风险^{[26][7]}。因此，构建高效、可靠的地下排水管道缺陷智能识别方法，具有明确的工程需求和现实意义。

当前工程场景仍以 CCTV 巡检为主。该技术能够在非开挖条件下获取连续图像和视频，但缺陷识别、分类和复核等关键环节仍主要依赖人工判读。随着巡检规模扩大，海量正常帧和高重复度图像显著增加了人工复核负担，并加剧了误判、漏判和效率下降等问题^{[24][23]}。在此背景下，利用计算机视觉方法提升排水管道缺陷识别效率与一致性，已成为 sewer inspection 领域的重要研究方向。

该方向的技术演进大致经历了传统图像处理与机器学习、深度分类与目标检测、弱监督定位与跨域适应三个阶段。早期研究主要依赖人工特征和经典分类器，近期研究则逐步转向以 CNN 和 YOLO 为代表的深度学习模型，并开始关注公开数据、低标注增强和跨域适应等更贴近真实部署的问题^{[30][1]}。基于上述技术演进与工程需求，本文围绕改进 YOLOv11 检测方法与跨域迁移策略展开研究。

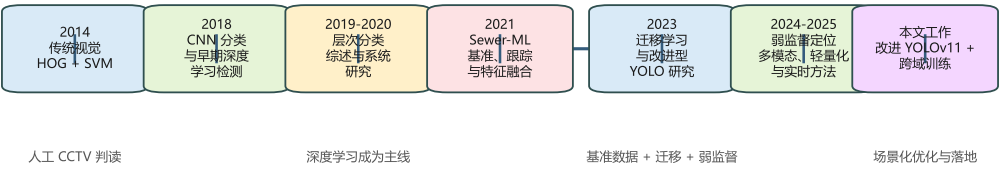


图 1.1 地下排水管道缺陷智能识别研究发展脉络

1.2 国内外研究现状

1.2.1 排水管道缺陷视觉检测研究

排水管道缺陷自动识别研究最初建立在传统图像处理和人工特征设计基础之上。Halfawy 等^[30] 较早将方向梯度直方图和支持向量机引入管道缺陷识别,证明了传统机器学习在规则明确场景下的可行性;随后,相关研究围绕候选区域提取、边缘纹理建模和视频序列分析展开,形成了早期计算机辅助判读框架^[29]。这一路线能够在局部场景中形成初步自动判别能力,但对光照变化、背景噪声和成像设备差异较为敏感,泛化能力有限。随着深度学习的发展,研究重心逐渐转向数据驱动的特征学习,排水管道缺陷识别的核心问题也由人工特征构造转向特征学习与任务适配^{[27][15]}。

1.2.2 基于 YOLO 的缺陷检测研究

近年来, YOLO 系列因具备较好的实时性、工程成熟度和部署便利性,已成为 sewer defect detection 中最常见的检测路线之一。Wang 等^[9] 和 Zhao 等^[10] 分别从特征增强、轻量化设计和场景适配等角度对 YOLO 路线进行了改进,说明一阶段检测器在该场景中具有较好的工程应用基础。与此同时,相关研究也表明,直接套用通用 detector 难以同时兼顾高召回、低误报和跨域稳定性,场景化改造仍然必要^{[47][2]}。

1.2.3 弱监督定位与低标注增强研究

Haurum 和 Moeslund^[6] 发布 Sewer-ML 数据集后,排水管道缺陷识别首次具备了相对统一的公开 benchmark 条件,图像级分类、CAM 与 Grad-CAM 候选区域生成以及弱监督定位研究由此得到明显推进。在此基础上,研究者进一步关注类别不均衡、标签质量和低标注增强等问题。相关结果表明,图像级标签能够为候选区域生成提供有效线索,但伪框质量仍显著依赖分类模型稳定性和后续质量控制机制^{[13][3]}。

1.2.4 迁移学习与跨域适应研究

公开数据与本地巡检数据在设备、照明、管材纹理和标签口径等方面普遍存在明显差异,导致模型跨域泛化能力受限。Situ 等^[8] 已证明,源域预训练与目标域微调能够在一定程度上缓解目标域样本不足问题;Jang 和 Kim^[14] 则进一步指出,数据质量和标签口径会显著影响 sewer defect model 的迁移表现。然而,如何将迁移学习与 detector 改进、弱监督增强和系统级误报控制整合为一条完整技术链,仍缺少系统研究。

表 1.1 现有研究路线对比与本文定位

路线类型	代表文献	监督粒度	主要优点	主要问题	与本文关系
传统图像处理与机器学习	[30][29]	图像级/候选区域级	解释性较强、实现简单	泛化能力弱、对场景变化敏感	作为发展起点与背景对照
深度分类与层次分类	[16][17]	图像级	适合筛查与长尾类别建模	难以直接输出精确位置	支撑前级 gate 与源域预训练
改进 YOLO 检测	[9][10]	框级监督	工程实现成熟、部署方便	依赖目标域检测框标注	对应本文创新点 1
弱监督定位与伪框增强	[3][20]	图像级/弱监督	可降低初始标注成本	伪框质量波动较大	支撑本文低标注增强链路
迁移学习与跨域适应	[8][42]	预训练 + 微调	缓解样本不足与域差	迁移收益依赖源域相关性	对应本文创新点 2

1.3 现有研究存在的问题

综合已有研究，当前排水管道缺陷智能识别仍面临四类核心问题。其一，正常帧占比高，直接检测容易造成误报累积并提高人工复核成本；其二，缺陷多表现为小目标、细长目标或弱纹理异常，通用 detector 难以稳定兼顾召回率与精度；其三，目标域高质量检测框标注代价较高，限制了模型快速构建与迭代；其四，源域与目标域之间存在明显 domain gap，现有研究尚未将源域预训练、目标域微调、弱监督增强和系统级验证组织为统一技术链^{[11][3]}。

上述问题表明，排水管道缺陷检测并非单一模型精度优化问题，而是数据组织、模型设计和系统验证协同推进的综合任务。基于此，本文将研究重点组织为一条连续技术路线：先利用源域分类学习建立 sewer-specific 表征，再通过高召回预筛与弱监督候选区域生成降低标注与误报压力，最终在改进 YOLOv11 与跨域迁移策略基础上完成目标域缺陷检测。




图 1.2 地下排水管道缺陷检测的问题链及本文技术路线

1.4 研究内容与技术路线

围绕上述问题，本文主要开展以下工作：构建源域单标签六类分类数据与目标域六类结构性缺陷检测数据；建立高召回预筛与弱监督伪框增强链路；提出面向 sewer 场景的改进 YOLOv11 检测模型；构建源域预训练、目标域微调与检测微调相衔接的跨域迁移训练策略。全文按照“问题背景—前级支撑链—改进 detector—跨域适应—系统级验证”的逻辑顺序逐步展开。

表 1.2 本文研究内容与章节对应关系

研究问题	对应章节	主要目标
RQ1: 高召回 gate 是否能有效降低误报	第 3 章、第 4 章、第 6 章	验证前级筛查在高召回约束下的减负效果
RQ2: 改进 YOLOv11 是否提升复杂场景检测性能	第 5 章、第 6 章	验证注意力、检测头和损失函数的协同增益
RQ3: 跨域迁移是否缓解样本不足与域差问题	第 5 章、第 6 章	验证源域预训练与目标域微调的迁移价值
RQ4: 两阶段系统是否优于单阶段直接检测	第 4 章、第 6 章	验证系统级误报控制与工程适配性

1.5 本文主要创新点

1. 提出一种面向地下排水管道缺陷场景的改进 YOLOv11 检测方法，通过注意力机制、检测头和损失函数协同优化，提升复杂背景和小目标条件下的检测能力。
2. 提出一种源域预训练与目标域微调相结合的跨域迁移适应训练策略，利用公开 Sewer-ML 数据和少量目标域样本提升目标域检测模型的初始化质量与泛化能力。

前级高召回预筛、CAM 热力图和伪框构建不单独定义为独立创新点，而被定位为支撑上述两项核心创新落地的关键工程链条。

1.6 论文结构安排

全文共分为七章：第 1 章为绪论；第 2 章介绍理论基础与关键技术；第 3 章介绍数据集构建与总体研究框架；第 4 章阐述前级高召回预筛与弱监督标注增强策略；第 5 章介绍改进 YOLOv11 检测方法与跨域迁移策略；第 6 章给出实验结果与分析；第 7 章总结全文并展望后续研究方向。

第 2 章 理论基础与关键技术

2.1 地下排水管道缺陷类型与图像特征

2.1.1 地下排水管道缺陷类型

地下排水管道缺陷并不是标准自然图像中的显著目标，而是与管壁纹理、接口结构、照明条件和运行工况耦合的工程视觉对象。结合本文目标域任务，最终检测类别固定为破裂裂缝类、表面损伤类、变形类、接口错位类、侵入类和渗漏类，其中既包含局部纹理破坏，也包含接口异常和整体几何形变^{[26][7]}。该类别冻结并非对 sewer 场景病害种类的简单删减，而是围绕最终检测任务的可实施性、类别语义稳定性以及目标域标注条件形成的任务化选择。

从工程属性看，结构性病害通常与管道安全、维修优先级和后续养护决策直接相关，因此更适合作为检测主任务。相较之下，部分功能性缺陷、构造信息和工况标签更适合用于预筛、分类辅助或附录说明，而不宜与最终检测类别混合建模^{[24][6]}。据此，本文不对源域类别体系与目标域检测类别进行机械的一一对应，而采用源域类别较粗、目标域类别固定的映射策略，以支撑后续跨域训练与实验对比。

从视觉表现上看，六类结构性缺陷具有明显差异。裂缝与破损更依赖于局部细纹理和细长轮廓感知；表面损伤与腐蚀更接近区域性异常，边界往往模糊；变形强调整体几何变化；错口与侵入则与接口结构关系紧密相关；渗漏通常表现为低对比度拖尾或局部湿痕^{[11][9]}。因此，后续模型设计必须同时考虑局部细节保持、上下文建模和复杂背景抑制，不能把所有缺陷等同为视觉属性一致的普通目标。

2.1.2 缺陷图像特征分析

这类图像的主要难点体现在四个方面：一是缺陷目标通常尺度较小，局部有效像素占比低；二是缺陷边界模糊，许多病害只表现为弱纹理或低对比异常；三是背景干扰强，反光、水膜、污渍和沉积物会造成明显伪激活；四是类别之间存在视觉相似性，易出现类间混淆^{[1][14]}。对于长视频巡检场景而言，摄像头自带光源造成的中心高亮、边缘衰减和局部曝光过强等现象，也会进一步放大模型对背景纹理的误响应。

除静态图像特征外，排水管道巡检数据还具有明显的分布不均衡特征。正常帧通常远多于缺陷帧，且不同缺陷类别样本数量差异很大，少数类往往具有更高

工程风险却更难获得稳定标注^{[13][16]}。在这种条件下，若模型仅优化总体准确率，训练过程往往偏向背景和多数类，从而在真实部署中出现总体指标尚可而关键缺陷漏检较多的现象。

上述视觉难点直接约束后续研究路线：若任务核心困难来自小目标与弱纹理，则需要在特征表达阶段尽量保留细粒度信息；若误报主要来自污渍、反光和沉积干扰，则需要在前级预筛与后级 detector 中同步强化背景抑制；若目标域高质量框标注有限，则必须通过迁移学习与弱监督定位降低监督构建成本。因此，第 4 章和第 5 章中的模型改进与跨域迁移并非彼此独立的附加操作，而是针对同一组任务困难的分层响应。




图 2.1 地下排水管道缺陷检测的关键理论支撑关系

2.2 图像分类与目标检测评价指标

2.2.1 常用评价指标

本文后续同时涉及源域分类、前级高召回预筛和目标域目标检测三个层次，因此评价体系不能仅依赖单一准确率。考虑到后文真正反复使用的是前级 gate 的 operating point 指标、分类基础指标以及后级 detector 的检测指标，本节不再展开通用检测范式演进等泛化背景，而仅保留能够直接支撑后续实验分析的核心指标定义。

其中，Precision、Recall 与 F1-score 用于刻画识别准确性与漏检之间的折中关系，Specificity 与 Gate Recall 用于服务第一阶段预筛在高召回约束下的误报控制分析，AP50 与 AP50-95 则用于评价第二阶段 detector 的检测与定位质量。上述指标既覆盖了分类与检测的主要评价需求，也对应后续章节中的系统级实验结论。为便于全文统一引用，表 2.1 对这六个核心指标作集中定义。

表 2.1 评价指标定义与说明

指标	计算方式 说明	主要含义	本文中的使用场景
精确率	预测为正的样本中，真实为正的的比例	预测结果的准确性	反映误报控制能力，直接影响人工复核成本。
召回率	真实正样本中，被模型成功检出的比例	对真实缺陷的覆盖能力	对缺陷检测尤其关键，漏检会直接削弱维护决策可靠性。
特异度	真实负样本中，被模型正确排除的比例	对正常样本的过滤能力	是第一阶段 gate 的核心指标，反映正常帧过滤能力。
F1 值	精确率与召回率的调和平均	识别效果的综合折中	适合用于概括模型总体识别能力，但仍需配合精确率与召回率同时分析。
门控召回率	前级预筛保留下来的异常样本占全部异常样本的比例	前级 gate 对异常样本的保留能力	是第一阶段的硬约束指标，用于保证真正异常样本尽可能不被误滤除。
AP50	在 IoU 阈值为 0.5 时统计平均精度	模型是否大致检出目标	是第二阶段 detector 的主评价指标之一，更贴近工程中缺陷发现能力的需求。
AP50-95	在多个 IoU 阈值下统计平均精度并取平均	同时反映检测与定位质量	适合用于正式实验对比，能够更严格地衡量定位边界是否稳定。

本节未在理论基础中展开 AUROC、AUPRC、NRR、PTR 和 FP/image 等指标，并非因为这些指标不重要，而是因为此类指标更适合在对应实验章节中结合具体任务视图解释。例如，第 4 章讨论第一阶段 operating point 时重点引入 NRR 与 PTR，第 6 章讨论系统级结果时引入 FP/image 及相关误报控制指标。这样的安排有助于避免理论基础章节过早堆积过多指标，并保证各指标在相应实验语境中被准确解释。

评价指标的选择本身体现了论文对任务目标的理解。若只强调单一精度指标，容易掩盖高召回条件下的误报成本；若只强调系统级过滤能力，又可能忽略 detector 的定位质量。因此，本文将六个核心指标在理论基础章节中统一定义，其目的不在于追求指标列举的完整性，而在于提前给出后续实验比较的统一评价语义。

2.3 YOLO 系列与 YOLOv11 原理

2.3.1 YOLO 系列的基本思想

YOLO 系列将目标检测统一建模为单阶段回归问题，能够在单个网络中同时完成类别判断和边界框预测，因此兼具较好的速度与工程可部署性^[33]。这一范式的关键优势在于训练和推理流程相对统一，便于在同一工程框架内完成数据准备、模型迭代和结果部署。对排水管道场景而言，该路线更适合长视频、大批量图片和快速迭代训练流程。

从方法发展上看，YOLO 的优势不只体现在实时性，更体现在其逐步形成了成熟的特征提取、多尺度融合和检测头组织范式。随着不同版本持续迭代，YOLO 家族逐渐在工业缺陷检测、基础设施巡检和嵌入式部署场景中形成较强工程竞争力。这也是本文选择在 YOLO 路线而非完全另起炉灶的端到端方案上开展改进的主要原因。

2.3.2 YOLOv11 结构概述

YOLOv11 在工程实现中延续了主干特征提取、颈部多尺度融合和检测头预测的基本结构，同时保留了较成熟的训练与部署接口。本文选择 YOLOv11 作为基线，原因在于其工程生态稳定、改造接口清晰，便于在同一平台上完成前级分类、后级检测和跨域迁移实验。




图 2.2 YOLO11 检测模型结构示意图

2.3.3 分类模型与检测模型的区别

YOLOv11 的分类模型与检测模型虽然共享部分工程接口，但二者面向的监督粒度和输出目标并不相同。分类模型更适合学习图像是否存在某类异常的判别边界，因此适合作为源域表征学习和前级 gate 的基础；检测模型负责同时完成类别识别与空间定位，更适合承担最终缺陷检测任务。这一区分构成本文采用源域分类预训练、目标域分类微调与目标域检测训练渐进路线的理论基础。

与此同时，YOLOv11 在 sewer 场景中的局限也很明确：面对小目标、弱纹理和复杂背景时，通用结构往往难以同时兼顾召回率与误报控制，因此需要在特征表达、检测头设计和训练目标三个层面做针对性改进^{[9][10]}。也就是说，YOLOv11 在本文中既是一个成熟的工程起点，也是一个必须被场景化改造的基线平台。

2.3.4 YOLOv11 作为本文基线的工程理由

本文最终选择 YOLOv11 而不是直接转向完全不同的检测体系，主要出于三点考虑。第一，YOLO 路线在排水管道缺陷研究中已经有较多成功实践，具备较强的同领域可迁移性，因此能够与本文的 SewerML 源域预训练、目标域 detector 训练形成自然衔接^{[9][8]}。第二，YOLOv11 在工程实现上具备较成熟的训练、验证和推理接口，适合与本文当前的数据组织方式和运行环境对接。第三，YOLOv11 仍保留了足够清晰的 backbone、neck、head 分层结构，便于后续在注意力、检测头和损失函数层面开展可解释的改进。

基线模型的选择还直接影响后续消融实验的可解释性。若基线平台本身过于冷门或改造接口不清晰，则很难将注意力模块、检测头改进和迁移策略置于统一实验矩阵下进行公平比较。YOLOv11 能够提供较稳定的统一平台，使后续改进均围绕同一基线展开，从而保证实验设计的可读性和结论的可归因性。

2.4 注意力机制理论

2.4.1 注意力机制的作用机理

注意力机制的核心作用是强化关键区域和关键通道响应，抑制背景噪声对特征学习的干扰。对于 sewer defect detection 而言，注意力模块的价值主要体现在两个方面：一是提升模型对细小裂缝、接口异常和局部渗漏等弱显著目标的聚焦能力；二是降低反光、污渍和壁面纹理带来的伪激活^[11]。

现有研究中常见的轻量级注意力模块包括 SE、CBAM 和 ECA。它们分别强调通道重标定、通道与空间联合建模以及低开销的局部跨通道交互。本文选择注意力模块时，关注重点并不在于结构复杂度本身，而在于其能否以较低代价在 sewer 场景中带来稳定增益。若某一模块虽然理论表达能力更强，却显著增加参

数量、推理时延或训练不稳定性，其工程价值就会受到限制。

因此，第二章对注意力模块的讨论重点并不是罗列所有变体，而是建立一个清晰的筛选准则：是否能增强关键缺陷区域响应、是否有助于抑制背景噪声、是否能够自然嵌入 YOLOv11 的 backbone/neck 结构，以及是否适合后续消融实验进行公平比较。第 5 章的注意力设计选择将严格围绕这些原则展开。

2.4.2 注意力机制与 sewer 场景的匹配性

对于地下排水管道场景，注意力机制的意义并不局限于一般性的特征增强，而是与具体误差来源直接相关。若模型在反光、水膜或污渍区域持续产生高响应，则说明其显著性分配已经偏离真实缺陷区域；若模型对细小裂缝和接口异常的响应被大面积背景纹理淹没，则说明其在关键区域聚焦方面存在不足。注意力模块正是在这一层面介入，通过对通道和空间信息进行重加权，使模型把更多表征能力集中到与缺陷有关的局部区域。

注意力机制并非越复杂越有效。对于需要长期运行的工程系统而言，任何结构改动都必须同时考虑复杂度、稳定性和部署成本。基于此，本文将注意力模块定位为具有明确任务指向的增强组件，而非单纯面向指标提升的装饰性叠加。后续消融实验将同时评估其有效性与代价合理性。

表 2.2 典型注意力模块比较表

模块	机制类型	参数/计算开销	优点	是否适合本文
SE	通道重标定	低到中等	结构简单，易集成	适合作为轻量基线
CBAM	通道 + 空间联合注意力	中等	对关键区域建模更直接	适合复杂背景场景
ECA	局部跨通道交互	低	代价较小，部署友好	适合作为低开销候选

2.5 损失函数与框回归相关理论

2.5.1 分类损失与定位损失的协同作用

检测模型的训练效果不仅取决于网络结构，也取决于训练目标的组织方式。对于 sewer 缺陷检测，损失函数需要同时面对类别不均衡、难样本区分不足和边界模糊等问题。分类侧常见损失包括 BCE、CE 和 Focal Loss；定位侧通常依赖 IoU、GIoU 等框回归损失^{[34][43]}。

从任务角度看，Focal Loss 更适合抑制大量易分类样本对梯度的主导，IoU

类损失则有助于提高边界回归质量。本文后续对损失函数的改进，核心并不是机械替换公式，而是围绕在保持召回率的同时抑制误报，并改善 hardest positive 与 hardest negative 的区分能力展开。对于排水管道场景而言，这种优化尤其关键，因为真实任务不仅要求检出缺陷，还要求减少大量正常背景中的误报。

损失函数设计在本文中承担将视觉难点转化为训练偏好的作用。如果任务主要困难在于少数类与弱纹理目标，则损失函数应强化难样本；如果系统更强调高召回条件下的误报抑制，则损失函数应避免过度偏向易样本和多数类。正因如此，第 5 章不会简单沿用通用损失设置，而是将损失函数与注意力模块、检测头并列为核心改进项。

2.5.2 损失设计与 Precision/Recall 折中

在工程检测任务中，损失函数选择还会直接影响 Precision 与 Recall 的平衡关系。若训练目标更强调容易区分的样本，模型可能在验证集上表现出较高 Precision，却牺牲了对弱显著目标和边界模糊目标的 Recall；反之，若训练目标过于强调正样本召回，又可能在复杂背景中引入更多误报。这种折中关系在 sewer defect detection 中尤为突出，因为正常背景占比高、异常边界不稳定且类间相似度大。

因此，本文不将损失函数视为单一公式替换问题，而是将其理解为把研究目标显式写入训练过程的机制。若后续改进能够在高召回条件下抑制误报，并改善 hardest normal 与 hardest positive 的区分能力，则可说明损失函数设计与本文任务需求相匹配，而非仅在个别指标上形成偶然增益。

表 2.3 典型损失函数与适用问题比较表

损失函数	主要解决问题	适合场景	与本文关系
BCE / CE	基础分类训练	常规分类与检测分类支路	作为基础对照
Focal Loss	类别不平衡、易样本主导	正负样本数量差距大时	适合作为候选改进项
IoU / GIoU 类损失	提升边界框回归质量	需要更稳定定位时	支撑后续定位优化分析
组合损失	同时兼顾分类与定位目标	场景化检测任务	对应本文损失设计主线

2.6 迁移学习与域适应理论

2.6.1 源域、目标域与域差定义

迁移学习的基本思想是在源域学习通用或同领域先验，再迁移到目标域进行微调，以缓解目标域标注不足问题^{[40][41]}。对本文而言，源域是公开 Sewer-ML 数据，目标域是本地巡检数据。两者在设备、纹理、照明和标签口径上存在差异，因此模型不能只依赖公开数据训练结果直接部署。

在工程实现上，本文采用的不是高复杂度对抗式域适应，而是源域分类预训练、目标域分类微调与目标域检测微调相衔接的渐进路线。该路线实现成本较低、解释性较强，也更适合与低标注增强流程结合。选择这一方案的重要原因在于，地下排水管道场景的 domain gap 不仅来自图像风格差异，还来自缺陷定义、标注口径和设备条件差异，因此过于抽象的端到端对抗式适配未必能够带来稳定收益。

更进一步地，迁移学习在本文中并不只是一般性的训练技巧，而是连接公开数据与本地任务的核心桥梁。若没有源域预训练，目标域 detector 只能在有限样本下从零开始学习，容易出现训练不稳定和类间混淆；若没有目标域微调，源域模型又难以适应本地场景中的成像条件与标签口径。这也是后续实验必须设置从零训练、官方预训练、源域预训练以及源域预训练加目标域分类微调多组对比的理论原因。

2.6.2 地下排水管道场景中的主要域差来源

对排水管道场景而言，域差并不是抽象的统计概念，而是由具体采集条件和标注条件共同形成的。不同地区在管材、接口形式、积水程度和照明环境上往往存在明显差异；不同巡检设备在分辨率、曝光方式、移动速度和畸变控制上也存在差别；不同数据集甚至可能对相同缺陷给出不同的标签口径^{[8][1]}。这些因素叠加后，会导致源域模型即便在公开数据上表现良好，也未必能直接迁移到本地目标域。




图 2.3 地下排水管道检测任务中的主要域差来源

2.6.3 渐进式迁移路线的理论依据

在这一前提下，本文采用渐进式迁移路线具有明确理论合理性。源域分类预训练负责学习同领域缺陷表征，目标域分类微调负责建立对本地图像分布的初步适应，目标域检测微调则进一步把这种表征转化为位置级监督能力。相较于直接采用重对抗式域适应，渐进式路线更易解释、训练代价更低，也更符合目前工程侧少量标注、逐步增强的现实条件。

这一路线的另一个优势在于能够与第一阶段 gate 和弱监督定位自然衔接。因为分类模型本身就是前级预筛与 CAM 热力图生成的基础，所以源域分类预训练不会成为独立于全文的旁支实验，而是同时服务于迁移学习、低标注增强和两阶段系统构建。这正是本文将迁移策略写成核心创新点之一的原因。

表 2.4 迁移学习与域适应策略比较表

方法类型	目标域标签	对抗训练	实现复杂度	本文采用情况
通用预训练 + 微调	需要	否	低	作为基础对照
同领域源域预训练 + 微调	需要少量标签	否	低到中等	本文主路线
对抗式域适应	可弱依赖标签	是	高	仅作理论参考
伪标签/自训练	需要少量标签或高置信预测	否	中等	作为扩展备选

2.7 CAM / Grad-CAM 与弱监督定位理论

2.7.1 CAM / Grad-CAM 的基本思想

CAM 和 Grad-CAM 通过分析分类模型的响应分布，给出图像中对当前类别判别最关键的区域，是图像级监督向候选区域监督过渡的重要工具^{[38][39]}。在本文中，热力图不直接作为最终真值，而是作为候选区域生成和低标注增强的中间监督信号。

该路线的意义在于把人工工作由全量从零标注转变为围绕候选区域的抽检与快修。对于目标域样本有限的 sewer 场景，这种做法能够在控制标注成本的同时，为 detector 训练提供更具针对性的初始监督。基于这一认识，本文在后续章节中将 CAM / Grad-CAM 明确界定为低标注增强支撑链的一部分，而不将其视为最终 detector 的替代品。

从监督粒度角度看，CAM / Grad-CAM 的理论价值在于说明图像级标签并不必然止步于分类任务。只要分类模型能够学到稳定的类别响应区域，热力图就可以转化为候选框、候选区域或人工抽检线索，从而为检测任务提供中间层监督^{[3][58]}。这也是本文后续从源域分类预训练逐步过渡到目标域检测训练的重要理论支点。

2.7.2 监督粒度连续体与低标注学习启示

在低标注视觉任务中，监督信息不宜被简单划分为有标注与无标注两种状态，而应理解为从图像级标签、候选区域、少量精确框到充分检测标注连续变化的监督粒度谱系。对 sewer defect detection 而言，这一点尤为重要，因为目标域真正稀缺的通常不是图像本身，而是高质量、口径稳定且可用于 detector 训练的框级标注^{[3][58]}。

把监督粒度理解为连续体有两个直接启示：其一，源域分类预训练、目标域分类微调、CAM 候选区域生成和少量人工精框并不是互斥资源，而是可以顺序衔接、相互补充的监督层级；其二，低标注训练的关键不是单纯减少标注数量，而是先建立可靠先验，再把有限标注投入到最值得的样本和阶段上。本文后续采用的技术路线，正是基于这一思路构建。

这也意味着，本文后续的实验顺序本身具有理论基础，而不是依据实现便利程度任意排列。源域分类实验之所以排在前面，是为了先验证同领域表征是否稳定；目标域分类微调之所以作为中间步骤，是为了把公开数据的先验压缩到本地场景；CAM 候选区域与少量人工快修之所以位于 detector 训练之前，则是为了在不大规模追加框标注成本的前提下，为检测模型建立第一版可用监督。这样的顺序安排体现了监督粒度连续体在工程任务中的实际落地方式。

2.7.3 人机协同闭环与工程意义

从系统层面看，地下排水管道智能巡检并非模型完全替代人工的单向过程，而是模型与人工分工重组的协同闭环。模型擅长从海量图像和长视频中快速筛选出疑似异常区域，人工擅长利用工程经验判断复杂边界、确认疑难样本并完成最终维护决策^{[23][22]}。因此，可用系统应将模型视为人工能力的放大器，而非孤立的最终判决器。

本文把前级预筛、CAM 候选区域和 detector 训练放在同一条链路中讨论，目的在于将分类是否降低人工逐帧查看成本、热力图是否降低初始标注成本以及检测器是否提高最终识别质量等问题统一到同一个工程闭环中解释。这样，后续第 6 章的实验就不仅是在报告某个模型指标更高，而是在回答整套技术路线是否真的更适合地下排水管道的真实巡检流程。

2.7.4 候选区域与伪标签的角色定位

在低标注检测任务中，伪标签并不应被理解为替代真值的廉价近似，而更适合作为一种中间层监督资源。对 sewer defect detection 而言，CAM / Grad-CAM 产生的候选区域本质上反映了分类模型认为最能支持当前类别判断的区域，因此它更适合承担提示人工关注区域、为 detector 提供初始粗监督的角色，而不宜直接等同于精确边界框^{[39][3]}。这一定位能够解释为什么本文后续会把 CAM 输出、抽检规则和人工快修放在同一实验链条中分析。

候选区域的核心价值在于重构标注流程。传统流程通常要求标注者从零开始浏览全部图像并绘制框标注，而基于候选区域的流程则先由模型给出高价值关注区域，再由人工进行确认、修正或否决。对于正常样本占比极高、专家标注成本较高的排水管道场景，这种流程重构意味着相同人工时间能够更集中地投入到高价值样本上。因此，本文在理论上将伪标签视为监督增强接口，而非临时性补丁。

表 2.5 监督粒度与训练目标对应关系表

监督粒度	典型监督形式	主要训练目标	在本文中的角色
图像级监督	单标签/多标签分类标签	学习类别存在性与粗粒度判别边界	服务于源域预训练、目标域分类微调与前级 gate
候选区域监督	CAM 热力图、伪框、人工抽检结果	提供候选位置先验, 降低精框构建成本	服务于弱监督增强与 detector 初始监督
框级监督	人工精修边界框	学习类别识别与空间定位	服务于最终 detector 训练与正式评测




图 2.4 从图像级监督到检测级监督的连续体

2.8 本章小结

本章围绕后续章节真正会用到的理论基础, 完成了四项铺垫工作: 其一, 明确排水管道缺陷图像在尺度、纹理、背景和类别分布上的任务特征, 并据此说明目标域六类结构性缺陷定义的合理性; 其二, 结合目标检测范式比较与 YOLOv11 结构特点, 给出本文以一阶段检测器作为主路线的工程依据; 其三, 从注意力机制、损失函数和迁移学习三个维度, 为第 5 章模型改进与跨域训练策略提供理论支撑; 其四, 界定 CAM、Grad-CAM 与监督粒度连续体在低标注增强链路中的角色。由此, 本章的作用不在于罗列概念, 而在于为后续数据组织、预筛设计、检测改进和迁移实验建立统一的理论语义。

在此基础上, 表 2.6 将研究问题与理论基础的对应关系进一步收束, 避免后续章节出现“方法提出有依据、实验设计无映射”的断裂现象。第 3 章将在这一理论框架上转入数据组织与总体系统设计, 第 4 章进一步展开前级高召回预筛

与弱监督增强策略，第 5 章则聚焦改进 YOLOv11 检测方法与跨域迁移训练策略本体。

表 2.6 研究问题与理论基础映射表

研究问题	对应理论基础	直接支撑章节	主要回答内容
RQ1	缺陷图像特征、核心评价指标、监督粒度连续体	第 4 章、第 6.2–6.3 节	高召回 gate 是否能有效降低误报与正常样本流入
RQ2	YOLOv11 原理、注意力机制、损失函数与框回归	第 5 章、第 6.4–6.5 节	改进 detector 是否能提升复杂场景下的检测性能
RQ3	迁移学习、域差来源、渐进式迁移路线	第 5 章、第 6.6 节	源域预训练与目标域微调是否能缓解样本不足和域差问题
RQ4	CAM 与 Grad-CAM、候选区域、两阶段协同与人机闭环	第 4 章、第 6.7 节	两阶段系统是否优于单阶段直接检测并更适合工程应用

从全文结构看，表 2.6 总结了公开文献中的关键结论及其与本文研究路线之间的对应关系。已有 sewer detection 文献分别证明了公开数据集的价值、YOLO 路线的工程优势、迁移学习在同领域任务中的潜力以及 CAM / WSOL 在低标注定位中的可行性，但这些结论大多聚焦单一环节，尚未自然汇聚为一条能够直接服务本文目标任务的完整方法链^{[6][9][8][3]}。本章通过理论梳理完成的工作，正是将这些分散结论重组为统一问题图景：为何 sewer 缺陷检测需要同时关注小目标与复杂背景，为什么一阶段 detector 虽适合工程部署仍需场景化改进，为什么目标域少标注条件下必须引入源域预训练、目标域微调与候选区域增强，以及为什么这些环节应被视为一条连续研究链。只有在这一图景明确建立之后，第 3 章的数据组织、第 4 章的前级预筛、第 5 章的模型改进与迁移策略以及第 6 章的系统级实验，才能形成首尾一致的论文闭环。

第 3 章 数据集构建与总体研究框架

3.1 数据来源与总体说明

3.1.1 源域数据

本文源域数据来自公开 Sewer-ML 数据集。考虑到 Sewer-ML 原始发布形态为多标签分类数据，而本文的前级预筛、CAM 热力图和迁移分类实验均需要稳定的单标签监督信号，因此本文在不改变原始数据来源的前提下，对原始标签进行了任务化重构，形成适用于分类预训练的单标签六类平衡数据集。将 Sewer-ML 选为源域的原因主要有三点：其一，数据规模较大且类别覆盖较广，能够为模型提供较强的 sewer scene prior；其二，数据来源公开、口径明确，适合在论文中形成可复现的源域背景；其三，已有研究已经证明 Sewer-ML 及其衍生任务可有效支撑 sewer-specific classification、transfer learning 与 weakly supervised localization 研究^{[6][13][3]}。

3.1.2 目标域数据

目标域数据来自本地或合作区域的地下排水管道巡检图像，包括图像级标签、少量检测框标注以及后续人工复核样本。目标域是本文最终检测任务的真实落点，其类别口径、误报约束和评价方式均以本地工程任务为准。与源域数据相比，目标域数据在拍摄设备、视角、照明条件、管材背景、污渍分布和缺陷表达方式等方面更具工程性，也更能体现真实 deployment 条件下的 domain gap。因此，本文并不追求让源域标签体系严格等价于目标域检测类别，而是通过层次化标签对齐和迁移训练，使源域数据主要承担“先学会看懂 sewer scene”的任务，目标域数据承担“完成本地检测任务定义”的任务。

3.2 源域分类数据集构建

3.2.1 单标签化原则

为适应分类预训练、二分类 gate 构建和 CAM 热力图生成流程，本文将 Sewer-ML 原始样本重构为单标签分类数据，并采用固定优先级将多标签样本映射到唯一主类。这样处理的目的是不是否定 Sewer-ML 的原始多标签语义，而是在当前实验框架中尽可能减弱标签重叠对分类训练稳定性的影响，使分类模型输出更适合作为候选区域生成的中间监督信号。与此同时，本文保留 Normal 类别，

使模型在源域阶段就具备明确的正常/异常判别能力，为后续第一阶段高召回预筛任务提供基础。

3.2.2 源域六类与样本规模

当前构建的源域单标签数据集为 sewerml_cls6_train7200，共 7200 张图像，按类别均衡组织，每类 1200 张，其中训练集每类 1080 张、验证集每类 120 张。源域六类分别为 Normal、Deformation、Roots、JointAnomaly、WallDamage 和 DepositAttachment。该数据集既是后续 source pretrain 的输入，也是第一阶段 gate 扫描和 CAM 候选区域生成的基础。选择 7200 张作为首版正式实验规模，主要是综合考虑了类别平衡、训练成本、3090 显卡平台上的迭代效率以及前级预筛研究对稳定表征的需求。

表 3.1 源域单标签六类分类数据集分布

类别	训练集数量	验证集数量	总数量
Normal	1080	120	1200
Deformation	1080	120	1200
Roots	1080	120	1200
JointAnomaly	1080	120	1200
WallDamage	1080	120	1200
DepositAttachment	1080	120	1200
合计	6480	720	7200

同样地，图 6.4 用于展示不同初始化与微调路径带来的迁移收益差异。

图 3.1 源域六类样本示例图

3.2.3 源域数据的任务定位

需要强调的是，源域分类数据集并不直接承担最终检测任务，而是同时服务于三个中间目标：第一，为 Normal/Abnormal 高召回预筛提供统一的初始特征表征；第二，为 CAM 与 Grad-CAM 候选区域生成提供稳定的类响应基础；第三，为后续目标域检测提供更贴近 sewer inspection 场景的初始化权重。也就是说，源域数据的角色是“可迁移缺陷表征学习平台”，而不是“目标域检测任务的直接替代品”。

3.3 目标域六类缺陷定义与标签映射

3.3.1 目标域最终检测类别

本文将目标域最终检测任务固定为六类结构性缺陷，包括破裂裂缝类、表面损伤类、变形类、接口错位类、侵入类以及渗漏类。该定义兼顾了中国排水管道检测评估口径、目标域图像表现特点以及后续检测模型的可训练性。与源域分类类别不同，目标域类别必须为最终检测任务服务，因此一经确定便不再随实验中途变动。

表 3.2 目标域六类缺陷与任务定义

编号	类别名称	说明
0	破裂裂缝类	对应破裂、裂缝、坍塌等管壁破坏性缺陷
1	表面损伤类	对应表面损伤、腐蚀样损伤及相关施工或制造缺陷
2	变形类	对应管道几何形态变化、变形等缺陷
3	接口错位类	对应接口错位、脱节、错口等接口异常
4	侵入类	对应接口侵入、材料侵入或局部异物侵入
5	渗漏类	对应渗漏、渗入水等渗漏类异常

从系统层面看，图 6.5 将单阶段与两阶段方案的关键指标并列展示，以突出整体路线的工程价值。

图 3.2 目标域六类样本示例图

3.3.2 源域与目标域的关系

源域分类类别与目标域检测类别并非严格一一对应。源域更强调稳定表征与预筛能力，目标域更强调最终缺陷位置与类别判定。本文采用“源域预训练较粗、目标域检测类冻结”的层次化标签对齐思路，使迁移学习服务于最终检测目标而不是反过来受制于源域原始标签体系。这种处理能够在避免语义硬映射冲突的同时，最大化公开 sewer 数据对本地任务的可迁移价值^{[6][8][53]}。

表 3.3 源域任务视图与目标域任务视图的关系

任务层级	类别视图	主要作用
源域分类预训练	正常、变形、树根、接口异常、壁面损伤、沉积附着	学习 sewer scene 通用表征，支撑 gate 与 CAM
第一阶段预筛	正常/异常二分类	在高召回约束下最大化正常样本过滤率
第二阶段检测	六类结构性缺陷检测	完成最终缺陷定位与类别判定

为避免总体指标掩盖类别差异，图 6.6 对各类别 AP 表现进行细化对比。

图 3.3 源域类别到目标域类别的映射关系图

3.4 第一阶段与第二阶段任务定义

本文将总体任务拆分为两个紧密衔接但职责不同的阶段。第一阶段是 Normal/Abnormal 高召回预筛，其目标不是给出最终缺陷类别，而是在“尽量不过漏异常”的约束下，尽可能过滤明显正常样本，从而降低第二阶段检测器的输入规模与误报传播风险。第二阶段是目标域六类结构性缺陷检测，它负责完成最终类别和位置判定，并输出可直接用于工程复核和维护决策的结果。这样的任务分解既符合 hierarchical classification 在 sewer inspection 中的已有经验^{[16][17]}，也更适合本文后续围绕误报控制、低标注增强与跨域迁移开展系统实验。

此外，图 6.7 进一步对照展示第一阶段 CAM 关注区域与第二阶段 detector 输出框的关系。

图 3.4 第一阶段与第二阶段任务定义示意图

3.5 数据预处理与划分协议

3.5.1 预处理与增强

分类阶段以轻量增强为主，包括尺度变换、随机翻转和颜色扰动，以避免过增强破坏缺陷语义；检测阶段则根据实验需要进一步引入 Mosaic、随机裁剪、几何变换等策略，以增强模型对复杂场景的鲁棒性。对于目标域图像，本文还将结合图像质量、重复帧比例和标注置信度进行筛选，以减轻低质量样本对检测器收敛稳定性的干扰^[14]。

3.5.2 划分协议与运行型验证集

除常规 train/val/test 划分外，本文在第一阶段预筛实验中强调“运行型验证集”的概念，即验证集尽量接近真实巡检流程中正常样本占比较高的分布条件。这样设计的目的在于避免仅在均衡样本上评价 gate 模块，而忽略其在真实运维场景中对误报和复核成本的影响。对于第二阶段检测任务，本文则保持目标域类别定义、训练配置和评价阈值的一致性，以确保不同 baseline、消融实验与迁移实验之间具有严格可比性。

为增强结论章节的收束性，表 7.1 将主要结论、对应章节和关键证据图表进行统一对应。

表 3.4 数据来源与划分协议

数据层级	当前状态	主要用途
源域分类数据	已构建源域单标签六类数据集（7200 张，含 train/val）	source pretrain、gate 扫描、CAM 生成
目标域图像级数据	按六类检测任务持续补充	target cls finetune、候选区域生成
目标域检测框数据	少量人工框与后续 reviewed box	detector baseline、改进模型与迁移实验
运行型验证集	以高 normal 占比组织	gate operating point 与系统级误报分析

为避免正文过度臃肿而又保留充分原始材料，表 2 对后续附录中建议补充的图表内容进行统一规划。

表 3.5 图像尺寸与长宽比分布统计表

数据层级	典型尺寸范围	长宽比分布特点	主要作用
源域分类数据	—	—	支撑 source pretrain 与 gate 实验
目标域图像级数据	—	—	支撑 target cls finetune 与 CAM 生成
目标域检测数据	—	—	支撑 detector baseline 与改进实验

表 3.6 数据质量与清洗规则表

问题类型	判定标准	是否剔除	后续用途
严重模糊/不可辨识	缺陷区域无法人工确认	是	不进入训练与验证
重复或近重复帧	连续多帧信息增量极低	部分剔除	保留少量代表帧构建运行型验证集
低质量但可判读样本	噪声较大但缺陷可辨认	否	用于增强真实场景鲁棒性
标注口径不一致样本	类别边界存在明显争议	暂缓使用	人工复核或进入附录分析
CAM 明显偏移样本	热力图无法覆盖主体区域	否	作为伪框抽检与人工快修重点对象

图 3.5 数据划分与运行型验证集构建流程图

3.6 总体系统框架设计

围绕“公开源域可用、目标域框标注昂贵、正常帧占比高、域差显著”这些现实约束，本文构建了“源域分类预训练 → 前级高召回预筛 → CAM/伪框辅助 → 改进 YOLOv11 检测 → 目标域迁移适应”的总体系统框架。该框架的核心思想是让不同子模块分别承担最擅长的职责：源域分类负责学习通用缺陷表征，前级 gate 负责削减正常样本流量并控制误报传播，CAM/伪框流程负责降低检测标注成本，改进 YOLOv11 负责完成最终高精度缺陷检测，而跨域迁移策略则负责把源域知识稳定转化为目标域性能。这样组织的目的不是“模块堆砌”，而是围绕工程问题把不同研究路径编排成一条可执行的完整技术链。

图 3.6 地下排水管道缺陷检测总体系统框架

3.7 评价协议与实验规范

为保证后续实验具有统一口径，本文将评价协议分为三层：第一阶段预筛层主要采用 Accuracy、Macro-F1、AUPRC、AUROC、Spec@Recall、Prec@Recall、PTR 和 NRR 等指标；第二阶段检测层采用 Precision、Recall、F1、AP50 和

AP50-95 等指标；系统级验证层则关注单图误报率、单视频误报率、门控召回率和整体复核效率。与此同时，本文统一记录实验环境、模型初始化方式、输入尺寸、阈值选择、数据划分和结果导出位置，以保证训练机推送回来的结果可以无歧义地接入论文写作过程。

3.8 本章小结

本章从数据来源、源域单标签分类数据构建、目标域任务定义、两阶段任务划分、数据划分协议和系统总体框架等方面，对本文后续研究所依赖的数据与任务组织方式进行了说明。与单纯介绍“用了什么数据”相比，本章更重要的作用是回答“为什么本文必须用这样的数据组织方式来支撑后续检测与迁移实验”。在此基础上，第 4 章将进一步聚焦前级高召回预筛与弱监督标注增强策略，第 5 章则聚焦改进 YOLOv11 检测方法与跨域迁移策略本体。

第 4 章 前级高召回预筛与弱监督标注增强策略

4.1 前级高召回预筛问题定义

真实巡检场景中，正常图像通常显著多于缺陷图像。如果将全部帧直接输入后级检测器，不仅会带来较高推理开销，也会因背景复杂和正常帧海量存在而放大误报累积。因此，本文将第一阶段任务明确重定义为 Normal/Abnormal 高召回 gate，其目标是在尽量不过漏异常图像的约束下，最大化对正常图像的过滤能力。更具体地说，第一阶段的优化目标可以概括为：在保证门控召回率不低于预设阈值的前提下，尽可能提高正常样本过滤率。这里的预设异常召回率通常取 99.0% 或 99.5%。在这一任务中，第一阶段并不承担最终类别输出责任，而是承担“高召回、低漏放”的门控角色，这一点与最终六类检测任务的目标存在本质差异。

4.2 基于同源图像重标注的二分类 gate 构建

本文第一阶段 gate 并未引入新的图像来源，而是在源域单标签六类分类数据上进行任务重映射：将 Normal 保留为负类，将其余五类合并为 Abnormal 正类。这样的设计具有两方面优势。其一，它保证第一阶段与源域六类分类实验在同一图像来源和同一 split 上比较，从而避免由于数据源变化带来的干扰。其二，它使 gate 任务与后续 CAM 生成、target finetune 和 detector 初始化天然衔接，形成统一的 source-side learning chain。已有 hierarchical classification 研究也表明，在 sewer inspection 中先建立 defect/non-defect 或 normal/abnormal 的高层判别，再进入更细粒度识别，是一种合理且工程上可解释的任务组织方式^{[16][17]}。

4.3 YOLO11-cls 源域分类基线扫描

为确定第一阶段最合适的源域分类容量，本文以 YOLO11-cls 系列的五个尺度模型作为统一候选，即 n、s、m、l 和 x。在相同数据集和相同训练协议下，本文分别开展六类 source 分类基线扫描与二分类 gate 基线扫描。其中，六类 source 分类结果用于回答源域表征能力差异，二分类 gate 结果用于回答第一阶段在高召回约束下的实际过滤能力。由于两种任务的最优容量并不完全一致，第一阶段模型选择以 direct binary gate baseline 与统一 calibration 结果为主，而六类 source 分类结果主要作为 source-side representation 的参照。

表 4.1 YOLO11-cls 六类分类统一重跑结果表

模型	准确率	ROC 面积	PR 面积	结果说明
yolo11n-cls	0.6944	0.9496	0.9882	当前已完成模型中整体最优
yolo11s-cls	0.6889	0.9461	0.9870	当前已完成模型中位于第二梯队
yolo11m-cls	0.6875	0.9373	0.9847	当前已完成模型中表现中等
yolo11l-cls	0.6889	0.9362	0.9839	六类 source 视图下未体现出大模型优势
yolo11x-cls	0.6972	0.9467	0.9866	准确率最高，整体位于第一梯队

从表4.1可以看出，在当前统一超参数重跑结果下，六类 source 视图的容量收益并未呈现简单的单调上升关系。yolo11x-cls 取得当前最高准确率 0.6972，而 yolo11n-cls 在 ROC 面积与 PR 面积上保持最高，说明 source 表征能力并非随容量线性增强，而是受模型容量与数据复杂度共同影响。yolo11s-cls、yolo11m-cls 与 yolo11l-cls 处于相近区间，其中 yolo11l-cls 并未表现出显著的大模型优势。由此可见，六类 source 分类更适合用来回答 source-side representation 的容量差异，而不宜直接据此决定第一阶段 gate 主模型。

表 4.2 YOLO11-cls 六类间接 gate 默认阈值过滤统计表

模型	异常正确 保留	异常 误过滤	正常正确 过滤	正常 未过滤	异常 召回率	正常 过滤率
yolo11n-cls	580	20	90	30	0.9667	0.7500
yolo11s-cls	577	23	95	25	0.9617	0.7917
yolo11m-cls	578	22	84	36	0.9633	0.7000
yolo11l-cls	577	23	89	31	0.9617	0.7417
yolo11x-cls	581	19	91	29	0.9683	0.7583

结合表4.2可以进一步看出，六类间接 gate 视图下的默认阈值 leader 仍为 yolo11s-cls，其正常过滤率达到 0.7917，高于 yolo11x-cls 的 0.7583、yolo11n-cls 的 0.7500、yolo11l-cls 的 0.7417 和 yolo11m-cls 的 0.7000。这说明六类 source 排序与六类间接 gate 排序并不完全一致，进一步表明第一阶段模型选择不能仅凭 source 分类精度拍板，而需要进入 direct binary gate 视角做统一比较。

表 4.3 YOLO11-cls 二分类 gate 基线结果表

模型	准确率	宏平均 F1	ROC 面积	PR 面积	Spec@ R99.5	Spec@ R99.0
yolo11n-cls	0.9208	0.8531	0.9206	0.9813	0.3167	0.4750
yolo11s-cls	0.9347	0.8762	0.9384	0.9854	0.4083	0.4250
yolo11m-cls	0.9292	0.8627	0.9428	0.9873	0.3917	0.4833
yolo11l-cls	0.9333	0.8740	0.9439	0.9867	0.5000	0.6167
yolo11x-cls	0.9292	0.8606	0.9328	0.9830	0.3417	0.4583

从表4.3可以看出，当前五组二分类 gate baseline 已形成完整容量扫描结果，但不同模型容量对应的收益并不一致。yolo11s-cls 在准确率和宏平均 F1 上表现最佳，说明其默认阈值下的总体判别能力最强；yolo11l-cls 则在 ROC 面积、Spec@R99.5 和 Spec@R99.0 上均取得当前最优结果，表明其在极高召回约束下具备更强的正常样本过滤能力。yolo11m-cls 继续在 AUPRC 上保持最高，说明其中高容量模型在阈值可调空间内仍具备较好的 gate 潜力；相比之下，yolo11x-cls 并未延续大模型优势，其关键锚点指标反而回落，说明容量进一步增大并不必然带来第一阶段 gate 收益。上述结果表明，第一阶段最优容量已经基本收敛于 s 与 l 两个尺度：前者更适合作为默认阈值下的高效 gate 基线，后者更适合在高召回约束下追求更强的正常样本过滤能力。

表 4.4 YOLO11-cls 二分类 gate 默认阈值过滤统计表

模型	异常正确保留	异常误过滤	正常正确过滤	正常未过滤	异常召回率	正常过滤率
yolo11n-cls	576	24	87	33	0.9600	0.7250
yolo11s-cls	584	16	89	31	0.9733	0.7417
yolo11m-cls	585	15	84	36	0.9750	0.7000
yolo11l-cls	583	17	89	31	0.9717	0.7417
yolo11x-cls	587	13	82	38	0.9783	0.6833

从表4.4可以进一步看出，直接二分类 gate 在默认阈值下的过滤统计更具可比性。yolo11s-cls 与 yolo11l-cls 均正确过滤了 89 张正常图像，是当前正常过滤数量最高的两组模型；yolo11x-cls 虽保留了最多的异常图像，但正常过滤数量回落至 82 张，未能继续扩大默认阈值下的过滤收益；yolo11x-cls 在异常误过滤数量上最低，仅误过滤 13 张异常图像，说明其大容量模型在异常保留能力上最强，但正常过滤数量的回落也表明异常保留与正常过滤之间仍需权衡。结合高召回锚点结果可知，二分类 gate 的优选模型并非单一容量垄断，而是需要在默认阈值和高召回约束两个视角下综合确定；这也是后续 calibration、HN 回流和损失

函数优化都围绕 yolo11l-cls 与 yolo11s-cls 展开的直接依据。




图 4.1 第一阶段不同模型容量的关键指标对比

4.4 阈值校准与 operating point 选择

第一阶段 gate 的有效性不能只通过默认阈值下的准确率判断，更需要结合高召回约束下的过滤能力进行分析。因此，本文在完成五尺度二分类 gate baseline 后，对 yolo11n-cls、yolo11s-cls、yolo11m-cls、yolo11l-cls 和 yolo11x-cls 全部开展统一 Temperature Scaling 实验，以比较不同容量模型在相同 calibration 协议下的分数可信度与 operating point 稳定性。需要说明的是，calibration 并未改变模型本体结构或训练参数，改变的只是输出分数的刻度；因此，本文后续并不是在“更换模型”后重新比较，而是在统一校准后的分数体系上完成第一阶段模型选型与阈值分析。

具体实现中，本文直接利用现有 raw materials 中逐图验证预测结果给出的 p_{abnormal} 作为输入，而不重新导出模型原始 logit。首先，对逐图概率进行裁剪以避免极端概率导致数值不稳定；随后根据二分类关系将裁剪后的概率反推为 logit，并仅在 val-cal 子集上拟合单标量温度参数 T ，使校准后分数在不改变样本排序的前提下更接近真实后验分布。为避免同一份验证集同时用于拟合和报告结果，全部 720 张验证图像按类别分层拆分为两部分：其中 val-cal 占 30%，用于拟合温度参数；val-op 占 70%，用于重新生成校准后概率，并进一步执行 threshold sweep、计算 ECE 与 Brier Score，最终报告正式 operating point。该流程的重点不在于提升模型本体表达能力，而在于降低输出分数的过度自信程度，使不同模型之间的阈值比较建立在统一、可解释的分数尺度上。

统一 calibration 完成后, yolo11l-cls 在高召回锚点上仍保持最优, 适合作为第一阶段主模型; 在 yolo11s-cls 与 yolo11m-cls 的第二模型比较中, yolo11s-cls 仍保持默认阈值整体最优, 且在统一 val-op 划分下的 Spec@R99.5 高于 yolo11m-cls, 因此后续 stage-1 对照模型选定为 yolo11s-cls, 而 yolo11m-cls 保留为 AUPRC 参考模型。

表 4.5 第一阶段 Temperature Scaling 前后对比表

模型	状态	温度 T	ECE	Brier	Spec@ R99.5	Spec@ R99.0	Prec@ R99.0	PTR@ R99.0
yolo11n-cls	校准前	1.0000	0.0496	0.0716	0.3690	0.4405	0.8987	0.9206
yolo11n-cls	校准后	1.0186	0.0470	0.0717	0.3690	0.4524	0.9004	0.9167
yolo11s-cls	校准前	1.0000	0.0605	0.0624	—	0.4167	0.8949	0.9246
yolo11s-cls	校准后	2.8025	0.0395	0.0611	0.3571	0.4167	0.8949	0.9246
yolo11m-cls	校准前	1.0000	0.0579	0.0670	0.3452	0.4524	0.9004	0.9167
yolo11m-cls	校准后	2.8371	0.0285	0.0622	0.3452	0.4524	0.9004	0.9167
yolo11l-cls	校准前	1.0000	0.0407	0.0581	0.4048	0.4643	0.9026	0.9167
yolo11l-cls	校准后	2.2227	0.0308	0.0581	0.4286	0.4762	0.9043	0.9127
yolo11x-cls	校准前	1.0000	0.0391	0.0664	0.1667	0.3929	0.8908	0.9266
yolo11x-cls	校准后	1.3067	0.0341	0.0657	0.1667	0.3929	0.8908	0.9266




图 4.2 五模型 Calibration 前后 Reliability Diagram 对比




图 4.3 五模型 Calibration 前后 threshold sweep 对比

需要强调的是，本文第一阶段并非直接凭经验选定二分类任务和后续优化模型，而是通过五组六类 source 分类基线与五组 direct binary gate 基线的系统比较，先验证任务重定义的必要性，再在统一评价口径下完成模型选型。由于六类 source 视图与二分类 gate 视图并不共享同一最优容量，第一阶段真正需要优化的对象不是异常内部细分类别判别能力，而是在高召回约束下的 normal 过滤能力。正因如此，后续 calibration、Hard Negative Mining 与损失函数优化才以 yolo11l-cla 为主模型、以 yolo11s-cla 为第二对照模型展开，从而为控制变量消融提供稳定起点。

4.5 Hard Negative Mining 策略

仅依赖均衡的源域训练集，往往仍不足以覆盖真实巡检场景中的 hardest normal 样本，例如受污渍、反光、水膜和局部结构变化影响而呈现异常外观的正常图像。因此，本文将 Hard Negative Mining 作为第一阶段的重要增强策略之一，即在高召回 gate 模型基础上，将置信度高但最终被人工确认或规则确认的误报 normal 样本重新回流到训练集，用于提升 gate 对复杂背景的抑制能力。该策略的目标并不是单纯提高整体准确率，而是在既定召回锚点附近提高 specificity 与 precision，从而为两阶段系统争取更大的误报控制收益。

之所以优先验证 HN 回流，而不是直接继续叠加更复杂的结构改动，主要有三点原因。其一，高置信误报 normal 往往并非随机噪声，而是当前决策边界附近最有信息量的反例；这些样本通常对应反光、水膜、污渍、接缝纹理或局部阴影等稳定伪线索，能够直接暴露 gate 模型在 normal 抑制上的薄弱模式。其二，第

一阶段属于高召回门控任务，真正拖住 Spec@R99.5 与 Spec@R99.0 的并不是大量 easy normal，而是少量“最像 abnormal 的 normal”；将训练注意力从大量易例转移到这些困难负样本，更符合当前阶段的优化目标。其三，统一 calibration 的结果已经表明，分数刻度问题只能带来有限收益，真正限制高召回锚点继续右移的因素，更可能是结构性 hardest normal 模式。因此，HN 回流在当前阶段并不是泛泛增加 normal 样本，而是有针对性地修正最危险的误报来源。

需要说明的是，HN 回流并非天然有效，其成立前提包括：误报样本必须经过确认，确保其为 true normal 而非漏标异常；回流样本必须来自训练侧或额外 normal 池，而不能直接污染用于报告结果的 val-op；同时还需控制回流强度并执行去重，避免同一视频或同一场景中的连续相似帧过度主导训练。基于这些约束，本文将 HN 视为第一阶段最值得优先验证的训练策略假设，而非默认必然有效的经验规则。

基于当前主模型 yolo11l-cls，本文先完成了固定校准协议下的 HN 回流比例扫描。全部实验沿用相同的 val-cal / val-op 划分、相同的 Temperature Scaling 流程以及一致的训练超参数，仅改变回流到训练集的 hardest normal 比例，并在 0%、2%、4%、6%、8%、10%、12%、14%、16%、18% 与 20% 十一组设置下比较 Spec@R99.5、Spec@R99.0、Prec@R99.0 与 PTR@R99.0。表4.6 给出了完整比例扫描结果。可以看出，在当前 sweep 中，hn02 即 2% 回流比例取得了最优的高召回锚点组合：Spec@R99.5 从基线组的 0.4405 提升至 0.5119，Spec@R99.0 由 0.5357 提升至 0.5476，Prec@R99.0 由 0.9143 提升至 0.9165，而 PTR@R99.0 保持不变。这意味着当前 val-op 上，模型在固定 R99.5 约束下多拦截了 6 张 normal 图像，即由 37/84 提升到 43/84，绝对提升 0.0714。

表 4.6 第一阶段 HN 回流比例扫描结果表

组别	回流比例/%	回流样本数	Spec@R99.5	Spec@R99.0	Prec@R99.0	PTR@R99.0
hn00	0	0	0.4405	0.5357	0.9143	0.9028
hn02	2	22	0.5119	0.5476	0.9165	0.9028
hn04	4	43	0.4286	0.4524	0.9004	0.9167
hn06	6	65	0.3929	0.4881	0.9063	0.9107
hn08	8	86	0.3452	0.4881	0.9063	0.9107
hn10	10	108	0.2500	0.5119	0.9103	0.9067
hn12	12	130	0.4167	0.4881	0.9063	0.9107
hn14	14	151	0.3214	0.5476	0.9163	0.9008
hn16	16	173	0.2976	0.4762	0.9043	0.9127
hn18	18	194	0.3571	0.3690	0.8872	0.9325
hn20	20	216	0.2738	0.3690	0.8870	0.9306




图 4.4 第一阶段 HN 回流比例扫描关键指标对比

从图4.4可以进一步看出, Spec@R99.5 对回流比例最为敏感: 当回流比例由 0% 提高到 2% 时, 曲线出现最明显的正向抬升; 而当比例继续扩大后, Spec@R99.5 反而整体回落。这说明当前阶段最值钱的并不是大量回流 hardest normal, 而是以较小比例注入最具信息量的误报 normal, 从而在不显著牺牲通过率的前提下改善高召回区间的过滤能力。进一步结合附录表3 可知, hn02 虽然在 Accuracy、Macro-F1、AUROC 与 AUPRC 上略低于 hn00, 但这种回落并不构成对 HN 路

线的否定。原因在于，第一阶段优化目标并非追求默认阈值下的总体分类分数，而是在固定高召回约束下尽可能提高 normal 过滤能力并维持通过率稳定。换言之，小比例高置信误报 normal 回流不会提升默认阈值下的总体分类分数，但能够显著提升第一阶段 gate 在固定高召回约束下的 normal 过滤能力；在当前 sweep 中，最优回流强度为 2%。因此，后续 stage-1 主线实验虽然只保留 hn00 与 hn02 作为正式对照，但完整的 2% 至 20% 比例扫描仍作为正文与附录中的证据链保留，用于支撑“最优回流强度为 2%”这一结论。

表 4.7 第一阶段主线消融与工程增强实验概览表

组别	模型	校准	HN 回流	损失函 数	后处 理	Spec@ R99.5	Spec@ R99.0	Prec@ R99.0	PTR@ R99.0
G0	yolo11l-cls	否	0%	BCE	P0	0.4048	0.4643	0.9026	0.9167
G1	yolo11l-cls	是	0%	BCE	P0	0.4286	0.4762	0.9043	0.9127
G2	yolo11l-cls	是	2%	BCE	P2	0.5119	0.5476	0.9165	0.9028
G3	yolo11l-cls	是	2%	Selective	P1	0.4881	0.5238	0.9125	0.9067
G4	yolo11l-cls	是	2%	HardMix	P0	0.5238	0.5833	0.9224	0.8948
G5	yolo11l-cls	是	2%	WBCE	P0	0.4881	0.5595	0.9183	0.8988
G6	yolo11l-cls	是	2%	Focal	P2	0.4405	0.5357	0.9143	0.9028
G7	yolo11l-cls	是	2%	DefectOS	P3	0.4048	0.5357	0.9143	0.9028

其中，后处理列表示各训练策略在共享 PTSG 协议下取得最优 operating point 的 gate 变体；HardMix 表示 hard positive + hard normal mining，DefectOS 表示 defect oversampling。

此外，本文还额外设置了第二模型 yolo11s-cls 的跨容量对照实验，用于验证 hn02 回流方案是否只对主模型 yolo11l-cls 有效。表4.8 给出了 yolo11s-cls 在统一校准基线与 hn02 回流后的对照结果。可以看出，Spec@R99.5 由 0.3571 提升至 0.4167，Spec@R99.0 由 0.4167 提升至 0.4881，Prec@R99.0 由 0.8949 提升至 0.9063，同时 PTR@R99.0 由 0.9246 降至 0.9107。该结果说明，hn02 并非只对主模型有效，而是在第二模型容量上同样能够改善高召回工作点附近的过滤能力；但其综合收益仍低于 G2，因此当前第一阶段主线仍保持为“l 作为主模型、s 作为跨容量对照模型”的双模型结构。

表 4.8 第一阶段第二模型跨容量对照实验表

设置	模型	校准	HN 回流	损失函 数	Spec@ R99.5	Spec@ R99.0	Prec@ R99.0	PTR@ R99.0
第二模型 基线	yolo11s- cls	是	0%	BCE	0.3571	0.4167	0.8949	0.9246
第二模型 +HN2%	yolo11s- cls	是	2%	BCE	0.4167	0.4881	0.9063	0.9107

其中，两行结果构成第二模型 yolo11s-cls 的自对照，主要用于补充说明 HN 回流的收益并非只依赖单一模型容量。

图 4.5 Hard Negative Mining 中的典型 hardest normal 样本

4.6 CAM 与 Grad-CAM 伪框生成与质量控制

第一阶段分类模型并不直接输出检测框，但其热力图响应可以作为弱监督定位的中间信号。本文基于源域预训练与目标域微调后的分类模型，生成 CAM 与 Grad-CAM 热力图，并通过阈值分割、连通域筛选与外接矩形拟合得到初始伪框。该流程的作用主要有两点：一是为后续 detector 训练提供低成本初始框；二是帮助识别哪些类别更适合走 CAM 主路线、哪些类别必须尽早切换到人工框支撑。伪框并不被视为最终真值，而是位于“自动生成、抽检评估、轻量快修”的中间层资源^{[39][3]}。

图 4.6 CAM 与 Grad-CAM 典型可视化结果

表 4.9 CAM 伪框抽检与后续处理模板

类别	抽检数量	可直接用	轻改可用	不可用	可用率	建议路线
破裂裂缝	—	—	—	—	—	—
表面损伤	—	—	—	—	—	—
变形	—	—	—	—	—	—
接口错位	—	—	—	—	—	—
侵入	—	—	—	—	—	—
渗漏	—	—	—	—	—	—

4.7 本章小结

本章围绕第一阶段高召回预筛和弱监督标注增强，系统完成了任务定义、容量选型、统一 calibration、HN 回流、PTSG 后处理及训练侧 max-filter 扩展的结构化分析。当前 raw materials 所支持的第一阶段结论已经较为完整：其一，六类 source 统一重跑口径下，yolo11x-cls 在准确率上最高，yolo11n-cls 在 AUROC 与 AUPRC 上更优；其二，二分类 gate 视图下，yolo11s-cls 是默认阈值 leader，yolo11l-cls 是高召回锚点 leader，yolo11m-cls 则保留为 AUPRC 参考模型；其三，统一 Temperature Scaling 完成后，后续 stage-1 训练的主模型确定为 yolo11l-cls，第二对照模型确定为 yolo11s-cls；其四，hn02 被证明是当前最优 HN 回流强度，‘P2’说明概率与 trust 融合的选择性门控具有阶段性收益，但多原型 trust 与强 embedding 并未继续带来稳定增益；其五，在训练侧 max-filter 套件中，最有效的剩余增益来自 HardMix，使第一阶段最终候选收敛为“yolo11l-cls + calibration + hn02 + HardMix”，其最优 gate 决策也回归到 $P0 = \text{calibrated } p_{\text{abnormal}}$ 。由此可见，第一阶段证据链已经基本闭合，后续研究重点应转入第 5 章的 detector 三大件优化与跨域迁移策略，而不再继续扩张 stage-1 的复杂度。

第 5 章 基于改进 YOLOv11 的管道缺陷检测与跨域迁移策略

5.1 基线检测模型与问题分析

本文以 YOLOv11 作为地下排水管道缺陷检测的 baseline。一方面，YOLO 路线具有较高的实时性与较成熟的工程实现，便于与实际巡检系统衔接；另一方面，YOLOv11 在通用检测任务中的性能平衡较好，适合作为本文开展场景化改进的基础模型。然而，直接将原始 YOLOv11 detector 用于排水管道缺陷检测时，仍会遭遇小目标漏检、细长缺陷边界表达不足、复杂背景误报偏高以及类间混淆明显等问题。因此，本文不把模型改进理解为简单替换某个模块，而是围绕“特征表达、预测组织和训练目标”三条主线展开协同优化^{[9][47][45]}。

5.2 注意力机制改进

5.2.1 改进动机

针对 sewer defect detection 中小目标弱纹理、边界模糊和背景干扰强的特点，本文在 YOLOv11 baseline 中引入注意力机制，以增强对关键区域和关键通道的聚焦能力。注意力机制的作用不仅在于提高总体精度，更重要的是帮助模型在反光、水膜、污渍和管壁纹理干扰下，稳定提取与缺陷结构真正相关的判别信息。

5.2.2 模块设计与嵌入方式

本文后续仅选择一个主注意力模块作为正式方案，其余候选模块作为消融对比或附录补充。设计原则是：优先选择参数开销可控、对多尺度特征融合有直接增益、且在复杂背景场景下能稳定提升 recall/precision 平衡的模块。注意力模块的插入位置主要考虑 backbone 后部和 neck 融合层，以兼顾高层语义与中低层细节信息。

图 5.1 注意力模块插入位置示意图

5.3 检测头改进

5.3.1 原始检测头局限性

在排水管道缺陷场景中，原始检测头在处理细粒度结构异常、低对比目标以及多尺度小目标时，存在边界表达能力不足和类别判别不稳定的问题。尤其对于破裂裂缝、接口错位和渗漏等类别，局部显著区域小而背景干扰强，容易导致分类支路与定位支路同时受噪声影响。

5.3.2 改进思路

检测头改进的核心思路是在保持整体推理效率可控的前提下，增强对多尺度结构异常的表达能力，并改善分类与定位分支对困难样本的响应组织方式。具体实现将在后续实验定型后给出，包括预测层组织方式、特征融合路径、额外监督分支或结构轻量化约束等内容。已有 sewer defect detection 文献表明，head-side 改造对于兼顾局部纹理破坏和整体结构异常往往是必要的^{[9][10][11]}。

图 5.2 检测头改进示意图

5.4 损失函数改进

5.4.1 优化目标

考虑到目标域检测样本存在类别不均衡、易混类别边界模糊以及 hardest positive/hardest negative 区分不足等问题，本文进一步对损失函数进行场景化设计。其优化目标是同时改善召回与误报控制，使模型在复杂背景下更稳定地区分正常纹理与真实缺陷响应。

5.4.2 形式化表达

本文在基线损失框架上保留定位项、分类项和分布聚焦项，并根据实验结果引入针对难样本或类别不均衡的补充项。换言之，最终总损失由边界框回归项、分类项、分布聚焦项以及可选的辅助项共同组成。其中，辅助项主要用于难样本补偿或类别重加权。最终采用哪一种组合方式，将以实验效果与复杂度控制结果为依据确定。

图 5.3 改进损失函数组成与优化信号流图

5.5 改进 YOLOv11 总体结构

结合注意力机制、检测头改进和损失函数优化，本文构建用于地下排水管道缺陷检测的改进 YOLOv11 模型。该模型的设计目标不是单一维度地追求最高精度，而是在复杂背景、小目标、低对比度缺陷和工程部署可行性之间取得更合理的平衡。整体结构将在后续实验中通过模块消融表和复杂度对比表进行验证。

图 5.4 改进 YOLOv11 总体结构

表 5.1 改进模块设计说明表

模块	设计目的
注意力机制	强化关键区域与关键通道响应，抑制复杂背景干扰
检测头改进	提升多尺度与细粒度缺陷的分类与定位组织能力
损失函数改进	缓解类别不均衡与难样本学习不足问题，优化 recall/precision 折中

表 5.2 模块插入位置与复杂度变化表

模块	插入层位置	Params 变化	FLOPs 变化	设计目的
注意力模块	—	—	—	增强关键区域与关键通道响应
改进检测头	—	—	—	提升多尺度与细粒度目标表达能力
损失函数优化	训练目标层	无显式参数变化	无显式 FLOPs 变化	改善长尾类别与难样本学习

5.6 跨域迁移适应训练策略

5.6.1 跨域问题分析

公开 Sewer-ML 数据与本地巡检数据在设备、视角、照明条件、管材纹理和标签口径等方面存在明显差异。若仅依赖目标域有限框标注从零训练 detector，模型往往难以获得足够稳定的初始化，且更容易出现过拟合与类间边界漂移。已有 transfer learning 研究已经表明，在 sewer defect detection 中，领域相关的预训练能够有效改善模型初始性能和收敛稳定性^[8]。

5.6.2 迁移路径设计

本文采用“源域分类预训练 → 目标域分类微调 / gate 迁移 → 目标域检测微调”的渐进式迁移路径。首先，在源域六类分类数据上学习 sewer-specific 通用表征；其次，在目标域图像级标签上进行分类微调，使特征分布更贴近本地巡检场景；最后，将上述表征迁移到 detector 训练中，并与少量人工框或伪框增强策略结合。这一路径的优点在于无需引入额外复杂的域对齐损失，却能够以较低的实现成本充分利用同领域源数据。

图 5.5 跨域迁移训练流程图

5.7 训练流程与实现细节

在训练流程上，本文遵循“先前级、后后级；先源域、后目标域；先分类、后检测”的组织原则。具体而言，先完成 source cls 六类预训练与 gate 扫描，再进行 target cls 微调与 CAM 伪框生成，最后进入 detector baseline、改进模型与迁移对比实验。对于不同训练阶段，输入尺寸、batch size、冻结策略、学习率和阈值选择均记录为可复现实验配置，以便后续将训练机推回来的结果直接映射到论文表格中。

表 5.3 迁移策略设置表

方案编号	训练策略说明
T0	目标域随机初始化，从零开始训练检测器
T1	使用官方 YOLOv11 通用预训练权重直接在目标域检测任务上微调
T2	使用源域分类预训练权重初始化，再迁移至目标域检测任务
T3	源域分类预训练 + 目标域分类微调 + 目标域检测微调
T4	—

表 5.4 训练阶段组织与冻结/解冻策略表

阶段	初始化方式	冻结层设置	学习率	训练轮数	输出结果
Source cls	官方分类权重	不冻结或轻冻结	—	—	source 预训练权重
Target cls / gate	source cls 迁移	视实验设定部分冻结	—	—	target 分类权重与 gate 模型
CAM / 伪框生成	target cls 权重	不涉及	—	—	热力图与伪框候选
Detector baseline	官方或迁移权重	—	—	—	baseline 检测模型
Improved detector	最优初始化方案	—	—	—	改进检测模型与迁移结果

5.8 本章小结

本章给出了本文的核心方法设计：一方面，通过注意力机制、检测头和损失函数三个层面的协同优化，构建改进 YOLOv11 检测模型；另一方面，通过源域分类预训练、目标域分类微调与检测微调组成跨域迁移适应训练策略。与第 4 章作为支撑链不同，本章构成本文真正的两项核心创新内容，后续第 6 章将围绕这两项创新展开系统实验验证。

第 6 章 实验结果与分析

6.1 实验设置

6.1.1 实验平台与训练配置

本文实验在单卡 GPU 工作站上完成，硬件平台采用 NVIDIA GeForce RTX 3090（24GB 显存）。软件环境以 Python 3.11.15 为基础，深度学习框架采用 PyTorch、TorchVision、CUDA 和 Ultralytics。在当前已完成的第一阶段实验中，六类 source 分类任务以 sewerml_cls6_train7200 为输入，二分类 gate 任务则基于同源图像重标注后的 sewerml_gate2_train7200 数据集开展。上一轮二分类 gate 五尺度 baseline 采用统一训练协议，即输入尺寸 640、训练轮数 200、batch size 32、数据加载线程数 4、早停 patience 20，并保持 optimizer=auto、cache=false 和 resume=false 不变。为消除早期六类 source baseline 中批大小等配置差异对容量排序的影响，本文随后补充了统一重跑方案：仍以 sewerml_cls6_train7200 为输入，对 YOLO11n/s/m/l/x-cls 统一采用输入尺寸 640、训练轮数 100、batch size 32、数据加载线程数 4、早停 patience 20 的设置，并保持其余优化器与数据增强参数一致。当前稿中六类 source 排名的正式口径已统一为该批 uniform rerun raw materials：其中 yolo11x-cls 为 accuracy leader，yolo11n-cls 为 AUROC/AUPRC leader；旧版 ‘yolo11l-cls’ 六类 source 结论仅保留为历史 raw materials 留档，不再作为当前正文 leader 表述。

表 6.1 实验参数设置表

项目	配置
硬件平台	NVIDIA GeForce RTX 3090, 24GB 显存
软件环境	Python 3.11.15, CUDA 12.8, PyTorch 2.11.0+cu128, Ultralytics 8.3.0
六类 source 数据集	sewerml_cls6_train7200
二分类 gate 数据集	sewerml_gate2_train7200
第一阶段模型范围	YOLO11n/s/m/l/x-cls
二分类 gate 统一训练设置	输入尺寸 640×640, 训练轮数 200, 批大小 32, 数据加载线程数 4, 早停轮数 20
Calibration 设置	五组 direct binary gate 模型统一开展 Temperature Scaling; 验证集按 30% / 70% 分层拆分为 val-cal 与 val-op, 随机种子为 20260330; 采用基于逐图 p_abnormal 反推 logit 的 Temperature Scaling
六类统一重跑设置	输入尺寸 640×640, 训练轮数 100, 批大小 32, 数据加载线程数 4, 早停轮数 20
第一阶段主要评价指标	Accuracy、Macro-F1、AUROC、AUPRC、Spec@R99.5、Spec@R99.0、Prec@R99.0、PTR@R99.0

6.2 第一阶段六类分类与二分类 gate 基线结果分析

本节围绕第一阶段 source 分类 baseline、direct binary gate baseline 以及统一 calibration 结果展开分析。六类 source 分类结果用于回答不同容量模型的 source-side representation 差异；二分类 gate baseline 用于回答默认阈值 leader 与高召回锚点 leader；统一 Temperature Scaling 结果则用于进一步确定第一阶段主模型与第二对照模型。全文第一阶段的所有结论均以 raw materials 中的原始导出文件为唯一依据，不再沿用任何与数值冲突的旧表述。

本节第一阶段六类 source 基线、二分类 gate 基线及其统一 calibration 结果，均已在第 4 章集中给出。为避免重复列示同一批 baseline 表格，第 6 章不再重复粘贴六类容量扫描表、二分类 gate 基线表和 calibration 主表，而是在统一口径下直接收束第一阶段模型选择与后续实验优先级。结合第 4 章表4.1、表4.3 与图4.1 可知：六类 source 视图下，yolo11x-cls 的准确率最高，yolo11n-cls 在 ROC 面积和 PR 面积上保持领先；二分类 gate 视图下，yolo11s-cls 仍是默认阈值 leader，而 yolo11l-cls 仍是高召回锚点 leader。由此可见，第一阶段 baseline 的

核心结论并未因统一重跑而发生方向性改变，即 source 容量排序与 direct binary gate 排序不一致，后续优化仍应围绕二分类 gate 主线展开。

6.3 第一阶段 calibration 结果分析

第 4 章已经给出了统一 Temperature Scaling 的协议、完整对比表以及五模型 calibration 前后的可视化结果，因此本节不再重复展开方法描述，而只从模型选型与后续 stage-1 训练准备的角度收束第一阶段 calibration 的实验结论。需要强调的是，本文后续用于第一阶段比较和阈值选择的依据，不再是未经处理的 raw score，而是基于统一 val-cal / val-op 划分得到的校准后分数体系。

这里还需说明一个口径边界：表4.5 中的 ‘yolo11l-cls + calibration + 0% HN’ 仅用于五模型 calibration 选型；而后续 HN 比例扫描、PTSG 与 max-filter 套件中出现的 ‘hn00’，则来自更晚一轮主线重算批次，用于充当 HN/PTSG/max-filter 链路内部的统一基线。两者都属于 ‘0% HN’ 风格 baseline，但服务于不同实验链路，因此本文只在各自链路内部做相对比较，不做跨表绝对值逐项比较。

从表4.5可以看出，五组模型拟合得到的温度参数均大于 1，说明 baseline 预测分数整体存在一定程度的过度自信倾向。校准后的 ECE 全部下降，其中 yolo11m-cls 从 0.0579 降至 0.0285，降幅最大；yolo11s-cls 从 0.0605 降至 0.0395；yolo11l-cls 从 0.0407 降至 0.0308；yolo11n-cls 与 yolo11x-cls 也出现了小幅改善。这说明 Temperature Scaling 对第一阶段的首要收益在于提升分数可信度与阈值稳定性，而不是简单改变模型排序。

进一步比较高召回锚点下的 operating point 可以发现，不同模型的 calibration 收益并不一致。yolo11l-cls 是唯一在两组高召回锚点上都出现明确正向增益的模型：其 Spec@R99.5 由 0.4048 提升到 0.4286，Spec@R99.0 由 0.4643 提升到 0.4762，Prec@R99.0 也由 0.9026 提升到 0.9043，说明分数经校准后形成了更稳健的筛选边界。yolo11m-cls 虽然在 ECE 与 Brier Score 上改善明显，但高召回锚点指标基本不变；yolo11s-cls 则在统一 val-op 口径下补齐了 Spec@R99.5，其值为 0.3571，高于 yolo11m-cls 的 0.3452，但仍落后于 yolo11l-cls。若按“先比较 Spec@R99.5，再比较 Spec@R99.0，最后比较 Prec@R99.0”的规则排序，统一 calibration 后的高召回锚点顺序为 yolo11l-cls、yolo11n-cls、yolo11s-cls、yolo11m-cls、yolo11x-cls。结合 baseline 中 yolo11s-cls 的默认阈值 leader 地位，本文最终将 yolo11l-cls 确定为第一阶段主模型，将 yolo11s-cls 确定为第二对照模型，并将 yolo11m-cls 保留为 AUPRC 参考模型。由此可见，Temperature Scaling 作为低成本后处理策略，已经足以帮助后续 Hard Negative Mining 的模型选择收敛为 l 与 s 两条主线。

在完成 calibration 验证后，第一阶段已经进一步完成了主模型 yolo11l-cls

的 HN 回流比例扫描。结果表明，hn02 即 2% 回流比例取得了当前最优的高召回锚点组合：Spec@R99.5 提升至 0.5119，Spec@R99.0 提升至 0.5476，Prec@R99.0 提升至 0.9165，而 PTR@R99.0 维持在 0.9028。相比之下，更高比例的 HN 回流并未继续带来稳定收益，说明 hardest normal 回流强度需要受到控制，不能简单按比例堆高。需要说明的是，hn02 相较基线组在 Accuracy、Macro-F1、AUROC 与 AUPRC 上均有小幅回落，但这一现象与第一阶段目标并不矛盾：stage-1 gate 更关心的是在固定高召回约束下提升 normal 过滤能力，而不是追求默认阈值下的总体分类得分。因此，只要 Spec@R99.5、Spec@R99.0 与 Prec@R99.0 同步改善且 PTR@R99.0 未恶化，就可以认为 HN 回流对当前门控任务是有效的。进一步地，在第二模型 yolo11s-cls 上，统一校准基线与 hn02 回流后的对照结果也表现出一致的正向变化：其 Spec@R99.5 由 0.3571 提升至 0.4167，Spec@R99.0 由 0.4167 提升至 0.4881，Prec@R99.0 由 0.8949 提升至 0.9063，PTR@R99.0 由 0.9246 降至 0.9107。这表明 hn02 的收益并非只依赖单一模型容量，而是具有一定跨容量稳定性；但与主模型 G2 相比，第二模型在高召回锚点上的综合收益仍然偏低，因此 stage-1 的正式主线结论仍收敛于 yolo11l-cls + hn02。为保证后续结果能直接回填，表6.2 固定了第一阶段主线消融与工程增强的结果字段。当前已写入统一 val-op 口径下的 G0、G1、HN 最优组 G2 以及 max-filter 套件扩展出的 G3–G7；第二模型自对照则单独列在表6.3 中作为补充验证，不再复用主线‘G’编号。

表 6.2 第一阶段主线消融与工程增强实验概览表

组别	模型	校准	HN 回流	损失函 数	后处 理	Spec@ R99.5	Spec@ R99.0	Prec@ R99.0	PTR@ R99.0
G0	yolo11l-cls	否	0%	BCE	P0	0.4048	0.4643	0.9026	0.9167
G1	yolo11l-cls	是	0%	BCE	P0	0.4286	0.4762	0.9043	0.9127
G2	yolo11l-cls	是	2%	BCE	P2	0.5119	0.5476	0.9165	0.9028
G3	yolo11l-cls	是	2%	Selective	P1	0.4881	0.5238	0.9125	0.9067
G4	yolo11l-cls	是	2%	HardMix	P0	0.5238	0.5833	0.9224	0.8948
G5	yolo11l-cls	是	2%	WBCE	P0	0.4881	0.5595	0.9183	0.8988
G6	yolo11l-cls	是	2%	Focal	P2	0.4405	0.5357	0.9143	0.9028
G7	yolo11l-cls	是	2%	DefectOS	P3	0.4048	0.5357	0.9143	0.9028

其中，后处理列表示各训练策略在共享 PTSG 协议下取得最优 operating point 的 gate 变体；HardMix 表示 hard positive + hard normal mining，DefectOS 表示 defect oversampling。

表 6.3 第一阶段第二模型跨容量对照结果表

对照项	模型	校准	HN 回流	损失函 数	Spec@ R99.5	Spec@ R99.0	Prec@ R99.0	PTR@ R99.0
第二模型 基线	yolo11s-cls	是	0%	BCE	0.3571	0.4167	0.8949	0.9246
第二模型 +HN2%	yolo11s-cls	是	2%	BCE	0.4167	0.4881	0.9063	0.9107

其中，两行结果构成第二模型 yolo11s-cls 的自对照组，用于补充证明 HN 回流在非主模型容量下同样具有一定稳定收益；为避免与主线消融组混淆，此处不再复用 ‘G’ 编号。

在完成 HN、PTSG、多原型 next-wave 与强 embedding 路线后，本文又进一步组织了统一的 max-filter 套件，用于测试第一阶段在现有协议下是否仍有剩余 headroom。该套件统一比较了 Selective / recall-constrained loss、HardMix、Weighted BCE、Focal BCE 以及 defect oversampling 五条训练侧增强路线，并在每条路线内部继续执行共享 PTSG 协议下的 ‘P0 P4’ 后处理评估。结果显

示，HardMix 是本轮综合最优的新实验：其在最严格的 ‘Spec@R99.5’ 上与旧主线最优 ‘H0’ 持平，均为 0.5238，但在次级排序指标上继续取得正向增益，即 ‘Spec@R99.0’ 由 0.5595 提升至 0.5833，‘Prec@R99.0’ 由 0.9183 提升至 0.9224，同时 ‘PTR@R99.0’ 由 0.8988 下降至 0.8948。若从计数角度观察，在 ‘R99.0’ 下其 ‘TN/FN’ 由 ‘47/4’ 提升为 ‘49/4’，说明在保持漏检不恶化的前提下，又额外拦截了 2 张 normal。相比之下，Selective loss 虽然进一步降低了 ‘FN’，但牺牲了 ‘Specificity’；WBCE 未形成新的综合优势；Focal BCE 与 defect oversampling 的整体收益更弱。更重要的是，这轮结果还表明最佳后处理不再固定为 ‘P2’：在 HardMix 与 WBCE 路线上，最优 gate 已退回到 ‘P0 = calibrated p_abnormal’。这说明 trust 并非在所有训练分布下都固定占优，而第一阶段当前更值钱的剩余增益，主要来自对 hardest positive 与 hardest normal 的更充分暴露。




图 6.1 第一阶段 max-filter 套件各实验最佳 operating point 指标对比图

图6.1 中每个方法族的柱值均取自其在共享 PTSG 协议下的最佳后处理变体，而非固定使用同一个 ‘P’ 编号。因此，该图反映的是“训练策略 + 最优 gate 决策”的综合表现，而不是单一后处理配置的平面比较。

6.4 第二阶段检测 baseline 对比实验

第二阶段检测 baseline 主要用于回答“原始 detector 在当前目标域任务中的起点水平如何”。本文计划选取原始 YOLOv11 baseline、2–3 个强 baseline 以及后续改进模型进行对比，重点关注 Precision、Recall、F1、AP50、AP50-95 和

FP/image 等指标。该部分实验将构成后续创新点一消融和创新点二迁移实验的统一比较底盘。自本节开始，后续表格默认均属于第二阶段目标检测或系统级实验，不能使用第一阶段分类/gate 指标直接替代填写。

表 6.4 第二阶段 baseline 对比表

模型	参数	计算量	精确率	召回率	F1 值	AP50	误报/图
YOLOv11 Baseline	—	—	—	—	—	—	—
一阶段候选基线 A	—	—	—	—	—	—	—
一阶段候选基线 B	—	—	—	—	—	—	—
其他范式候选基线	—	—	—	—	—	—	—

图 6.2 第二阶段 baseline 对比柱状图

6.5 创新点一消融实验

创新点对应的是改进 YOLOv11 检测方法，因此消融实验必须围绕注意力机制、检测头和损失函数三部分展开，回答每个模块是否真正产生增益，以及三者协同后是否形成可解释的性能提升。该表是本文答辩时最关键的实验表之一，因此字段在当前阶段先完全固定。特别说明：表6.5 中的 B0 表示第二阶段未引入任何改进模块的原始 YOLOv11 detector baseline，而不是第一阶段的分类或 gate 基线。

表 6.5 创新点一消融表

组别	注意力	检测头	损失	参数	计算量	精确率	召回率	AP50
B0	否	否	否	—	—	—	—	—
B1	是	否	否	—	—	—	—	—
B2	否	是	否	—	—	—	—	—
B3	否	否	是	—	—	—	—	—
B4	是	是	否	—	—	—	—	—
B5	是	否	是	—	—	—	—	—
B6	否	是	是	—	—	—	—	—
B7	是	是	是	—	—	—	—	—

图 6.3 创新点一消融收益图

6.6 创新点二迁移学习对比实验

创新点二对应“源域预训练到目标域微调”的跨域迁移适应策略。该部分实验重点回答：仅使用官方通用预训练权重是否足够；加入同领域 source cls pretrain 后能否提升 detector 初始化质量；进一步加入 target cls finetune 是否还能带来额外收益。该实验将直接决定本文第二个创新点能否成立。需要说明的是，本节虽会调用第一阶段 source cls 结果作为初始化来源，但表6.6 的评价对象仍然是第二阶段 detector 的最终检测性能。

表 6.6 创新点二迁移对比表

组别	初始化	源域 预训练	目标域 微调	精确率	召回率	AP50	误报/图
T0	从零训练	否	否	—	—	—	—
T1	官方预训	否	否	—	—	—	—
T2	源域预训	是	否	—	—	—	—
T3	源域预训 + 目标域微调	是	是	—	—	—	—
T4	最优迁移 方案	是	是	—	—	—	—

图 6.4 创新点二迁移收益图

6.7 系统级对比实验

仅比较 detector 精度并不足以反映本文路线的真实价值，系统级实验还需要回答“两阶段系统是否比单阶段直接检测更适合排水管道 CCTV 场景”。因此，本文将比较单阶段直接检测、两阶段 baseline、两阶段 + 改进 detector、两阶段 + 改进 detector + transfer 等系统版本，重点从 Gate Recall、NRR、PTR、Precision、Recall 和 FP/image 等角度评价整体方案。该部分表格同时涉及第一阶段与第二阶段输出，但评价对象已经从单一模块扩展为整体系统。

表 6.7 两阶段系统对比表

系统	阶段一	阶段二	门控 召回	NRR	PTR	精确率	召回率	误报/图
S0	无	单阶段 直接检测	—	—	—	—	—	—
S1	基线 gate	基线 检测器	—	—	—	—	—	—
S2	改进 gate	基线 检测器	—	—	—	—	—	—
S3	改进 gate	改进 检测器	—	—	—	—	—	—
S4	改进 gate	迁移增强 检测器	—	—	—	—	—	—

图 6.5 两阶段系统对比图

6.8 可视化与错误分析

为了更直观地说明模型在真实巡检场景中的表现，本文将在本节通过典型检测结果、误检样例、漏检样例、hardest normal 样例以及 CAM/Detector 可视化结果，对模型行为进行系统分析。重点关注三类现象：一是哪些类别或哪些背景纹理最容易引发误报；二是哪些缺陷在不同训练策略下最容易漏检；三是迁移学习和两阶段系统是否改变了这些错误的分布结构。

表 6.8 各类别检测结果表

类别	精确率	召回率	F1	AP50	AP50-95	主要错误类型
破裂裂缝	—	—	—	—	—	—
表面损伤	—	—	—	—	—	—
变形	—	—	—	—	—	—
接口错位	—	—	—	—	—	—
侵入	—	—	—	—	—	—
渗漏	—	—	—	—	—	—

图 6.6 各类别 AP 柱状图

图 6.7 CAM 与 detector 对照可视化图

图 6.8 第二阶段检测可视化结果

图 6.9 典型误检与漏检案例

6.9 本章小结

本章重新组织了全文实验矩阵：先系统收束第一阶段 gate 的容量选择、calibration、HN 回流、PTSG 与 max-filter 套件，再比较第二阶段 baseline、创新点一消融、创新点二迁移以及系统级路线。就当前已完成的第一阶段结果而言，证据链已经基本闭合：统一 calibration 完成了主模型与第二模型的选型，‘hn02’证明 hardest normal 回流有效，‘P2’证明 prototype trust 对 safe-normal gate 具有阶段性价值，而多原型 trust 与强 embedding 没有继续形成稳定增益；随后 max-filter 套件进一步表明，最有效的剩余 headroom 来自 HardMix，而在该训练分布下最优 gate 也回归到 ‘P0 = calibrated p_abnormal’。因此，当前第一阶段的最终候选可以正式收敛为 “yolo11l-cls + calibration + hn02 + HardMix”，后续不再继续扩张 stage-1 的复杂度，而将研究主线转入 detector、迁移与系统级验证。

第 7 章 结论与展望

7.1 研究结论

本文围绕地下排水管道 CCTV 图像缺陷检测中的小目标难识别、背景干扰强、正常样本占比高、目标域标注不足以及跨域泛化能力不足等问题展开研究，构建了面向地下排水管道智能巡检的检测方法与实验体系。论文的主要工作包括源域单标签分类数据集构建、目标域缺陷类别体系设计、高召回预筛与后级精检总体框架构建、改进 YOLOv11 检测模型设计以及源域预训练与目标域微调相结合的跨域迁移训练策略设计。

从当前已完成的实验链来看，第一阶段高召回 gate 的方法边界已经较为清晰：其核心作用并不是追求默认阈值下的总体分类分数，而是在固定高召回约束下尽可能拦截 normal。围绕这一目标，本文已经依次完成了统一 calibration、HN 回流、PTSG、多原型 next-wave、强 embedding 以及 max-filter 套件验证，最终使第一阶段收敛到“yolo11l-cls + calibration + hn02 + HardMix”，并以‘ $P_0 = \text{calibrated } p_{\text{abnormal}}$ ’作为最终 gate 决策。后续真正的研究增量，应集中于改进 YOLOv11 detector、跨域迁移策略以及系统级两阶段验证，而不再继续扩张 stage-1 的复杂度。

表 7.1 本文主要结论与证据对应表

主要结论	对应章节	关键证据图表	工程意义
第一阶段高召回 gate 已在高召回约束下稳定降低正常样本流量，并收敛至 hn02 + HardMix + P0 的最终候选	第 4 章、第 6 章	第 4 章任务设计说明、表6.2、表6.3及图6.1	降低复核压力，减少后续计算负担
改进 YOLOv11 能提升复杂背景与小目标场景下的检测表现	第 5 章、第 6 章	表 5.1、图 5.1–图 5.3、表 6.4、表 6.5	提升目标域检测精度与稳定性
源域预训练与目标域微调的迁移策略能缓解目标域样本不足问题	第 5 章、第 6 章	图 5.4、表 5.2、表 6.6	降低对大量框标注的依赖
两阶段系统整体优于单阶段直接检测的工程运行方式	第 3 章、第 6 章	图 3.2、表 6.7、图 6.9	提升系统可部署性与误报控制能力

7.2 不足之处

尽管本文构建了较为完整的研究链条，但仍存在一些不足。首先，目标域高质量检测框标注规模仍然有限，模型最终性能仍受目标域数据规模约束。其次，部分复杂缺陷类别在图像表现上存在较强相似性，容易引发误检和类别混淆。再次，本文采用的跨域迁移方法以源域预训练和目标域微调为主，尚未引入更复杂的域对齐机制。最后，本文更多侧重于图像级与目标检测级实验，尚未充分利用长视频的时序信息。

7.3 展望

未来可从以下几个方向进一步开展研究：

1. 继续扩充目标域高质量检测数据，完善类别分布与场景覆盖范围；
2. 探索更加稳健的跨域泛化方法，如特征对齐、半监督学习或自训练策略；
3. 结合视频时序信息，研究基于连续帧上下文的缺陷识别与误报抑制方法；
4. 面向实际巡检系统，进一步开展模型压缩、部署优化和在线辅助判读研究。

参考文献

- [1] Ma D, Fang H, Wang N, et al. The state-of-the-art in pipe defect inspection with computer vision-based methods[J]. Measurement, 2026, 257: 118431.
- [2] Oğurlu M, Bayram B, Kulavuz B, et al. Deep Learning for Automated Sewer Defect Detection: Benchmarking YOLO and RT-DETR on the Istanbul Dataset[J]. Applied Sciences, 2025, 15(20): 11096.
- [3] Yin J, Yin X, Pan M, et al. Scalable and transparent automated sewer defect detection using weakly supervised object localization[J]. Automation in Construction, 2025, 174: 106152.
- [4] Goharinezhad S, Hadi A, Mirzaei S, et al. Automated defect classification and localization in sewer pipelines using hybrid ResNet50–Swin transformer and modified YOLOv8 on CCTV inspection images[J]. Scientific Reports, 2025, 15(1).
- [5] Yang C, Zheng F, Kapelan Z, et al. Automated quantification of sewage pipe cracks using deep learning for urban water environment management[J]. Tunneling and Underground Space Technology, 2025, 155: 106195.
- [6] Haurum J B, Moeslund T B. Sewer-ML: A Multi-Label Sewer Defect Classification Dataset and Benchmark[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 13451-13462.
- [7] Sun L, Zhu J, Tan J, et al. Deep learning-assisted automated sewage pipe defect detection for urban water environment management[J]. Science of the Total Environment, 2023, 882: 163562.
- [8] Situ Z, Teng S, Feng W, et al. A transfer learning-based YOLO network for sewer defect detection in comparison to classic object detection methods[J]. Developments in the Built Environment, 2023, 15: 100191.

- [9] Wang T, Li Y, Zhai Y, et al. A Sewer Pipeline Defect Detection Method Based on Improved YOLOv5[J]. Processes, 2023, 11(8): 2508.
- [10] Zhao X, Xiao N, Cai Z, et al. YOLOv5-Sewer: Lightweight Sewer Defect Detection Model[J]. Applied Sciences, 2024, 14(5): 1869.
- [11] Li D, Xie Q, Yu Z, et al. Sewer pipe defect detection via deep learning with local and global feature fusion[J]. Automation in Construction, 2021, 129: 103823.
- [12] Zhang J, Liu X, Zhang X, et al. Automatic Detection Method of Sewer Pipe Defects Using Deep Learning Techniques[J]. Applied Sciences, 2023, 13(7): 4589.
- [13] Dang L M, Kyeong S J, Li Y, et al. Deep learning-based sewer defect classification for highly imbalanced dataset[J]. Computers & Industrial Engineering, 2021, 161: 107630.
- [14] Jang S, Kim D. Impact of Data Quality on CNN-Based Sewer Defect Detection[J]. Water, 2025, 17(13): 2028.
- [15] Cheng J C P, Wang M. Automated detection of sewer pipe defects in CCTV images using deep learning techniques[J]. Automation in Construction, 2018, 95: 155-171.
- [16] Li D, Cong A, Guo S, et al. Sewer damage detection from imbalanced CCTV inspection data using deep convolutional neural networks with hierarchical classification[J]. Automation in Construction, 2019, 101: 199-208.
- [17] Meijer D, Scholten L, Clemens F, et al. A defect classification methodology for sewer image sets with convolutional neural networks[J]. Automation in Construction, 2019, 104: 281-298.
- [18] He J, Wang Z, Yong Z, et al. An automatic defect detection and localization method using imaging geometric features for sewer pipes[J]. Measurement, 2025, 243: 116367.

- [19] Taormina R, van der Werf J A, et al. Interpretable Sewer Defect Detection with Large Multimodal Models[C]//The 3rd International Joint Conference on Water Distribution Systems Analysis & Computing and Control for the Water Industry (WDSA/CCWI 2024). 2024: 158.
- [20] Yang Y, Yang S, Zhao Q, et al. Weakly supervised collaborative localization learning method for sewer pipe defect detection[J]. Machine Vision and Applications, 2024, 35(5).
- [21] Oh C, Dang L M, Han D, et al. Robust Sewer Defect Detection With Text Analysis Based on Deep Learning[J]. IEEE Access, 2022, 10: 46224-46237.
- [22] Wang M, Kumar S S, Cheng J C P, et al. Automated sewer pipe defect tracking in CCTV videos based on defect detection and metric learning[J]. Automation in Construction, 2021, 121: 103438.
- [23] Yin X, Ma T, Bouferguene A, et al. Automation for sewer pipe assessment: CCTV video interpretation algorithm and sewer pipe video assessment (SPVA) system development[J]. Automation in Construction, 2021, 125: 103622.
- [24] Haurum J B, Moeslund T B. A Survey on Image-Based Automation of CCTV and SSET Sewer Inspections[J]. Automation in Construction, 2020, 111: 103061.
- [25] Yin X, Chen Y, Bouferguene A, et al. A deep learning-based framework for an automated defect detection system for sewer pipes[J]. Automation in Construction, 2020, 109: 102967.
- [26] Moradi S, Zayed T, Golkhoo F. Review on Computer Aided Sewer Pipeline Defect Detection and Condition Assessment[J]. Infrastructures, 2019, 4(1): 10.
- [27] Kumar S S, Abraham D M, Jahanshahi M R, et al. Automated defect classification in sewer closed circuit television inspections using deep convolutional neural networks[J]. Automation in Construction, 2018, 91: 273-283.

- [28] Myrans J, Everson R, Kapelan Z, et al. Automated detection of faults in sewers using CCTV image sequences[J]. *Automation in Construction*, 2018, 95: 64-71.
- [29] Hawari A, Alamin M, Alkadour F, et al. Automated defect detection tool for closed circuit television (CCTV) inspected sewer pipelines[J]. *Automation in Construction*, 2018, 89: 99-109.
- [30] Halfawy M R, Hengmeechai J. Automated defect detection in sewer closed circuit television images using histograms of oriented gradients and support vector machine[J]. *Automation in Construction*, 2014, 38: 1-13.
- [31] Girshick R, Donahue J, Darrell T, et al. Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation[C]//2014 IEEE Conference on Computer Vision and Pattern Recognition. 2014: 580-587.
- [32] Liu W, Anguelov D, Erhan D, et al. SSD: Single Shot MultiBox Detector[C]//Computer Vision–ECCV 2016. Cham: Springer, 2016: 21-37.
- [33] Redmon J, Divvala S, Girshick R, et al. You Only Look Once: Unified, Real-Time Object Detection[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 779-788.
- [34] Lin T Y, Goyal P, Girshick R, et al. Focal Loss for Dense Object Detection[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2020, 42(2): 318-327.
- [35] Hu J, Shen L, Sun G. Squeeze-and-Excitation Networks[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018: 7132-7141.
- [36] Woo S, Park J, Lee J Y, et al. CBAM: Convolutional Block Attention Module[C]//Computer Vision–ECCV 2018. Cham: Springer, 2018: 3-19.
- [37] Wang Q, Wu B, Zhu P, et al. ECA-Net: Efficient Channel Attention for Deep Convolutional Neural Networks[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 11531-11539.

- [38] Zhou B, Khosla A, Lapedriza A, et al. Learning Deep Features for Discriminative Localization[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 2921-2929.
- [39] Selvaraju R R, Cogswell M, Das A, et al. Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization[C]//2017 IEEE International Conference on Computer Vision (ICCV). 2017: 618-626.
- [40] Pan S J, Yang Q. A Survey on Transfer Learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2010, 22(10): 1345-1359.
- [41] Weiss K, Khoshgoftaar T M, Wang D. A survey of transfer learning[J]. Journal of Big Data, 2016, 3(1).
- [42] Wang M, Deng W. Deep visual domain adaptation: A survey[J]. Neurocomputing, 2018, 312: 135-153.
- [43] Rezatofighi H, Tsoi N, Gwak J Y, et al. Generalized Intersection Over Union: A Metric and a Loss for Bounding Box Regression[C]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 658-666.
- [44] Carion N, Massa F, Synnaeve G, et al. End-to-End Object Detection with Transformers[C]//Computer Vision–ECCV 2020. Cham: Springer, 2020: 213-229.
- [45] Cheng X, Wang Y. Pipeline Defect Detection Based on Improved YOLOv11[J]. Processes, 2026, 14(3): 530.
- [46] Jung J T, Reiterer A. Improving Sewer Damage Inspection: Development of a Deep Learning Integration Concept for a Multi-Sensor System[J]. Sensors, 2024, 24(23): 7786.
- [47] Huang J, Kang H. Automatic Defect Detection in Sewer Pipe Closed-Circuit Television Images via Improved You Only Look Once Version 5 Object Detection Network[J]. IEEE Access, 2024, 12: 92797-92825.

- [48] Lu J, Song W, Zhang Y, et al. Real-time defect detection in underground sewage pipelines using an improved YOLOv5 model[J]. *Automation in Construction*, 2025, 173: 106068.
- [49] Yu H, Liu J, Lin M. A Comprehensive Literature Review on YOLO-Based Small Object Detection: Methods, Challenges, and Future Trends[J]. *Computers, Materials & Continua*, 2026, 87(1).
- [50] Jing R, Zhang W, Li Y, et al. Dynamic Feature Focusing Network for small object detection[J]. *Information Processing & Management*, 2024, 61(6): 103858.
- [51] Ma Y, Yin J, Huang F, et al. Surface defect inspection of industrial products with object detection deep networks: a systematic review[J]. *Artificial Intelligence Review*, 2024, 57(12): 333.
- [52] Fu G, Zhang Z, Li J, et al. An evaluation method for model transfer learning performance in industrial surface defect detection tasks[J]. *Expert Systems with Applications*, 2025, 293: 128680.
- [53] Ye B, Lai J, Xie X, et al. Prototype-guided domain adaptive one-stage object detector for defect detection[J]. *Advanced Engineering Informatics*, 2024, 62: 102618.
- [54] Lv Z, Dong S, He J, et al. Lightweight Sewer Pipe Crack Detection Method Based on Amphibious Robot and Improved YOLOv8n[J]. *Sensors*, 2024, 24(18): 6112.
- [55] Wang H, Feng Z, Jiang M, et al. RDLK-YOLO enhanced pipeline defect detection in uneven illumination[J]. *Scientific Reports*, 2025, 15: 43594.
- [56] Lee S, Uh Y, Choe J, et al. Discovering an inference recipe for weakly-supervised object localization[J]. *Pattern Recognition*, 2024, 157: 110838.
- [57] Farrugia M. YOLO11 Architecture Diagram: Visual Representation of the YOLO11 Object Detection Model[EB/OL]. Zenodo, 2025.

- [58] Božič J, Tabernik D, Skočaj D. Mixed supervision for surface-defect detection: From weakly to fully supervised learning[J]. Computers in Industry, 2021, 129: 103459.
- [59] Ameri R, Hsu C C, Band S S. A systematic review of deep learning approaches for surface defect detection in industrial applications[J]. Engineering Applications of Artificial Intelligence, 2024, 130: 107717.
- [60] Wang H, Li Z, Wang H. Few-Shot Steel Surface Defect Detection[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-12.

致谢

在本论文的选题、数据整理、方法设计、实验推进和写作过程中，指导教师、课题组同学以及相关协作人员都给予了大量帮助。在此谨向所有关心、支持和帮助过本研究工作的老师、同学、家人和朋友致以诚挚谢意。论文从问题凝练到章节重构，再到实验方案设计与结果分析，均得益于导师在研究方向把握、技术路线梳理和论文写作规范方面的持续指导。课题组同学在数据整理、实验讨论和阶段性汇报中提供了大量建设性意见，也为本文顺利推进创造了良好条件。与此同时，家人对本人学习与生活的理解、支持与包容，也是完成本论文的重要保障。

在读期间发表的学术论文与取得的其他成果

1. 与本论文相关的学术论文、专利、项目与竞赛成果将在终稿提交前据实补录，并统一按照学校要求进行格式化整理。

补充图表规划

为避免正文过度臃肿而又保留充分原始材料，本附录对后续建议补充的图表内容进行统一规划。附录部分主要用于安置全量阈值扫描结果、完整 baseline 指标表、更多样本示例、额外 CAM 与 Grad-CAM 可视化、训练曲线以及错误样本画廊等材料，以增强实验过程的可复核性与材料完整性。

表 2 附录补充图表规划表

附录编号	建议内容	主要作用
表 A.1-表 A.2	全量 threshold sweep 表、五尺度完整 baseline 指标表	补充正文未展开的原始数值
表 A.3-表 A.6	全量 run config、混淆矩阵明细、伪框抽检记录、错误样本统计表	展示实验原材料的完整性
图 A.1-图 A.2	更多 source/target 样本图	增强数据集展示的直观性
图 A.3-图 A.4	更多 CAM 与 Grad-CAM 及校准图	支撑第一阶段支撑链分析
图 A.5-图 A.8	全量训练曲线、每类 PR 曲线、更多误检/漏检画廊、资源监控图	支撑实验充分性与可复核性

补充说明

本附录用于安置最终定稿时不宜在正文中大篇幅展示、但对答辩和归档具有支撑意义的辅助材料，包括：详细网络结构图、迁移训练阶段配置表、类别映射细则、伪框生成规则、数据清洗口径、实验日志样例及更多定性可视化图件。若后续实验中产生新的系统级图表，也将在本附录中按学校规范继续补充。

.1 六类间接 gate 的统一 calibration 补充结果

为补充展示第一阶段六类 source 分类模型在间接 gate 视角下的分数校准特征，本附录进一步给出统一超参数重跑后的 yolo11n/s/m/l/x-cla 五组模型在统一 calibration 协议下的补充结果。具体协议与正文二分类 gate calibration 保持一致：全部基于现有逐图 p_abnormal 反推二分类 logit，按 val-cal=30%、val-op=70%、随机种子 20260330 拟合单标量温度参数 T。这组附录结果主要用于说明六类间接 gate 的分数可信度变化与高召回锚点排序变化，不改变正文中“第一阶段主线仍以 direct binary gate 为核心”的总体判断。




图 1 六类间接 gate 五模型的 Reliability Diagram 对比




图 2 六类间接 gate 五模型的 calibration 前后 threshold sweep 对比




图 3 六类间接 gate 五模型的关键锚点指标对比

2 第一阶段 HN 回流比例扫描补充结果

为补充展示第一阶段主模型 yolo11l-cls 在不同 HN 回流强度下的响应规律，本附录进一步给出 hn00 至 hn20 十一组实验的全量指标汇总。正文主要保留高召回锚点相关指标及最优比例结论；本附录额外补充整体精度、排序质量和分数可信度指标，以增强实验过程的可复核性。

表 3 第一阶段 HN 回流比例扫描全量指标表

组别	回流比例/%	回流样本数	Accuracy	Macro-F1	AUROC	AUPRC	ECE
hn00	0	0	0.9385	0.8818	0.9497	0.9886	0.0326
hn02	2	22	0.9246	0.8630	0.9397	0.9858	0.0298
hn04	4	43	0.9167	0.8407	0.9009	0.9712	0.0381
hn06	6	65	0.9365	0.8760	0.9355	0.9842	0.0447
hn08	8	86	0.9246	0.8559	0.9288	0.9828	0.0314
hn10	10	108	0.9226	0.8464	0.9244	0.9824	0.0291
hn12	12	130	0.9147	0.8325	0.9188	0.9805	0.0275
hn14	14	151	0.9385	0.8818	0.9346	0.9826	0.0337
hn16	16	173	0.9067	0.8107	0.9195	0.9806	0.0383
hn18	18	194	0.9226	0.8513	0.9350	0.9838	0.0271
hn20	20	216	0.9226	0.8497	0.9321	0.9851	0.0363




图 4 第一阶段 HN 候选样本累计数量与分数分布补充图