

基于改进 YOLOv11 的地下排水管道缺陷智能检测方法研究

学位论文初稿框架

作者姓名: [待补充: 填写作者姓名]
指导教师: [待补充: 填写指导教师姓名]
学科专业: [待补充: 填写学科专业]
研究方向: 计算机视觉与地下排水管道缺陷智能检测
完成时间: [待补充: 填写完成时间]

摘要

地下排水管网是城市基础设施体系中的重要组成部分，其运行状态直接影响城市排涝安全、道路运行秩序与生态环境质量。当前，基于闭路电视图像的排水管道检测已成为管网运维中的重要技术手段，但传统人工判读方式仍存在效率低、主观性强以及漏判误判率高等问题。与此同时，地下排水管道缺陷图像普遍具有缺陷目标尺度小、边界模糊、背景干扰强、正常样本占比高以及源域与目标域分布差异明显等特点，导致现有通用目标检测方法在该场景中的检测精度、鲁棒性和跨域泛化能力仍然受限。

针对上述问题，本文围绕地下排水管道 CCTV 图像缺陷检测任务展开研究，构建了前级高召回预筛与后级精确检测相结合的总体框架。在数据层面，结合公开 SewerML 数据与目标域巡检数据，构建源域单标签分类数据集和目标域六类缺陷检测数据集，形成从源域表征学习到目标域检测优化的实验链条。在方法层面，针对复杂背景下排水管道缺陷检测中的特征表达不足、多尺度缺陷识别困难以及类别分布不均衡等问题，提出一种基于改进 YOLOv11 的地下排水管道缺陷检测方法，通过引入注意力机制、改进检测头并优化损失函数，提升模型对细粒度缺陷、多尺度目标和难样本的识别能力。在训练策略层面，针对源域与目标域存在显著分布差异且目标域标注样本有限的问题，提出源域分类预训练与目标域微调相结合的跨域迁移适应训练策略，以增强模型在目标域中的特征适应能力与泛化性能。

本文进一步设计了源域分类实验、目标域微调实验、CAM 热力图生成、伪框构建、检测对比实验、消融实验、迁移实验和可视化分析等实验流程。后续将通过 Precision、Recall、F1、mAP、误报率以及系统级指标等多维度指标，对所提方法的有效性进行验证，并从工程应用角度分析其在地下排水管网智能巡检中的应用潜力。

本文的研究目标是为地下排水管道缺陷自动识别提供一条兼顾检测精度、跨域适应能力与工程可落地性的技术路线，为城市排水管网智能巡检与辅助决策提供理论基础和方法支撑。

关键词：地下排水管道；缺陷检测；YOLOv11；迁移学习；跨域适应；CCTV 图像

Abstract

Urban underground drainage pipelines are critical components of municipal infrastructure, and their operating conditions directly affect urban flood control, traffic safety, and environmental governance. CCTV-based inspection has become an important technical approach for drainage pipeline maintenance. However, conventional manual inspection still suffers from low efficiency, strong subjectivity, and high rates of missed and false judgments. In addition, CCTV images of drainage pipelines usually contain small defect targets, blurred boundaries, complex background noise, a high proportion of normal samples, and obvious distribution gaps caused by different devices, lighting conditions, and regional environments. These factors limit the accuracy, robustness, and cross-domain generalization of existing generic detection methods in real sewer inspection scenarios.

To address these challenges, this thesis studies intelligent defect detection for underground drainage pipelines and builds a two-stage framework that combines high-recall pre-screening with precise downstream detection. At the data level, a source-domain single-label classification dataset and a target-domain six-class detection dataset are constructed by integrating the public SewerML dataset and target-domain inspection data. At the method level, an improved YOLOv11-based detector is designed by introducing attention mechanisms, improving the detection head, and refining the loss function. At the training-strategy level, a cross-domain transfer scheme is further designed by combining source-domain classification pretraining with target-domain fine-tuning, so as to improve target-domain feature adaptation and generalization under limited annotation conditions.

The proposed framework will be evaluated through classification experiments, CAM-based pseudo-box generation, comparative detection experiments, ablation studies, transfer experiments, and visualization-based error analysis. The overall goal is to provide a practical and engineering-oriented technical solution for intelligent CCTV inspection of urban drainage pipelines.

Key words: underground drainage pipeline, defect detection, YOLOv11, transfer learning, cross-domain adaptation, CCTV image

目录

摘要	ii
Abstract	iii
第 1 章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	3
1.2.1 从人工判读到传统视觉方法的早期发展	3
1.2.2 深度学习引入后的研究转向	3
1.2.3 公开数据集与 benchmark 对研究范式的改变	4
1.2.4 改进检测模型与工程部署导向研究	4
1.2.5 迁移学习、弱监督定位与跨域适应的最新进展	5
1.2.6 研究趋势、阶段性共识与本文切入点	6
1.2.7 文献评述与本章小结性认识	7
1.2.8 不同研究路径的比较与评价	8
1.2.9 本文课题与现有研究的关系定位	8
1.3 现有研究存在的问题	9
1.4 本文研究内容	11
1.5 本文主要创新点	12
1.6 论文结构安排	12
第 2 章 相关理论与关键技术基础	14
2.1 地下排水管道缺陷类型与图像特征分析	14
2.1.1 地下排水管道缺陷类型	14
2.1.2 缺陷图像特征分析	14
2.2 目标检测基本理论	15
2.2.1 目标检测任务定义	15
2.2.2 目标检测方法演进	16
2.2.3 常用评价指标	16
2.2.4 多尺度表示与后处理机制	17
2.2.5 小目标检测与密集背景场景难点	17
2.2.6 一阶段检测器在工程任务中的优势与边界	17
2.3 YOLO 系列方法与 YOLOv11 基线分析	18
2.3.1 YOLO 系列方法的发展逻辑	18
2.3.2 YOLOv11 基线结构的任务适配性	19
2.3.3 YOLOv11 在排水管道缺陷场景中的局限性	20
2.3.4 基线模型的可改进位置分析	20
2.3.5 特征金字塔、感受野与上下文建模	20
2.4 小目标检测与复杂背景建模理论	21

2.4.1	小目标信息保持理论	21
2.4.2	复杂背景抑制理论	21
2.4.3	显著性建模与误报控制关系	22
2.5	注意力机制相关理论	22
2.5.1	注意力机制的基本思想	22
2.5.2	典型注意力模块及其特点	22
2.5.3	注意力机制与局部-全局特征建模关系	23
2.5.4	注意力机制的引入原则	23
2.5.5	注意力机制的局限与选择依据	23
2.5.6	注意力机制在缺陷检测中的作用	23
2.6	检测头改进与损失函数设计相关理论	24
2.6.1	检测头设计的作用	24
2.6.2	类别不均衡与难样本学习	24
2.6.3	损失函数优化的任务意义	25
2.6.4	标签分配与难样本学习理论	25
2.6.5	分类、定位与后处理之间的协同关系	25
2.6.6	优化目标之间的冲突与平衡	26
2.7	迁移学习、跨域适应与热力图定位理论	26
2.7.1	迁移学习基本概念	26
2.7.2	跨域适应问题	26
2.7.3	CAM 与 Grad-CAM 的理论基础	27
2.7.4	源域预训练与低标注伪框学习的理论合理性	27
2.7.5	域差来源分解与低标注学习路径	27
2.7.6	人机协同与低标注闭环	28
2.7.7	从理论基础到实验设计的映射	29
2.8	低标注学习与人机协同检测理论	29
2.8.1	低标注学习的工程含义	29
2.8.2	伪标签与候选区域的角色定位	30
2.8.3	人机协同检测闭环	30
2.8.4	本章理论对后续研究的支撑关系	30
2.8.5	监督粒度连续体与少样本检测启示	31
2.9	本章小结	32
第 3 章	数据集构建与地下排水管道缺陷检测总体框架	33
3.1	数据来源与总体说明	33
3.1.1	源域数据来源	33
3.1.2	目标域数据来源	33
3.2	源域单标签分类数据集构建	33
3.2.1	单标签化原则	33
3.2.2	当前数据集规模与分布	33
3.3	目标域缺陷类别定义与标签映射	34
3.3.1	目标域最终检测类别	34
3.3.2	源域与目标域的关系	34

3.4	数据预处理与增强策略	35
3.4.1	预处理策略	35
3.4.2	数据增强策略	35
3.5	高召回预筛与后级精检的总体框架	35
3.6	CAM 热力图与伪框生成流程	36
3.7	评价指标与实验平台	36
3.8	本章小结	36
第 4 章	基于改进 YOLOv11 的地下排水管道缺陷检测方法	37
4.1	基线模型与问题分析	37
4.2	注意力机制改进	37
4.2.1	改进动机	37
4.2.2	模块设计与嵌入方式	37
4.3	检测头改进	37
4.3.1	原始检测头局限性	37
4.3.2	改进思路	38
4.4	损失函数改进	38
4.4.1	损失函数优化目标	38
4.4.2	损失函数表达形式	38
4.5	改进 YOLOv11 总体结构	38
4.6	模型复杂度与可部署性分析	39
4.7	本章小结	39
第 5 章	面向跨域场景的迁移适应训练策略	40
5.1	跨域问题分析	40
5.2	源域分类预训练策略	40
5.3	目标域分类微调与特征迁移	40
5.4	基于迁移分类模型的候选区域生成与标注增强	40
5.5	检测阶段的迁移训练策略	40
5.6	本章小结	41
第 6 章	实验结果与分析	42
6.1	实验设置	42
6.1.1	实验平台与训练配置	42
6.2	源域分类实验结果分析	42
6.3	两阶段系统有效性分析	43
6.4	改进 YOLOv11 与其他模型对比实验	43
6.5	创新点一的消融实验	43
6.6	创新点二的迁移实验	44
6.7	可视化与错误分析	44
6.8	本章小结	45
第 7 章	结论与展望	46

7.1 研究结论	46
7.2 不足之处	46
7.3 展望	46
参考文献	47
附录说明	54

第 1 章 绪论

1.1 研究背景与意义

地下排水管网是城市基础设施系统中的关键组成部分，其运行状态直接关系到雨污输送、城市防涝、道路安全、水环境治理以及地下空间稳定性。与地上可见设施相比，排水管道长期处于封闭、潮湿、腐蚀性强且不易直接观测的工作环境中，受材料老化、施工偏差、长期荷载、接口松动、根系侵入和沉积堵塞等因素影响，极易在服役过程中产生裂缝、破损、错口、变形、渗漏和侵入等缺陷。一旦这些隐患不能被及时发现和处置，就可能进一步演化为排水能力衰减、道路积水、污染泄漏，甚至地面塌陷等城市安全事件。因此，建立高效、可靠、可持续迭代的地下排水管道缺陷检测方法，既是智慧城市与生命线工程建设中的现实需求，也是基础设施智能运维的重要研究方向^{[26][24][7]}。

从工程实践看，地下排水管道状态评估长期依赖人工巡检与人工判读。早期排水管道养护工作更多建立在经验性检查、局部开挖和人工记录基础上，效率低、覆盖范围有限且扰动成本高。随着闭路电视检测技术的发展，CCTV inspection 逐渐成为地下排水管道巡检的主流技术路径。相较于传统开挖检查，CCTV 检测可以在非破坏条件下获取管道内部连续图像与视频信息，明显提升病害发现效率和巡检覆盖范围。然而，CCTV 技术本身只是完成了“看见管道内部”的问题，真正的缺陷识别、分类、分级和维护决策，仍然高度依赖人工判读。随着巡检规模持续扩大，海量视频与图像数据的人工分析压力不断增加，人工复核成本、主观差异、疲劳误判和漏判问题日益突出^{[29][23][24]}。

从研究发展历程看，地下排水管道缺陷识别经历了较为清晰的技术演进脉络。最早期的自动化尝试主要依赖传统图像处理、人工特征设计和经典机器学习分类器，如边缘算子、纹理描述子、方向梯度直方图以及支持向量机等。这一阶段的代表性工作已经开始尝试在 CCTV 图像中自动提取病害区域，并证明计算机视觉方法在 sewer inspection 场景中具有潜在可行性^[30]。随后，研究者进一步围绕视频序列分析、规则驱动的候选区域提取和基于人工特征的缺陷分类展开探索，逐步推动排水管道自动检测从“辅助观察工具”向“初步自动识别系统”过渡^{[29][28]}。

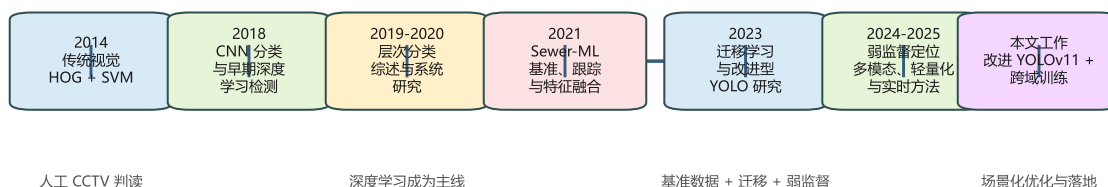


图 1.1 地下排水管道缺陷智能识别研究发展脉络

注：根据文献^{[30][27][15][24][6][8][3][1]} 整理与改绘。

真正推动该方向进入快速发展阶段的，是深度学习特别是卷积神经网络和目标检测模型的引入。自 2018 年前后起，研究者开始将 CNN 用于 sewer defect classification,

将深度学习检测模型用于 CCTV 缺陷定位，并逐步替代传统手工特征方法^{[27][15]}。进入 2019–2021 年后，围绕类别不均衡、层次分类、局部与全局特征融合、视频缺陷跟踪和系统化评测的研究明显增多，说明该领域已经从“证明深度学习可用”转向“提高模型性能并适应真实工程场景”^{[16][17][25][22][11]}。Sewer-ML 数据集与 benchmark 的提出，则进一步推动该方向从小规模闭门数据研究，走向了更具可复现性与可比较性的公开研究阶段^[6]。

尽管如此，地下排水管道缺陷图像并不是标准的自然图像识别任务。首先，缺陷常表现为小目标、细长目标或局部弱纹理异常，边界模糊、对比度低且类间差异不均衡。其次，真实巡检场景伴随反光、水膜、污渍、沉积物、照明不均、运动模糊以及压缩噪声等问题，这些干扰会显著增加模型误报与漏报风险。再次，连续视频中大量帧为正常帧或近重复帧，若直接使用检测器对全部图像进行重分析，会造成较高算力开销与误报累积。最后，不同地区、不同管材、不同巡检设备和不同标注规范带来的 domain gap，使得公开数据上训练出的模型难以直接迁移到本地工程环境^{[24][7][14][8]}。

因此，排水管道缺陷智能识别研究不能简单理解为“在某个公开数据集上训练一个检测网络”，而应当被视为一个从数据、算法到系统流程协同设计的问题。从数据角度，需要解决公开数据与目标域数据之间的分布差异，以及检测框标注昂贵导致的低标注学习问题；从算法角度，需要针对 sewer defect 的小目标、多尺度、弱纹理和高背景噪声特征，对检测模型进行适配性改进；从系统角度，还需要考虑高召回预筛、候选区域生成、误报控制和人工复核成本等工程约束^{[3][20][18]}。只有在这三个层面形成闭环，研究结果才具备真正的工程应用潜力。

基于上述认识，本文将研究对象聚焦于地下排水管道 CCTV 图像中的结构性缺陷检测问题，试图回答三个彼此关联的问题：其一，在真实 sewer 场景下，通用目标检测模型为何难以直接达到理想效果；其二，如何通过注意力机制、检测头与损失函数协同优化，构建更适用于该场景的改进 YOLOv11 检测模型；其三，如何利用公开 SewerML 数据和少量目标域数据，建立一条源域预训练、目标域微调、低标注增强与检测训练相衔接的跨域迁移技术路线。围绕这三个问题展开系统研究，不仅可以为后续章节中的模型改进和实验验证提供明确主线，也能够使论文从一开始就围绕真实业务痛点逐层展开，而不是停留在对单一模型结构的局部修改层面。

进一步从论文定位看，本文并不试图将“分类、热力图、伪框、检测、迁移”割裂成若干彼此独立的小问题，而是将其组织为一条具有明确逻辑顺序的研究链条。第一步利用开源域数据建立更稳健的缺陷表征能力；第二步通过目标域分类微调与 CAM 候选区域生成降低检测框构建成本；第三步在此基础上以改进 YOLOv11 为核心完成目标域缺陷检测；第四步通过系统级实验验证该链条对工程场景的有效性。这一研究路线既延续了 sewer inspection 自动化从“人工判读”到“自动识别”再到“低标注增强与智能辅助决策”的发展趋势，也与当前基础设施智能运维中强调“数据驱动 + 可部署 + 可迭代”的总体方向保持一致^{[23][7][1]}。

还需要强调的是，本文讨论研究意义时，并不把算法精度视为唯一目标。在地下排水管道场景中，真正决定技术价值的往往是“精度、误报、标注成本和部署效率”之间的综合平衡。如果一种方法需要大量高质量检测框标注才能工作，那么它在多数工程部门中就难以快速复制；如果一种方法只在单一数据集上精度较高，但在目标域迁移后误报严重、人工复核压力巨大，其实际价值同样有限^{[14][3][1]}。因此，本文从一开始就将研究定位为“面向真实业务链条的检测方法研究”，而不是将其限定为纯粹的模型竞赛问题。

从学术层面看，地下排水管道缺陷检测也是一个很有代表性的交叉研究场景。一方面，它要求研究者理解基础设施运维中的工程痛点，如缺陷类型、维护优先级、巡检流程和标注约束；另一方面，它又迫使研究者面对计算机视觉中最具挑战的若干问题，包括小目标检测、长尾分布学习、跨域适应、弱监督定位和可解释性增强^{[8][42][19]}。因此，这一课题既具有工程驱动特征，也具备方法研究深度，适合构建一篇主线清晰、问题明确且后续实验可逐步验证的硕士论文。

1.2 国内外研究现状

1.2.1 从人工判读到传统视觉方法的早期发展

地下排水管道缺陷识别最初并非源自深度学习，而是源自排水行业对人工判读效率瓶颈的长期积累性反思。CCTV 技术普及之后，城市运维部门可以更便捷地获取管道内部视频，但真正决定维护质量的仍是后端人工解释过程。人工判读不仅需要长期经验积累，而且在大规模管网场景下存在高度重复劳动和明显主观性差异。正因为如此，计算机辅助判读逐渐成为早期研究的主要方向，其目标并不是完全替代人工，而是尽可能减少人工逐帧查看和重复确认的工作量^{[26][24]}。

这一阶段的研究主要采用传统图像处理 and 人工特征工程方法。Halfawy 等较早将方向梯度直方图与支持向量机引入 sewer CCTV 缺陷检测，说明传统机器学习在规则明确的缺陷场景中可以形成初步自动识别能力^[30]。随后，研究者围绕候选区域提取、运动信息利用和视频序列中的异常模式识别开展工作，尝试通过轮廓、纹理、边缘和时序变化来检测病害区域^{[29][28]}。这一阶段研究的贡献主要有两个：一是证明了 sewer inspection 自动化分析具有现实可行性；二是逐步明确了该任务不同于通用自然图像识别的复杂性，即缺陷纹理弱、背景噪声强、目标形态不规则且数据获取质量波动大。

然而，传统视觉方法的局限性也十分明显。首先，这类方法通常高度依赖人工设计特征，对不同场景的适配性较弱，当摄像头参数、光照条件、管壁材质或污渍状态发生变化时，手工特征往往失效。其次，传统方法对细粒度纹理和弱对比异常的建模能力有限，难以同时适应裂缝、侵入、渗漏、错口等多样化病害。再次，这类方法通常需要较复杂的阈值调节和规则组合，稳定性与鲁棒性都较差，在大规模真实工程部署中难以保持一致性^{[26][24][30]}。因此，尽管早期工作为后续研究奠定了问题定义基础，但并未真正解决 sewer defect detection 在复杂工程场景中的核心矛盾。

1.2.2 深度学习引入后的研究转向

2018 年前后，随着深度卷积神经网络在通用目标检测领域取得显著进展，排水管道缺陷识别研究开始进入以深度学习为主导的新阶段。Kumar 等和 Cheng 等分别从分类与检测角度证明了深度学习模型能够明显优于传统手工特征方法^{[27][15]}。这一阶段的关键变化在于，研究重点从“如何定义缺陷手工特征”转向“如何通过网络自动学习区分性表征”。相比传统方法，深度学习模型能够在更大程度上利用上下文信息与层次语义信息，从而更适应排水管道图像中类内差异大、类间边界模糊的特点。

2019 年以后，该方向逐渐从单纯的分类或检测试验，扩展为更系统的数据与模型研究。Myrans、Meijer 等工作关注类别不平衡、层次分类和更稳健的卷积特征学习，说明 sewer 场景并非简单的通用图像分类问题，而是一个受类别长尾分布影响显著的工程视觉问题^{[16][17]}。Yin 等提出面向排水管道的深度学习检测框架和视频级评估系统，说明研究对象也从单张图像扩展到面向巡检业务流程的连续视频系统^{[25][23]}。Wang 等的缺陷跟踪研究进一步表明，在真实应用中，单帧检测准确率只是系统性能的一部分，跨帧一致

性和复核效率同样重要^[22]。

与此相对应，公开综述工作开始对 sewer defect detection 的整体技术谱系进行梳理。Moradi 等从计算机辅助缺陷检测与状态评估角度总结了传统方法与深度学习方法的差异^[26]；Haurum 等则从图像自动化角度系统回顾了 CCTV 与 SSET 等 sewer inspection 视觉技术路线，指出数据稀缺、缺陷定义不统一和评价体系分散是该领域长期存在的问题^[24]。这些综述的共同作用，是将原本零散的算法实验上升为一个更清晰的研究领域，并为后续数据集构建、benchmark 设计和跨任务比较提供了基础。

1.2.3 公开数据集与 benchmark 对研究范式的改变

在 sewer defect detection 研究中，公开数据集的出现具有关键性意义。过去很多工作依赖自建私有数据，样本规模有限且标注口径不统一，导致研究结果难以复现和比较。Sewer-ML 的提出改变了这一局面。Haurum 和 Moeslund 构建了大规模、多标签、覆盖多种管道缺陷的公开数据集，并建立了分类 benchmark，使 sewer inspection 研究首次拥有了较为统一的公开实验平台^[6]。这不仅推动了排水管道图像分类研究的发展，也间接促进了后续弱监督定位、迁移学习和低标注检测研究。

围绕 Sewer-ML，研究者开始从不同角度展开更细化的探索。Kumar 等关注高度不平衡数据集下的分类问题，指出长尾分布会导致少数类缺陷识别性能明显下降^[13]。Jang 和 Kim 则从数据质量角度分析标签错误、图像冗余和低质量样本对模型性能的影响，说明 sewer 数据并非规模越大越好，而是需要在质量控制和信息增益之间取得平衡^[14]。这些研究提示我们，在 sewer inspection 场景中，数据问题并不仅仅是“数量不足”，还包括“质量不稳定”“类别不均衡”和“标签口径复杂”等更深层次问题。

另一方面，公开 benchmark 的出现也改变了研究评价方式。早期很多论文仅报告少量自建数据上的准确率或召回率，难以反映方法在不同缺陷类别和复杂场景中的泛化能力。随着公开数据与标准化评测的引入，研究者能够更清晰地比较分类、检测、轻量化和弱监督方法的优劣，并从误报率、类间混淆、跨设备泛化等更具工程价值的指标出发分析模型表现^{[6][24][1]}。可以说，数据集与 benchmark 的发展，使 sewer defect detection 逐渐从“能不能做”走向“做得如何”“能否迁移”和“是否可部署”。

1.2.4 改进检测模型与工程部署导向研究

在检测模型层面，近年来 sewer defect detection 已经明显从通用 detector 直接套用，转向针对场景特征的适配性改进。Li 等提出局部与全局特征融合策略，强调在缺陷识别中既要保留局部纹理细节，也要利用更大范围的结构上下文^[11]。Wang 等、Zhang 等和 Zhao 等则分别围绕改进 YOLOv5、轻量化部署和 sewer-specific detector 设计开展研究，说明 YOLO 系列在该场景中已经成为最具工程吸引力的技术路线之一^{[9][12][10]}。这些工作的共同特点是，不再满足于单纯沿用通用目标检测结构，而是从注意力机制、特征融合、检测头设计、损失函数乃至轻量化部署角度，对模型进行针对性改造。

2024–2025 年的研究进一步体现出该方向的两个新趋势。其一，是模型结构上从纯 CNN 向混合架构、解释性增强和多模态扩展演化。例如，基于 ResNet50–Swin Transformer 的混合分类定位框架、基于大型多模态模型的可解释 sewer defect detection 研究，都反映出模型设计正向更强表征能力与更好可解释性方向演进^{[4][19]}。其二，是从“只看精度”转向“兼顾透明性、可复核性与工程成本控制”。WSOL 方法和基于几何特征的缺陷定位方法，强调在低标注甚至图像级标注条件下获得可用于后续复核的候选区域，这与实际工程中控制标注成本、缩短模型迭代周期的需求高度一致^{[3][18][20]}。

同时,最新 benchmark 研究也表明 sewer defect detection 仍处于快速演化阶段。对 Istanbul Dataset 上 YOLO 与 RT-DETR 的系统比较说明,一阶段检测器和 transformer-based detector 各有优势,但在复杂 sewer 场景中仍受到误报、细粒度区分和训练稳定性影响^[2]。Measurement 期刊发表的最新综述则指出,pipe defect inspection 已从单一图像级识别,逐步走向检测、定位、定量评估与全流程智能巡检,但稳定的跨域泛化能力和低标注部署能力仍是核心瓶颈^[1]。这些最新工作意味着,本文围绕改进 YOLOv11 和跨域迁移策略展开研究,具有明确的问题背景与现实必要性。

如果进一步聚焦到 2024–2025 年 sewer-specific detector 的发展,可以发现研究者已经不再满足于“把通用 YOLO 直接迁入排水管道场景”。Huang 和 Kang 在 IEEE Access 上系统讨论了 improved YOLOv5 在 sewer CCTV 图像中的应用,说明结构级改造在真实管道缺陷识别中具有明确收益^[47];Lv 等则把轻量化改进 YOLOv8n 用于 sewer pipe crack detection,强调移动平台与机器人载体条件下的实时性约束^[54];Lu 等在 2025 年进一步给出 improved YOLOv5 的实时检测研究,说明 sewer defect detection 已经从“做出更高精度模型”逐步转向“在复杂场景下维持实时性、稳定性与部署可行性”的综合优化^[48]。这些文献共同表明,排水管道缺陷检测的研究范式已经从早期的“验证深度学习可行”进入到“围绕小目标、低对比、复杂背景和部署限制开展场景化优化”的阶段。

与此同时,采集链条与数据获取方式本身也正在成为研究对象。Jung 和 Reiterer 提出的多传感器深度学习集成概念说明,sewer inspection 已经开始从单一 CCTV 图像分析向多源信息协同演化^[46]。这类工作虽然不直接等同于本文的方法路线,但它传递出一个很重要的信号:真实工程中的缺陷识别越来越被理解为“成像条件、传感配置、数据质量和算法模型”的联合问题,而不只是纯粹的网络结构问题。这一点与 Jang 和 Kim 关于数据质量影响的分析相互印证,共同说明后续研究若只关注网络结构微调而忽视数据源和质量控制,就很难在工程层面取得稳定收益^{[14][46]}。

1.2.5 迁移学习、弱监督定位与跨域适应的最新进展

由于目标域高质量框标注代价高昂,迁移学习与低标注学习已经成为 sewer inspection 研究中的重要方向。Situ 等直接比较了 transfer learning-based YOLO 与传统检测方法,证明在 sewer defect detection 场景中,领域相关预训练能够显著提升模型初始表现和收敛稳定性^[8]。这一结论对本文非常关键,因为它说明与其完全依赖目标域有限框标注,不如先利用同领域公开数据学习更贴近 sewer scene 的特征表征,再迁移到目标域微调。


除迁移学习外,弱监督定位正在成为连接图像级分类与目标检测的重要桥梁。Yang 等提出弱监督协同定位学习方法,说明在缺乏精确框标注时,依靠图像级标签和热力图信息也可以获得具有一定可用性的缺陷区域^[20]。Yin 等则进一步提出透明、可扩展的弱监督定位框架,强调热力图与候选区域不应只作为可视化结果,而应成为低标注数据构建和工程复核流程的一部分^[3]。这类研究与本文的 CAM 伪框生成思路具有直接对应关系,也从侧面证明了“先分类、后热力图、再伪框”的路线不是简单的工程拼接,而是具有明确研究基础的低标注策略。

另一方面,跨域问题在 sewer inspection 中尤为突出。排水管道图像不仅在视觉风格上受到城市、设备和照明条件影响,还受缺陷定义、巡检标准和标注习惯影响,因而 domain gap 往往比自然图像任务更复杂^{[24][7]}。尽管不少工作已经关注迁移学习的应用价值,但真正聚焦于 sewer-specific cross-domain detection 的文献仍然较少,大量研究仍停

留在“通用 ImageNet 预训练 + 目标域微调”的范式上。就此而言，如何利用 Sewer-ML 这类同领域公开数据开展源域分类预训练，并将其转化为目标域检测能力，是当前公开研究中仍未充分解决的问题。

如果从更广义的工业缺陷检测研究看，跨域迁移与低标注学习的理论与方法也正在快速发展。关于工业表面缺陷检测的系统综述指出，真实生产或巡检场景中的域差来源往往包括采集设备差异、材料纹理差异、照明变化和标注口径差异，这与 sewer inspection 中的 domain gap 具有高度相似性^[51]。Fu 等进一步从工业缺陷任务角度讨论 source model selection 对 transfer learning 表现的影响，说明“选择什么源模型进行迁移”本身就是一个独立而重要的问题，而不是默认使用任意预训练模型即可^[52]。对本文而言，这一认识具有直接启示意义，即选择 Sewer-ML 作为同领域源域并构建单标签预训练集，并非单纯出于数据可得性考虑，而是希望在源模型层面尽量缩小与目标域任务之间的语义距离。

同样值得注意的是，近年的 defect-domain adaptation 研究已经开始强调类别原型和结构级对齐，而不只是整体特征分布对齐。Ye 等提出 prototype-guided domain adaptive one-stage detector，用类别原型引导目标检测中的域适应过程，说明跨域问题并不仅仅是图像风格差异，还涉及类别语义边界在源域与目标域中的重塑^[53]。虽然本文不直接采用这类较重的域对齐算法，但这类研究从理论上证明了“缺陷检测中的跨域适应必须考虑类别层级信息”这一点。结合 sewer-specific 研究现状可以看出，本文选择“源域同领域分类预训练 + 目标域渐进微调”的路线，实际上是在工程复杂度和理论合理性之间取一个更稳健的平衡点。



需要：源域先验 + 目标域适配 + 低标注增强

图 1.2 地下排水管道检测任务中的主要域差来源

注：根据 sewer defect detection 与 domain adaptation 相关文献整理与改绘^{[8][7][53][14][1]}。

1.2.6 研究趋势、阶段性共识与本文切入点

如果把现有文献按研究目标进行归类，可以看到该领域已经逐渐形成三个相对清晰的层次。第一层是“数据与任务定义”，其核心问题是公开数据集构建、类别体系建立和评价口径统一；第二层是“模型性能提升”，其核心问题是如何在分类、检测、定位和轻量化部署等任务上获得更优精度与效率；第三层是“系统级落地”，其核心问题是如何面向真实巡检流程降低人工成本、减少误报累积并提升跨域可复用性^{[24][6][9][3]}。从这

个角度看, 本文的研究并非从零起步, 而是站在已有研究逐步积累的三层结构之上, 选择其中尚未被充分打通的部分作为切入点。

从阶段性共识看, 当前研究至少已经明确以下几点。首先, 深度学习已经取代传统人工特征, 成为 sewer defect detection 的主导技术路线; 其次, 公开数据与 benchmark 是该领域进一步标准化和可复现化的基础; 再次, YOLO 类方法因其实时性和工程成熟度, 在实际部署研究中具有突出优势; 最后, 迁移学习、弱监督定位与数据质量控制正在成为提升系统可用性的关键方向^{[26][24][6][8][14][2]}。这些共识为本文确立研究主线提供了重要依据。

若把这些共识再放回近年的一般目标检测研究中观察, 可以发现 sewer defect detection 的关键难点与“小目标检测”“复杂背景显著性抑制”“域差条件下的稳定迁移”三条更广义研究线高度重合。小目标检测综述指出, 特征下采样导致的信息丢失、目标与背景比例失衡以及上下文依赖不足, 是影响细粒度目标检测性能的核心原因^[49]; Dynamic Feature Focusing Network 等研究则进一步说明, 对于小尺度与弱纹理目标, 模型不仅要增强局部区域响应, 还要动态调节不同特征层的关注重心^[50]。这意味着 sewer 场景中的许多困难并非孤立个案, 而是更一般视觉理论在特定工程任务上的集中体现。本文后续围绕注意力、检测头和损失函数展开改进, 本质上也是在这一共性理论背景下, 对 sewer-specific 难题做场景化求解。

与此同时, 现有文献的缺口也相对明确。一方面, 许多工作关注单一公开数据集上的方法比较, 却没有回答开源域知识如何更有效地迁移到本地目标域; 另一方面, 许多改进型 YOLO 工作关注结构替换, 却较少说明为何这些改进在 sewer 场景下成立, 以及它们如何与低标注增强链路发生耦合^{[9][10][12][3]}。因此, 本文将切入点放在“改进 YOLOv11 + 源域分类预训练到目标域检测迁移”这条路径上, 既顺应文献演化逻辑, 又能够形成较强的问题指向性。

1.2.7 文献评述与本章小结性认识

综合已有文献可以发现, 地下排水管道缺陷检测的研究重心实际上经历了三次转移。第一次转移, 是从人工判读转向计算机辅助视觉分析, 其核心目的是减少人工逐帧查看负担; 第二次转移, 是从人工特征与传统机器学习转向深度学习分类和检测, 其核心目的是提高识别精度与鲁棒性; 第三次转移, 则是从“在局部数据上做出一个可用模型”转向“在公开 benchmark、跨域迁移和低标注条件下建立更完整的工程流程”, 其核心目的是让模型真正进入业务闭环^{[30][27][6][3][1]}。

如果进一步按任务形态细分, 现有研究大致可以分为四类。第一类是图像级分类研究, 强调快速判断某类病害是否存在; 第二类是目标检测研究, 强调缺陷区域定位与类别识别; 第三类是视频级与系统级研究, 强调连续帧处理、跟踪与复核效率; 第四类是迁移学习、弱监督和解释性研究, 强调在低标注、高域差和实际业务约束下提升系统可用性^{[17][22][23][8][19]}。这四类研究共同构成了本文后续研究的外部背景。

从论文写作角度看, 绪论不能只是把这些文献按年份罗列, 而应当把它们组织成能引出本文课题的问题链。就本文而言, 这条问题链可以概括为: 人工 CCTV 判读难以支撑大规模巡检需求, 因此需要自动化识别; 传统方法鲁棒性不足, 因此深度学习成为主线; 公开数据与 benchmark 虽然推动了研究发展, 但公开模型难以直接迁移到本地工程场景; 目标域框标注成本又较高, 因此必须在改进检测模型的同时引入源域预训练和低标注增强策略。只有沿着这条链条展开, 后续关于改进 YOLOv11 与跨域迁移的研究才显得自然且必要。

因此，本章的真正目标并不是简单说明“这个方向有人做过”，而是通过文献递进证明：第一，地下排水管道缺陷检测具备明确的工程需求；第二，深度学习已经成为最有前景的技术路线；第三，现有研究虽然丰富，但在跨域、低标注和完整系统链路方面仍存在明显空白；第四，本文提出的研究方案既能够承接已有研究，又能够针对现有空白形成较清晰的学术与工程回应。这也是后续章节展开的前提。

1.2.8 不同研究路径的比较与评价

从现有文献看，围绕地下排水管道缺陷智能识别，至少存在三种常见研究路径。第一种是以图像级分类为核心的路径，重点解决“有没有缺陷”“属于哪类缺陷”的问题。这类路径实现相对简单、标注成本较低、适合大规模样本训练，但难以直接满足定位和维修决策需求^{[17][13][6]}。第二种是以目标检测为核心的路径，重点解决“缺陷在哪里”的问题，更贴近工程应用，但对高质量框标注依赖较强^{[15][9][12]}。第三种是以弱监督、迁移学习和系统集成为核心的路径，试图在较低标注成本下构建更完整的业务链条，但这一路径对方法衔接和实验设计要求更高^{[8][3][20]}。

从研究难度和应用价值的平衡上看，第一种路径适合建立基础表征与大规模预训练能力，第二种路径适合形成最终的缺陷定位输出，第三种路径则更适合在真实工程条件下解决数据和部署约束。本文之所以没有只选择其中一条路线，而是将三者串联起来，本质上是因为单一路线都无法独立解决本文面对的全部问题。若只做分类，则无法完成最终检测任务；若只做检测，则难以摆脱目标域框标注不足的限制；若直接做弱监督检测而没有稳定的源域表征支撑，又容易在目标域上出现训练不稳定和伪框质量不足的问题。

因此，本文最终采用的研究路径是一种“分类预训练能力 + 候选区域增强能力 + 改进检测能力”的组合路线。这种组合并不是为了增加工作量，而是为了让不同研究路径承担各自最擅长的角色：分类负责学习稳定表征，CAM 负责提供低成本候选区域，改进 YOLOv11 负责完成最终缺陷检测，迁移学习负责连接源域与目标域。这样的组织方式既顺应已有研究的发展逻辑，也更容易在后续章节中形成清晰的实验矩阵与结果解释框架。

1.2.9 本文课题与现有研究的关系定位

在现有研究版图中，本文课题可以被理解为一种“面向工程约束的组合式研究”。它既不等于单纯的 sewer 数据集研究，也不等于单纯的改进型 YOLO 检测论文，更不等于一般性的迁移学习实验。更准确地说，本文位于三条研究线的交叉点：一条是 sewer-specific defect detection 研究线，强调场景特征与病害识别；一条是改进目标检测模型研究线，强调小目标、复杂背景和类别不均衡问题；另一条是低标注与跨域适应研究线，强调如何在目标域数据有限条件下形成可用模型^{[6][9][8][3]}。

这一定位意味着，本文不能简单照搬任何一条已有研究路径。若完全沿用 sewer-specific 分类路线，则难以完成最终检测任务；若完全沿用改进 detector 路线，则又无法回答目标域低标注与显著域差问题；若完全沿用一般迁移学习路线，则又容易忽视排水管道图像中复杂背景、小目标与接口结构异常的特殊性。因此，本文的研究设计更像是在已有三条研究线之间搭桥：既继承它们各自有效的部分，又试图把它们组织成一条更完整的工程技术路线。

从论文写作角度看，这样的关系定位也有助于避免后文主次失衡。本文的主角始终是“改进 YOLOv11 检测方法”和“源域预训练到目标域检测的跨域迁移策略”，而分

类预训练、CAM 热力图和伪框构建等环节，则被定位为支撑主角落地的关键链路。把这一点在绪论中讲清楚，后续整篇论文的叙事就会更稳定，不会出现方法章节与实验章节互相争夺主线的问题。

1.3 现有研究存在的问题

综合上述文献可以看出，地下排水管道缺陷智能识别虽已从传统视觉阶段迈入深度学习与系统化评估阶段，但在面向真实工程场景时仍存在若干关键问题。

第一，缺陷视觉特征弱、尺度小且形态复杂，导致通用检测模型的特征表达能力不足。无论是裂缝、破损这类细纹理目标，还是接口错位、侵入和局部变形这类结构关系异常，许多病害都只占据图像中的很小区域，且与背景纹理存在强烈耦合^{[11][15][1]}。通用检测网络在自然图像上学习到的大目标与显著目标偏好，往往难以直接迁移到 sewer defect detection 场景，造成细粒度缺陷漏检和相似类别混淆问题。

第二，真实巡检环境中的干扰因素复杂，模型误报控制仍然困难。水膜反光、污渍附着、沉积物遮挡、光照波动、压缩噪声和视频模糊等因素共同作用，使得模型容易将背景纹理激活为缺陷区域^{[26][24][14]}。很多论文在受控数据集上报告较高精度，但在真实业务流中往往仍面临误报累积问题。对于工程系统而言，误报不仅意味着单张图片预测错误，更意味着人工复核负担上升和整体巡检流程效率下降。

第三，高正常样本占比导致“全量检测”路线在工程上效率不高。连续 CCTV 巡检视频中，大量帧是正常帧、近重复帧或信息量较低的过渡帧。若对全部图像一视同仁地进行高成本检测，不仅增加算力消耗，也会因为海量正常帧上的误报累积而降低系统可用性^{[23][22][12]}。因此，许多实际系统需要先进行高召回预筛，再对疑似缺陷图像进行精细分析。现有研究虽然已有视频级或系统级探索，但围绕“预筛 + 精检”这一完整流程的统一设计仍不充分。

第四，公开数据与目标域数据之间存在显著分布差异，直接迁移效果有限。排水管道影像受城市环境、摄像头参数、管材、施工年代、照明方式和病害定义口径影响极大，同一类缺陷在不同场景中可能呈现出完全不同的视觉模式^{[8][7][1]}。这意味着即便模型在公开数据集上表现良好，也未必能够在本地实际巡检场景中稳定工作。如何在不大量增加目标域精细框标注的前提下，提升模型跨域适应能力，是当前 sewer defect detection 研究中的核心难题之一。

第五，目标域高质量框标注昂贵，限制了检测模型的快速迭代。相较于图像级分类标签，边界框标注不仅耗时，更需要具备工程背景的专业人员参与，尤其当缺陷边界模糊、多个病害共存或区域范围不规则时，标注一致性难以保证^{[3][20][14]}。因此，许多工程单位拥有大量历史图像和视频，却缺乏足够规模、足够规范的检测标注库。现有研究虽然已经开始尝试弱监督定位和伪标签策略，但相关方法在排水管道场景中的系统衔接仍不成熟。

第六，现有研究往往分散于单一环节优化，缺乏面向完整业务链条的统一设计。部分研究聚焦于分类，部分研究聚焦于检测网络结构，部分研究关注数据清洗或系统可视化，但较少有工作同时考虑源域表征学习、目标域适配、低标注增强和误报控制之间的整体关系^{[24][9][10][3]}。对于硕士论文而言，如果只在某一个局部模块上做微小改动，很难形成完整研究闭环；而如果能够把模型改进、跨域迁移与工程支撑链统一起来，则更能体现研究的系统性和应用价值。

第七，现有研究对“数据质量与源模型选择”的讨论仍然不足。数据质量研究已经

表明，冗余样本、错误标签和低质量图像会显著影响 sewer defect detection 的训练稳定性和最终性能^[14]；多传感器研究和工业迁移研究则进一步说明，输入源质量、源模型选取和训练数据组织方式会共同决定后续模型收益^{[46][52]}。然而在不少 sewer-specific 文献中，研究重点仍然集中在“换了什么模块、提升了多少精度”，对源域为何这样构建、训练集为何这样筛选、不同源模型为何产生不同迁移效果等问题讨论不够充分。本文将源域单标签六类分类集构建写成显式研究环节，目的也正在于补足这一被忽视但极其关键的前提层。

第八，改进型检测模型的收益往往缺乏统一而可解释的归因。近年来已有多篇 sewer detection 论文围绕注意力机制、neck 融合、检测头调整和轻量化展开改进^{[9][10][47][48][55]}，但其中不少工作更强调结果对比，而较少系统说明模块收益与 sewer 场景任务属性之间的因果关系。对于硕士论文而言，如果不能把“为什么这些改进在 sewer 场景下成立”解释清楚，那么后续改进 YOLOv11 的方法章节就容易沦为经验性堆叠。基于这一认识，本文在第 2 章中专门铺垫小目标检测、复杂背景抑制、注意力机制和损失函数优化的理论基础，并在后续实验中通过消融设计尽量建立模块收益与任务需求之间的对应关系。

基于上述问题，本文将研究目标明确聚焦于两个核心方向和一条支撑链路。两个核心方向分别是：面向 sewer defect detection 的改进 YOLOv11 模型设计，以及面向源域与目标域显著分布差异的跨域迁移适应训练策略；一条支撑链路则是高召回预筛、分类微调、CAM 候选区域生成和低标注伪框构建。这样的组织方式使研究逻辑能够从数据现实约束自然过渡到模型改进需求，再进一步过渡到跨域适应和系统部署问题，也为后续章节的结构安排提供了清晰主线。




图 1.3 地下排水管道缺陷检测的问题链及本文技术路线

注：根据文献^{[24][7][8][3][14]} 整理与改绘。

换言之，第一章承担的不只是“简单介绍研究背景”的功能，而是要把本文后续所有技术选择的理由讲清楚。为什么不是直接从零开始做目标域检测？为什么不是只做单纯分类？为什么需要改进 YOLO，而不是只做数据增强？为什么要引入 CAM 与伪框，而不是一开始就全面人工框标注？这些问题都必须在绪论中给出有依据的回答，否则后

续第 4 章和第 5 章中的方法设计就会显得缺乏问题导向。正因如此，本文将第一章写成一条逐层推进的逻辑链：先讲清楚行业背景，再梳理技术发展，再归纳当前瓶颈，最后自然引出本文研究内容和创新点。

从这一意义上说，绪论并不是全文中最“虚”的部分，反而是后续方法章节是否站得住的基础。若第一章不能把研究对象、文献谱系、问题来源和本文切入点讲清楚，那么第 4 章提出的改进检测模型就容易被理解为随意加模块，第 5 章提出的跨域迁移策略也容易被理解为工程性补丁。正因为如此，本文在绪论部分刻意保留较多文献梳理与问题分析篇幅，以确保研究主线从一开始就具备充分的论证基础。

进一步看，本文的研究对象还具有一个容易被忽视的特点，即“业务问题与算法问题高度耦合”。在通用视觉任务中，研究者往往可以把数据、模型和部署看作相对独立的层次；但在地下排水管道场景中，很多算法选择本身就是由业务流程决定的。例如，是否要做前级筛帧，取决于正常帧比例与人工复核压力；是否要采用源域预训练，取决于目标域是否存在足够框标注；是否要引入 CAM 候选区域，取决于分类模型能否为后续低标注检测提供有效先验^{[23][8][3]}。正因为这种强耦合关系的存在，绪论部分必须把问题定义得更完整，后续章节才不会显得“方法有了，但来龙去脉不清楚”。

与此同时，本文也不回避一个现实事实：在当前 sewer defect detection 研究中，许多看上去“先进”的方法，最终未必能成为工程主流。其原因并不一定是精度不高，而往往是数据要求过高、复现门槛过高、对目标域适应不足或解释成本过高^{[14][1]}。因此，本文在问题设定上选择了一条更加稳健的路线，即在保留研究深度的同时强调实现可控、实验可验证和工程可落地。这样的研究定位，也决定了后续章节会更加重视基线选择依据、迁移路径合理性和系统级评价，而不仅仅是单点精度对比。

由此可见，第一章不仅需要完成“交代背景”的任务，还要承担“限定问题边界”和“建立后文解释框架”的职责。换句话说，绪论写得是否扎实，直接决定后续方法章和实验章能否被理解为一个完整研究，而不是若干技术环节的松散堆叠。这也是本文坚持以较大篇幅梳理发展脉络、文献谱系和现实瓶颈的根本原因。

1.4 本文研究内容

围绕地下排水管道 CCTV 图像缺陷检测中的实际需求和现有研究空白，本文拟开展如下工作。

1. 构建面向跨域迁移的源域单标签分类数据集与目标域六类结构性缺陷检测数据集。具体而言，利用 Sewer-ML 公开数据构建面向源域表征学习的单标签六类分类数据集，同时面向目标域工程场景建立六类结构性缺陷检测类别体系，并形成源域类别、目标域类别与最终检测任务之间的映射关系。
2. 设计前级高召回预筛与后级精确检测相结合的总体框架。针对真实巡检场景中正常帧占比高、视频帧冗余显著和全量精检成本偏高的问题，引入分类预筛与候选区域生成机制，为后续精确检测缩小搜索空间并降低误报累积风险。
3. 提出一种基于改进 YOLOv11 的地下排水管道缺陷检测方法。围绕特征表达不足、多尺度缺陷识别困难和类别不均衡等问题，从注意力机制、检测头和损失函数三个层面对基线模型进行协同改进，形成适配 sewer defect detection 场景的检测网络。

4. 提出一种源域分类预训练与目标域微调相结合的跨域迁移适应训练策略。通过源域单标签分类任务学习管道缺陷通用表征，再在目标域图像级或检测级任务上进行微调，并结合 CAM 候选区域生成与伪框增强流程，提升目标域有限样本条件下的模型适应能力。
5. 构建由源域分类实验、目标域微调实验、CAM 可视化、伪框构建实验、检测对比实验、消融实验、迁移实验和错误分析组成的完整实验体系，从精度、召回、误报控制、训练稳定性和跨域泛化等多个维度验证所提方法的有效性。

从研究组织形式看，本文并不将分类、热力图、伪框、检测与迁移视为若干互不相关的技术堆叠，而是围绕同一主线逐步推进。首先，源域单标签分类用于学习更稳定的 sewer 场景特征；其次，目标域微调和 CAM 热力图用于将源域知识逐步对齐到目标域，并生成低成本候选框；再次，在此基础上训练并改进 YOLOv11 检测器，形成面向本地场景的精确检测能力；最后，通过迁移实验、消融实验和系统级分析，验证整条路线的有效性与工程可实施性。这种从“源域知识获取”到“目标域检测落地”的递进关系，是本文后续章节展开的基本逻辑。

1.5 本文主要创新点

本文的主要创新点概括如下。

1. 提出一种面向地下排水管道缺陷场景的改进 YOLOv11 检测方法。该方法不是简单替换单一模块，而是从注意力机制、检测头和损失函数三个方面进行协同优化，针对 sewer defect detection 中小目标、弱纹理、边界模糊和背景干扰强等问题提升模型的检测精度与鲁棒性。
2. 提出一种源域预训练与目标域微调相结合的跨域迁移适应训练策略。该策略利用公开 Sewer-ML 数据建立源域缺陷表征能力，再通过目标域分类微调、CAM 候选区域生成和低标注检测训练实现从源域到目标域的知识迁移，缓解目标域框标注不足和域差明显带来的性能损失。

需要说明的是，本文中的高召回预筛、CAM 热力图和伪框构建并不被单独定义为独立创新点，而是作为支撑上述两个核心创新点落地的重要工程链条。这样的安排既有助于保持论文主线清晰，也更符合硕士学位论文强调“方法创新 + 系统验证 + 工程可落地性”的整体写作逻辑。

1.6 论文结构安排

全文共分为七章，各章主要内容如下。

1. 第 1 章为绪论，介绍研究背景与意义、国内外研究现状、现有研究存在的问题、本文研究内容、创新点以及全文结构安排，重点构建从人工 CCTV 判读到深度学习排水管道缺陷检测，再到跨域迁移与改进 YOLOv11 切入点的完整问题链条。
2. 第 2 章为相关理论与关键技术基础，系统阐述地下排水管道缺陷图像特征、目标检测基础理论、YOLO 系列方法演进、注意力机制、损失函数与迁移学习理论，为后续方法设计提供理论支撑。

3. 第 3 章介绍数据集构建与总体框架，说明源域与目标域数据来源、源域单标签分类数据集构建、目标域类别映射、CAM 伪框流程以及高召回预筛与后级精检的整体系统设计。
4. 第 4 章介绍基于改进 YOLOv11 的地下排水管道缺陷检测方法，从注意力机制、检测头和损失函数三个方面阐述改进思路与整体模型设计，是本文的核心方法章节之一。
5. 第 5 章介绍面向跨域场景的迁移适应训练策略，重点说明源域分类预训练、目标域微调、候选区域生成以及检测阶段迁移训练方法，是本文第二个核心研究章节。
6. 第 6 章为实验结果与分析，通过源域分类实验、检测对比实验、模块消融实验、跨域迁移实验及可视化错误分析，对本文方法的有效性进行系统验证。
7. 第 7 章总结全文工作，概括研究结论，分析存在的不足，并对地下排水管道缺陷智能检测的后续研究方向进行展望。

第 2 章 相关理论与关键技术基础

2.1 地下排水管道缺陷类型与图像特征分析

2.1.1 地下排水管道缺陷类型

地下排水管道缺陷并非单一视觉对象，而是与结构状态、接口关系、材料老化、周边环境侵入和运行工况共同相关的一组病害表现。不同研究和不同地区标准在缺陷细分类上存在差异，但从视觉检测任务角度看，大体可以归纳为破损裂缝类、表面损伤类、接口异常类、变形类、侵入类和渗漏类等结构性问题，以及沉积、附着、障碍物和树根等影响过水能力的功能性问题^{[26][24][6][7]}。由于本文最终目标是面向目标域结构性病害检测，因此在任务层面将目标域检测类别收缩为 CrackBreak、SurfaceDamage、Deformation、JointDislocation、Intrusion 和 Infiltration 六类，并在前级分类与预筛阶段保留 Normal 作为显式正常类。

这样的类别收缩并不是对 sewer defect taxonomy 的简单删减，而是围绕检测任务可实施性、类别语义稳定性和目标域标注可获得性进行的任务化设计。首先，结构性病害在工程维护中通常优先级更高，其检测结果更直接服务于维修决策；其次，部分功能性缺陷与构造信息在视觉上更接近环境状态或运行工况，直接纳入检测主任务容易造成语义混淆；再次，源域数据中的多标签信息与目标域数据中的检测标签并非严格一一对应，因此必须通过更稳定的映射规则来支撑后续跨域迁移^{[6][13][8]}。这种“源域类别较粗、目标域检测类别冻结”的思路，也是本文后续层次化数据构建和跨域训练的前提。

从视觉实体属性看，六类结构性病害具有明显不同的识别难点。CrackBreak 常表现为细长裂缝、断裂边缘或局部破损，依赖于局部纹理与轮廓的精细感知；SurfaceDamage 通常表现为腐蚀、磨损、表面剥蚀等区域性异常，边界往往不清晰，容易与普通壁面纹理混淆；Deformation 更接近整体几何形态变化，其异常并不总是局限于小区域，而可能体现在局部截面变圆、变扁或弯曲上；JointDislocation 与 Intrusion 则更依赖接口上下文和结构关系；Infiltration 往往是低对比度渗流痕迹，对光照与水膜变化极为敏感^{[11][9][12]}。正因如此，排水管道缺陷检测不能将所有类别视为同质对象，而必须从特征表达和训练目标设计上兼顾不同病害的视觉属性差异。

2.1.2 缺陷图像特征分析

地下排水管道图像具有明显不同于自然图像和一般工业图像的视觉属性。首先，摄像头通常工作于封闭狭长空间，照明由巡检设备自带光源提供，因此图像中普遍存在中心高亮、边缘衰减、局部反射和不均匀曝光现象。其次，管壁表面往往附着水渍、泥膜、沉积物和裂缝阴影，这些背景因素会在纹理层面与真实缺陷形成耦合，增加模型区分难度^{[26][24][14]}。再次，巡检设备在管道内移动时会产生轻微抖动、压缩噪声和运动模糊，使得视频连续帧既存在冗余，又存在单帧质量波动。

如果进一步从数据获取链条分析，缺陷图像特征并不只由病害本身决定，还受到成像系统和载体平台影响。多传感器 sewer inspection 研究表明，当采集系统从单一摄像头扩展到多传感融合或机器人平台时，图像质量、观察角度、局部遮挡和几何稳定性都会发生变化，进而影响后续模型对缺陷显著性的判断^[46]。这一结论对于本文具有直接启示：目标域图像分布并不是静态不变的，而是与设备条件和巡检策略绑定，因此后续跨域迁移章节必须把“设备差异”和“成像条件差异”视为 domain gap 的组成部分，而

不能只从视觉风格层面抽象理解域差。

从目标尺度角度看,许多管道缺陷只占图像中的极小区域,这使得特征提取网络在连续下采样过程中极易丢失关键细节。对于细小裂缝、薄层渗漏和轻微错口而言,即使在原始图像中仍可人工辨识,但经过卷积和池化后,判别性纹理可能被背景噪声淹没^{[15][9][10]}。因此,在 sewer defect detection 中,模型不仅需要较强的深层语义能力,更需要保留足够细致的局部结构信息。

从目标形态角度看,排水管道缺陷存在“细长”“弥散”“局部接口异常”和“整体几何异常”并存的现象。裂纹和破损常呈线状或不规则块状,侵入与错口常集中出现在接口附近,变形则更多体现为局部截面轮廓异常,渗漏则常表现为低对比拖尾或局部湿痕。这些差异意味着单一尺度、单一感受野或单一纹理偏好的网络结构很难同时对所有类型取得均衡效果^{[11][4][5]}。这也是本文后续关注多尺度特征融合、注意力重加权 and 检测头适配的重要原因。

此外,排水管道巡检场景还具有显著的样本分布不均衡特征。一方面,正常帧远多于缺陷帧,且许多正常帧与轻微异常帧之间差异极小;另一方面,不同缺陷类别样本数量差距显著,少数类病害往往最具工程危害,却在数据中最为稀缺^{[13][16]}。这一分布特性会进一步放大检测训练中的类别偏置,使模型更倾向于学习多数类与背景模式,而忽视少数类、小目标和边界模糊目标。

综合而言,地下排水管道缺陷图像具有小目标、弱纹理、复杂背景、多尺度、多形态、强场景噪声和长尾分布等多重困难。上述特征决定了后续模型设计必须同时考虑以下问题:如何在特征提取阶段保留细粒度缺陷信息;如何在特征融合阶段增强上下文建模能力;如何在预测阶段提升小目标与相似类别的区分能力;以及如何在训练阶段缓解类别不均衡和定位偏差问题。后续第 4 章提出的改进 YOLOv11 模型,正是围绕这些理论问题展开。

进一步说,图像特征分析不仅是对“缺陷长什么样”的描述,更是后续方法设计的直接约束来源。例如,如果任务难点主要来自局部细纹理目标,那么模型就应增强局部响应;如果任务难点主要来自接口结构关系,那么模型就不能只依赖局部卷积窗口;如果任务难点主要来自背景伪激活,那么模型就需要更强的显著性抑制与候选区域筛选能力^{[11][4][1]}。因此,本节分析并不是形式上的背景介绍,而是在为后文注意力机制、检测头改进和跨域策略设计提供直接理论依据。

2.2 目标检测基本理论

2.2.1 目标检测任务定义

目标检测任务要求模型同时完成目标类别识别与空间定位。对于输入图像,模型需要输出若干边界框、对应类别及其置信度分数。从任务属性上看,目标检测比图像分类更复杂,因为它不仅要回答“图像里有什么”,还要回答“它在哪里”和“边界大致如何”。在地下排水管道场景中,这一任务复杂性进一步提升,因为许多缺陷边界本就不清晰,且单图中可能同时存在多个弱显著性目标或不同类型病害^{[15][12]}。

按照候选区域生成方式不同,目标检测方法通常分为两阶段检测器和一阶段检测器。两阶段检测器以 R-CNN 为代表,先生成候选区域,再对候选区域进行分类与边界框回归,具有较强的精细识别能力^[31]。一阶段检测器则以 SSD 和 YOLO 系列为代表,将分类与回归统一到同一网络中,具备更好的速度优势和工程部署便利性^{[32][33]}。此外,DETR 等基于 Transformer 的 end-to-end 方法则从集合预测角度重构目标检测流程,试

图在统一框架中完成目标匹配与预测^[44]。

对 sewer defect detection 而言，检测器选择不仅是算法精度问题，更是系统效率问题。由于巡检视频规模大、正常帧多且工程部署常有实时或准实时需求，具有较高推理效率的一阶段检测器通常更适合作为主干技术路线^{[9][10][2]}。但与此同时，一阶段检测器在小目标、长尾类别和复杂背景场景中也面临表征不足与误报偏高问题，因此需要通过特征增强、注意力重加权和训练目标优化来补足其短板。

2.2.2 目标检测方法演进

从发展脉络看，目标检测经历了从候选区域驱动到统一回归、再到端到端集合预测的演进过程。R-CNN 系列的出现标志着深度学习检测进入主流研究阶段，其核心思想是先生成候选区域，再对每个候选区域提取深度特征并进行分类^[31]。这一范式显著优于传统滑动窗口方法，但速度较慢，难以满足大规模视频和工程部署需求。SSD 将多尺度检测引入单阶段网络，使检测速度和精度取得较好平衡^[32]；YOLO 则进一步强调统一回归和实时性，在工业场景和嵌入式部署中获得广泛应用^[33]。

近年来，目标检测研究一方面继续沿着 YOLO 家族进行结构迭代，提升速度与精度平衡；另一方面也沿着 Transformer 路线发展，试图构建更统一的端到端框架^{[44][2]}。对于本文关注的排水管道场景而言，这一演进带来两个启示：第一，检测器已经具备较成熟的通用结构基础，因此研究重点不应停留在重新发明一个全新的通用框架，而应考虑如何针对 sewer defect 的任务特征进行适配性优化；第二，不同检测范式各有优劣，选择具体基线模型时需要兼顾工程效率、训练稳定性和后续改造空间。基于此，本文最终选择 YOLOv11 工程实现作为基线平台，并在此基础上展开有针对性的模型改进。

2.2.3 常用评价指标

目标检测模型通常使用 Precision、Recall、F1 和 mean Average Precision 等指标进行评估。设真正例、假正例和假负例分别为 TP 、 FP 和 FN ，则 Precision 和 Recall 可表示为

$$Precision = \frac{TP}{TP + FP}, \quad Recall = \frac{TP}{TP + FN}. \quad (2.1)$$

其中，Precision 反映模型预测结果的准确性，Recall 反映模型对真实缺陷样本的覆盖能力。对于排水管道缺陷检测而言，Recall 尤其重要，因为漏检真实病害可能直接影响后续维护决策；但若 Precision 过低，又会显著增加人工复核成本。因此，二者需要结合分析，而不能单看某一个指标^{[12][2]}。

在综合评价方面，本文后续实验主要采用 $mAP@0.5$ 与 $mAP@0.5 : 0.95$ 。前者在 IoU 阈值为 0.5 时评估检测精度，更接近工程中“是否大致检出缺陷”的需求；后者在多个 IoU 阈值下求平均，更能反映模型对边界定位的稳定性。对 sewer defect detection 来说，由于部分缺陷边界天然模糊，过高 IoU 阈值下的评价结果通常更苛刻，因此两类 mAP 指标都需要结合解释。

除通用检测指标外，排水管道工程场景还常需关注单图误报数、每视频误报数、正常帧误报率和筛帧召回率等系统级指标^{[23][22]}。原因在于真实巡检业务不仅关注“在测试集上是否更准”，还关注“在长视频与海量正常图像中是否足够省人、省时和可复核”。因此，本文后续实验在报告标准检测指标的同时，也会结合系统级误报控制效果进行分析。

2.2.4 多尺度表示与后处理机制

在目标检测任务中，多尺度表示是提高小目标与大目标同时识别能力的关键机制。SSD 的多尺度预测思想和后续各类特征金字塔结构，都体现出一个基本事实：不同尺度目标在网络不同层级上具有不同的最佳表征位置^[32]。对于 sewer defect detection 而言，这一点尤为重要，因为裂缝、错口、侵入和变形在尺度、形态和上下文依赖上差异很大。如果网络仅依赖单一层特征进行预测，就很容易造成小目标遗漏或结构异常识别不足。

除多尺度表示外，后处理机制同样会影响最终检测结果。无论采用何种检测器，网络通常都会输出大量候选框，随后通过置信度阈值、IoU 判定和非极大值抑制等方式剔除冗余预测。对于排水管道场景，后处理不只是技术细节，而是误报控制的重要一环。因为缺陷目标常常靠近、边界模糊甚至存在多个相关激活区域，若后处理策略过于激进，可能压掉真实缺陷；若过于宽松，又可能产生大量相邻误报框。因此，检测器的最终性能不仅由特征学习决定，也由后处理策略影响^{[12][2]}。

这一点对本文后续实验设计也有启示。本文不会仅将检测性能归因于网络主体，而会把输入尺寸、候选框筛选、置信度阈值和系统级误报控制一并纳入分析。这种写法更符合真实工程场景，也能避免把本应属于系统设计的问题误写成单纯网络结构问题。

2.2.5 小目标检测与密集背景场景难点

地下排水管道缺陷检测与通用目标检测相比，最大的区别之一在于目标往往并不“显眼”。在自然图像中，很多检测对象具有清晰轮廓和相对稳定的尺度，而在 sewer 场景中，裂缝、渗漏、轻微错口等目标不仅尺寸小，而且经常被复杂背景纹理所包围。这种“目标弱、背景强”的特性会导致网络在训练中更容易学习到背景统计规律，而不是缺陷本身的判别模式^{[15][11][1]}。

小目标检测的困难还体现在有效像素占比低。对网络而言，如果目标区域在特征图上只对应极少数响应单元，那么任何轻微的下采样、模糊或背景激活都可能导致目标信息丢失。正因为如此，许多 sewer detection 研究都会强调更高输入分辨率、更合理的特征融合或更敏感的关键区域增强机制^{[9][10][2]}。本文后续实验在设置输入尺寸和改进模块时，也将围绕这一理论问题展开。

此外，密集背景场景中的误报问题与小目标漏检问题往往同时存在。也就是说，一个模型可能通过放宽阈值提升召回，但随后又在大量背景区域上产生伪激活；反之，若过于保守，又会错过真正的弱显著性病害。这种矛盾决定了 sewer defect detection 不能只追求单一指标最优，而需要在特征增强、后处理策略和系统级误报控制之间形成平衡。

2.2.6 一阶段检测器在工程任务中的优势与边界

从工程部署角度看，一阶段检测器之所以在排水管道场景中更受青睐，并不仅仅是因为速度快，还因为其训练和部署链条更短、更易于与现有巡检流程集成。相较于两阶段方法，一阶段检测器通常更容易与大规模图像批量处理、前级筛帧和边缘端部署结合，这对于巡检视频处理尤其重要^{[33][9][10]}。在大量正常帧存在的条件下，快速给出较稳定的候选结果，本身就具有系统价值。

但与此同时，一阶段检测器也存在天然边界。其统一回归机制虽然提升了效率，却可能在极端小目标、边界模糊目标和类别极不均衡场景中遭遇表达不足问题。尤其当目标和背景之间不存在显著外观差异时，一阶段方法容易出现“对简单场景有效、对复杂场景保守”的现象^{[2][1]}。因此，本文选择一阶段检测器并不意味着忽视其局限，而是基于工程适配性将其作为基线，并通过后续改进尽可能弥补其短板。

从更一般的小目标检测研究出发，这种局限具有明确的理论来源。相关综述指出，小目标在卷积网络中的困难主要体现在三方面：其一，连续下采样会迅速削弱局部纹理信息，使小目标难以在高层语义特征中保留足够判别线索；其二，目标本身占图像面积很小，背景统计特征更容易主导梯度更新；其三，小目标常常更依赖上下文和结构关系，而不只是自身外观^[49]。这三点与 sewer defect detection 的任务特征高度吻合，因此后续对注意力机制、检测头和特征融合路径的设计，本质上都是围绕“小目标信息保持”这一理论命题展开。

进一步地，Dynamic Feature Focusing Network 的研究说明，小目标检测并不是简单提高输入分辨率就能解决的问题，更关键的是模型能否在不同层级特征之间动态分配关注重点，并抑制大背景区域对训练的干扰^[50]。这对于排水管道场景尤其重要，因为许多缺陷不仅小，而且与背景纹理共存，若特征网络缺乏动态聚焦能力，模型就容易在表面纹理、反光边缘和污渍区域产生伪激活。由此可见，第 4 章中的模型改进不应被理解为单纯的结构堆叠，而应被理解为围绕“小目标与复杂背景”理论难点展开的场景化适配。

这一选择逻辑也体现出本文的整体研究态度：不是为了追求形式上的“最先进”而盲目更换模型范式，而是围绕任务需求选择更合适的基线，再在此基础上进行场景化优化。这种做法更符合硕士论文的研究边界，也更容易在后续实验中形成清晰可验证的比较关系。

2.3 YOLO 系列方法与 YOLOv11 基线分析

2.3.1 YOLO 系列方法的发展逻辑

YOLO 的基本思想是将目标检测视为统一回归问题，在单个网络中同时输出类别概率和目标位置，从而兼顾检测精度与实时性^[33]。这一思想非常适合需要快速处理大量巡检图像的 sewer 场景。经过多代迭代，YOLO 系列逐渐在多尺度特征融合、标签分配策略、损失函数设计和工程部署效率方面不断改进，使其成为工业视觉领域最常用的目标检测技术路线之一。

对本文而言，YOLO 系列的价值不在于某一代模型本身，而在于其一阶段统一检测范式与较强工程适配性。相比候选区域驱动的两阶段方法，YOLO 更适合处理长视频、大规模样本和需要快速迭代训练的业务环境^{[9][10]}。此外，YOLO 系列拥有成熟的工程实现与活跃生态，便于后续结合分类预训练、CAM 候选区域生成和低标注增强开展完整实验流程。

需要指出的是，YOLOv11 目前更多是以工程框架与实践版本的形式存在，而非已经形成统一学术定义的单篇经典论文。因此，本文对 YOLOv11 的讨论主要基于 YOLO 系列方法发展逻辑和其在 Ultralytics 工程实现中的通用结构特征展开，而不是将其视为与 YOLOv1 或 SSD 类似的单篇基础文献。换言之，本文真正关注的是“为何选择 YOLO 系列作为基线”以及“为何需要针对 sewer defect detection 对该基线进行改进”。

从方法演化逻辑看，YOLO 系列之所以适合作为本文基线，不仅因为它快，还因为它已经形成一种相对成熟的工程研究范式：先在统一框架上建立可复现基线，再围绕特征表达、neck 融合、head 设计和损失函数逐项开展针对性优化^{[9][47][48]}。对于硕士论文而言，这种范式尤其重要。它能够保证研究工作建立在清晰的对照链之上，避免因频繁更换底座模型而导致实验解释失焦。本文后续选择在 YOLOv11 基线上展开改进，正是希望在保持工程实现稳定性的前提下，把研究重点集中到 sewer 场景真正困难的环节

上。

还需要指出的是，选择 YOLO 系列作为基线并不意味着忽视其它范式，而是意味着在研究边界内优先选择更适合形成闭环验证的技术底座。Transformer 路线在统一建模和全局关系建模上具有明显优势，但其训练代价、数据需求和调参复杂度也相对更高^{[44][2]}。对于本文所面对的 sewer defect detection、小样本目标域迁移和低标注伪框增强任务而言，若底座模型过于复杂，后续很难清晰区分“模型范式差异”与“场景化改进收益”各自贡献。因此，采用更成熟的一阶段基线，有助于把研究重点稳定落在 sewer 场景真正困难的部分。




图 2.1 YOLO11 检测模型结构示意图

注：根据 Ultralytics 官方公开结构关系整理与改绘^[57]。

2.3.2 YOLOv11 基线结构的任务适配性

从功能上看，YOLO 系列工程实现通常由主干特征提取、颈部特征融合和检测头三部分构成。主干网络负责提取层级化视觉特征，颈部结构负责聚合多尺度语义与细节信息，检测头负责输出类别分数和边界框回归结果。这种结构天然适合小目标与多尺度目标混合场景，因为不同尺度特征可以在融合后共同参与预测^{[32][33][44]}。然而，面对 sewer 场景中的弱纹理小目标和结构关系异常，仅依赖通用多尺度融合往往仍然不够。

一方面，管道缺陷中有相当一部分需要依赖局部纹理细节才能识别，如裂缝、表面损伤和渗漏；另一方面，另一些缺陷则依赖较大范围结构关系，如接口错位、侵入和整体变形^{[11][4]}。这意味着模型既需要较强局部感知能力，也需要一定全局上下文建模能力。如果主干与特征融合对关键区域关注不足，则容易在背景噪声中丢失缺陷信号；如果检测头对相似类别分界刻画不足，则容易产生类间混淆。

此外，YOLO 系列在工程上强调速度与轻量化，这虽然有利于部署，却也意味着部分场景下精细表征能力可能不足。已有 sewer defect detection 研究不断通过引入注意力模块、优化 neck、增强 head 或调整损失函数来弥补这一短板，说明通用 YOLO 基线在 sewer 场景下仍有较大改造空间^{[9][10][12][45]}。因此，本文选择 YOLOv11 作为基线，不是因为其天然最优，而是因为它在精度、速度和工程生态之间具有较好平衡，同时保留了足够清晰的改进接口。

2.3.3 YOLOv11 在排水管道缺陷场景中的局限性

尽管 YOLO 系列具有较强实用性，但在地下排水管道场景中仍存在若干局限。其一，对细小缺陷和弱纹理目标的显著性建模仍不充分，导致裂缝、轻微破损和渗漏等病害容易漏检。其二，复杂背景下的误激活问题较为突出，尤其是在水膜、污渍和壁面纹理与缺陷纹理相近时，模型容易产生假阳性预测。其三，相似类别之间的决策边界不清晰，例如表面损伤与轻微破裂、侵入与接口异常之间容易混淆。其四，在类别不均衡和目标域样本稀缺条件下，训练过程对难样本和少数类的关注不足，影响最终泛化能力^{[15][11][14][2]}。

这些局限直接说明，若仅仅把通用 YOLO 基线拿来直接微调，很难在目标域上获得稳定、可解释且误报可控的检测效果。相应地，后续第 4 章从注意力机制、检测头和损失函数三个方面开展改进，并非为了追求形式上的“模块堆叠”，而是为了逐项回应上述局限：注意力机制对应关键区域增强与背景抑制，检测头优化对应小目标和相似类别的预测能力提升，损失函数优化对应类别不均衡与定位偏差问题缓解。

2.3.4 基线模型的可改进位置分析

从理论上讲，YOLO 基线的改进空间主要集中在三个位置。第一，是特征提取与特征融合阶段，这一阶段决定网络能否保留足够丰富的局部纹理与全局结构信息；第二，是检测头阶段，这一阶段决定网络如何将融合特征转化为类别与位置预测；第三，是训练目标阶段，这一阶段决定网络在长尾分布、难样本和定位偏差条件下如何学习^{[9][10][34][43]}。

对于 sewer defect detection 场景，三者之间并不是独立关系。假如特征层没有突出关键缺陷区域，那么检测头再复杂也难以恢复有效信息；假如检测头无法有效区分相似类别，那么再强的主干特征也难以转化为正确分类；假如损失函数无法让训练过程关注少数类和难样本，那么前两者的优势也会被训练偏置削弱。因此，本文后续将模型改进表述为“协同优化”，而不是“单模块替换”。

这种写法也更符合硕士论文的研究逻辑。因为本文真正要回答的问题并不是某一个模块在通用场景下是否更强，而是这些模块性改动为什么能共同作用于地下排水管道缺陷检测任务，并最终改善目标域性能与跨域泛化能力。

2.3.5 特征金字塔、感受野与上下文建模

从理论上讲，小目标检测并不只是“把图像放大”这么简单，更关键的是如何在不同感受野之间建立有效协同。感受野过小，模型难以理解接口关系和局部结构异常；感受野过大，又可能把真实缺陷稀释在大范围背景之中。特征金字塔与多尺度融合结构的作用，正是帮助网络在不同层级上同时保留局部纹理与更大范围的上下文信息^{[32][44][11]}。

在 sewer 场景中，这种局部-全局协同尤为重要。以 JointDislocation 和 Intrusion 为例，如果网络只看局部纹理，可能只能看到边缘和噪声；但如果结合更大范围接口结构关系，就更容易判断该区域是否异常。相反，像 CrackBreak 这类缺陷若缺乏局部高分辨率表达，又很容易在大感受野特征中被抹平。因此，多尺度特征融合不只是提高“不同大小目标”的检测能力，更是在为不同视觉成因的缺陷提供差异化表征路径。

这也解释了为什么后续改进模型不能只在主干网络上做局部增强，而必须把特征融合和检测头一并考虑。否则，即使主干提取到某些有用信号，也可能在后续融合与预测阶段被削弱。




图 2.2 本文理论基础与方法响应关系图

注：作者根据小目标检测、注意力机制、损失函数设计与迁移学习相关文献整理绘制^{[49][35][36][34][40][42]}。

2.4 小目标检测与复杂背景建模理论

2.4.1 小目标信息保持理论

小目标检测的核心难点在于信息密度不足。一个目标如果在原图中只占据极少数像素，那么在多次下采样之后，其有效响应可能只剩下极少数特征单元，稍有噪声干扰便会被背景淹没。这一问题在 sewer defect detection 中尤为突出，因为很多病害并不是独立的大块异常，而是裂纹边缘、局部渗漏痕迹或接口附近的细微结构变化^{[15][11][5]}。因此，小目标检测理论的第一要点，是尽可能在网络前中层保留细粒度信息，并避免在过早下采样中损失关键特征。

从实践上看，提高输入分辨率、多尺度特征融合和关键区域重加权，都是围绕“小目标信息保持”这一目标展开的不同实现路径^{[32][9][10]}。其中，提高输入分辨率可以直接增加目标像素占比，但会增加训练和推理成本；多尺度融合可以把不同层特征联合起来，但设计不当时也可能引入冗余噪声；注意力与显著性增强则有助于在有限分辨率下突出关键区域。因此，针对 sewer 场景的小目标检测优化，通常需要多种策略协同，而不是依赖单一技巧。

2.4.2 复杂背景抑制理论

复杂背景抑制问题的本质，是如何让模型区分“看起来像缺陷”的纹理和“真正属于缺陷”的区域。在排水管道图像中，反光、水膜、污渍、沉积附着、拍摄阴影和壁面纹理都会产生类似缺陷的视觉模式^{[26][24][14]}。因此，一个检测模型如果只追求局部显著性增强，而缺乏足够上下文约束，就很容易把背景干扰误当成缺陷目标。

复杂背景抑制通常依赖两类信息。第一类是局部判别信息，即目标纹理与周围背景之间的差异；第二类是结构上下文信息，即该区域是否位于合理的接口、管壁或病害高发位置附近^{[11][4]}。对于 sewer defect detection 而言，两类信息缺一不可。若只看局部纹理，会把污渍或反光误检为病害；若只看结构上下文，又可能忽略真实细小裂缝。因此，复杂背景抑制实际上要求模型在不同尺度和不同上下文范围之间建立稳定协同。

2.4.3 显著性建模与误报控制关系

在排水管道巡检任务中，“显著性建模”与“误报控制”是紧密相关的两个概念。显著性建模解决的是模型是否能够突出关键区域，而误报控制解决的是模型是否会在大量背景上产生无效激活。很多时候，一个模型显著性越强，未必误报越低，因为它可能把背景中的高反差区域也一并放大。因此，真正有效的显著性建模不应只是“把响应抬高”，而应同时考虑背景抑制和类别判别稳定性^{[9][2][1]}。

这一点也与更广义工业表面缺陷检测研究形成呼应。系统综述指出，工业缺陷场景中大量误报并不来自模型完全“看不见缺陷”，而是来自模型把背景瑕疵、材质纹理和照明反射误解为缺陷，从而在检测环节放大了伪显著性^[51]。排水管道场景中的反光、水膜、污渍和阴影，本质上就是更复杂、更动态的“背景伪显著性”来源。换句话说，复杂背景抑制并不是 sewer inspection 的个别问题，而是缺陷检测理论中一个普遍而关键的难点；本文后续强调注意力重加权与误报控制，也是建立在这一更一般的理论背景之上。

这一关系也说明，后续第 4 章中引入注意力机制并不是单纯为了让特征图更“亮”，而是为了让有意义的区域更突出、无意义的区域更被抑制。把这一理论关系提前说明，有助于后续在实验分析中解释：为什么某些改进可能提高召回但同时带来误报，为什么另一些改进虽然精度提升有限，却能显著改善系统级复核效率。

2.5 注意力机制相关理论

2.5.1 注意力机制的基本思想

注意力机制的核心思想，是显式建模不同特征在当前任务中的重要性分布，使模型能够将有限表示能力优先分配给更有价值的通道、空间位置或局部区域。对于视觉任务而言，这种机制能够在特征图层面形成“哪里更重要、哪些通道更关键”的重加权过程，从而提升关键区域表征、抑制无关背景噪声。对于 sewer defect detection 这类目标弱、背景强、纹理易混淆的任务，注意力机制天然具有较高适配性^{[35][36][37]}。

从实现角度看，注意力机制大致可以分为通道注意力、空间注意力及其组合形式。通道注意力关注“什么特征更重要”，通过学习不同通道权重，增强与目标相关的语义表达；空间注意力关注“哪里更重要”，通过突出关键位置来强化局部区域响应；组合式注意力则兼顾二者，从而同时提升特征选择能力与区域聚焦能力^{[35][36]}。在本文面向的排水管道场景中，前者有助于强化缺陷纹理响应，后者有助于压制大面积背景干扰。

2.5.2 典型注意力模块及其特点

SE-Net 是通道注意力的经典代表，其核心思想是通过全局信息压缩和通道重标定，增强关键通道的响应^[35]。这一思想结构简单、插入成本低，适合在保持网络整体效率的同时提高重要语义通道的表达能力。CBAM 在 SE 的基础上进一步联合建模通道注意力与空间注意力，使网络同时关注“哪些特征重要”和“哪些区域重要”^[36]。ECA-Net 则进一步强调在保持较低参数开销的同时完成通道交互建模，适合对部署效率仍有要求的场景^[37]。

对于 sewer defect detection 而言，这些模块的意义不在于谁是“通用最优”，而在于它们分别代表了不同的注意力建模思路。若任务主要受背景噪声和局部误激活影响，则空间或联合注意力可能更有价值；若任务主要受特征选择不足影响，则轻量化通道注意力可能更具性价比。因此，后续改进模型中引入何种注意力模块，并不是随意添加，而

是要围绕 sewer 缺陷图像的干扰模式和目标形态特征展开。

2.5.3 注意力机制与局部-全局特征建模关系

在 sewer 场景中，注意力机制的价值还体现在协调局部与全局信息之间的关系。局部信息决定裂缝、剥蚀和渗漏等目标的纹理细节；全局信息则帮助判断接口位置、管壁走向和异常区域与周围结构的关系。若模型只依赖局部纹理，容易把污渍或反光误当成病害；若模型只依赖大范围语义，又可能忽略真实缺陷中的微小边界变化^{[11][4]}。因此，注意力机制的作用不仅是“让模型更专注”，更是帮助模型在不同尺度和不同上下文范围上重新分配感知资源。

从这个角度看，注意力模块并不是孤立存在的附加单元，而是对整个特征流进行再组织的工具。它既可以增强局部区域响应，也可以辅助多尺度特征在融合时形成更合理的权重分配。这也是本文后续为何将注意力机制放在模型改进的核心位置之一，而不是仅把它当作轻量化提升精度的小技巧。

2.5.4 注意力机制的引入原则

在实际模型设计中，注意力机制并不是插得越多越好。若模块过重、插入位置过多，虽然可能提升局部精度，却会增加训练难度和推理负担；若模块选择不当，也可能因为过分强调局部显著性而忽略整体结构关系。因此，在 sewer defect detection 这类兼顾精度和部署效率的场景中，注意力模块的引入必须遵循“问题驱动、位置明确、代价可控”的原则^{[35][36][37]}。

对于本文而言，这一原则具体体现为三点：一是优先考虑能够提升关键区域响应又不会显著破坏原始主干结构的模块；二是优先放置在对多尺度特征影响较大的位置，而非随意堆叠；三是评估其对后续检测头和损失设计的协同作用。将这一原则提前在理论章节中说明，有助于后续第 4 章的方法设计显得更加克制和有针对性。

2.5.5 注意力机制的局限与选择依据

注意力机制并非没有代价。首先，过强的显著性增强可能导致模型对少量局部区域过度敏感，从而放大噪声响应；其次，一些复杂注意力模块会增加参数量和推理时延，与工程部署需求相冲突；再次，不同任务对注意力类型的需求并不相同，在一个任务上有效的模块，在另一个任务上未必同样有效^{[35][36][37]}。因此，在 sewer defect detection 场景中，注意力模块的价值必须建立在明确的任务问题和实验验证基础之上。

对本文而言，选择注意力机制的依据主要有三点。第一，模块是否能够对复杂背景中的关键区域形成更稳定响应；第二，模块是否与现有基线结构兼容，便于与检测头和损失函数共同优化；第三，模块是否具有可接受的计算开销，不会因为局部精度提升而显著损害整体部署效率。将这些依据明确写入理论章节，有助于后续方法章节保持研究克制，避免出现“看到什么模块流行就往模型里加什么”的问题。

2.5.6 注意力机制在缺陷检测中的作用

在缺陷检测任务中，注意力机制通常承担三个方面作用。第一，增强目标显著性，使网络更容易从复杂背景中突出真实病害区域；第二，缓解不同尺度和不同形态目标之间的表示冲突，使特征融合阶段更容易保留关键信息；第三，提升对相似类别间细微差异的敏感性，从而降低误分类概率^{[9][10][4]}。这些作用与本文研究对象高度契合，因此注意力机制构成第 4 章模型改进的重要理论支撑。

但也正因为注意力机制会显式改变特征分布，它与检测头和损失函数之间存在天然

耦合关系。如果注意力模块强化的是错误区域，那么后续检测头会在更偏置的特征上做决策，损失函数也会进一步放大这种偏差；反之，若注意力增强能够稳定聚焦真实病害区域，则检测头和损失优化的收益会更容易被释放。因此，本文在后续方法章中不会把注意力模块写成独立于其它改进之外的“孤立增强项”，而是将其放在协同优化框架下理解，这也与近年来 improved YOLO 在 sewer 和 pipeline defect detection 中越来越强调模块联动的趋势相一致^{[47][55][45]}。

换言之，注意力机制在本文中的理论定位并不是“为了让模型更复杂”，而是为了使特征表达更符合 sewer 缺陷识别的视觉成因。若后续实验能够证明某类注意力机制在 CrackBreak、Infiltration 或 JointDislocation 等目标上更有效，那么其解释不应停留在“这个模块更先进”，而应回到本章已经讨论过的小目标保持、背景抑制和局部-全局协同这些理论事实上。这样的写法也有助于让第 4 章的实验分析更具解释力度，而不是停留在简单的性能差异罗列。

2.6 检测头改进与损失函数设计相关理论

2.6.1 检测头设计的作用

检测头是将融合特征映射为最终类别和位置预测的关键模块，其结构设计直接影响模型的最终识别能力。对于 sewer defect detection 而言，检测头不仅需要处理小目标与多尺度目标，还要面对弱纹理目标、类间边界模糊和局部结构关系复杂等问题^{[11][12]}。如果检测头过于依赖粗粒度语义信息，则容易忽视局部细节；如果检测头对不同类别共享相同预测模式过多，则容易在结构相似类别间出现混淆。

已有研究表明，针对小目标和复杂背景任务，对检测头进行适配性调整往往能够带来比单纯扩大主干更直接的收益^{[9][10][2]}。这是因为检测头处于最终决策层，直接决定类别分数与边界框回归质量。对于本文而言，后续改进检测头的理论依据，在于通过更合理的预测分支组织与特征利用方式，提高模型对细粒度缺陷的分类判别力与边界定位能力。

从更一般的缺陷检测理论看，检测头优化之所以重要，还因为它是缓解“分类冲突”和“定位冲突”的关键位置。系统综述指出，在复杂缺陷检测任务中，很多误差并不是由于前端特征完全不足，而是由于最终预测分支无法把相似类之间的细微差别稳定地投射为分类分数，同时也无法把模糊边界转化为足够稳健的定位结果^[51]。这意味着第 4 章中对检测头的改进不应被理解为对现有结构的机械替换，而应被理解为让最终决策层更符合 sewer defect detection 的任务属性。

2.6.2 类别不均衡与难样本学习

目标检测中的另一个核心问题，是类别不均衡与难样本学习。Lin 等提出的 Focal Loss 指出，密集检测中易分类样本占比过高会压制难样本学习，导致模型更关注大量简单背景而忽视真正困难的目标^[34]。这一问题在 sewer defect detection 场景中尤为突出，因为正常背景极多，少数类缺陷和弱显著性缺陷相对稀缺。若损失函数对易分类背景样本过于敏感，则模型很容易形成偏向背景和多数类的决策倾向。

同时，边界框回归损失也会影响定位能力。GIoU 等工作从几何重叠关系角度改进边界框回归目标，为检测器提供了更合理的定位学习信号^[43]。在排水管道缺陷场景中，边界往往并不规则且目标区域较小，回归损失若对弱定位偏差过于宽松，则可能使最终检测框虽然“碰到目标”，却难以满足后续人工复核需求。因此，合理设计分类与回归损失的协同关系，是提升模型精度和训练稳定性的必要条件。

2.6.3 损失函数优化的任务意义

对于本文任务，损失函数优化至少具有三层意义。其一，缓解长尾分布造成的少数类学习不足；其二，提升对难样本、模糊样本和边界弱样本的关注程度；其三，在有限目标域样本条件下提高训练收敛的稳定性。换言之，损失函数不仅是数学形式上的细节设计，更是把“任务难点”显式编码进训练目标的重要手段。后续第 4 章对损失函数的改进，即建立在这一理论逻辑之上。

与此同时，损失函数设计还承担着“把系统目标翻译成训练目标”的作用。对于 sewer inspection 而言，工程上更关心的是少漏检、少误报和较低复核成本，而不是单一指标在离线测试集上的局部最优。因此，若训练目标无法反映少数类、难样本和边界模糊样本的重要性，模型即使在总体精度上看似不错，也可能无法满足真实巡检需要。正因如此，本文后续将损失函数优化与类别不均衡、误报控制和跨域训练稳定性放在同一逻辑框架下讨论，而不是只把它写成一段公式替换说明。

从这一角度看，损失函数优化也不应被理解为对现有公式的局部修补，而应被理解作为一种任务表达方式。因为在 sewer defect detection 中，不同错误的工程代价并不相同：漏掉严重缺陷和误报普通背景在业务上并不等价，少数类缺陷和多数类背景样本的重要性也不相同。只有当训练目标能够体现这种差异，模型才可能在真实巡检场景中表现出更合理的行为模式。这也是本文强调“损失函数与任务需求一致性”的原因。

2.6.4 标签分配与难样本学习理论

除损失函数本身外，检测训练还受到标签分配策略影响。所谓标签分配，是指在训练阶段如何确定哪些预测应被视为正样本、哪些应被视为负样本，以及不同尺度特征应如何承担不同目标的学习责任。对于排水管道缺陷这种小目标、弱目标和边界模糊目标并存的任务，标签分配若不合理，就可能导致真正困难的缺陷样本长期得不到有效监督，从而加剧漏检^{[34][43]}。

虽然本文后续不将标签分配单独列为核心创新点，但其理论意义不可忽视。因为注意力机制、检测头改进和损失函数优化，最终都要通过训练过程作用到模型参数上，而标签分配恰恰是连接预测结果与训练信号的重要桥梁。将其纳入理论章节，有助于后续解释为什么某些改进虽然结构简单，却能显著影响收敛速度和难样本识别效果。

2.6.5 分类、定位与后处理之间的协同关系

目标检测的最终效果并不是由分类分支、回归分支和后处理独立决定的，而是三者共同作用的结果。分类分支决定模型是否把某一区域视为潜在缺陷，回归分支决定该区域边界是否合理，后处理则决定多个候选结果如何被保留或抑制。如果三者的设计目标不一致，就会出现“分类看起来正确但框很差”或“框位置尚可但类别不稳定”的问题^{[34][43]}。

对 sewer defect detection 而言，这种协同关系尤为重要。因为很多缺陷天生边界模糊，检测框更多是“工程上可复核的近似区域”，而不是严格意义上的精确轮廓。因此，后续模型设计必须同时考虑类别稳定性、定位合理性和系统级误报控制，而不能只追求某一个局部指标的提升。把这一点写入理论章节，有助于后续实验分析时避免片面解读结果。

2.6.6 优化目标之间的冲突与平衡

在检测任务中,许多优化目标并不是天然一致的。提高召回率往往意味着放宽判定边界,但这可能带来更多误报;强化小目标检测能力可能需要更高分辨率和更复杂特征融合,但这又会增加训练与推理成本;增强少数类学习能力可能需要改变损失权重,却可能导致多数类稳定性下降^{[34][43][1]}。因此,检测模型设计本质上是一个多目标平衡过程。

对于本文任务,这种平衡尤为突出。排水管道巡检中的真实需求通常是“先不要漏掉真正病害,再尽量减少无效复核”,这意味着 Recall 和 Precision 需要动态平衡,而不是单纯追求单项极值。又由于本文后续还要结合跨域迁移和低标注伪框,模型若过度依赖某一单一指标最优,可能在整体链条中表现并不稳定。因此,后续方法设计会强调整体协同和系统级有效性,而不是把某一个局部指标的微小提升过度夸大。

这种“目标冲突”也是为什么本文不会把检测头改进与损失函数优化分开理解。已有 sewer 与 pipeline defect detection 研究已经反复说明,仅调整预测层而不调整训练目标,或者仅调整损失而不考虑最终预测结构,往往很难在复杂场景中获得稳定收益^{[9][48][45]}。因此,本文在方法层面将二者放入同一协同优化框架,既是对文献经验的总结,也是对本任务多目标平衡本质的回应。

2.7 迁移学习、跨域适应与热力图定位理论

2.7.1 迁移学习基本概念

迁移学习旨在利用源任务或源域中获得的知识来提升目标任务学习效果。Pan 和 Yang 对迁移学习进行了较早而系统的定义,指出迁移学习的核心在于源域与目标域或源任务与目标任务存在某种共享结构,从而使已有知识可以迁移复用^[40]。Weiss 等进一步指出,迁移学习在样本不足、高标注成本和目标域学习困难的场景中尤其具有价值^[41]。对于排水管道缺陷检测而言,这一理论非常契合,因为目标域高质量框标注昂贵,而同领域公开数据却可以提供可迁移的缺陷表征。

从应用层面看,迁移学习常见形式包括使用大规模自然图像模型作为初始化、使用同领域公开数据进行预训练,以及在目标域有限样本上微调。对 sewer defect detection 而言,第二种形式更具研究价值,因为同领域源域数据能够提供更贴近管道图像纹理和结构特征的先验,而不仅仅是通用自然图像语义^{[8][6]}。这也是本文采用源域分类预训练的直接理论依据。

2.7.2 跨域适应问题

当源域与目标域之间存在明显分布差异时,仅依赖普通迁移学习往往不足以获得理想效果。Wang 和 Deng 的综述指出,deep visual domain adaptation 的核心在于缓解源域和目标域在特征空间上的偏移,使模型在目标域保持可接受的判别能力^[42]。在 sewer inspection 场景中,这种偏移不仅体现为图像风格差异,还体现为采集设备、压缩策略、照明条件、材质背景、缺陷口径和标注方式差异,因此 domain gap 更具有工程复杂性^{[24][7][8]}。

对本文而言,跨域适应并不意味着必须采用对抗训练等重型域对齐方法。考虑到硕士论文的实现可控性和工程可落地性,本文更关注一种稳健、可执行的跨域路线,即利用源域分类任务学习 sewer-specific representation,再通过目标域分类微调和检测微调逐步完成知识迁移。这种做法虽然相对朴素,但具有更明确的数据依赖关系和更好的工程实现稳定性。

近年的 defect-domain adaptation 研究也为这一判断提供了补充说明。Prototype-guided domain adaptive detector 研究指出,目标检测中的跨域适应不仅要缓解整体分布偏移,还要尽量维护类别原型与类别边界在源域和目标域之间的一致性^[53]。对于 sewer defect detection 而言,这一点尤为关键,因为缺陷类别往往视觉相近、边界模糊,若迁移过程中类别语义进一步漂移,模型就很容易在目标域上出现“整体精度尚可但类别混淆严重”的现象。与此同时,关于工业缺陷任务中 transfer learning 表现的评估研究还表明,源模型的相关性、训练数据的组织方式和目标任务的语义粒度,会共同影响最终迁移效果^[52]。因此,本文在后续章节中将 Sewer-ML 源域单标签预训练显式写成一个研究步骤,而不是把它视作可有可无的初始化细节。

2.7.3 CAM 与 Grad-CAM 的理论基础

在低标注学习场景中,如何从图像级标签中获得定位线索是一个关键问题。Zhou 等提出 CAM,证明卷积网络中的分类激活图可以用于挖掘类别相关区域^[38];Selvaraju 等进一步提出 Grad-CAM,使热力图生成可以适配更一般的卷积网络结构^[39]。这些工作为“分类模型生成候选区域”提供了重要理论基础,也使得从图像级标注向伪框检测数据过渡成为可能。

在 sewer inspection 场景中,CAM 和 Grad-CAM 的意义并不在于生成绝对准确的边界框,而在于在缺乏大规模精确框标注的前提下,为人工复核或伪框构建提供高价值候选区域^{[20][3]}。这与本文采用 CAM 热力图辅助伪框生成的设计完全一致。换言之,本文中的 CAM 不是单纯的可视化工具,而是连接源域分类预训练与目标域低标注检测训练的重要桥梁。

此外,弱监督定位研究近年还进一步强调“热力图如何被使用”与“热力图如何被生成”同样重要。关于 WSOL inference recipe 的研究指出,推理阶段的阈值、区域聚合、尺度处理和候选框生成方式会显著影响最终定位结果,因此不能把热力图简单等同为最终候选框^[56]。这一点与本文的工程设定高度一致:本文并不把 CAM 结果视为真值框,而是将其理解为需要经过阈值筛选、候选区域规则约束和后续人工抽检的中间信息。正是基于这样的理论认识,后续第 3 章和第 5 章才会把 CAM 阈值设置、伪框质量台账和人工复核机制写成完整流程,而不是一句话带过。

2.7.4 源域预训练与低标注伪框学习的理论合理性

从方法论上看,本文采用“源域分类预训练 + 目标域微调 + CAM 伪框”的路线,实际上建立在两个理论假设之上。第一个假设是,同领域公开数据中学到的缺陷表征具有可迁移性,即使目标域数据分布不同,这些表征仍能作为目标域检测任务的有效初始化^{[40][41][8]}。第二个假设是,分类模型产生的热力图虽然不能完全替代精确框标注,但能够为后续人工复核和检测训练提供高价值的候选区域^{[38][39][3]}。

这两个假设共同构成了本文跨域链路的理论基础。前者解释了为什么要先做源域分类预训练,而不是直接从零开始训练目标域检测器;后者解释了为什么在目标域框标注有限条件下,CAM 伪框仍然具有研究价值。把这两个问题讲清楚,后续第 5 章中的跨域适应训练策略才会显得顺理成章,而不是工程上的临时折中。

2.7.5 域差来源分解与低标注学习路径

在排水管道场景中,域差并不是单一来源造成的。它至少包括成像域差、场景域差和标注域差三个层面。成像域差来自摄像头型号、照明条件、分辨率和压缩策略差异;场景域差来自管材、污渍分布、沉积状态和地区维护历史差异;标注域差则来自缺陷定

义口径、标注习惯和任务粒度差异^{[24][7][1]}。只有把域差拆开理解，后续迁移策略设计才不会流于抽象。

相应地，低标注学习也不应被简单理解为“少标一点框”。更准确地说，它是一组围绕标注成本控制展开的方法组合，包括源域预训练、目标域图像级微调、候选区域生成、伪框构建和人工轻量复核等环节^{[3][20][38][39]}。本文采用的技术路线正是将这些环节组织为一条渐进式学习路径：先用公开源域学到同领域先验，再用目标域图像级数据完成适配，最后再把有限框标注资源投入到真正需要的检测训练中。

这一思路的理论优势在于，它尽可能把高成本监督推迟到最必要的阶段。与一开始就大量标框相比，这种路径更符合真实工程单位的数据条件，也更适合在研究早期快速迭代模型与实验设计。因此，第 5 章中的跨域迁移策略并不是孤立提出的训练技巧，而是建立在上述域差分解和低标注学习逻辑基础上的系统设计。

如果进一步结合本文任务设定，还可以看到域差分解与类别映射之间存在紧密关系。源域 Sewer-ML 以分类标签组织，目标域则以结构性缺陷检测为最终任务，两者并不是简单的一一对应关系。因此，跨域适应不仅包括视觉分布对齐，也包括标签语义层级的重构与压缩。本文之所以在第 3 章中引入单标签六类源域构建，并在目标域冻结六类结构病害检测标签，本质上就是在做一种“层次化标签对齐”。把这一点提前在理论章节中说明，有助于后续解释：为什么本文的跨域训练不是直接把所有源域标签硬搬到目标域，而是先进行任务化重组，再开展迁移学习。

这种层次化标签对齐还有助于减少跨域迁移中的语义噪声。由于源域原始标签中包含多标签共存、构造信息和状态信息，若不经任务化重组就直接参与目标域检测训练，模型学到的可能并不是稳定的结构性缺陷表征，而是与目标任务无关的混合语义。通过先在源域上构建更稳定的单标签结构病害分类集，再把这种表征迁移到目标域检测任务，能够在一定程度上降低语义漂移风险，也使后续 CAM 候选区域更容易围绕目标域真正关心的病害类型展开。

2.7.6 人机协同与低标注闭环

从工程应用角度看，低标注学习并不意味着完全取消人工，而是重构人工参与方式。传统流程往往要求人工从零开始逐张标框，而在低标注闭环中，人工更多承担“抽检、修正和确认”的角色，即先由模型给出候选区域，再由人工对高价值样本进行快速复核^{[3][20]}。这种变化的本质，是把专业人员的时间从重复性标注中释放出来，集中投入到最困难、最关键的样本上。

这种人机协同思路与本文整体路线高度一致。源域预训练负责提供先验表征，目标域微调负责建立场景适配，CAM 负责提供低成本候选区域，而有限人工则负责保证关键监督质量。也就是说，本文最终试图构建的并不是一个“完全脱离人工”的黑盒系统，而是一套能够在有限人工参与下持续优化的智能巡检技术链。这种定位更符合当前排水行业的现实条件，也更容易在后续实验中形成可解释的性能提升来源。

从系统设计角度看，人机协同闭环还意味着评价标准需要相应改变。若只使用离线分类准确率或 mAP 来评价整个技术链，就无法反映“是否减少人工逐帧查看”“是否降低无效复核量”“是否提高高价值样本发现效率”等工程收益。因此，本文后续在实验章节中除报告传统指标外，还会尽量讨论误报、筛帧收益、候选区域可用率等更贴近业务流程的结果。这样的安排并不是为了扩展指标数量，而是为了让理论章节中提出的人机协同逻辑，在实验章节中能够被真正验证。

进一步看，人机协同闭环其实也反向规定了算法研究的边界。若一个方法虽然在标

准测试集上取得更高分数，却需要更复杂的推理流程、更重的人工筛选或更高的部署成本，那么它在真实巡检流程中的综合收益可能并不理想^{[23][1]}。因此，本文在理论上把“人工复核负担”视为和精度、召回同样重要的系统变量，这样后续第 6 章的实验分析才能既讨论检测性能，也讨论整个业务链条的有效性。

2.7.7 从理论基础到实验设计的映射

本章前述理论内容之所以需要写得相对完整，是因为后续实验矩阵并不是随意搭建的，而是与理论假设一一对应。源域分类实验对应“同领域表征可迁移”这一假设；目标域微调实验对应“跨域适应可通过渐进式迁移改善”这一假设；CAM 可视化与伪框实验对应“图像级标注可以转化为候选区域监督”这一假设；改进 YOLOv11 的对比与消融实验，则对应“场景化模型优化优于直接沿用通用基线”这一假设。

换言之，第 2 章不是为了“把一些基础概念补齐”而存在，而是为了给第 4 章和第 5 章建立可追溯的理论前提。只有把这些理论关系提前讲清楚，后续实验结果才能被解释为对前述假设的验证，而不是孤立的数据现象。这也是本文坚持把第 2 章写成完整理论章节，而不是只列出几个名词定义的原因。

进一步说，本章的理论铺垫还承担一个论文写作上的关键任务，即把“模型改进”和“迁移策略”连接到同一个问题框架中。若没有前文关于域差、类别语义漂移、源模型选择和 WSOL 候选区域生成的理论讨论，那么第 5 章中的跨域训练策略就会显得像是对第 4 章的附加补丁；反之，当这些理论前提被系统展开后，后续方法章节就可以被理解为围绕同一工程问题链的连续求解过程^{[52][53][56]}。这也是本文在第二章保留较多理论分析篇幅的根本原因。

2.8 低标注学习与人机协同检测理论

2.8.1 低标注学习的工程含义

在许多计算机视觉任务中，低标注学习通常被理解为一种为了节约标注成本而采用的附加技巧；但在地下排水管道场景中，低标注学习更接近一种基本前提。原因在于，目标域高质量框标注不仅耗费时间，还需要具有工程知识的人员参与，不同标注者之间还可能因缺陷边界理解不同而产生较大差异^{[14][3]}。因此，真实工程单位很难在短时间内构建出足够大、足够稳定的检测标注库。

从这个意义上说，低标注学习不是“为了进一步节约成本”的可选项，而是使研究能够真正对接工程现实的必要条件。本文将低标注学习写入理论章节，目的正是表明：后续采用源域预训练、目标域分类微调、CAM 候选区域生成和有限人工复核，并不是实验上的权宜之计，而是由任务属性决定的合理方法论。

进一步讲，低标注学习的工程价值还在于重构监督资源的投入顺序。工业缺陷迁移研究表明，当高质量标注预算有限时，把资源优先投入到“源模型选择”“候选区域生成”和“高价值样本复核”往往比盲目扩大人工框标注规模更有效^[52]。对 sewer inspection 而言，这种资源重构尤其重要：一方面，原始视频量巨大，全部精标并不现实；另一方面，真正困难的往往不是“有没有图像”，而是“哪些图像值得专家投入时间”。因此，本文把低标注学习写成理论基础的一部分，目的正是为后续“先源域分类、再目标域微调、再 CAM 伪框、最后有限人工校正”的路线建立清晰的方法论依据。

2.8.2 伪标签与候选区域的角色定位

在低标注检测任务中，伪标签的价值主要体现在两个层面。其一，是扩大监督信号覆盖范围，使本来只有图像级标签或少量框标注的数据，也能够在一定程度上参与检测训练；其二，是把人工工作从“从零标注全部样本”转变为“复核高价值候选区域”，从而提高标注效率^{[38][39][20][3]}。对本文而言，CAM 生成的候选区域并不被视为最终真值，而被视为连接分类知识与检测监督的重要中间表征。

这种角色定位十分关键。若把伪框误当成精确框，后续实验容易在定位误差上产生系统性偏差；若完全否认伪框价值，又会重新回到高成本人工标注路径。因此，本文在理论上将候选区域定义为“有监督价值但需后续筛选”的中间信息，这为后续实验阶段采用抽检、阈值筛选和人工快修提供了合理依据。

2.8.3 人机协同检测闭环

从更宏观的角度看，地下排水管道智能巡检并不是“模型替代人工”的单向过程，而更像是“模型与人工分工重组”的协同闭环。模型擅长的是从海量数据中快速筛出疑似区域和高风险样本，人工擅长的是利用工程知识判断复杂边界、确认疑难样本和完成最终维护决策^{[23][22][19]}。因此，一个真正可用的巡检系统应当把模型视为人工能力放大器，而不是孤立的最终判决器。

本文后续提出的技术链条正是沿着这一思路展开：分类模型先完成高召回预筛，CAM 负责提供候选区域，检测模型负责做精细识别，人工则集中处理最有价值的修正与确认工作。这样的闭环不仅符合工程现实，也有助于解释为什么本文在方法层面既关注模型精度，也关注筛帧效率、误报率和伪框可用性等系统级指标。

2.8.4 本章理论对后续研究的支撑关系

综上所述，第 2 章涉及的理论并不是彼此孤立的。缺陷类型与图像特征分析说明了 sewer defect detection 的任务难点；目标检测理论和 YOLO 系列方法说明了为何选择一阶段检测器作为基线；注意力机制、检测头与损失函数理论说明了后续模型改进的方向与依据；迁移学习、跨域适应和 CAM 理论则为源域预训练、目标域微调与伪框生成提供了方法论支撑。后续第 3 章至第 5 章的设计，正是在这些理论基础之上逐层展开。

从更高层次看，本章的各部分理论最终都指向同一件事：在地下排水管道场景中，任何单点算法优化都必须被放回完整业务流程中理解。无论是注意力机制、检测头、损失函数，还是跨域迁移和低标注学习，它们的价值都不只体现在单个指标的提升上，更体现在是否能够共同服务于“低成本构建监督、稳定识别关键病害、降低误报并支撑人工复核”的总体目标^{[23][3][1]}。因此，本章既是理论基础章，也是后续整篇论文方法论的一次集中定界。

进一步说，第二章完成的不只是概念梳理，更是把本文后续研究压缩为一个可验证的问题框架：一方面，地下排水管道缺陷图像在视觉上具有小目标、弱纹理、复杂背景和类间相似度高等特征，因此需要在检测模型层面做场景化改进；另一方面，目标域高质量框标注有限、源域与目标域存在明显域差，因此又必须在训练策略层面引入源域预训练、目标域渐进微调和低标注增强机制。也就是说，后续第 4 章回答的是“模型为什么要改、该往哪里改”，第 5 章回答的是“数据不足和域差存在时模型如何训得起来”，而第 3 章则承担把理论路线转化为数据组织、任务定义和实验链路的过渡作用。只有在这一问题框架下理解全文，本文的两个核心创新点和一条工程支撑链才能构成真正连续的研究闭环。

2.8.5 监督粒度连续体与少样本检测启示

在低标注视觉任务中，监督信息并不是简单划分为“有标注”和“无标注”两种状态，而更应被理解为从图像级标签、候选区域、少量精确框到较充分检测标注之间连续变化的监督粒度谱系。工业表面缺陷研究已经明确指出，弱监督、混合监督与全监督之间并不存在绝对割裂的边界，相反，不同粒度标注往往可以在同一训练框架中协同发挥作用^{[58][59][51]}。其中，图像级标签更适合学习类别存在性和粗粒度判别线索，少量精确框或分割标注则更适合校正空间定位偏差，而混合监督策略的价值就在于用较低的精标成本换取显著高于纯弱监督的定位能力。将这种监督粒度连续体引入地下排水管道场景，有助于从理论上解释为什么本文并不把源域分类、CAM 候选区域和少量目标域检测标注看成彼此独立的资源，而是把它们视作可以渐进衔接的监督层级。

进一步地，少样本缺陷检测文献还表明，当标注预算不足时，决定模型可用性的关键不只是“样本有多少”，更在于“样本是否覆盖了高价值判别模式”以及“已有先验是否能被有效迁移”。Wang 等在钢表面缺陷少样本检测研究中指出，少量支持样本条件下若缺乏稳定先验，模型容易在类别相似、纹理细弱和背景复杂条件下出现识别退化^[60]；相关综述也强调，监督粒度设计、样本筛选与先验知识迁移共同决定了低标注缺陷检测的最终上限^{[59][51]}。这意味着对 sewer defect detection 而言，仅仅减少标注量并不能自动带来更优的训练路径，必须同时回答“用什么先验学”“先标什么样本”“哪一层监督先进入系统”这三个问题。本文后续采用源域单标签分类预训练、目标域分类微调 and CAM 伪框生成的顺序，本质上就是对这一问题的任务化回答：先建立较稳的缺陷表征，再把表征转化为候选空间监督，最后才进入检测级训练。

从工程实现角度看，这一理论还有一个直接后果，即监督资源的投入应当服从“先放大样本价值，再放大样本数量”的原则。若在目标域上直接追求大规模精框标注，不仅成本高昂，而且很可能在类间边界尚未澄清、源域先验尚未建立时形成低效率标注；相反，若先利用公开源域学习稳健表征，再通过目标域分类样本和候选区域对监督进行逐步细化，则可以把有限专家时间更多集中到最难、最关键的样本上^{[8][3][58]}。因此，监督粒度连续体与少样本检测理论并不是与本文主线无关的泛化讨论，而是后续第 3 章数据组织方式、第 5 章迁移路径设计以及第 6 章低标注实验解释的重要理论支点。




图 2.3 从图像级监督到检测级监督的连续体

注：根据 CAM、Grad-CAM、弱监督定位、混合监督与迁移学习相关文献整理与改绘^{[38][39][58][20][56][3]}。

2.9 本章小结

本章围绕地下排水管道缺陷检测任务所需的关键理论基础进行了系统阐述。首先，从缺陷类别、视觉属性和样本分布等角度分析了地下排水管道图像的任务特征，说明该场景具有小目标、弱纹理、强背景干扰和长尾分布等多重困难。其次，从目标检测任务定义、方法演进和评价指标出发，说明一阶段检测器特别是 YOLO 系列在该场景中的工程优势与适配价值。再次，从注意力机制、检测头设计和损失函数优化角度分析了模型改进的理论依据。最后，从迁移学习、跨域适应以及 CAM/Grad-CAM 理论出发，阐明了源域分类预训练、目标域微调和伪框构建的技术可行性。上述内容为后续章节中的数据集构建、改进 YOLOv11 模型设计和跨域迁移训练策略提供了完整的理论支撑。

更进一步地，本章也明确了本文后续研究必须同时回应的三层问题。第一层是“视觉表征问题”，即如何在小目标、弱纹理和复杂背景条件下获得更可靠的缺陷表征；第二层是“训练机制问题”，即如何通过检测头组织、损失函数设计和标签分配策略把这种表征稳定转化为可用预测；第三层是“工程闭环问题”，即在目标域数据有限、域差显著且人工复核成本高昂的条件下，如何通过源域预训练、目标域微调、CAM 候选区域生成和人机协同形成可实施的技术路线。后续第 3 章到第 5 章的展开，正是围绕这三层问题逐级推进：先把数据与任务组织清楚，再对基线模型做针对性改进，最后用跨域迁移与低标注增强把方法真正连到目标域场景中去。因而，第二章并不是背景性铺垫，而是全文方法论和实验设计的逻辑起点。

从论文整体结构上看，第二章实际上还承担了一个更深层次的作用，即把“公开文献中的分散结论”整合为本文可执行的研究路线。已有 sewer detection 文献已经分别证明了公开数据集的价值、YOLO 路线的工程优势、弱监督候选区域生成的可行性以及迁移学习在同领域任务中的潜力^{[6][9][8][3]}；但这些工作往往各自聚焦于单一环节，尚未自动汇聚为一条能够直接解决本文目标任务的完整方法链。第二章通过理论梳理所完成的，正是把这些分散结论重新编排为一个统一的问题图景：为什么 sewer 缺陷检测需要关注小目标与复杂背景，为什么一阶段检测器虽然适合工程落地却仍需场景化改进，为什么目标域少标注条件下必须借助源域表征、CAM 候选区域和人机协同来完成监督增强，以及为什么这些环节必须被视为同一条研究链而不是若干互不相干的技术拼接。只有在这一图景被明确建立之后，后续第 3 章的数据组织、第 4 章的模型改进和第 5 章的迁移策略才会显得逻辑连续、问题明确且方法有据可依。这也是本文坚持在第二章投入较大篇幅的原因：它不仅解释“已有方法是什么”，更解释“为什么本文必须这样设计”。

还需要补充指出的是，第二章最终形成的理论闭环并不是封闭静态的，而是允许不同监督层级和不同实验路径在同一问题框架内被解释。换言之，即便后续实验发现某些类别更适合直接少量人工框监督，另一些类别更适合沿用 CAM 候选区域增强，本文在第二章中建立的理论体系仍然能够解释这种分化现象，因为监督粒度本来就应当被理解为任务相关、类别相关和资源相关的连续决策问题^{[58][60][59]}。这也使得后续实验章节不仅能够回答“哪种方法效果更好”，还能够进一步回答“为什么在当前 sewer 场景与标注约束下，应当优先选择这一训练组织方式”。从这个意义上说，第二章完成的不是单纯的知识回顾，而是为全文建立了一套能够解释结果差异、支撑方法选择并联系工程现实的分析语言。

第 3 章 数据集构建与地下排水管道缺陷检测总体框架

3.1 数据来源与总体说明

3.1.1 源域数据来源

本文源域数据主要来自公开 SewerML 数据库。考虑到原始 SewerML 数据以多标签分类为主，不直接适合作为本文流程中的单标签分类预训练数据，因此本文对其进行了单标签化处理，并构建了平衡的源域分类数据集。选择 SewerML 作为源域的主要原因在于：其一，数据规模较大，包含丰富的管道内部视觉模式；其二，类别覆盖较广，能够为模型提供较强的 sewer scene prior；其三，该数据集已经形成公开 benchmark，便于论文中对源域背景进行标准化说明^[6]。需要指出的是，本文对 SewerML 的使用定位并非“直接拿来训练最终检测器”，而是将其作为源域分类预训练和跨域迁移适应的起点。

3.1.2 目标域数据来源

目标域数据来自本地或合作区域的地下排水管道巡检图像，包含图像级标签、检测框标注以及后续人工修正数据。目标域数据是本文最终检测任务的直接支撑数据，其标签体系和评价口径均以本地工程任务为准。相较于源域数据，目标域数据在成像设备、分辨率、照明条件、管材背景、污渍分布和标注口径等方面都具有更强的工程属性，因此更能代表最终落地场景，但同时也面临标注成本高、类别分布不均衡和高质量样本数量有限等现实问题。正因为如此，本文才需要通过“源域预训练 + 目标域微调 + 低标注检测训练”的方式减少对大规模框标注数据的直接依赖。

3.2 源域单标签分类数据集构建

3.2.1 单标签化原则

为适应分类预训练与 CAM 候选区域生成流程，本文将原始 SewerML 数据中的多标签样本按照固定优先级映射到唯一主类别，形成单标签训练样本。同时，排除暂不纳入主任务的干扰标签和构造信息标签，从而保证源域数据与后续实验目标的一致性。这里的“单标签化”并不是否定 SewerML 原始多标签属性，而是为了更稳定地适配当前使用的分类训练框架、降低类别语义混叠，并为后续 CAM 热力图生成提供更清晰的监督信号。换言之，本文的源域单标签集是一种面向跨域迁移和伪框生成任务的重构数据形态，而不是对原始数据语义的简单压缩。

3.2.2 当前数据集规模与分布

本文当前构建的源域单标签六类分类数据集共包含 7200 张图像，按类别均衡划分，每类 1200 张，其中训练集每类 1080 张，验证集每类 120 张。类别包括 Normal、Deformation、Roots、JointAnomaly、WallDamage 和 DepositAttachment。该数据集的主要作用是为后续分类预训练、CAM 热力图生成和伪框构建提供稳定基础。从实验设计角度看，7200 张数据并不是“尽可能大”的结果，而是综合考虑类别平衡、数据质量、训练效率和 3090 平台下试验迭代成本之后的折中规模。相比 3000 张级别的原型集，该规模能够提供更稳定的分类表征；相比继续盲目扩容，又具有更高的训练性价比，适合作为论文前期源域实验的基准配置。

表 3.1 源域单标签六类分类数据集分布

类别	训练集数量	验证集数量	总数量
Normal	1080	120	1200
Deformation	1080	120	1200
Roots	1080	120	1200
JointAnomaly	1080	120	1200
WallDamage	1080	120	1200
DepositAttachment	1080	120	1200
合计	6480	720	7200

后续替换为源域单标签六类样本分布图
建议文件：source_dataset_distribution.pdf

图 3.1 源域单标签六类分类数据集分布示意图

3.3 目标域缺陷类别定义与标签映射

3.3.1 目标域最终检测类别

为与工程需求保持一致，本文将目标域最终检测任务固定为六类结构性缺陷，包括 CrackBreak、SurfaceDamage、Deformation、JointDislocation、Intrusion 和 Infiltration。该分类方式兼顾了国内排水管道缺陷评估口径、目标域图像表现特点以及后续检测模型的可训练性。

3.3.2 源域与目标域的关系

需要说明的是，源域分类类别与目标域最终检测类别并非严格一一对应。源域数据主要服务于缺陷表征学习与候选区域生成，而目标域六类检测任务才是本文最终关注的落地任务。因此，本文采用“源域预训练较粗、目标域检测类冻结”的思路，使迁移学习服务于最终检测目标。这种做法本质上属于层次化标签对齐思路：源域侧强调可迁移的缺陷表征学习，目标域侧强调任务边界清晰、标注口径稳定和检测评估可执行。通过将二者解耦，本文避免了直接把 SewerML 原始标签体系硬套到本地检测任务上的语义错位问题。

表 3.2 目标域最终六类检测任务定义

编号	类别名称	说明
0	CrackBreak	对应破裂、裂缝、坍塌等管壁破坏性缺陷
1	SurfaceDamage	对应表面损伤、腐蚀样损伤或制造施工缺陷
2	Deformation	对应管道几何形态变化、变形等缺陷
3	JointDislocation	对应接口错位、脱节、错口等接口异常
4	Intrusion	对应接口侵入、材料侵入或局部异物侵入
5	Infiltration	对应渗漏、渗入水等渗漏类异常

3.4 数据预处理与增强策略

3.4.1 预处理策略

在数据集构建过程中，本文对源域和目标域图像进行了统一的路径规范化、类别目录标准化和训练集与验证集划分。对于目标域检测数据，还将结合图像质量和标注质量进一步筛选，以保证训练样本的可用性与一致性。

3.4.2 数据增强策略

分类阶段以轻量增强为主，例如尺度变换、随机翻转和颜色扰动，以避免过强增强破坏缺陷语义；检测阶段则根据实验需要进一步引入 Mosaic、MixUp、随机裁剪或几何变换等策略，以增强模型对复杂场景的鲁棒性。

3.5 高召回预筛与后级精检的总体框架

考虑到真实巡检场景中正常帧数量远大于缺陷帧，若将全部图像直接送入检测器进行精细检测，不仅会增加推理成本，也会放大误报问题。因此，本文构建了前级高召回预筛与后级精确检测相结合的总体框架。前级模块主要用于尽量不漏缺陷帧的前提下，对明显正常帧进行筛除或降权；后级模块则对候选缺陷图像进行高精度检测与类别判定。需要强调的是，前级模块的设计目标不是替代检测器完成最终决策，而是在工程链条中承担“降低搜索空间、减少无效推理、控制误报传播”的系统角色。这样的两阶段设计与 sewer defect detection 中强调高召回和工程可用性的既有研究目标是一致的^{[12][7]}。

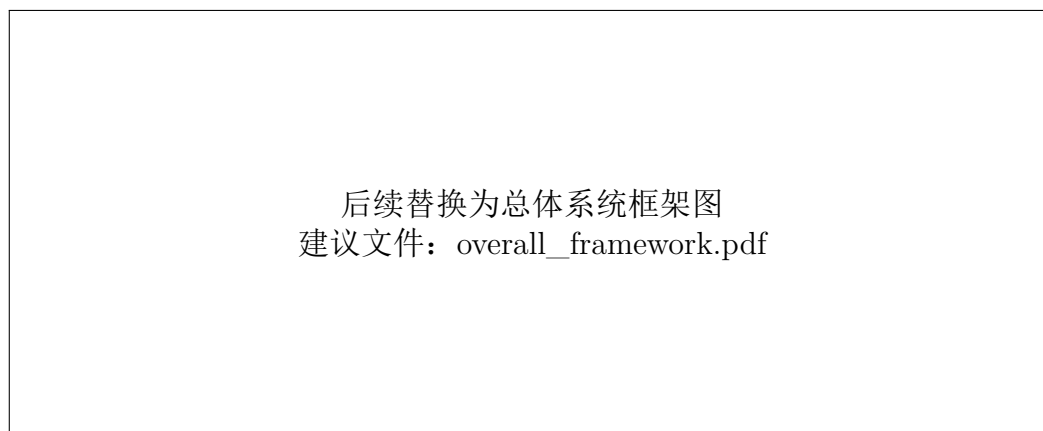


图 3.2 地下排水管道缺陷检测总体框架

3.6 CAM 热力图与伪框生成流程

由于目标域高质量检测框标注成本较高，本文引入了基于分类模型的 CAM 热力图生成与伪框构建流程。首先利用源域单标签分类数据集完成缺陷表征学习，再在目标域图像级标签数据上进行微调，使分类模型获得更贴近目标域场景的表征能力。随后，通过 CAM 可视化得到图像中与目标类别相关的高响应区域，并进一步结合阈值化、连通域分析和外接矩形生成候选框，形成初始伪标注。该流程在本文中的定位属于“低标注工程支撑链”，即通过尽量低成本的图像级监督去换取第一版可用检测样本，而不是把 CAM 直接当成最终检测真值。后续实验将进一步分析不同类别下 CAM 生成候选框的稳定性差异，并将其与人工快修成本、检测效果提升幅度结合讨论。

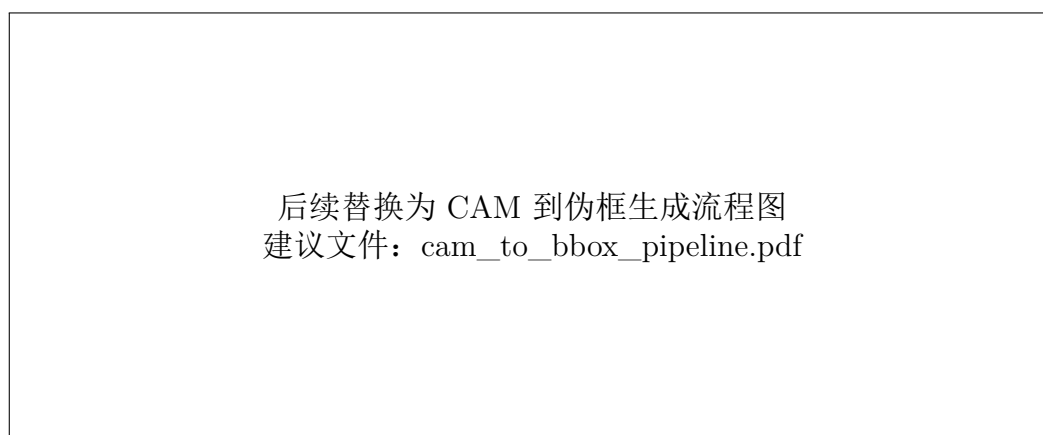


图 3.3 CAM 热力图与伪框生成流程

3.7 评价指标与实验平台

分类实验主要采用 Accuracy、Macro-F1 和混淆矩阵等指标进行评价；检测实验主要采用 Precision、Recall、 $mAP@0.5$ 和 $mAP@0.5:0.95$ 等指标进行评价。针对系统级性能，本文还将从误报数、单图误报率、预筛模块召回率、负样本过滤率以及处理效率等角度对整体流程进行分析。

当前实验环境采用 Python 3.11.15 与 uv 0.11.2 进行统一管理，硬件平台为 NVIDIA GeForce RTX 3090，显存为 24GB，驱动版本为 581.29。深度学习软件环境包括 PyTorch 2.11.0+cu128、TorchVision 0.26.0+cu128、CUDA 12.8 与 Ultralytics 8.3.0。辅助依赖库包括 NumPy 1.26.4、OpenCV 4.11.0.86、Pillow 12.1.1、PyYAML 6.0.3、Matplotlib 3.10.8、Pandas 3.0.1 和 Seaborn 0.13.2。上述环境信息将作为后续实验复现的基础配置。

3.8 本章小结

本章介绍了本文所使用的数据来源、源域单标签分类数据集构建方式、目标域类别定义、数据预处理与增强策略，以及前级高召回预筛和后级精确检测相结合的总体框架。同时，给出了 CAM 热力图与伪框生成流程以及实验评价指标体系，为后续章节奠定了实验基础。

第 4 章 基于改进 YOLOv11 的地下排水管道缺陷检测方法

4.1 基线模型与问题分析

本文以 YOLOv11 作为地下排水管道缺陷检测的基线模型。虽然该模型在通用检测任务中具有良好的速度与精度平衡，但在地下排水管道场景中仍然存在小目标漏检、复杂背景误检、相似缺陷混淆以及类别不均衡训练不稳定等问题。因此，有必要围绕地下排水管道场景特点对其进行针对性改进。与已有 sewer detection 工作相比，本文并不打算简单重复“替换某个模块再做常规对比”的套路，而是尝试从特征表达、检测头建模和训练目标三方面构建协同优化链路，使模型更适配细长裂缝、接口异常、渗漏痕迹和局部侵入等结构性缺陷的视觉特征^{[9][10][11][45]}。

4.2 注意力机制改进

4.2.1 改进动机

针对复杂背景下缺陷区域响应不足的问题，本文在基线网络中引入注意力机制，以增强模型对关键特征的聚焦能力。该改进旨在强化缺陷区域的显著性表达，抑制背景纹理、反光和污渍等干扰因素带来的冗余响应。对于 sewer defect detection 而言，注意力模块的价值不仅在于“提高精度”，更在于帮助网络在多种低对比度区域中筛出真正具有结构意义的特征，这一点对 SurfaceDamage、Infiltration 以及 CrackBreak 等类别尤其重要。

4.2.2 模块设计与嵌入方式

本节后续将结合实际实现，补充所采用注意力模块的结构原理、嵌入位置与参数设置，并分析其与 YOLOv11 主干或颈部结构的结合方式。

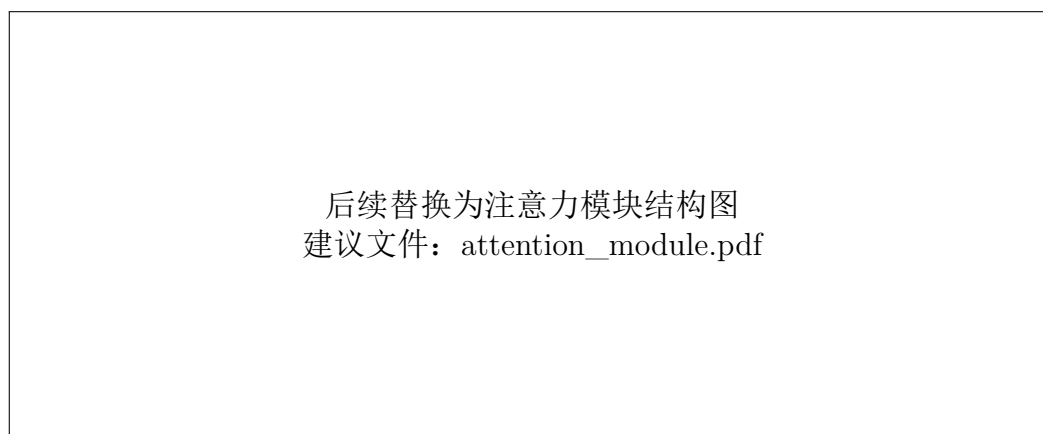


图 4.1 注意力机制改进示意图

4.3 检测头改进

4.3.1 原始检测头局限性

原始检测头在面对小尺度、多尺度和细粒度缺陷时，可能存在边界表达不足和类别区分能力有限的问题。尤其在排水管道图像中，细小缺陷与背景纹理的视觉差异并不总是明显。

4.3.2 改进思路

本节后续将结合实际网络结构，说明改进检测头的具体设计，包括特征融合路径、分支结构调整和预测层优化方式，并阐述其对多尺度与细粒度缺陷识别的促进作用。已有 sewer detection 文献表明，仅依赖通用检测头往往难以同时兼顾局部破损与整体结构异常，因此在特征融合与预测路径上进行适配，是提升目标域实际检测效果的重要方向^{[9][10][11]}。

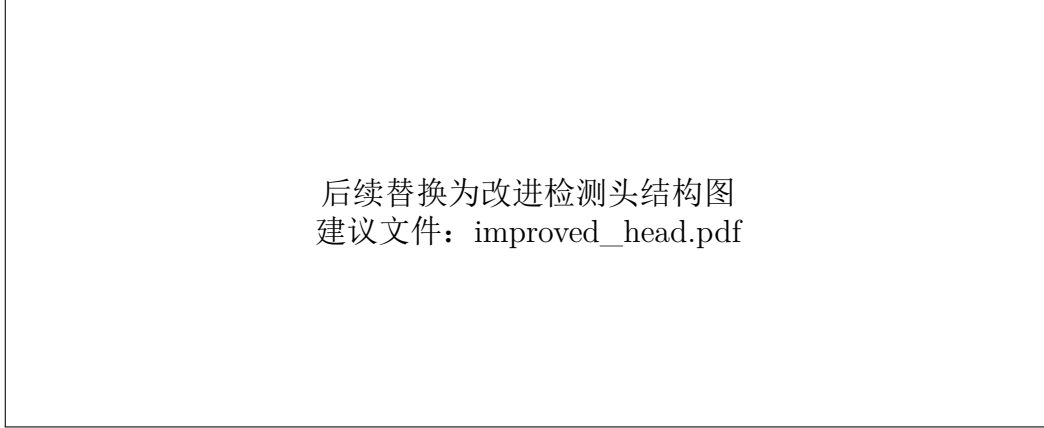


图 4.2 改进检测头结构示意图

4.4 损失函数改进

4.4.1 损失函数优化目标

针对类别不均衡、难样本学习不足和边界框定位偏差等问题，本文进一步对基线模型的损失函数进行优化。其目标在于提升模型对难样本和少样本类别的学习能力，并改善边界框回归稳定性。考虑到 sewer defect detection 中部分类别具有样本稀缺、边界模糊和视觉相似的特点，损失函数优化不仅影响最终精度，也会影响模型收敛稳定性与错误类型分布，因此是本文创新点一中不可忽略的组成部分。

4.4.2 损失函数表达形式

损失函数的总形式可写为：

$$\mathcal{L} = \lambda_1 \mathcal{L}_{\text{box}} + \lambda_2 \mathcal{L}_{\text{cls}} + \lambda_3 \mathcal{L}_{\text{dfl}} + \lambda_4 \mathcal{L}_{\text{aux}}, \quad (4.1)$$

其中， $\mathcal{L}_{\text{box}}$ 表示定位损失， $\mathcal{L}_{\text{cls}}$ 表示分类损失， $\mathcal{L}_{\text{dfl}}$ 表示分布聚焦损失， $\mathcal{L}_{\text{aux}}$ 表示辅助损失项。后续将根据实际改进方案替换具体表达式并给出参数设置。

4.5 改进 YOLOv11 总体结构

在注意力机制、检测头和损失函数三个层面完成针对性改进后，本文构建了适用于地下排水管道缺陷检测的改进 YOLOv11 模型。整体设计思路是：通过注意力模块增强关键特征表达，通过改进检测头强化多尺度与细粒度目标识别，再通过损失函数优化提升训练稳定性和对难样本的适应能力，从而形成协同改进的整体检测框架。



图 4.3 改进 YOLOv11 总体结构

4.6 模型复杂度与可部署性分析

在实际工程应用中，检测精度并不是唯一评价标准，模型参数量、计算量和推理速度同样直接影响部署效果。因此，本文将在后续实验中从参数量、FLOPs、推理时延以及精度提升幅度等方面分析改进模型的可部署性。

表 4.1 改进模型复杂度与效率分析表

模型	参数量/M	FLOPs/G	推理速度/ms	备注
YOLOv11 Baseline	[待补充: 填写]	[待补充: 填写]	[待补充: 填写]	基线模型
YOLOv11 + Attention	[待补充: 填写]	[待补充: 填写]	[待补充: 填写]	注意力改进
YOLOv11 + Head	[待补充: 填写]	[待补充: 填写]	[待补充: 填写]	检测头改进
YOLOv11 + Loss	[待补充: 填写]	[待补充: 填写]	[待补充: 填写]	损失函数改进
Ours	[待补充: 填写]	[待补充: 填写]	[待补充: 填写]	全部改进

4.7 本章小结

本章围绕地下排水管道缺陷检测任务，对基线 YOLOv11 模型进行了问题分析，并从注意力机制、检测头和损失函数三个方面提出改进思路，构建了适用于本文场景的改进检测模型。该模型构成了本文的核心检测方法。

第 5 章 面向跨域场景的迁移适应训练策略

5.1 跨域问题分析

公开数据与目标域巡检数据在成像设备、分辨率、纹理风格、光照条件以及标签口径等方面存在明显差异，这些差异会削弱模型在目标域中的泛化能力。同时，目标域高质量检测框标注获取成本较高，导致直接从零构建大规模检测数据集难度较大。因此，充分利用开源域数据进行预训练，再迁移到目标域进行适配，是一种兼顾性能与成本的现实可行方案。与“重型域对齐方法”相比，本文选择先采用更稳健的源域分类预训练和目标域微调路径，一方面是因为其更适合当前数据条件，另一方面也是因为已有 sewer detection 研究已经初步证明 transfer learning 对该类任务具有明确增益^[8]。

5.2 源域分类预训练策略

本文首先在源域单标签六类分类数据集上训练分类模型，用于学习排水管道缺陷的通用表征。该阶段的目标并不是直接完成检测，而是通过平衡、低成本的源域分类样本，使模型具备对缺陷纹理、结构和局部异常的基础认知能力。与直接在目标域有限框标注上训练检测器相比，这一步能更充分地利用公开数据资源，让模型先学会“看懂 sewer scene”，再进入目标域场景适配与检测优化阶段。

5.3 目标域分类微调与特征迁移

在源域分类预训练基础上，本文进一步引入目标域图像级标签数据进行分类微调。该阶段的作用是使模型在保留源域通用表征能力的同时，更好地适应目标域中的图像风格、缺陷表现形式和标签口径差异，从而为后续 CAM 热力图生成提供更稳定的响应基础。该策略实质上属于“先学公共缺陷表征、再学目标域特有分布”的两步式迁移路径，其优势在于不需要复杂的额外域对齐损失，但仍能在有限标注条件下提升目标域适应效果。

5.4 基于迁移分类模型的候选区域生成与标注增强

在完成源域预训练和目标域分类微调之后，本文利用迁移后的分类模型对目标域图像进行 CAM 可视化，提取高响应区域作为缺陷候选区域，并通过阈值化、区域筛选和边界框生成等步骤构建初始伪框数据集。该过程有助于降低初始检测标注成本，为后续人工轻量修正和检测训练提供基础。需要指出的是，本文并不将伪框视作与人工真值等价的数据，而是将其定位为低标注训练中的过渡性资源；后续实验也将从伪框可用率、类别差异和对检测性能的真实增益等方面进行分析。

5.5 检测阶段的迁移训练策略

在检测阶段，本文将对不同初始化策略与不同训练路径，包括目标域从零训练、使用官方通用预训练权重训练、使用源域分类预训练权重迁移训练，以及源域预训练加目标域分类微调后再迁移到检测任务的训练方式。通过这些对比，分析源域预训练、目标域微调和伪框增强对最终检测性能的贡献。

表 5.1 跨域迁移训练策略实验设计表

方案编号	训练策略说明
A	目标域随机初始化，从零开始训练检测器
B	使用官方 YOLOv11 通用预训练权重，直接在目标域训练检测器
C	使用源域分类预训练权重初始化，再迁移至目标域检测任务
D	源域分类预训练 + 目标域分类微调 + 检测迁移训练
E	[待补充：视实验条件决定是否加入伪框增强或半监督增强方案]

5.6 本章小结

本章围绕地下排水管道缺陷检测中的跨域问题，提出了源域分类预训练、目标域分类微调和检测阶段迁移训练相结合的跨域适应策略。该策略既服务于特征迁移，也支撑了 CAM 伪框构建和检测数据增强，是本文第二个核心研究内容。

第 6 章 实验结果与分析

6.1 实验设置

6.1.1 实验平台与训练配置

本章将围绕源域分类效果、两阶段系统有效性、改进 YOLOv11 检测性能以及跨域迁移策略效果展开实验分析。实验设置包括训练轮次、输入尺寸、优化器、批大小、学习率、评价指标以及硬件平台等内容。当前实验工作基于 `yolo-cv-workspace` 项目环境开展，项目版本为 0.1.0，当前实际训练环境记录对应仓库提交为 79bf440。实验采用基于 `uv` 的 Python 工作区完成环境管理，便于在不同设备之间复现实验配置。

表 6.1 主要实验配置

项目	配置
项目环境	yolo-cv-workspace 0.1.0，仓库提交号 79bf440
Python 环境	Python 3.11.15，uv 0.11.2
训练平台	NVIDIA GeForce RTX 3090，显存 24GB，驱动版本 581.29
深度学习框架	PyTorch 2.11.0+cu128，TorchVision 0.26.0+cu128，CUDA 12.8，Ultralytics
主要依赖库	NumPy 1.26.4，OpenCV 4.11.0.86，Pillow 12.1.1，PyYAML 6.0.3，Matplotlib
当前 source 配置文件	YOLOv11/configs/runtime/cls_source_cls6.json
source 训练模型	yolo11m-cls.pt
source 数据集	sewerml_cls6_train7200
输入尺寸	source 分类实验输入尺寸为 640
优化器	当前 source 分类实验采用 Ultralytics 默认自动优化器策略
训练轮数	当前 source 分类实验设置为 200 epochs
批大小	当前 source 分类实验 batch size 为 32，workers 为 2
评价指标	Precision、Recall、F1、mAP、误报率等

6.2 源域分类实验结果分析

本节用于分析源域单标签六类分类模型的训练效果，重点关注 Accuracy、Macro-F1、各类别识别效果以及混淆关系，以验证源域分类预训练是否能够为后续 CAM 热力图生成和目标域迁移提供稳定基础。当前主实验采用 YOLOv11m-cls 作为分类骨干网络，使用 YOLOv11/configs/runtime/cls_source_cls6.json 作为基础配置文件，并在实际训练中设置 `imgsz=640`、`epochs=200`、`batch=32`、`workers=2`，训练数据集为 `sewerml_cls6_train7200`。

表 6.2 源域单标签六类分类实验结果

模型	Accuracy	Macro-F1	训练时间	备
YOLOv11m-cls	[待补充：填写]	[待补充：填写]	[待补充：填写]	当前 source 主实验，输入尺寸

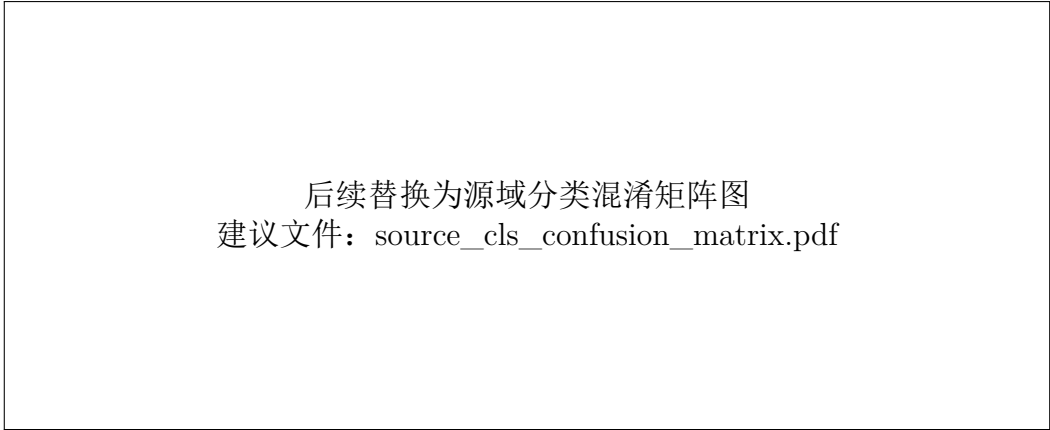


图 6.1 源域分类实验混淆矩阵

6.3 两阶段系统有效性分析

本节用于验证“高召回预筛 + 后级精检”系统设计的有效性，重点关注预筛阶段的缺陷召回能力、正常样本过滤效果以及对后级检测误报率的影响。

表 6.3 两阶段系统有效性分析结果

方案	Gate Recall	NRR	PTR	Precision	Recall
直接检测 Baseline	[待补充：填写]	[待补充：填写]	[待补充：填写]	[待补充：填写]	[待补充：填写]
预筛 + 检测	[待补充：填写]	[待补充：填写]	[待补充：填写]	[待补充：填写]	[待补充：填写]

6.4 改进 YOLOv11 与其他模型对比实验

本节用于比较本文改进模型与原始 YOLOv11 以及其他主流检测模型在地下排水管道缺陷检测任务中的性能差异，重点评价 Precision、Recall、F1、 $mAP@0.5$ 、 $mAP@0.5 : 0.95$ 以及误报情况。

表 6.4 不同检测模型对比实验结果

模型	Precision	Recall	F1	$mAP@0.5$	$mAP@0.5 : 0.95$
YOLOv11 Baseline	[待补充：填写]	[待补充：填写]	[待补充：填写]	[待补充：填写]	[待补充：填写]
[待补充：填写对比模型 1]	[待补充：填写]	[待补充：填写]	[待补充：填写]	[待补充：填写]	[待补充：填写]
[待补充：填写对比模型 2]	[待补充：填写]	[待补充：填写]	[待补充：填写]	[待补充：填写]	[待补充：填写]
Ours	[待补充：填写]	[待补充：填写]	[待补充：填写]	[待补充：填写]	[待补充：填写]

6.5 创新点一的消融实验

为验证注意力机制、检测头改进和损失函数优化三个模块的独立贡献与协同作用，本文将设计系统化消融实验，比较不同模块组合对检测性能的影响。

表 6.5 改进 YOLOv11 各模块消融实验结果

方案	Attention	Head	Loss	Precision	Recall	$mAP@0.5$
Baseline				[待补充: 填写]	[待补充: 填写]	[待补充: 填写]
A	✓			[待补充: 填写]	[待补充: 填写]	[待补充: 填写]
B		✓		[待补充: 填写]	[待补充: 填写]	[待补充: 填写]
C			✓	[待补充: 填写]	[待补充: 填写]	[待补充: 填写]
D	✓	✓		[待补充: 填写]	[待补充: 填写]	[待补充: 填写]
E	✓		✓	[待补充: 填写]	[待补充: 填写]	[待补充: 填写]
F		✓	✓	[待补充: 填写]	[待补充: 填写]	[待补充: 填写]
Ours	✓	✓	✓	[待补充: 填写]	[待补充: 填写]	[待补充: 填写]

6.6 创新点二的迁移实验

本节主要验证跨域迁移适应训练策略对目标域检测性能的影响。通过比较不同初始化策略与不同训练路径，可分析源域预训练和目标域微调对检测模型性能、收敛速度及泛化能力的提升作用。

表 6.6 跨域迁移实验结果

训练策略	Precision	Recall	F1	$mAP@0.5$
目标域从零训练	[待补充: 填写]	[待补充: 填写]	[待补充: 填写]	[待补充: 填写]
官方预训练直接微调	[待补充: 填写]	[待补充: 填写]	[待补充: 填写]	[待补充: 填写]
源域预训练迁移	[待补充: 填写]	[待补充: 填写]	[待补充: 填写]	[待补充: 填写]
源域预训练 + 目标域微调迁移	[待补充: 填写]	[待补充: 填写]	[待补充: 填写]	[待补充: 填写]

6.7 可视化与错误分析

为了更直观地说明模型在不同场景下的表现，本文将通过典型检测结果图、误检样例、漏检样例和热力图可视化结果，对模型行为进行分析。重点讨论哪类缺陷更容易漏检、哪些背景纹理更容易引发误报、跨域迁移是否改善了特定类别的识别效果，以及 CAM 候选区域在不同类别上的稳定性差异等问题。




图 6.2 典型检测效果示意图




图 6.3 误检与漏检案例分析图

6.8 本章小结

本章从源域分类实验、两阶段系统有效性、改进检测模型对比实验、模块消融实验、跨域迁移实验以及可视化错误分析等多个方面给出了实验分析框架。后续将依据实际训练与测试结果补充各表格、图像和分析文字，从而系统验证本文方法的有效性。

第 7 章 结论与展望

7.1 研究结论

本文围绕地下排水管道 CCTV 图像缺陷检测中的小目标难识别、背景干扰强、正常样本占比高、目标域标注不足以及跨域泛化能力不足等问题展开研究，构建了面向地下排水管道智能巡检的检测方法与实验体系。论文的主要工作包括源域单标签分类数据集构建、目标域缺陷类别体系设计、高召回预筛与后级精检总体框架构建、改进 YOLOv11 检测模型设计以及源域预训练与目标域微调相结合的跨域迁移训练策略设计。

从本文研究路线来看，后续实验预期将验证以下结论：其一，改进 YOLOv11 模型能够提升地下排水管道缺陷检测的精度、召回能力与复杂背景鲁棒性；其二，源域预训练与目标域微调相结合的跨域迁移策略能够在目标域标注不足条件下提升模型性能和收敛效率；其三，高召回预筛与后级精检相结合的系统设计能够在工程层面降低误报并提升整体运行效率。

7.2 不足之处

尽管本文构建了较为完整的研究链条，但仍存在一些不足。首先，目标域高质量检测框标注规模仍然有限，模型最终性能仍受目标域数据规模约束。其次，部分复杂缺陷类别在图像表现上存在较强相似性，容易引发误检和类别混淆。再次，本文采用的跨域迁移方法以源域预训练和目标域微调为主，尚未引入更复杂的域对齐机制。最后，本文更多侧重于图像级与目标检测级实验，尚未充分利用长视频的时序信息。

7.3 展望

未来可从以下几个方向进一步开展研究：

1. 继续扩充目标域高质量检测数据，完善类别分布与场景覆盖范围；
2. 探索更加稳健的跨域泛化方法，如特征对齐、半监督学习或自训练策略；
3. 结合视频时序信息，研究基于连续帧上下文的缺陷识别与误报抑制方法；
4. 面向实际巡检系统，进一步开展模型压缩、部署优化和在线辅助判读研究。

参考文献

参考文献

- [1] Ma D, Fang H, Wang N, et al. The state-of-the-art in pipe defect inspection with computer vision-based methods[J]. Measurement, 2026, 257: 118431. DOI: 10.1016/j.measurement.2025.118431.
- [2] Oğurlu M, Bayram B, Kulavuz B, et al. Deep Learning for Automated Sewer Defect Detection: Benchmarking YOLO and RT-DETR on the Istanbul Dataset[J]. Applied Sciences, 2025, 15(20): 11096. DOI: 10.3390/app152011096.
- [3] Yin J, Yin X, Pan M, et al. Scalable and transparent automated sewer defect detection using weakly supervised object localization[J]. Automation in Construction, 2025, 174: 106152. DOI: 10.1016/j.autcon.2025.106152.
- [4] Goharinezhad S, Hadi A, Mirzaei S, et al. Automated defect classification and localization in sewer pipelines using hybrid ResNet50–Swin transformer and modified YOLOv8 on CCTV inspection images[J]. Scientific Reports, 2025, 15(1). DOI: 10.1038/s41598-025-27765-5.
- [5] Yang C, Zheng F, Kapelan Z, et al. Automated quantification of sewage pipe cracks using deep learning for urban water environment management[J]. Tunnelling and Underground Space Technology, 2025, 155: 106195. DOI: 10.1016/j.tust.2024.106195.
- [6] Haurum J B, Moeslund T B. Sewer-ML: A Multi-Label Sewer Defect Classification Dataset and Benchmark[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 13451-13462. DOI: 10.1109/CVPR46437.2021.01325.
- [7] Sun L, Zhu J, Tan J, et al. Deep learning-assisted automated sewage pipe defect detection for urban water environment management[J]. Science of the Total Environment, 2023, 882: 163562. DOI: 10.1016/j.scitotenv.2023.163562.
- [8] Situ Z, Teng S, Feng W, et al. A transfer learning-based YOLO network for sewer defect detection in comparison to classic object detection methods[J]. Developments in the Built Environment, 2023, 15: 100191. DOI: 10.1016/j.dibe.2023.100191.
- [9] Wang T, Li Y, Zhai Y, et al. A Sewer Pipeline Defect Detection Method Based on Improved YOLOv5[J]. Processes, 2023, 11(8): 2508. DOI: 10.3390/pr11082508.
- [10] Zhao X, Xiao N, Cai Z, et al. YOLOv5-Sewer: Lightweight Sewer Defect Detection Model[J]. Applied Sciences, 2024, 14(5): 1869. DOI: 10.3390/app14051869.
- [11] Li D, Xie Q, Yu Z, et al. Sewer pipe defect detection via deep learning with local and global feature fusion[J]. Automation in Construction, 2021, 129: 103823. DOI: 10.1016/j.autcon.2021.103823.

- [12] Zhang J, Liu X, Zhang X, et al. Automatic Detection Method of Sewer Pipe Defects Using Deep Learning Techniques[J]. *Applied Sciences*, 2023, 13(7): 4589. DOI: 10.3390/app13074589.
- [13] Dang L M, Kyeong S J, Li Y, et al. Deep learning-based sewer defect classification for highly imbalanced dataset[J]. *Computers & Industrial Engineering*, 2021, 161: 107630. DOI: 10.1016/j.cie.2021.107630.
- [14] Jang S, Kim D. Impact of Data Quality on CNN-Based Sewer Defect Detection[J]. *Water*, 2025, 17(13): 2028. DOI: 10.3390/w17132028.
- [15] Cheng J C P, Wang M. Automated detection of sewer pipe defects in CCTV images using deep learning techniques[J]. *Automation in Construction*, 2018, 95: 155-171. DOI: 10.1016/j.autcon.2018.08.006.
- [16] Li D, Cong A, Guo S, et al. Sewer damage detection from imbalanced CCTV inspection data using deep convolutional neural networks with hierarchical classification[J]. *Automation in Construction*, 2019, 101: 199-208. DOI: 10.1016/j.autcon.2019.01.017.
- [17] Meijer D, Scholten L, Clemens F, et al. A defect classification methodology for sewer image sets with convolutional neural networks[J]. *Automation in Construction*, 2019, 104: 281-298. DOI: 10.1016/j.autcon.2019.04.013.
- [18] He J, Wang Z, Yong Z, et al. An automatic defect detection and localization method using imaging geometric features for sewer pipes[J]. *Measurement*, 2025, 243: 116367. DOI: 10.1016/j.measurement.2024.116367.
- [19] Taormina R, van der Werf J A, et al. Interpretable Sewer Defect Detection with Large Multimodal Models[C]//The 3rd International Joint Conference on Water Distribution Systems Analysis & Computing and Control for the Water Industry (WDSA/CCWI 2024). 2024: 158. DOI: 10.3390/engproc2024069158.
- [20] Yang Y, Yang S, Zhao Q, et al. Weakly supervised collaborative localization learning method for sewer pipe defect detection[J]. *Machine Vision and Applications*, 2024, 35(5). DOI: 10.1007/s00138-024-01587-3.
- [21] Oh C, Dang L M, Han D, et al. Robust Sewer Defect Detection With Text Analysis Based on Deep Learning[J]. *IEEE Access*, 2022, 10: 46224-46237. DOI: 10.1109/ACCESS.2022.3168660.
- [22] Wang M, Kumar S S, Cheng J C P, et al. Automated sewer pipe defect tracking in CCTV videos based on defect detection and metric learning[J]. *Automation in Construction*, 2021, 121: 103438. DOI: 10.1016/j.autcon.2020.103438.
- [23] Yin X, Ma T, Bouferguene A, et al. Automation for sewer pipe assessment: CCTV video interpretation algorithm and sewer pipe video assessment (SPVA) system development[J]. *Automation in Construction*, 2021, 125: 103622. DOI: 10.1016/j.autcon.2021.103622.

- [24] Haurum J B, Moeslund T B. A Survey on Image-Based Automation of CCTV and SSET Sewer Inspections[J]. *Automation in Construction*, 2020, 111: 103061. DOI: 10.1016/j.autcon.2019.103061.
- [25] Yin X, Chen Y, Bouferguene A, et al. A deep learning-based framework for an automated defect detection system for sewer pipes[J]. *Automation in Construction*, 2020, 109: 102967. DOI: 10.1016/j.autcon.2019.102967.
- [26] Moradi S, Zayed T, Golkhoo F. Review on Computer Aided Sewer Pipeline Defect Detection and Condition Assessment[J]. *Infrastructures*, 2019, 4(1): 10. DOI: 10.3390/infrastructures4010010.
- [27] Kumar S S, Abraham D M, Jahanshahi M R, et al. Automated defect classification in sewer closed circuit television inspections using deep convolutional neural networks[J]. *Automation in Construction*, 2018, 91: 273-283. DOI: 10.1016/j.autcon.2018.03.028.
- [28] Myrans J, Everson R, Kapelan Z, et al. Automated detection of faults in sewers using CCTV image sequences[J]. *Automation in Construction*, 2018, 95: 64-71. DOI: 10.1016/j.autcon.2018.08.005.
- [29] Hawari A, Alamin M, Alkadour F, et al. Automated defect detection tool for closed circuit television (CCTV) inspected sewer pipelines[J]. *Automation in Construction*, 2018, 89: 99-109. DOI: 10.1016/j.autcon.2018.01.004.
- [30] Halfawy M R, Hengmeechai J. Automated defect detection in sewer closed circuit television images using histograms of oriented gradients and support vector machine[J]. *Automation in Construction*, 2014, 38: 1-13. DOI: 10.1016/j.autcon.2013.10.012.
- [31] Girshick R, Donahue J, Darrell T, et al. Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation[C]//2014 IEEE Conference on Computer Vision and Pattern Recognition. 2014: 580-587. DOI: 10.1109/CVPR.2014.81.
- [32] Liu W, Anguelov D, Erhan D, et al. SSD: Single Shot MultiBox Detector[C]//Computer Vision—ECCV 2016. Cham: Springer, 2016: 21-37. DOI: 10.1007/978-3-319-46448-0_2.
- [33] Redmon J, Divvala S, Girshick R, et al. You Only Look Once: Unified, Real-Time Object Detection[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 779-788. DOI: 10.1109/CVPR.2016.91.
- [34] Lin T Y, Goyal P, Girshick R, et al. Focal Loss for Dense Object Detection[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2020, 42(2): 318-327. DOI: 10.1109/TPAMI.2018.2858826.
- [35] Hu J, Shen L, Sun G. Squeeze-and-Excitation Networks[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018: 7132-7141. DOI: 10.1109/CVPR.2018.00745.

- [36] Woo S, Park J, Lee J Y, et al. CBAM: Convolutional Block Attention Module[C]//Computer Vision–ECCV 2018. Cham: Springer, 2018: 3-19. DOI: 10.1007/978-3-030-01234-2_1.
- [37] Wang Q, Wu B, Zhu P, et al. ECA-Net: Efficient Channel Attention for Deep Convolutional Neural Networks[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 11531-11539. DOI: 10.1109/CVPR42600.2020.01155.
- [38] Zhou B, Khosla A, Lapedriza A, et al. Learning Deep Features for Discriminative Localization[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 2921-2929. DOI: 10.1109/CVPR.2016.319.
- [39] Selvaraju R R, Cogswell M, Das A, et al. Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization[C]//2017 IEEE International Conference on Computer Vision (ICCV). 2017: 618-626. DOI: 10.1109/ICCV.2017.74.
- [40] Pan S J, Yang Q. A Survey on Transfer Learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2010, 22(10): 1345-1359. DOI: 10.1109/TKDE.2009.191.
- [41] Weiss K, Khoshgoftaar T M, Wang D. A survey of transfer learning[J]. Journal of Big Data, 2016, 3(1). DOI: 10.1186/s40537-016-0043-6.
- [42] Wang M, Deng W. Deep visual domain adaptation: A survey[J]. Neurocomputing, 2018, 312: 135-153. DOI: 10.1016/j.neucom.2018.05.083.
- [43] Rezatofighi H, Tsoi N, Gwak J Y, et al. Generalized Intersection Over Union: A Metric and a Loss for Bounding Box Regression[C]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 658-666. DOI: 10.1109/CVPR.2019.00075.
- [44] Carion N, Massa F, Synnaeve G, et al. End-to-End Object Detection with Transformers[C]//Computer Vision–ECCV 2020. Cham: Springer, 2020: 213-229. DOI: 10.1007/978-3-030-58452-8_13.
- [45] Cheng X, Wang Y. Pipeline Defect Detection Based on Improved YOLOv11[J]. Processes, 2026, 14(3): 530. DOI: 10.3390/pr14030530.
- [46] Jung J T, Reiterer A. Improving Sewer Damage Inspection: Development of a Deep Learning Integration Concept for a Multi-Sensor System[J]. Sensors, 2024, 24(23): 7786. DOI: 10.3390/s24237786.
- [47] Huang J, Kang H. Automatic Defect Detection in Sewer Pipe Closed-Circuit Television Images via Improved You Only Look Once Version 5 Object Detection Network[J]. IEEE Access, 2024, 12: 92797-92825. DOI: 10.1109/ACCESS.2024.3422275.

- [48] Lu J, Song W, Zhang Y, et al. Real-time defect detection in underground sewage pipelines using an improved YOLOv5 model[J]. *Automation in Construction*, 2025, 173: 106068. DOI: 10.1016/j.autcon.2025.106068.
- [49] Yu H, Liu J, Lin M. A Comprehensive Literature Review on YOLO-Based Small Object Detection: Methods, Challenges, and Future Trends[J]. *Computers, Materials & Continua*, 2026, 87(1). DOI: 10.32604/cmc.2025.074191.
- [50] Jing R, Zhang W, Li Y, et al. Dynamic Feature Focusing Network for small object detection[J]. *Information Processing & Management*, 2024, 61(6): 103858. DOI: 10.1016/j.ipm.2024.103858.
- [51] Ma Y, Yin J, Huang F, et al. Surface defect inspection of industrial products with object detection deep networks: a systematic review[J]. *Artificial Intelligence Review*, 2024, 57(12): 333. DOI: 10.1007/s10462-024-10956-3.
- [52] Fu G, Zhang Z, Li J, et al. An evaluation method for model transfer learning performance in industrial surface defect detection tasks[J]. *Expert Systems with Applications*, 2025, 293: 128680. DOI: 10.1016/j.eswa.2025.128680.
- [53] Ye B, Lai J, Xie X, et al. Prototype-guided domain adaptive one-stage object detector for defect detection[J]. *Advanced Engineering Informatics*, 2024, 62: 102618. DOI: 10.1016/j.aei.2024.102618.
- [54] Lv Z, Dong S, He J, et al. Lightweight Sewer Pipe Crack Detection Method Based on Amphibious Robot and Improved YOLOv8n[J]. *Sensors*, 2024, 24(18): 6112. DOI: 10.3390/s24186112.
- [55] Wang H, Feng Z, Jiang M, et al. RDLK-YOLO enhanced pipeline defect detection in uneven illumination[J]. *Scientific Reports*, 2025, 15: 43594. DOI: 10.1038/s41598-025-18808-y.
- [56] Lee S, Uh Y, Choe J, et al. Discovering an inference recipe for weakly-supervised object localization[J]. *Pattern Recognition*, 2024, 157: 110838. DOI: 10.1016/j.patcog.2024.110838.
- [57] Farrugia M. YOLO11 Architecture Diagram: Visual Representation of the YOLO11 Object Detection Model[EB/OL]. Zenodo, 2025. DOI: 10.5281/zenodo.15628103.
- [58] Božič J, Tabernik D, Skočaj D. Mixed supervision for surface-defect detection: From weakly to fully supervised learning[J]. *Computers in Industry*, 2021, 129: 103459. DOI: 10.1016/j.compind.2021.103459.
- [59] Ameri R, Hsu C C, Band S S. A systematic review of deep learning approaches for surface defect detection in industrial applications[J]. *Engineering Applications of Artificial Intelligence*, 2024, 130: 107717. DOI: 10.1016/j.engappai.2023.107717.

- [60] Wang H, Li Z, Wang H. Few-Shot Steel Surface Defect Detection[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-12. DOI: 10.1109/TIM.2021.3128208.

附录说明

如后续需要，可将详细网络结构图、额外实验表格、参数配置文件、类别映射说明、伪框生成规则、训练日志样例等补充材料放入附录部分。