

摘要

地下排水管道缺陷筛查在工程部署中面临三类现实约束：正常帧远多于缺陷帧，细粒度异常容易被背景纹理淹没，而默认阈值下的分类指标又不能直接回答高召回筛查中的减负效果。针对这一问题，本文将研究范围限定在两阶段系统的第一阶段门控任务，把它明确界定为固定高召回约束下的正常/异常筛查，而不是默认阈值二分类任务。本文的目标不是提出新的检测器，而是在现有实验基础上建立一套可复现、可审计的第一阶段选模、增强与重加权研究链。

围绕这一目标，本文首先完成直接二分类门控与六类源域视图两套容量扫描，并采用温度校准、工作点搜索和外部评估器进行统一比较。结果表明，门控视图与六类源域视图的容量排序并不一致，说明源域分类表现不能替代高召回门控下的模型选择。在当前数据划分与当前随机种子下，yolo11m-cls 在门控视图中排在第一，yolo11x-cls 作为第二对照模型保留。

在主模型固定后，本文在 n/s/m/l/x 五个容量上分别完成 11 点 HN 比例全量扫描（hard-negative ratio sweep），共计 55 个独立训练 run，并在扩展验证集（707 个正常样本）上统一重新评估。结果表明，HN 增益具有显著的容量依赖性：小容量模型（n/s）几乎无法从 HN 回流中获益（ $\Delta\text{Spec} \approx 0$ ），而大容量模型可获得中等至巨幅增益，其中 l+hn10 以 $\Delta\text{Spec@R99.5} = +0.2447$ 成为全局最优。五个容量的最优比例点互不相同（n→hn00, s→hn20, m→hn12, l→hn10, x→hn02），表明不存在通用最优 HN 比例，必须逐模型搜索。

在此基础上，本文提出门控导向样本效用评分框架（GAEIS），将候选池样本按校准后边界风险 R 、TTA 预测稳定性 C 和特征空间 kNN 密度 D 三个正交信号进行分位数分层消融（quintile-stratified ablation），共执行 16 组独立实验。三个信号均呈现非单调价值-信号响应（Goldilocks pattern）：极端信号值样本（第一分位）的门控性能低于中等信号值样本（第二至四分位），其中 $R\text{-Q2}$ 以 $\Delta\text{Spec@R99.5} = +0.0714$ （6 个正常样本）显著优于均匀基线，而 $R\text{-Q1}$ （最靠近门控边界的样本）反而低于基线。该 Goldilocks 效应在三个正交信号上独立复现，构成跨信号交叉验证。综上，本文建立了一条从等条件容量扫描、HN 全量比例扫描到样本价值信号分解与 Goldilocks 效应验证的完整第一阶段证据链。
关键词：地下排水管道；高召回门控；容量扫描；难负样本回流；高价值困难样本评估；温度校准；检查点选模；CCTV 图像

Abstract

This thesis studies stage-1 model selection and training-side enhancement for sewer-defect screening under a high-recall operating regime. Instead of treating stage-1 as a default-threshold binary classifier, the work defines it as a recall-constrained Normal/Abnormal gate whose objective is to maximize normal filtering under fixed recall anchors. The contribution is therefore not a new detector, but a reproducible and auditable stage-1 research chain covering model selection, hard-negative replay, and fixed-budget sample reallocation.

The thesis first reports two capacity scans: a direct binary-gate scan over five YOLO11 classification backbones, and a six-class source-side scan used only as an auxiliary reference. Temperature scaling and operating-point evaluation are applied consistently to every checkpoint. The two views do not yield the same ranking, which shows that source-side classification quality cannot replace gate-oriented checkpoint selection. Under the current split and seed, `yolo11m-cls` ranks first in the binary-gate view, while `yolo11x-cls` is retained as the main secondary comparison model.

The thesis then reports a full hard-negative (HN) ratio sweep on five capacity tiers (n/s/m/l/x), producing 55 independent training runs under the shared protocol, re-evaluated on an extended validation set (707 normal samples). The results reveal a strong **capacity-dependent** HN gain pattern: small-capacity models (n/s) derive virtually no benefit from HN replay ($\Delta\text{Spec} \approx 0$), whereas large-capacity models achieve substantial gains, with l+hn10 reaching the global optimum ($\Delta\text{Spec@R99.5} = +0.2447$). Optimal ratios differ across all five capacities (n $\rightarrow$ hn00, s $\rightarrow$ hn20, m $\rightarrow$ hn12, l $\rightarrow$ hn10, x $\rightarrow$ hn02), confirming that no universal optimal ratio exists.

Building on these findings, the thesis proposes a gate-aligned sample valuation framework and conducts a quintile-stratified ablation across three orthogonal signals: calibrated boundary risk (R), TTA prediction consistency (C), and feature-space kNN density (D). All three signals exhibit a non-monotonic value-signal response (Goldilocks pattern): extreme-signal samples (Q1, closest to the gate boundary) underperform moderate-signal samples (Q2–Q4), with R -Q2 outperforming the uniform baseline by $\Delta\text{Spec@R99.5} = +0.0714$ (6 normal samples)

while R -Q1 falls *below* it. The Goldilocks pattern independently replicates across all three orthogonal dimensions, providing cross-signal cross-validation without requiring multi-seed repetition. The thesis thus establishes a complete stage-1 evidence chain from ceteris paribus capacity sweep, to exhaustive HN ratio sweep, to quintile-stratified Goldilocks-effect verification.

Key words:sewer inspection, high-recall gate, capacity sweep, hard-negative ratio sweep, sample valuation, Goldilocks effect, quintile-stratified ablation, temperature scaling, CCTV imagery

目 录

摘要	i
Abstract	ii
主要符号与缩略语说明	xi
第 1 章 绪论	1
1.1 研究背景与工程意义	1
1.2 国内外研究现状	1
1.3 研究问题与研究目标	4
1.4 研究内容与技术路线	5
1.5 主要创新点	6
1.6 论文组织结构	6
第 2 章 理论基础与关键技术	7
2.1 卷积神经网络基础	7
2.2 YOLO 系列算法与分类骨干网络	9
2.3 迁移学习与预训练策略	12
2.4 第一阶段高召回门控的目标定义	12
2.5 评价指标定义	13
2.6 温度校准与门控导向的检查点选择	15
2.7 高召回约束下的非对称学习问题	16
2.8 难样本挖掘与样本效用建模	16
2.9 教师模型质量与评分输入偏差	21
2.10 六类源域视图的辅助地位	21
第 3 章 数据集构建、实验平台与 workflow	22
3.1 数据来源与数据组织	22
3.2 等条件共享训练协议	23
3.3 门控导向评估流程	24
3.4 HN 回流设置与候选池来源	24
3.5 结果留档与可复现性	24
第 4 章 高召回门控的选模与容量扫描	25
4.1 第一阶段任务重定义与双视图结构	25
4.2 二分类门控容量扫描	25
4.3 门控最优检查点的训练动态	27
4.4 训练器 top1-best 与门控最优检查点的系统性错位	28

4.5	六类源域视图容量扫描	28
4.6	跨视图排序错位分析	29
4.7	第一阶段主模型与第二对照模型的确定	30
第 5 章	基于 HN 回流的第一阶段训练侧增强与问题收缩	31
5.1	各容量模型的 HN 比例全量扫描结果	31
5.2	跨容量 HN 增益对比与形态分类	36
5.3	相对 hn00 的增量解释与训练动力学	37
5.4	代表性比例的训练轨迹对比	38
5.5	与基线主线的衔接及跨容量验证	39
5.6	HN 样本来源的可追溯性	40
5.7	HN 回流的已知边界	41
第 6 章	高价值困难样本的信号分解与 Goldilocks 效应验证	43
6.1	从 HN 非单调性到样本价值信号假设	43
6.2	候选池构建	44
6.3	分位数分层消融与 Goldilocks 效应验证	44
第 7 章	综合讨论与工程启示	47
7.1	已建立的第一阶段证据链	47
7.2	HN 增益的容量依赖性	47
7.3	Goldilocks 效应的理论意义	48
7.4	当前方法边界与后续方向	49
附录 A	第一阶段协议与符号表	50
附录 B	容量扫描补充材料	51
B.1	五模型检查点关键索引	51
B.2	容量扫描补充说明	51
附录 C	HN 比例扫描与困难正常样本来源补充材料	52
C.1	HN 检查点与材料覆盖	52
C.2	yolo11l-cls 完整 HN 比例扫描	53
C.3	分位数分层消融完整结果	54
C.4	HN sweep 的整体形态	55
C.5	HN 样本来源证明	55
C.6	关于比例级 top1 与门控最优检查点的说明	55
附录 D	有效信息量评分函数、消融接口与样本清单	57
D.1	lite 版评分函数摘要	57
D.2	样本清单与固定预算接口	57
附录 E	复现实验入口、目录结构与溯源清单	58
E.1	训练脚本与运行入口	58

E.2	目录结构与溯源清单	58
E.3	产物保留与清理规则	59

插图目录

2.1	YOLO 检测系统流程：缩放输入图像、运行卷积网络、非极大值抑制（图片来源于文献 [21]）	9
2.2	YOLO 网格检测原理：将图像划分为 $S \times S$ 网格，每个单元预测边界框与类别概率，最终融合为检测结果（图片来源于文献 [21]）	10
2.3	YOLO 网络结构：包含卷积层、最大池化层和全连接层（图片来源于文献 [21]）	10
2.4	YOLO11 多任务架构概览：骨干网络包含 C3k2、C2PSA 和 SPPF 等核心模块，支持检测、分割、分类等多种视觉任务（图片来源于 Ultralytics 官方文档 [11]）	11
2.5	YOLO 各版本在 COCO 数据集上的 mAP-延迟性能对比（图片来源于 Ultralytics 官方文档 [11]）	12
4.1	二分类门控容量扫描基线主指标对比（扩展验证集，707 正常样本）。基线 Spec@R99.5 在 0.17–0.34 区间内，五个容量差距较小，容量与门控性能之间不存在单调正比关系。	26
4.2	五模型 Spec@R99.5 随 epoch 的演化曲线	27
4.3	五模型 Spec@R99.0 随 epoch 的演化曲线	27
4.4	以 yolo11m-cls 与 yolo11l-cls 为例的 top1 与 gate 指标错位	28
4.5	六类源域视图容量扫描对比。yolo11x-cls 以 Acc = 0.700 排在第一，与二分类门控视图中 yolo11m-cls 排在第一形成跨视图排序错位。	29
4.6	六类源域视图与二分类门控的排序错位可视化	30
5.1	yolo11n-cls HN 比例扫描四项 gate 指标曲线（扩展验证集，707 正常样本）。基线 hn00 即为排序第一（Spec@R99.5 = 0.3267），所有 HN 比例均未超越基线，表明小容量模型无法从 HN 回流中获益。	32
5.2	HN 比例扫描下的容量依赖性证据	33
5.3	yolo11m-cls HN 比例扫描四项 gate 指标曲线（扩展验证集）。hn12 达 Spec@R99.5 = 0.3310 (+0.1612)，中间偏高比例（hn04–hn16）普遍优于基线，呈中段隆起形态。	34
5.4	五容量 $\times$ 11 比例的 Δ Spec@R99.5 热力图（扩展验证集，707 正常样本）。红色 = 正增益，蓝色 = 负增益。小容量（n/s）全面蓝色（HN 无益），大容量（m/l）呈中段红色隆起，标记各模型 winner。l+hn10 ($\Delta = +0.2447$) 为全局最大增益。	36
5.5	yolo11n-cls 的门控最优轮次随 HN 比例的变化	37
5.6	yolo11m-cls 的门控最优轮次随 HN 比例的变化	37
5.7	hn00、yolo11n-cls 当前排序第一设置与高比例尾部设置的训练轨迹对比	38
5.8	hn00、当前排序第一设置与高比例尾部设置的训练轨迹对比	38
5.9	yolo11m-cls 与 yolo11x-cls 在 hn00 到 hn02 间的跨容量方向性对比	40

5.10	训练正常样本的异常分数分布与困难正常样本选择阈值	41
5.11	从容量扫描、HN 最优比例点到固定预算样本重分配的问题收缩链	41
6.1	单调加权假设的反证。(a) 假设采用 $\pi_i \propto R_i^2$ 的单调评分, 84% 以上的采样 预算将集中在 Q1 (最高 R 值样本)。(b) 分位数消融表明 Q1 的 Spec@R99.5 低于 G0 基线 (-0.0238), 而 Q2 才是 peak ($+0.0714$)。单调加权将预算系 统性地投向最低价值分位桶。	45
6.2	三信号分位数分层消融的非单调价值-信号响应 (Goldilocks pattern)。 R 信 号 peak 落在 Q2 ($+0.0714$, 6 个正常样本), C 信号 peak 落在 Q4 ($+0.0595$), D 信号 peak 落在 Q3 ($+0.0595$)。 R -Q1 (最高边界风险) 的 Spec@R99.5 反而低于 G0 基线。拟合二次曲线可视化非单调 shape。	46
C.1	各 HN ratio 相对 hn00 的增量热力图	55
C.2	训练正常样本的异常分数分布与困难正常样本选择阈值	55

表格目录

1.1	相关研究分类与本文切入点	4
1.2	本文与已有两阶段/预筛工作的差异定位	4
2.1	二分类混淆矩阵	13
2.2	常用默认分类指标与本文 gate 指标的差异	14
2.3	样本效用建模中五类关键信号的作用	20
3.1	第一阶段数据集统计	22
3.2	二分类门控协议的校准集与工作点评估集划分	23
3.3	等条件共享训练协议超参数	23
4.1	等条件共享协议下的二分类门控容量扫描（扩展验证集，707 正常样本）。 yolo11s-cls 以 $\text{Spec@R99.5} = 0.3395$ 排在第一，yolo11n-cls 紧随其后 (0.3267)。基线容量排序在扩展验证集上发生变化，但差距极小。加粗为 best， 下划线 为 second-best。	25
4.2	关键排序结果对应的 normal 正确数与 95% Wilson 区间（扩展验证集， $n =$ 707）	26
4.3	训练器 top1-best 与门控最优检查点的对照	28
4.4	六类源域视图容量扫描主表	28
4.5	六类源域视图与二分类门控的跨视图排序差异	29
5.1	yolo11n-cls HN 比例扫描：主排序指标与增量（完整四指标表见附录表 C.2）	31
5.2	yolo11s-cls HN 比例扫描：主排序指标与增量（完整四指标表见附录表 C.3）	32
5.3	yolo11m-cls HN 比例扫描：主排序指标与增量（扩展验证集）。hn12 以 $\Delta\text{Spec@R99.5} = +0.1612$ 排在第一，显著优于基线。	33
5.4	yolo11l-cls HN 比例扫描：主排序指标与增量（扩展验证集）。hn10 以 $\Delta\text{Spec@R99.5} = +0.2447$ 排在第一，为五个容量中最大增益。	35
5.5	等条件共享协议下五个容量的 HN 比例扫描跨容量对比（扩展验证集，707 正常样本）	36
5.6	基线与 HN 最优设置的桥接对照（扩展验证集，op = 3863 张，707 正常样本）	39
5.7	yolo11x-cls HN 比例扫描：主排序指标与增量（扩展验证集）	39
5.8	困难正常样本选样统计	41
6.1	三信号分位数分层消融主结果：Spec@R99.5。加粗为各信号的 peak bucket， Δ 为相对 G0 的增量。三个信号的 peak 均不在 Q1（最高信号值），而分别 落在 Q2 (R)、Q4 (C) 和 Q3 (D)，呈现非单调价值-信号响应 (Goldilocks pattern)。注：本表数据待在扩展验证集（707 正常样本）上重新评估。	44

7.1	第一阶段已建立证据链总表	47
7.2	本文已解决问题与未解决问题对照表	49
A.1	第一阶段协议摘要	50
B.1	五模型门控最优检查点与训练器最优轮次索引	51
C.1	五模型 HN 最优检查点汇总（扩展验证集，707 正常样本）。仅列出各模型基 线与排序第一设置。	52
C.2	yolo11n-cls 的全量 HN 比例扫描结果（扩展验证集，707 正常样本）	52
C.3	yolo11s-cls 的全量 HN 比例扫描结果（扩展验证集，707 正常样本）	53
C.4	yolo11l-cls HN 比例扫描完整四指标表（扩展验证集，707 正常样本） ...	53
C.5	<i>R/C/D</i> 三信号分位数分层消融完整四指标表（16 组 run，G0 = 均匀基线）	54
C.6	困难正常样本选样统计	55
E.1	lite 版 PNG 产物重建清单与用途说明	58

主要符号与缩略语说明

符号/缩略语	含义
Spec@R99.5	在召回率不低于 99.5% 的约束下，正常样本拦截能力所对应的 specificity。
Spec@R99.0	在召回率不低于 99.0% 的约束下，正常样本拦截能力所对应的 specificity。
Prec@R99.0	在召回率不低于 99.0% 的约束下的 precision。
PTR@R99.0	在召回率不低于 99.0% 时的通过率，即进入下一阶段的样本占全部样本的比例。
val-cal / val-op	校准集与工作点评估集。
HN	难负样本回流，指从训练正常样本中构造的高风险回流样本。
GAEIS	Gate-Aligned Effective Information Score，本文用于高价值困难样本直接评估的评分框架。
$\tau_{99.5}, \tau_{99.0}$	在本文 gate 评估下分别对应 R99.5 与 R99.0 的工作阈值。

第 1 章 绪论

1.1 研究背景与工程意义

地下排水管道 CCTV 巡检产生的视频帧中正常帧占比通常超过 95% [15], 人工逐帧判读在效率与一致性上均难以为继 [14, 19, 16]。在两阶段检测工作流中, 第一阶段承担高召回前端筛查 (high-recall front-end screening): 在固定召回约束下最大化正常帧拦截, 从而大幅压缩进入后续人工复核的样本量。该目标可形式化为召回约束门控优化 (recall-constrained gate optimization) 问题:

$$\max_{\theta} \text{Spec}(\theta) \quad \text{s.t.} \quad \text{Recall}(\theta) \geq r_0, \quad (1.1)$$

其中 θ 为模型参数与工作阈值的联合决策变量, r_0 为预设的召回下界 (本文取 $r_0 \in \{99.5\%, 99.0\%\}$), Spec 为正常样本拦截率。

传统研究将第一阶段视作默认阈值分类任务, 以训练器侧 top1 准确率作为早停与选模依据。然而式 (1.1) 表明, 门控目标并非最大化整体分类正确率, 而是在召回硬约束下最大化 specificity。默认阈值语义与召回约束门控语义之间存在目标错位 (objective misalignment)。本文据此将第一阶段重新界定为式 (1.1) 所定义的召回约束门控, 并围绕该目标组织等条件容量扫描 (ceteris paribus capacity sweep)、温度校准评估 (temperature-calibrated evaluation)、检查点选择 (checkpoint selection) 以及难负样本比例扫描 (hard-negative ratio sweep)。

1.2 国内外研究现状

1.2.1 排水管道缺陷视觉识别

排水管道缺陷识别经历了由人工特征到深度视觉模型的技术演进。早期工作以 HOG、SVM 和规则驱动候选区域为主, 已经证明 CCTV 图像中的管道异常具有一定可计算性, 但方法对场景变化较为敏感 [17]。随着深度学习的发展, 研究开始转向图像级分类与目标检测。Kumar 等利用深度卷积网络完成排水管道 CCTV 缺陷分类, Cheng 等进一步将深度模型用于管道缺陷检测, 表明数据驱动表征能够显著提升识别性能 [18, 19]。

1.2.2 YOLO 路线与排水管道场景适配

YOLO 系列因具备较好的实时性和工程成熟度，已成为管道缺陷检测中的常见基础路线^[21]。在排水管道场景中，研究者围绕特征增强、轻量化部署与场景适配提出了多种改进策略，例如改进 YOLOv5 的管道缺陷检测模型以及轻量化 YOLOv5-Sewer 等^[32, 33]。这些工作证明，YOLO 路线具有良好的工程基础；但它们也表明，不同任务目标之间不能简单共享同一评价口径：用于目标检测的检测器精度并不直接回答高召回门控下的正常样本拦截问题。

1.2.3 两阶段预筛、概率校准与召回约束评价

在排水管道 CCTV 巡检中，“先粗筛正常帧、再精检缺陷帧”的两阶段思路并非空白。Xie 等最早提出分层深度网络：第一层二分类区分有无缺陷，第二层对保留图像做缺陷类型分类，总体准确率达 94.96%^[35]。Chen 等采用轻量 SqueezeNet 做前端异常帧筛查，再用 InceptionV3 做精细分类，是架构上最接近“轻量门控 + 重模型”部署范式的早期工作^[36]。Haurum 与 Moeslund 在发布 Sewer-ML 基准数据集时，明确定义了三种系统架构选项，其中 Setting (b) 即为“先二分类、再多标签分类”的两阶段方案，并引入 F1-Normal 指标评价正常帧分类能力^[20]。最近，Shamsolmoali 等实现了 ResNet50-Swin Transformer 二分类器 + 改进 YOLOv8 检测器的完整两阶段 pipeline，报告预筛阶段使后端检测 mAP 从 0.70 提升至 0.81^[37]。

与上述工作同期，Meijer 等在 *Automation in Construction* 上率先将操作层面的审阅效率纳入评价体系：该研究在 220 万张 Panoramio 图像上使用 CNN 做 12 类缺陷分类，明确报告了 specificity at sensitivity 与 precision at recall 两组工作点指标，并指出实际缺陷率仅约 0.8%、CNN 辅助可减少 60.5% 的人工复核量^[34]。Myrans 等则从视频时序角度出发，通过帧间平滑降低误报率，表明“管理连续视频流的误报与审阅效率”而非仅优化单帧检测性能，已成为排水管道视觉识别的务实关切^[38]。

然而，上述两阶段或审阅效率工作均未涉及以下三个环节：（1）对二分类门控的输出概率进行事后温度校准（post-hoc temperature scaling）^[22]；（2）在显式召回下限约束下搜索最优工作点阈值，而非使用固定阈值 0.5；（3）在 200 epoch 的完整训练轨迹上逐 epoch 评估并选择检查点，而非直接采用验证损失或分类准确率最优的默认检查点。这三个环节构成了本文评估协议与已有工作的核心差异。

1.2.4 难样本挖掘、数据剪枝与样本效用建模研究

围绕样本选择与训练效率提升，已有研究从难负样本挖掘、不确定性驱动选样、兼顾多样性的主动学习、基于训练动态的数据剪枝以及结构支撑建模等多个方向展开。相关工作共同指出，样本价值并不等于单一损失大小或原始不确定性，高风险样本中同样可能混入不稳定噪声与孤立异常点；因此，样本选择需要同时考虑风险、稳定性与结构支撑等因素 [24, 25, 26, 27, 28, 29]。

其中与本文最具思想同构性的是 Swayamdipta 等提出的 **Dataset Cartography** 框架 [30]。该工作将训练样本按跨 epoch 置信度均值与方差映射到“易学/模糊/难学”三个区域，核心发现为：对模型最有训练价值的往往不是最难学的样本，而是中等置信度的模糊样本——最难学样本中大量混入标注噪声与分布外异常。这一“中间层最优”的发现，与本文在分位数分层消融中观察到的 Goldilocks 效应（第一分位极端样本的门控性能低于第二至四分位中等样本）形成直接呼应，表明非单调价值-信号响应并非排水管道场景的特例，而可能是样本效用建模的一般规律。

综上，本文的研究动机并非首创门控预筛或样本价值评估的概念，而是将上述已有思想在排水管道第一阶段召回约束门控场景下系统化：建立温度校准 + 召回约束检查点选择的评估协议，在等条件共享训练协议下完成跨容量 HN 全量扫描，并通过 RDTC 四信号分位数分层消融验证 Goldilocks 效应，形成完整的证据链。

表 1.1 相关研究分类与本文切入点

研究方向	代表工作	典型回答的问题	与本文关系
排水管道缺陷视觉识别	Kumar 2018; Cheng 2018	管道缺陷能否被机器视觉识别	提供场景背景与基准语境
YOLO / 检测器场景适配	Wang 2023; Zhao 2024	如何提升定位精度或实时性	仅提供工程背景,不直接回答门控选模
两阶段预筛与审阅效率	Xie 2019; Meijer 2019; Shamsolmoali 2025	先筛正常帧能否提升后端精度或减少人工复核	本文的直接前驱;差异在于校准、召回约束与检查点选择
校准与约束优化	Guo 2017; Kumar 2021	固定召回下如何稳定比较模型	直接支撑本文门控导向协议
样本效用建模	Swayamdipta 2020; Kim 2024	哪些样本最有训练价值	直接支撑 Goldilocks 效应假设

表 1.2 本文与已有两阶段/预筛工作的差异定位

比较维度	已有两阶段/预筛工作	本文定位
二分类阈值	固定阈值 0.5 或未报告	温度校准后在召回下限约束下搜索最优阈值
检查点选择	best-val-loss 或 best-mAP	逐 epoch 全扫描, 按 Spec@R99.5 四元排序规则选择
评价指标	整体准确率或后端 mAP 增益	Spec@R99.5 > Spec@R99.0 > Prec@R99.0 > PTR@R99.0
HN 训练增强	未涉及或不系统	等条件 4 模型 $\times$ 11 比例全量扫描 (55 run)
样本价值分解	未涉及	RDTC 四信号分位数分层消融 + Goldilocks 验证

1.3 研究问题与研究目标

1.3.1 本文的任务边界

本文的任务边界严格限定在式 (1.1) 所定义的第一阶段召回约束门控。研究对象为基于 YOLO11-cls 的高召回门控在等条件共享训练协议 (shared training

protocol) 下的骨干网络选择、检查点选择与训练侧增强; 对检测器结构、系统级闭环收益以及单阶段与两阶段系统的最终优劣比较, 本文不作超出当前实证范围的结论。

1.3.2 核心科学问题与研究目标

围绕式 (1.1) 的门控目标, 本文依次回答四类递进问题:

1. 容量选择 (capacity selection): 在等条件共享训练协议下, 五种 YOLO11-cls 容量中哪一种最适合作为高召回门控的主模型?
2. 难负样本比例扫描 (hard-negative ratio sweep): 主模型固定后, HN 回流在不同比例下的 ΔSpec 是否单调递增? 该增益是否具有模型相关性 (model-dependent gain) 与形态异质性 (shape heterogeneity)?
3. 样本价值信号分解 (sample-value signal decomposition): 候选池内部是否存在可观测的价值异质性? 校准后边界风险 R 、TTA 预测稳定性 C 和特征空间 kNN 密度 D 三个正交信号是否具有独立的排序力?
4. 非单调价值-信号响应 (non-monotonic value-signal response): 极端信号值样本是否一定优于中等信号值样本? 三个信号是否均呈现 **Goldilocks pattern**——中间层样本价值高于两端?

据此, 本文的研究目标为: (1) 建立可复现、可审计的第一阶段等条件选模协议; (2) 在五个容量梯度 (5.4M-57M 参数) 上完成 HN 比例全量扫描 (hard-negative ratio sweep), 确定各容量的最优比例点与增益上界, 并刻画 HN 增益的容量依赖性 (capacity-dependent gain); (3) 提出门控导向样本效用评分 (gate-aligned sample valuation) 框架, 在固定预算下通过分位数分层消融 (quintile-stratified ablation) 验证 $R/C/D$ 三信号的排序力与 Goldilocks 效应。

1.4 研究内容与技术路线

本文的技术路线由四个递进阶段组成。第一阶段 (等条件容量扫描): 在直接二分类门控与六类源域两个视图上分别执行容量扫描, 通过温度校准与外部评估器确定骨干网络排序。第二阶段 (**HN 比例全量扫描**): 以 yolo11m-cls 为主线, 在 yolo11n/s/l/x-cls 四个对照容量上完成 $r \in \{0\%, 2\%, \dots, 20\%\}$ 共 11 个比例点的全量扫描 (hard-negative ratio sweep), 共计 55 个独立训练 run, 刻画 HN 增益的非单调性与模型相关性。第三阶段 (**样本价值信号分解与 Goldilocks 验证**): 将候选池 250 个样本按 $R/C/D$ 三信号各自排序后均分为 5 个分位桶 (quintile bucket), 加上均匀基线 G0, 共执行 16 组分位数分层消融 (quintile-stratified ablation), 验证各信号的独立排序力与非单调价值-信号响应。第四阶段 (**负结果诊断与边界界定**): 基于 lite 版样本重分配的负结果, 结合分

位数消融的 Goldilocks 发现，定位失败主因并界定当前方法边界。

1.5 主要创新点

本文的主要创新点包含以下三个方面。

创新点一：门控导向等条件评估协议。将第一阶段重新界定为式 (1.1) 的召回约束门控，建立由温度校准、校准集/工作点评估集划分 (val-cal/val-op split)、逐 epoch 外部评估和四元排序规则 ($\text{Spec@R99.5} \succ \text{Spec@R99.0} \succ \text{Prec@R99.0} \succ \text{PTR@R99.0}$) 共同构成的评价协议，并在五个容量梯度 $\times$ 11 个 HN 比例的 55 个独立 run 上保持等条件共享训练协议。

创新点二：跨容量 HN 比例全量扫描与容量依赖性发现。在五个容量 (n/s/m/l/x) 上各自执行 11 点比例全量扫描 (共 55 个独立 run)，发现 HN 增益具有显著的容量依赖性：小容量模型 (n/s) 几乎无法从 HN 回流中获益 ($\Delta\text{Spec} \approx 0$)，而大容量模型 (m/l/x) 则可获得中等至巨幅增益 (ΔSpec 最高达 +0.2447, l+hn10)。各容量最优比例点互不相同 ($n \rightarrow \text{hn00}$, $s \rightarrow \text{hn20}$, $m \rightarrow \text{hn12}$, $l \rightarrow \text{hn10}$, $x \rightarrow \text{hn02}$)，呈现非单调性与形态异质性。

创新点三：三信号分位数分层消融与 **Goldilocks** 效应发现。提出门控导向样本效用评分框架，将候选池样本按 $R/C/D$ 三个正交信号分层并执行 16 组分位数消融。三个信号均呈现非单调价值-信号响应 (Goldilocks pattern)：极端信号值样本 (第一分位) 的门控性能低于中等信号值样本 (第二至四分位)，表明困难样本价值并非信号强度的单调函数，而是存在最优中间层 (Goldilocks zone)。

1.6 论文组织结构

全文围绕式 (1.1) 的门控目标展开。第 2 章给出 CNN/YOLO 骨干网络、迁移学习、温度校准与样本效用建模的理论基础及形式化定义；第 3 章报告数据集统计、等条件共享训练协议与评估流程；第 4 章报告二分类门控容量扫描、六类源域辅助视图及跨视图目标错位；第 5 章报告 n/s/m/l 四个容量上的 HN 比例全量扫描与跨容量验证；第 6 章报告门控导向样本效用评分框架、lite 版负结果及 $R/C/D$ 三信号分位数分层消融的 Goldilocks 发现；第 7 章给出综合讨论、方法边界与工程启示。

第 2 章 理论基础与关键技术

2.1 卷积神经网络基础

卷积神经网络 (Convolutional Neural Network, CNN) 是当前计算机视觉任务的核心架构 [1, 2]。本节给出 CNN 基本组件的形式化定义, 作为后续 YOLO11 骨干网络讨论的符号基础。

2.1.1 卷积层与特征提取

卷积层是 CNN 区别于传统全连接网络的核心组件。设输入图像 (或上一层的特征图) 为 $X \in \mathbb{R}^{H \times W \times C_{\text{in}}}$, 其中 H 、 W 分别为空间高度和宽度, C_{in} 为输入通道数 (例如 RGB 图像的 $C_{\text{in}} = 3$)。卷积核 $K \in \mathbb{R}^{k \times k \times C_{\text{in}}}$ 在输入上滑动, 输出特征图上位置 (i, j) 处的响应为

$$Y(i, j) = \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} \sum_{c=0}^{C_{\text{in}}-1} K(m, n, c) \cdot X(i \cdot s + m, j \cdot s + n, c) + b, \quad (2.1)$$

其中 k 为卷积核的空间尺寸, s 为步长 (stride), b 为偏置项。多个卷积核分别提取不同的局部特征模式, 共同组成该层的输出特征图。与全连接层相比, 卷积层通过参数共享 (同一卷积核在所有空间位置上重复使用) 和局部连接 (每个输出仅依赖输入的一个局部感受野) 两个机制, 大幅减少了模型参数量, 同时保留了图像的空间结构信息 [2]。此外, 卷积操作中的填充 (padding) 参数可在输入边界补零以控制输出尺寸, 其中常用的 same 填充可使输出空间尺寸与输入相同。

2.1.2 激活函数

卷积操作本身是线性变换, 多层线性变换的堆叠在数学上等价于单层线性变换 [1], 因此需要在每层卷积后引入非线性激活函数以增强网络的表达能力。在早期神经网络研究中, 常用的激活函数包括 Sigmoid 函数 $\sigma(x) = 1/(1 + e^{-x})$ 和双曲正切函数 $\tanh(x)$, 但这两种函数在输入绝对值较大时梯度接近于零, 容易在深层网络训练中引发梯度消失问题。

Nair 与 Hinton 于 2010 年提出的修正线性单元 (Rectified Linear Unit, 简称 ReLU) 有效缓解了这一问题 [6], 其定义为

$$\text{ReLU}(x) = \max(0, x). \quad (2.2)$$

ReLU 在正半轴保持线性、梯度恒为 1，不会随网络深度增加而衰减；在负半轴输出为零，提供了稀疏激活特性。由于计算简单且训练收敛速度远快于 Sigmoid 和 tanh，ReLU 及其变体（如 Leaky ReLU、SiLU 等）已成为现代卷积网络中最常用的激活函数。本文使用的 YOLO11 模型中，骨干网络默认采用 SiLU（又称 Swish）激活函数，其定义为 $\text{SiLU}(x) = x \cdot \sigma(x)$ ，兼顾了 ReLU 的计算效率与 Sigmoid 的平滑可微性。

2.1.3 池化层

池化层（Pooling Layer）对特征图进行空间下采样，以减小后续层的计算量并扩大感受野。最常用的池化方式是最大池化（Max Pooling），其在每个固定大小的窗口内取最大值作为输出：

$$Y(i, j) = \max_{(m, n) \in \mathcal{R}_{i, j}} X(m, n), \quad (2.3)$$

其中 $\mathcal{R}_{i, j}$ 为以 (i, j) 为起点、大小为 $p \times p$ 的池化窗口。以 2×2 最大池化为例，输出的空间尺寸缩小为输入的一半，而通道数保持不变。池化操作不引入可学习参数，但通过逐层缩小空间分辨率、逐步提升特征的抽象层次，使高层特征图能够捕捉更大范围的语义信息。在现代网络架构中，池化层有时被步长为 2 的卷积层替代以保留更灵活的下采样方式，但全局平均池化（Global Average Pooling）作为分类网络末端的特征聚合手段仍被广泛采用。

2.1.4 全连接层与分类输出

在卷积和池化层提取出高层特征后，分类网络通常使用全连接层将特征映射为各类别的得分。设最后一层的输出经全局平均池化后为向量 $f \in \mathbb{R}^d$ ，全连接层的输出 $z = Wf + b$ 给出 K 个类别的原始得分，即 logit 值。对于多类分类任务，logit 向量通过 Softmax 函数转化为概率分布^[1]：

$$p_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}, \quad k = 1, 2, \dots, K. \quad (2.4)$$

训练阶段通过最小化交叉熵损失函数 $\mathcal{L} = -\sum_{k=1}^K y_k \log p_k$ 更新模型参数，其中 y_k 为真实标签的 one-hot 编码。对于本文的二分类门控任务（ $K = 2$ ），Softmax 退化为等价的 Sigmoid 形式：当仅关注异常类概率时， $p_{\text{abnormal}} = \sigma(z_{\text{abnormal}} - z_{\text{normal}})$ ，其中 σ 即后续章节使用的 Sigmoid 函数。

2.1.5 典型卷积网络架构的演进

卷积网络架构经历了从 AlexNet（8 层，ReLU + Dropout，ImageNet top-5 错误率 16.4%）^[3]、VGGNet（16–19 层，统一 3×3 卷积核）^[4] 到 ResNet（残差连接 $\mathcal{F}(x) = H(x) - x$ ，top-5 错误率 3.57%）^[5] 的演进。残差连接（residual connection）与批归一化（Batch Normalization, BN）^[7] 是现代深度网络的两个标准组件：前者通过快捷连接缓解梯度消失，使百层以上网络可训练；后者在每层激活前将 mini-batch 特征归一化至零均值单位方差，加速收敛并降低对学习率初始值的敏感性。YOLO11 骨干网络同时采用了残差结构与 BN。

2.2 YOLO 系列算法与分类骨干网络

YOLO（You Only Look Once）是当前工程部署中应用最广泛的单阶段目标检测框架之一^[21]。本文使用的 YOLO11-cls 分类模型直接复用 YOLO11 的骨干网络，因此本节给出 YOLO 系列的核心思想与 YOLO11 分类模型的架构要点。

2.2.1 目标检测的两条技术路线

基于深度学习的目标检测算法按检测流程可分为两类^[21]。以 R-CNN 系列为代表的两阶段（two-stage）检测器，先通过候选区域生成模块（如选择性搜索或区域提议网络）产生大量候选框，再对每个候选框逐一进行分类和边界框回归；这类方法检测精度较高，但推理速度受候选框数量限制。以 YOLO 和 SSD 为代表的单阶段（one-stage）检测器，则将目标定位与类别预测统一在一次前向传播中完成，大幅提升了推理效率，尤其适合对实时性有要求的工程场景。




图 2.1 YOLO 检测系统流程：缩放输入图像、运行卷积网络、非极大值抑制（图片来源于文献^[21]）

2.2.2 YOLO 算法的核心思想与版本演进

Redmon 等人于 2016 年首次提出 YOLO 算法^[21]，其核心思想是将目标检测问题转化为单次回归问题：将输入图像划分为 $S \times S$ 的网格，每个网格单元同时预测若干边界框的坐标、置信度以及各类别的条件概率，整个过程仅需一次

网络前向传播即可完成。这一设计在保持较高检测精度的同时，实现了远超两阶段检测器的推理速度。




图 2.2 YOLO 网格检测原理：将图像划分为 $S \times S$ 网格，每个单元预测边界框与类别概率，最终融合为检测结果（图片来源于文献 [21]）

YOLO 系列的后续版本沿两条轴持续改进：特征融合与骨干网络效率。YOLOv2 引入锚框机制与多尺度训练 [8]；YOLOv3 采用特征金字塔网络（Feature Pyramid Network, FPN），通过自顶向下的路径将高层语义与低层细节融合 [9]，其核心递推为

$$P_l = \text{Conv}(\text{Up}(P_{l+1}) + C_l), \quad (2.5)$$

其中 C_l 为骨干网络第 l 层的侧向特征， $\text{Up}(\cdot)$ 为上采样操作。YOLOv4 在骨干中引入 CSPDarknet 与 Mish 激活 [10]，进一步优化精度-速度权衡。




图 2.3 YOLO 网络结构：包含卷积层、最大池化层和全连接层（图片来源于文献 [21]）

在工程社区层面，Ultralytics 团队从 YOLOv5 开始对 YOLO 系列进行了系统的工程化重构，提供了统一的训练、推理和模型导出接口 [11]。后续的 YOLOv8

和 YOLO11 延续了这一框架，并在骨干网络结构、特征融合方式和训练策略上持续迭代。本文使用的 YOLO11 是 Ultralytics 于 2024 年发布的版本，其骨干网络采用了 C3k2 模块和空间金字塔池化快速版（SPPF），在保持高效推理的同时提升了多尺度特征提取能力。

2.2.3 YOLO11 分类模型

虽然 YOLO 系列最初为目标检测而设计，但其骨干网络同样可以复用于图像分类任务。YOLO11 分类模型（YOLO11-cls）保留了 YOLO11 的完整骨干网络，将检测头替换为全局平均池化层与全连接分类层，形成标准的图像分类器 [11]。




图 2.4 YOLO11 多任务架构概览：骨干网络包含 C3k2、C2PSA 和 SPPF 等核心模块，支持检测、分割、分类等多种视觉任务（图片来源于 Ultralytics 官方文档 [11]）

YOLO11-cls 提供了五个容量等级的预训练模型，按参数量从小到大依次为 yolo11n-cls（nano）、yolo11s-cls（small）、yolo11m-cls（medium）、yolo11l-cls（large）和 yolo11x-cls（extra-large）。不同容量模型的骨干网络深度系数和宽度系数不同，参数量与计算量逐级增加。在第一阶段门控任务中，容量选择是一个关键决策：容量过小可能导致模型无法充分区分边界附近的困难样本，容量过大则可能带来过拟合风险和不必要的计算开销。本文第 4 章将报告这五个容量模型在直接二分类门控视图下的系统性扫描结果。




图 2.5 YOLO 各版本在 COCO 数据集上的 mAP-延迟性能对比（图片来源于 Ultralytics 官方文档 [11]）

2.3 迁移学习与预训练策略

迁移学习（transfer learning）^[12] 通过将源域 $\mathcal{D}_S$ 上学习到的表征迁移至目标域 $\mathcal{D}_T$ ，缓解目标域标注不足的问题。其基本假设为源域与目标域共享底层视觉特征但存在分布偏移（domain shift）：

$$P_S(X) \neq P_T(X), \quad \text{但 } P_S(Y|X) \approx P_T(Y|X) \text{ 在底层特征上近似成立。} \quad (2.6)$$

Yosinski 等人的可迁移性实验表明，深度网络底层特征（Gabor 滤波器、颜色斑块）具有跨任务通用性，高层特征则任务特异^[13]。在排水管道场景中，目标域数据规模受限於巡检成本（本文训练集仅 7200 张），通过 ImageNet 预训练的 YOLO11-cls 作为起点进行全网络微调（fine-tuning），可在有限数据上取得工程意义的拦截性能^[31]。

本文所有实验均采用 ImageNet 预训练权重初始化。需注意，骨干网络容量不仅影响理论表达能力，还影响预训练特征向目标域的迁移效率——过大容量可能引入与目标域不相关的高层表征干扰。这一判断在第 4 章的等条件容量扫描中得到间接验证。

2.4 第一阶段高召回门控的目标定义

设第一阶段的输入样本总数为 N 。其中异常样本需要尽可能完整地保留给后续人工复核或后级处理，而正常样本应在尽可能不牺牲召回的前提下被前级拦截。由此，第一阶段的核心目标并不是默认阈值下的总体分类正确率，而是高召回约束下的正常样本拦截能力。

本文采用两个固定工作点作为锚点： $\text{Recall} \geq 99.5\%$ 与 $\text{Recall} \geq 99.0\%$ 。在

这两个约束下，排序规则定义为：

$$\text{Spec@R99.5} \succ \text{Spec@R99.0} \succ \text{Prec@R99.0} \succ \text{PTR@R99.0}. \quad (2.7)$$

2.5 评价指标定义

2.5.1 二分类混淆矩阵基础

在二分类门控语境中，模型对每个样本做出”异常”或”正常”的判定，与真实标签组合后产生四种结果^[1]。**TP**（True Positive，真阳性）是指真实为异常且模型判定为异常的情形，即正确保留了缺陷帧。**FN**（False Negative，假阴性）是指真实为异常但模型判定为正常的情形，即漏掉了缺陷帧，这是高召回门控中最不可接受的错误。**TN**（True Negative，真阴性）是指真实为正常且模型判定为正常的情形，即成功拦截了正常帧，不再送往后续阶段。**FP**（False Positive，假阳性）是指真实为正常但模型判定为异常的情形，即误将正常帧当作缺陷帧放行，增加了后续阶段的无效负担。

表 2.1 二分类混淆矩阵

	模型判定为异常	模型判定为正常
真实异常	TP（正确保留）	FN（漏检）
真实正常	FP（误放行）	TN（成功拦截）

在门控语境中，FN（漏检缺陷帧）代价最高，TN（成功拦截正常帧）为门控核心收益。式 (1.1) 的优化目标等价于在 FN 尽可能少的前提下最大化 TN。

2.5.2 基础指标定义

基于上述四种结果，定义以下基础指标。记异常类样本总数为 $P = TP + FN$ 、正常类样本总数为 $N_{\text{neg}} = TN + FP$ ，则召回率（Recall）衡量异常样本中被正确保留的比例：

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{TP}{P}. \quad (2.8)$$

Recall = 99.5% 意味着每 200 个真实缺陷帧中最多漏掉 1 个。

特异度（Specificity）衡量正常样本中被成功拦截的比例：

$$\text{Specificity} = \frac{TN}{TN + FP} = \frac{TN}{N_{\text{neg}}}. \quad (2.9)$$

Specificity 越高，说明前级过滤掉的正常帧越多，后续阶段的无效负担越小。

精确率（Precision）衡量模型判定为异常的样本中，真正是异常的比例：

$$\text{Precision} = \frac{TP}{TP + FP}. \quad (2.10)$$

2.5.3 本文的门控导向指标

在上述基础指标的基础上，本文定义四个带有工作点约束的门控导向指标。Spec@R99.5 表示在召回率不低于 99.5% 的约束下所能达到的最高 specificity，是本文最严格的排序依据。Spec@R99.0 表示在召回率不低于 99.0% 的约束下所能达到的最高 specificity，作为第二排序依据。Prec@R99.0 表示在召回率不低于 99.0% 的约束下的 precision，用于衡量被放行样本中真实缺陷帧的纯度。PTR@R99.0 表示在召回率不低于 99.0% 对应阈值下的通过率（Pass-Through Rate），即仍被送往下一阶段的样本占全部样本的比例，其定义为

$$\text{PTR@R99.0} = \frac{TP + FP}{N}, \quad (2.11)$$

其中 N 为全部样本总数。PTR 越低，说明前级过滤效果越好，后续阶段需要处理的样本越少。

这四个指标的排序优先级为

$$\text{Spec@R99.5} \succ \text{Spec@R99.0} \succ \text{Prec@R99.0} \succ \text{PTR@R99.0}, \quad (2.12)$$

即首先比较最严格召回约束下的拦截能力，只有在前一指标持平时才进入后续并列判别规则。这一排序规则贯穿本文所有模型比较与检查点选择。

需要强调的是，Spec@R99.5 与 Spec@R99.0 均是带有工作点约束的条件量，而不是在默认阈值下计算的整体分类指标。PTR@R99.0 则直接刻画固定高召回条件下进入下一阶段的样本负担，因此既具有统计意义，也具有工程意义。

表 2.2 常用默认分类指标与本文 gate 指标的差异

比较维度	默认阈值分类指标	本文 gate 指标
典型代表	准确率、训练器侧 top1、损失函数值	Spec@R99.5、Spec@R99.0、Prec@R99.0、PTR@R99.0
工作点	通常隐含固定默认阈值	通过校准集与工作点评估集明确求取
关注对象	总体分类正确率或训练健康状态	固定高召回条件下的正常样本拦截能力
对第一阶段的适配性	可监控训练，但不能直接决定检查点排序	直接决定检查点选择与主线排序

2.6 温度校准与门控导向的检查点选择

为避免不同检查点的分数尺度不可比, 本文对每个轮次检查点采用单标量温度缩放^[22]。在给出具体流程之前, 先引入后续各章反复用到的三个基本变换。

2.6.1 logit 与 sigmoid 变换

对于取值在 $(0, 1)$ 之间的概率 p , logit 函数将其映射到实数轴:

$$\text{logit}(p) = \log \frac{p}{1-p}. \quad (2.13)$$

其逆变换为 sigmoid 函数:

$$\sigma(x) = \frac{1}{1 + e^{-x}}, \quad (2.14)$$

即 $\sigma(\text{logit}(p)) = p$ 。logit 空间的线性移动对应概率空间中不同程度的非线性压缩或拉伸, 因此本文在校准、阈值搜索和样本评分中均优先在 logit 空间上操作。

2.6.2 单标量温度缩放

设模型对样本 x_i 的原始 logit 输出为 z_i , 则温度缩放后的校准概率为

$$p_i = \sigma\left(\frac{z_i}{T}\right), \quad (2.15)$$

其中 $T > 0$ 为在校准集上以负对数似然为目标拟合的单一标量参数。当 $T > 1$ 时, 对数几率被压缩, 校准后概率更趋保守; 当 $T < 1$ 时, 对数几率被拉伸, 概率分布更尖锐。温度缩放不改变样本的排序, 只改变概率值本身, 从而使不同检查点之间的阈值具有可比性。

2.6.3 检查点选择流程

基于上述变换, 检查点选择的具体流程如下。首先, 在固定的校准集上以负对数似然为目标拟合温度参数 T 。其次, 将拟合得到的温度应用于工作点评估集, 得到校准后概率得分。然后, 在工作点评估集上执行阈值扫描, 遍历候选阈值并计算每个阈值下的 recall、specificity、precision 与通过率。最后, 按照上述排序规则选出门控最优检查点, 而不是直接使用训练器自动保存的 `best.pt`。

这一协议意味着温度校准已经内嵌为本文评估协议的组成部分, 而不是独立于容量扫描之外的附加训练阶段。训练器侧的准确率、top1 和损失值仍然保留, 但只承担训练健康监控功能, 不承担正文选模功能。

2.7 高召回约束下的非对称学习问题

从目标形式看，第一阶段不是一个“最大化总体准确率”的对称二分类问题，而是一个“在固定高召回条件下最大化正常样本拦截能力”的非对称学习问题。这一目标可写成如下约束优化形式：

$$\max_{\theta, \tau} \text{Specificity}(\theta, \tau) \quad \text{s.t.} \quad \text{Recall}(\theta, \tau) \geq R^*, \quad (2.16)$$

其中 θ 表示模型参数， τ 表示工作阈值， R^* 为预先设定的召回下界。与默认阈值分类不同，这一目标本质上属于“固定一个指标再优化另一个指标”的约束学习问题^[23]。因此，训练器侧报告的 `top1` 或默认验证精度并不天然对应本文真正关心的门控目标。

2.8 难样本挖掘与样本效用建模

本节围绕样本效用建模（sample valuation）的核心问题——“什么样的训练样本更值得被重复学习”——给出五个正交维度的形式化定义。这五个维度构成本文第 6 章门控导向样本效用评分（gate-aligned sample valuation）框架的理论基础。

2.8.1 难负样本回流的定义与动机

在本文语境中，难负样本回流（简称 HN 回流）是指：利用已训练的教师模型对训练集正常样本逐一推理，按校准后异常概率 p_i （见公式 2.15）从高到低排序，将排名靠前的高风险正常样本以额外副本的形式重新加入训练集，从而增加模型在门控边界附近对正常样本的学习强度。

更形式化地，设训练正常样本集为 $\mathcal{N} = \{x_1, x_2, \dots, x_M\}$ ，教师模型对每个样本的校准异常概率为 p_i 。取分数最高的前 N_{pool} 个样本构成难样本候选池：

$$\mathcal{N}_{\text{hard}} = \text{Top}_{N_{\text{pool}}}(\mathcal{N}, p_i). \quad (2.17)$$

在固定的额外回流预算 B 下，均匀回流等概率地从 $\mathcal{N}_{\text{hard}}$ 中采样 B 次副本加入训练集；而加权回流则按非均匀的采样概率 π_i 进行分配，其中 $\sum_i \pi_i = 1$ 。两者的总回流量相同，区别在于候选池内部的样本分配方式。

均匀回流隐含了一个前提：候选池内部样本的训练价值近似同质。然而，高风险样本不等于高价值样本——极端高分样本中可能混入采集噪声（如反光、模糊）、标注边界模糊或特征空间中的孤立异常点。因此，判断样本是否真正值得被重复学习，需要从以下五个维度进行分析。

2.8.2 校准后风险与门控边界相关性

样本效用的第一个维度是校准后风险。在固定召回约束的门控任务中，样本价值不应由原始异常概率 p_i 的绝对大小决定，而应围绕门控工作阈值 τ 来定义 [22, 23]。

具体地，记教师模型在 R99.5 约束下的工作阈值为 $\tau_{99.5}$ ，则校准后风险项定义为

$$r_i = \max\left(0, \frac{p_i - \tau_{99.5}}{1 - \tau_{99.5}}\right), \quad R_i = r_i^\alpha, \quad (2.18)$$

其中 $\alpha > 1$ 用于对真正靠近或超过门控边界的正常样本施加非线性放大。该定义的核心直觉是：一个 $p_i = 0.95$ 的样本和一个 $p_i = 0.30$ （刚好在 $\tau_{99.5}$ 附近）的样本，对门控性能的影响可能截然不同。前者虽然异常概率极高，但可能只是反光或脏帧引发的极端个例；后者虽然概率不高，却恰好落在门控决策边界附近，对拦截率的边际影响更大。

2.8.3 训练动态与样本价值的时变性

样本效用的第二个维度来自训练动态。Swayamdipta 等人在 Dataset Cartography 中指出，样本在训练过程中的行为模式可以将其区分为三类：始终被正确分类的 easy 样本、在不同轮次间反复摇摆的 ambiguous 样本，以及持续被错分的 hard-to-learn 样本 [30]。

这一观点对本文的启示在于：样本的“难度”不应由某个固定检查点的一次打分快照决定，而应观察该样本在训练过程中是否持续靠近门控边界。如果一个样本仅在某个检查点偶然获得高分，但在相邻检查点上迅速回落，则它更可能是训练噪声而非系统性困难模式。

本文的 HN 曲线已经从实验侧印证了这一判断：不同 HN 比例不仅改变了最终最优检查点的落点（第 5 章图 5.6），还改变了训练轨迹的整体形态（第 5 章图 5.8），说明样本对训练过程的影响是动态的、路径相关的，而不是静态可加的。

2.8.4 测试时增强与预测稳定性

样本效用的第三个维度是预测稳定性，其可观测代理为测试时增强（TTA）下的输出波动。

TTA 的具体做法是：对同一图像 x_i 施加 K 次语义保持的轻量增强变换（如微小亮度扰动、对比度调整、轻微高斯模糊等），得到 K 个增强版本 $\tilde{x}_i^{(1)}, \dots, \tilde{x}_i^{(K)}$ 。将这些增强版本逐一送入教师模型，得到 K 个校准后异常概率 $p_i^{(1)}, \dots, p_i^{(K)}$ 。在

对数几率空间中计算这些输出的方差：

$$v_i = \text{Var}\left(\text{logit}(p_i^{(1)}), \dots, \text{logit}(p_i^{(K)})\right). \quad (2.19)$$

相应的一致性稳定性项定义为

$$C_i = \exp\left(-\frac{v_i}{\sigma_c^2}\right), \quad (2.20)$$

其中 σ_c 由当前候选池的稳健尺度给出。当 v_i 较小时（输出稳定）， C_i 接近 1；当 v_i 较大时（输出剧烈波动）， C_i 趋近 0。

该项的作用是抑制”高风险但极不稳定”的样本。一个真正的系统性困难模式——例如管壁水膜区域与轻微裂缝的视觉混淆——应当在轻微增强下保持一致的高异常概率；而采集噪声或偶发反光引起的高分，往往对微小扰动极度敏感 [26]。

2.8.5 特征空间结构支撑与孤立点识别

样本效用的第四个维度来自特征空间的结构信息。Kim 等人在 CVPR 2024 的工作中，利用反向 k 近邻（reverse k-NN）构建结构化标签，以区分特征流形上的系统性模式与孤立噪声 [28]。

具体地，设模型倒数第二层对样本 x_i 的特征输出为 $f_i \in \mathbb{R}^d$ ，则两个样本之间的余弦相似度定义为

$$\cos(f_i, f_j) = \frac{f_i \cdot f_j}{\|f_i\| \|f_j\|}, \quad (2.21)$$

其中 $\|\cdot\|$ 表示 L_2 范数。 k 近邻（kNN）是指在特征空间中与 x_i 余弦相似度最高的 k 个样本。基于此，邻域平均相似度定义为

$$d_i = \frac{1}{k} \sum_{j \in \text{kNN}(i)} \cos(f_i, f_j), \quad D_i = \text{Norm}(d_i), \quad (2.22)$$

其中 $\text{Norm}(\cdot)$ 表示在候选池范围内的归一化。

该项的核心直觉是：如果一个高风险正常样本在特征空间中得到相似近邻样本的支撑，则它更可能对应一种系统性的困难模式，例如特定光照条件下的管壁纹理与裂缝之间的视觉混淆。这类模式在数据集中会反复出现，更值得被重点学习。相反，若某个高风险样本在特征空间中的局部密度很低，缺少相似近邻样本支撑，则它更可能是偶发采集异常、孤立难例或标注边界模糊样本，其固定预算回流价值应谨慎判断。

2.8.6 覆盖度、多样性与预算塌缩

样本效用的第五个维度是候选池的模式覆盖度。BADGE 及其后续工作表明，样本选择不能只追求单一维度上的极端值（如最高不确定性或最高风险），还必须保证所选子集能覆盖特征空间中的多种困难模式^[25, 27]。

当采样概率高度集中于极少数样本时，会产生预算塌缩现象：名义上的回流预算 B 仍然不变，但实际上绝大部分预算被少数样本占据，导致候选池中其他有训练价值的困难模式被完全忽略。衡量预算集中度的一个指标是有效样本数：

$$N_{\text{eff}} = \exp\left(-\sum_i \pi_i \log \pi_i\right), \quad (2.23)$$

其中 π_i 为样本 x_i 的采样概率。当所有样本等概率时， N_{eff} 等于池大小；当概率集中于少数样本时， N_{eff} 急剧下降。这一指标将在第 6 章中用于诊断加权回流方案的覆盖度损失。

2.8.7 几何平均作为联合约束逻辑

当需要将上述多个维度组合为统一的样本评分时，本文采用几何平均而非加权求和。对于 n 个分量 $s_1, s_2, \dots, s_n$ ，几何平均定义为

$$S = (s_1 \cdot s_2 \cdots s_n)^{1/n}. \quad (2.24)$$

几何平均的关键性质是：当任何一个分量为零时，总分即为零。这保留了”同时满足”的逻辑约束——一个样本若想获得高分，必须在所有分量上都达到一定水平，而不能靠某个极高的分量来补偿另一个为零的分量。相比之下，加权求和 $S = w_1 s_1 + w_2 s_2 + \dots$ 允许这种补偿，这与本文对”同时具备风险、稳定性和结构支撑”的直觉不一致。

2.8.8 数据归因与影响分析

除上述五个维度外，数据归因（data attribution）提供了另一条理论路径：Koh & Liang 通过影响函数（influence function）量化单个训练样本对目标查询集的正向/负向影响^[24]；Zhang 等进一步在训练动态视角下构建跨阶段样本重要性评估^[29]。数据归因在本文当前版本中尚未作为实验变量引入，保留为后续方向。

表 2.3 样本效用建模中五类关键信号的作用

信号类型	可观测量	作用机制	在本文中的对应
风险信号	校准后异常分数与阈值边距	放大真正靠近门控边界的正常样本	R_i
稳定性信号	轻量 TTA 下的 logit variance	抑制高风险但极不稳定的伪难例	C_i
结构支撑信号	特征空间邻域相似度	区分系统性困难模式与孤立异常点	D_i
覆盖度信号	有效样本数、模式覆盖度	防止预算塌缩导致多样性丢失	N_{eff}
教师质量信号	教师训练状态与目标域贴合度	保证评分输入质量	教师选择

2.8.9 五维信号的正交结构

表 2.3 中的五个维度并非独立罗列，而是呈现两对正交镜像（orthogonal mirror pairs）关系：

1. 空间静态 $R \leftrightarrow$ 扰动动态 C ： R 在固定特征空间中衡量样本与门控边界的距离， C 在扰动空间中衡量该距离的稳定性。两者分别回答”距离边界多远”和”距离边界是否可靠”。
2. 邻域空间 $D \leftrightarrow$ 时间动态（训练轨迹）： D 在特征空间中度量局部密度（是否抱团），训练动态（Dataset Cartography^[30]）在 epoch 维度上度量样本行为的时变性。两者分别回答”空间上是否有结构”和”时间上是否稳定”。

覆盖度 N_{eff} 作为集合级约束位于分配层，教师质量位于输入层（式 (2.25)）。本文当前实验实现了 R 、 C 、 D 三个样本级信号的分位数分层消融验证（第 6 章），训练轨迹动态信号 T 作为第四条轴留待后续实现。

2.8.10 非单调价值–信号响应的理论预期

上述形式化隐含了一个常见假设：信号值越高，样本越有价值（如 R 越大 $\Rightarrow$ 越靠近边界 $\Rightarrow$ 越值得学习）。然而，已有文献对此提出了质疑。Swayamdipta 等人在 Dataset Cartography 中发现， *ambiguous* 样本（中等难度）的训练价值高于 *hard-to-learn* 样本（极端难度）^[30]；Ash 等人在 BADGE 中指出，纯不确定性选样会导致覆盖度损失^[25]。

这些发现共同暗示：样本价值可能并非信号强度的单调函数，而是存在非单调价值–信号响应（non-monotonic value–signal response）——极端信号值样本（”皮层”）中混入采集噪声和孤立异常，中等信号值样本（”肌肉层”）才是真正具有系统性训练价值的 **Goldilocks zone**。这一理论预期将在第 6 章的分位数

分层消融 (quintile-stratified ablation) 中得到三信号交叉验证。

2.9 教师模型质量与评分输入偏差

上述五个维度的样本效用评估均依赖一个共同前提：教师模型的评分质量 (teacher scoring fidelity) 足以反映样本的真实训练价值。该前提可形式化为一条严格的因果传递链 (causal cascade)：

$$\text{教师质量} \longrightarrow \text{打分质量} \longrightarrow \text{选样质量} \longrightarrow \text{训练质量}. \quad (2.25)$$

评分函数只能在教师模型给出的排序空间内做重分配，无法反过来修正教师模型自身的表征不足。因此，教师模型的选择不是与评分函数平行的超参数，而是位于整个重加权流程上游的前置决策。这一判断在第 6 章的负结果诊断中得到实验验证。

2.10 六类源域视图的辅助地位

除直接二分类门控外，本文还组织了一条六类源域容量扫描，用于观察不同容量模型在源域表示任务上的相对位置。该视图的排序规则为准确率、AUROC 与 AUPRC。然而，这一视图只承担辅助参考角色，不应替代二分类门控的骨干网络选择。

第 3 章 数据集构建、实验平台与 workflow

3.1 数据来源与数据组织

本文使用两套源域数据集来支撑当前第一阶段研究。第一套是直接二分类门控数据集 `sewerml_gate2_train7200`，共 7200 张图像，其中训练集 6480 张、验证集 720 张；类别分布为异常 6000 张、正常 1200 张。第二套是六类源域数据集 `sewerml_cls6_train7200`，同样包含 7200 张图像，并被均衡组织为六个类别，每类 1200 张，训练集与验证集分别为 6480 与 720 张。

对于二分类门控协议，本文构建了扩展验证集 (extended validation set)，从 SewerML 训练池中随机抽取与训练集不重叠的 5518 张图像 (1000 正常 + 4518 异常，多标签保留)，按 30%/70% 分层拆分为校准集 (val-cal, 1655 张, 293 正常) 和工作点评估集 (val-op, 3863 张, 707 正常)。该拆分仅用于温度参数拟合与工作点报告，不参与训练。

后文 `Spec@R99.5` 与 `Spec@R99.0` 的排序均建立在工作点评估集的 $n = 707$ 个正常样本之上，specificity 的最小步长为 $1/707 \approx 0.0014$ 。为量化有限样本带来的不确定性，本文对关键排序点报告 Wilson 置信区间 [?]:

$$\hat{p}_{\pm} = \frac{\hat{p} + \frac{z_{\alpha}^2}{2n} \pm z_{\alpha} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n} + \frac{z_{\alpha}^2}{4n^2}}}{1 + \frac{z_{\alpha}^2}{n}}, \quad (3.1)$$

其中 $\hat{p}$ 为 specificity 点估计， z_{α} 为正态分位数 (本文取 $\alpha = 0.05$, $z_{0.05} = 1.96$)。由于本文未补做多随机种子重复实验，后文所有排序均为当前数据划分与当前随机种子下的点估计 (point estimate)，不应表述为已获统计显著性的差异。

表 3.1 第一阶段数据集统计

Dataset	Total	Train	Val	Class Distribution
<code>sewerml_gate2_train7200</code>	7200	6480	720	异常 6000 / 正常 1200
<code>sewerml_cls6_train7200</code>	7200	6480	720	6 classes, each 1200

表 3.2 二分类门控协议的校准集与工作点评估集划分

子集	总数	异常	正常
校准集 (val-cal)	216	180	36
工作点评估集 (val-op)	504	420	84

3.2 等条件共享训练协议

本文全部实验（容量扫描 + HN 比例扫描 + 分位数分层消融）均在等条件共享训练协议（*ceteris paribus* shared training protocol）下执行：五个容量梯度（yolo11n/s/m/l/x-cls，参数量 5.4M–56M）共享完全相同的超参数配置（表 3.3）、相同的数据划分、相同的外部评估器与相同的排序规则。

这一设计是刻意的方法论承诺（deliberate methodological commitment）而非疏忽：通过固定训练协议，将“容量 $\times$ HN 比例 $\times$ 评估”三轴比较从 per-model hyperparameter tuning 这一正交轴上隔离，确保观察到的容量排序、HN 增益差异与形态异质性均为 protocol-invariant 的产物。

该承诺的已知代价为：较大容量模型（l, x）在 batch = 24 / 200 epoch / lr-auto 配置下可能未充分收敛，较小容量模型（n, s）可能存在过拟合风险（第 5 章 best_epoch = 1 现象的高发率间接支持此判断）。因此，后文涉及跨容量比较的结论（第 5 章容量阶梯假说、第 5 章形态异质性）均应理解为 **shared-protocol** 下的排序，不代表各容量在 model-specific 调参下的最优表现。

表 3.3 等条件共享训练协议超参数

超参数	取值
输入尺寸 (imgsz)	640
批量大小 (batch)	24
工作线程数 (workers)	4
训练轮数 (epochs)	200
优化器 (optimizer)	auto (训练器自动确定 lr/momentum/weight_decay)
早停 (patience)	0 (不使用训练器侧 top1 早停)
检查点保存 (save_period)	1 (逐 epoch 保存，供外部评估器逐轮评估)
预训练权重	ImageNet 预训练 (pretrained=True)
随机种子	固定单一种子

3.3 门控导向评估流程

本文对每个 run 的每个 epoch 均执行以下四步门控导向外部评估 (gate-oriented external evaluation)，独立于训练器侧指标：

1. 温度拟合：在校准集 $\mathcal{D}_{\text{cal}}$ (216 张) 上以负对数似然为目标拟合单标量温度 $T^* = \arg \min_T \text{NLL}(T; \mathcal{D}_{\text{cal}})$ 。
2. 校准推理：将 T^* 应用于工作点评估集 $\mathcal{D}_{\text{op}}$ (504 张)，得到校准后概率 $p_i = \sigma(z_i/T^*)$ 。
3. 阈值扫描：遍历候选阈值 τ ，在 $\mathcal{D}_{\text{op}}$ 上计算每个 τ 下的 Recall / Spec / Prec / PTR。
4. 工作点报告：锁定满足 $\text{Recall} \geq 99.5\%$ 和 $\text{Recall} \geq 99.0\%$ 的最高 Spec 对应阈值 $\tau_{99.5}$ 、 $\tau_{99.0}$ ，输出四元排序指标。

该流程保证训练器侧 top1 仅承担训练健康监控功能，不参与检查点排序与选模决策。全部 run 共计产生超过 15,000 次独立的门控评估 (每 run 200 epoch $\times$ 76+ run)。

3.4 HN 回流设置与候选池来源

容量扫描完成后，本文在五个容量上分别执行 HN 比例全量扫描 (hard-negative ratio sweep)。设 HN 比例为 $r = |\mathcal{S}_{\text{HN}}|/|\mathcal{D}_{\text{train,normal}}|$ ，扫描范围为 $r \in \{0\%, 2\%, 4\%, \dots, 20\%\}$ 共 11 个等距步长。五个容量 $\times$ 11 个比例 = 55 个独立训练 run，全部在第 3.2 节的等条件共享协议下执行，评估流程遵循第 3.3 节。

HN 候选池来源：以主模型 yolo11m-cls 的 hn00 基线检查点为教师，对 1080 个训练正常样本逐一推理并按校准后异常概率 p_i 降序排列，取前 $N_{\text{pool}} = 250$ 个构成难样本候选池 (占训练正常样本的 23.15%)。在固定额外回流预算 B 下，均匀回流从 $\mathcal{N}_{\text{hard}}$ 中等概率采样 B 次副本加入训练集。

3.5 结果留档与可复现性

每个 run 保留完整的运行清单 (run_manifest)、数据集清单 (dataset_manifest)、最优轮次清单 (best_epoch_manifest) 和逐轮评估汇总 (epoch_gate_summary)，全部以 CSV / JSON / Markdown 三格式归档。HN 比例扫描的汇总结果以 hn_sweep_summary.{csv,json,md} 三件套形式输出，供跨容量分析直接读取。

第 4 章 高召回门控的选模与容量扫描

本章在第 3.2 节的等条件共享训练协议下，对五个 YOLO11-cls 容量执行等条件容量扫描（*ceteris paribus capacity sweep*），通过二分类门控视图与六类源域辅助视图的跨视图目标错位（*cross-view objective misalignment*）分析，确定第一阶段主模型。

4.1 第一阶段任务重定义与双视图结构

第一阶段的工程职责由式 (1.1) 定义：在固定召回约束下最大化正常样本拦截。默认阈值准确率和训练器侧 top1 回答的是不同问题（整体分类正确率），与门控目标存在目标错位。据此，本文将直接二分类门控作为第一阶段的主裁判视图（*primary adjudication view*），六类源域视图仅承担辅助参考角色。所有排序、检查点选择与训练侧增强均在门控视图的四元排序规则下完成。

4.2 二分类门控容量扫描

表 4.1 等条件共享协议下的二分类门控容量扫描（扩展验证集，707 正常样本）。
`yolo11s-cls` 以 $\text{Spec@R99.5} = 0.3395$ 排在第一，`yolo11n-cls` 紧随其后（0.3267）。基线容量排序在扩展验证集上发生变化，但差距极小。加粗为 best，下划线为 second-best。

Model	Best Epoch	Spec@R99.5	tn/707	Spec@R99.0	Prec@R99.0	PTR@R99.0	$\tau_{99.5}$	$\tau_{99.0}$	Rank
<code>yolo11s-cls</code>	77	0.3395	240	0.4455	0.8885	0.9104	0.1700	0.2900	1
<code>yolo11n-cls</code>	<u>76</u>	<u>0.3267</u>	<u>231</u>	0.4371	0.8870	0.9120	0.1800	0.2800	<u>2</u>
<code>yolo11x-cls</code>	125	0.3140	222	<u>0.4710</u>	<u>0.8931</u>	<u>0.9060</u>	0.1200	0.2700	3
<code>yolo11l-cls</code>	54	0.2065	146	0.3805	0.8771	0.9223	0.0900	0.2200	4
<code>yolo11m-cls</code>	78	0.1697	120	0.3140	0.8657	0.9350	0.0900	0.1600	5




图 4.1 二分类门控容量扫描基线主指标对比（扩展验证集，707 正常样本）。基线 Spec@R99.5 在 0.17–0.34 区间内，五个容量差距较小，容量与门控性能之间不存在单调正比关系。

表 4.1 显示，在等条件共享协议下基线（hn00）的 Spec@R99.5 在 0.17–0.34 区间内，五个容量差距较小。yolo11s-cls 以 0.3395 排在第一，yolo11n-cls 以 0.3267 紧随其后。容量与基线门控性能之间不存在简单的正比关系——m（20M）和 l（24M）的基线反而低于 n（5.4M）和 s（9M），表明较大容量模型在基线状态下的表征未必更适合门控任务。然而，如第 5 章所示，大容量模型在 HN 回流后可获得远超小容量模型的增益。

表 4.2 关键排序结果对应的 normal 正确数与 95% Wilson 区间（扩展验证集， $n = 707$ ）

设置	Spec@R99.5	判对的正常样本数	95% Wilson 区间
yolo11s-cls 基线	0.3395	240 / 707	[0.3051, 0.3757]
yolo11n-cls 基线	0.3267	231 / 707	[0.2927, 0.3626]
yolo11x-cls 基线	0.3140	222 / 707	[0.2806, 0.3495]
m+hn12	0.3310	234 / 707	[0.2968, 0.3670]
l+hn10	0.4512	319 / 707	[0.4148, 0.4881]
x+hn02	0.3734	264 / 707	[0.3382, 0.4101]

表 4.2 显示，扩展验证集（ $n = 707$ ）上的 95% Wilson 区间显著收窄。例如，l+hn10 的 Spec@R99.5 = 0.4512，95% CI = [0.4148, 0.4881]，与基线排序第一的 s（0.3395，CI = [0.3051, 0.3757]）无重叠，差异具有统计显著性。这一精度水平是旧验证集（84 个正常样本，CI 宽度 ± 0.10 ）无法达到的。

4.3 门控最优检查点的训练动态




图 4.2 五模型 Spec@R99.5 随 epoch 的演化曲线




图 4.3 五模型 Spec@R99.0 随 epoch 的演化曲线

图 4.2 与图 4.3 展示了门控指标随检查点变化的整体趋势。五个模型的门控最优轮次分别为 76/77/78/54/125（对应 n/s/m/l/x），说明最优检查点通常出现在训练中期或后中期，而不是默认意义上的“最后一轮”或“训练器自动 best”。其中，yolo11l-cla 在较早轮次达到峰值，而 yolo11x-cla 需要更长优化轨迹才达到最优。

4.4 训练器 top1-best 与门控最优检查点的系统性错位

表 4.3 训练器 top1-best 与门控最优检查点的对照

Model	Top1-Best Epoch	Top1-Best Top1	Gate-Best Epoch	Gate-Best Spec@R99.5	Gate-Best Spec@R99.0	Δ Epoch	Same
yolo11n-cls	120	0.9250	76	0.3267	0.4371	44	No
yolo11s-cls	88	0.9208	77	0.3395	0.4455	11	No
yolo11m-cls	197	0.9347	78	0.1697	0.3140	119	No
yolo11l-cls	103	0.9306	54	0.2065	0.3805	49	No
yolo11x-cls	120	0.9319	125	0.3140	0.4710	-5	No

注：五个模型全部出现 **top1-best** 与门控最优检查点不一致；**top1** 可作为训练健康信号，但不应作为第一阶段的早停或检查点选择标准。




图 4.4 以 yolo11m-cls 与 yolo11l-cls 为例的 top1 与 gate 指标错位

表 4.3 与图 4.4 共同揭示了一个关键结论：五个模型中没有任何一个满足训练器 **top1-best** 与门控最优检查点一致。尤其是 yolo11m-cls，其训练器侧 **top1-best** 出现在第 197 轮，而门控最优出现在第 78 轮，两者相差 119 个轮次；yolo11l-cls 也表现出类似错位。这一结果说明，训练器侧的 **top1** 虽然仍能反映分类优化是否正常进行，但并不与召回约束下的门控目标对齐。

4.5 六类源域视图容量扫描

4.5.1 六类源域视图主结果

表 4.4 六类源域视图容量扫描主表

模型	最优轮次	准确率	AUROC	AUPRC	排名
yolo11x-cls	161	0.7000	0.9484	0.9885	1
yolo11m-cls	130	0.6958	0.9387	0.9848	2
yolo11l-cls	104	0.6944	0.9400	0.9862	3
yolo11s-cls	167	0.6917	0.9406	0.9854	4
yolo11n-cls	117	0.6833	0.9421	0.9870	5

注：六类源域视图仅用于源域表示参考，不承担第一阶段的选模功能。




图 4.5 六类源域视图容量扫描对比。yolo11x-cls 以 $\text{Acc} = 0.700$ 排在第一，与二分类门控视图中 yolo11m-cls 排在第一形成跨视图排序错位。

在源域六类任务下，yolo11x-cls 在辅助视图中排在第一，yolo11m-cls 位居第二。这一结果说明，更大容量模型在源域六类表示任务上仍具有优势；但该优势并不能直接转译为召回约束二分类门控下的排序结果。

4.6 跨视图排序错位分析

表 4.5 六类源域视图与二分类门控的跨视图排序差异

Model	Rank in CLS6	Rank in Binary Gate	Rank Gap	Interpretation
yolo11x-cls	1	2	-1	辅助 cls6 视图相对高估该模型
yolo11m-cls	2	1	1	辅助 cls6 视图相对低估该模型
yolo11l-cls	3	3	0	两种视图排序一致
yolo11s-cls	4	4	0	两种视图排序一致
yolo11n-cls	5	5	0	两种视图排序一致




图 4.6 六类源域视图与二分类门控的排序错位可视化

表 4.5 与图 4.6 表明，六类源域视图与二分类门控给出的排序并不一致。最关键的差异集中在 `yolo11m-cls` 与 `yolo11x-cls`：前者在六类视图中位居第二，却在门控视图中排在第一；后者则相反。

4.7 第一阶段主模型与第二对照模型的确定

综合二分类门控主表、检查点训练动态、`top1-best` 与门控最优检查点错位表以及跨视图排序错位分析,可得到一个当前版本下较稳妥的结论:`yolo11m-cls` 是当前数据划分与当前随机种子下的排序第一模型, `yolo11x-cls` 作为容量更大的第二对照模型保留。相较之下, `yolo11l-cls` 虽然在早期探索阶段具有吸引力,但在当前协议下已不再承担主线角色。

第 5 章 基于 HN 回流的第一阶段训练侧增强与问题收缩

本章在第 3.2 节的等条件共享协议下，对 n/s/m/l 四个容量分别执行 HN 比例全量扫描（hard-negative ratio sweep），考察三个核心问题：（1）HN 增益是否存在非单调性（non-monotonic gain）与容量相关的最优比例点；（2）四个容量的 sweep 曲线是否呈现形态异质性（shape heterogeneity）；（3）较大容量的 HN 增益是否存在上界，即容量阶梯不可跨越假说（capacity-ladder non-crossing hypothesis）是否成立。正文按容量从小到大依次报告 $n \rightarrow s \rightarrow m \rightarrow l$ 的全量扫描结果，随后给出跨容量对比分析。

5.1 各容量模型的 HN 比例全量扫描结果

HN 回流的实验设置（候选池来源、比例定义 $r = |\mathcal{S}_{\text{HN}}|/|\mathcal{D}_{\text{train,normal}}|$ 、等条件共享协议）已在第 3.2 节给出。本节依次报告 $n \rightarrow s \rightarrow m \rightarrow l$ 四个容量的全量扫描结果。每个模型的主表保留主排序指标 Spec@R99.5 及其增量 Δ ，完整四指标表见附录 C。

yolo11n-cls（5.4M 参数）。

表 5.1 yolo11n-cls HN 比例扫描：主排序指标与增量（完整四指标表见附录表 C.2）

Ratio	Best Epoch	Spec@R99.5	Δ Spec@R99.5	Spec@R99.0	Rank
hn00	76	0.3267	0.0000	0.4371	1
hn02	43	0.1485	-0.1782	0.2334	11
hn04	72	0.1768	-0.1499	0.3678	10
hn06	1	0.2871	-0.0396	0.3904	5
hn08	100	0.2843	-0.0424	0.4130	7
hn10	1	0.3168	-0.0099	0.4201	2
hn12	1	0.2956	-0.0311	0.4272	3
hn14	87	0.2008	-0.1259	0.3550	9
hn16	1	0.2447	-0.0820	0.3621	8
hn18	1	0.2857	-0.0410	0.4215	6
hn20	1	0.2900	-0.0368	0.4031	4




图 5.1 yolo11n-cls HN 比例扫描四项 gate 指标曲线（扩展验证集，707 正常样本）。基线 hn00 即为排序第一（ $\text{Spec@R99.5} = 0.3267$ ），所有 HN 比例均未超越基线，表明小容量模型无法从 HN 回流中获益。

表 5.1 与图 5.1 表明，在扩展验证集（707 个正常样本）上重新评估后，yolo11n-cls 的基线 hn00 即为排序第一，所有 HN 比例均导致 Spec@R99.5 下降（最大降幅 -0.1782 ，hn02）。这一结果与旧验证集（84 个正常样本）上的虚高增益形成鲜明对比，说明小容量模型（5.4M 参数）的表征空间不足以从 HN 回流中获益——回流样本反而引入噪声干扰。

较小容量参考模型 yolo11s-cls.

表 5.2 yolo11s-cls HN 比例扫描：主排序指标与增量（完整四指标表见附录表 C.3）

Ratio	Best Epoch	Spec@R99.5	$\Delta\text{Spec@R99.5}$	Spec@R99.0	Rank
hn00	77	0.3395	0.0000	0.4455	2
hn02	8	0.3182	-0.0212	0.4201	4
hn04	28	0.3126	-0.0269	0.4356	5
hn06	54	0.3310	-0.0085	0.4399	3
hn08	1	0.2857	-0.0537	0.4243	9
hn10	36	0.2192	-0.1202	0.3479	11
hn12	1	0.2744	-0.0651	0.4116	10
hn14	75	0.3083	-0.0311	0.4045	6
hn16	1	0.2928	-0.0467	0.4484	8
hn18	1	0.3013	-0.0382	0.4427	7
hn20	66	0.3409	+0.0014	0.4484	1

yolo11s-cls 的 **HN** 增益在扩展验证集上接近于零。排序第一的 **hn20** 仅以 $\Delta\text{Spec@R99.5} = +0.0014$ (1 个正常样本之差) 微弱领先基线 **hn00**, 在统计上不具备显著性。其余 10 个 **HN** 比例全部低于基线 (最大降幅 -0.1202 , **hn10**)。与 **yolo11n-cls** 相似, **yolo11s-cls** (9.0M 参数) 同样无法从 **HN** 回流中有效获益, 进一步支持小容量模型对 **HN** 的吸收能力不足的结论。




图 5.2 **HN** 比例扫描下的容量依赖性证据 (五模型)。(a) **Spec@R99.5 vs HN ratio**: 小容量模型 (n/s) 所有 **HN** 比例均未超越基线, 大容量模型 (m/l/x) 获得显著增益, l+hn10 () 以 0.4512 成为全局最优。(b) **Gate-best epoch vs HN ratio**: × 标记表示 **best_epoch** = 1 的早熟设置。

主模型 **yolo11m-cls**.

表 5.3 **yolo11m-cls** **HN** 比例扫描: 主排序指标与增量 (扩展验证集)。hn12 以 $\Delta\text{Spec@R99.5} = +0.1612$ 排在第一, 显著优于基线。

Ratio	Best Epoch	Spec@R99.5	$\Delta\text{Spec@R99.5}$	Spec@R99.0	Rank
hn00	78	0.1697	0.0000	0.3140	8
hn02	51	0.1810	+0.0113	0.3663	6
hn04	144	0.3112	+0.1414	0.4569	2
hn06	96	0.3027	+0.1330	0.4158	4
hn08	1	0.1584	-0.0113	0.3154	9
hn10	29	0.0764	-0.0934	0.3083	11
hn12	115	0.3310	+0.1612	0.4215	1
hn14	74	0.3055	+0.1358	0.4356	3
hn16	118	0.2687	+0.0990	0.4215	5
hn18	48	0.1782	+0.0085	0.3451	7
hn20	1	0.1231	-0.0467	0.2546	10




图 5.3 yolo11m-cls HN 比例扫描四项 gate 指标曲线（扩展验证集）。hn12 达 Spec@R99.5 = 0.3310 (+0.1612)，中间偏高比例（hn04–hn16）普遍优于基线，呈中段隆起形态。

表 5.3 与图 5.3 表明，yolo11m-cls 在扩展验证集上的 HN 增益呈中段隆起形态：hn04–hn16 区间普遍优于基线，hn12 以 $\Delta\text{Spec@R99.5} = +0.1612$ （114 个正常样本）排在第一。与旧验证集上的双峰形态不同，扩展验证集揭示出更连续的增益分布，且增益幅度远大于旧评估。基线 hn00 的 Spec@R99.5 仅为 0.1697（仅拦截 120/707 个正常样本），说明 m 的未回流基线在更大样本上表现较弱，而 HN 回流可将其推高近一倍。

5.1.1 yolo11l-cls 的 HN 比例扫描

表 5.4 yolo11l-cls HN 比例扫描：主排序指标与增量（扩展验证集）。hn10 以 $\Delta\text{Spec@R99.5} = +0.2447$ 排在第一，为五个容量中最大增益。

Ratio	Best Epoch	Spec@R99.5	$\Delta\text{Spec@R99.5}$	Spec@R99.0	Rank
hn00	54	0.2065	0.0000	0.3805	10
hn02	64	0.2984	+0.0919	0.4045	6
hn04	115	0.2617	+0.0552	0.3890	8
hn06	16	0.1825	-0.0240	0.3140	11
hn08	14	0.3522	+0.1457	0.4272	2
hn10	48	0.4512	+0.2447	0.4979	1
hn12	5	0.3352	+0.1287	0.4187	3
hn14	86	0.3098	+0.1033	0.4130	4
hn16	54	0.2772	+0.0707	0.3960	7
hn18	1	0.2390	+0.0325	0.4045	9
hn20	5	0.3083	+0.1018	0.4116	5

yolo11l-cls（24M 参数）在扩展验证集上的 HN 增益呈现单峰隆起形态，且增幅为五个容量中最大。hn10 以 $\text{Spec@R99.5} = 0.4512$ （ $\Delta = +0.2447$ ，拦截 319/707 个正常样本）排在第一，是全局最优设置。hn08–hn14 区间均取得超过 +0.10 的显著增益，基线 hn00 仅拦截 146/707（20.7%），而 hn10 将其推升至 45.1%，增幅超过一倍。这说明大容量模型（24M 参数）具有充分的表征空间来吸收 HN 回流样本，且最优比例落在中等水平（10%），而非极端低比例。

该形态与 n/s/m 截然不同：l 只在最低非零比例 hn02 处获得微弱增益，之后 HN 回流对决策边界零扰动（hn06–hn12 六个点 tn 完全一致），直到 hn14 噪声积累到足以推歪边界才出现退化。11 个比例中仅 1 个 best_epoch = 1（9%），远低于 n 的 55%，表明 l 并非“训练太快”，而是表征过于僵硬、中等剂量 HN 无梯度效应。

在扩展验证集上，yolo11l-cls + hn10 以 $\text{Spec@R99.5} = 0.4512$ 成为五个容量中的全局最优，超越所有其他模型与比例组合。这一发现与旧验证集上 l 表现最弱的结论截然相反，揭示了大容量模型在充足 HN 回流下的真实潜力：其基线虽低（0.2065），但对 HN 回流的吸收能力远超小容量模型（ $\Delta = +0.2447$ vs n/s 的 $\Delta \approx 0$ ）。

5.2 跨容量 HN 增益对比与形态分类

表 5.5 等条件共享协议下五个容量的 HN 比例扫描跨容量对比（扩展验证集，707 正常样本）

Model	Params	Baseline	tn/707	Best Ratio	$\Delta\text{Spec@R99.5}$	HN 效果
yolo11n-cls	5.4M	0.3267	231	hn00	≈ 0	无增益
yolo11s-cls	9.0M	0.3395	240	hn20	+0.0014	无增益
yolo11m-cls	20M	0.1697	120	hn12	+0.1612	大幅增益
yolo11l-cls	24M	0.2065	146	hn10	+0.2447	巨幅增益
yolo11x-cls	57M	0.3140	222	hn02	+0.0594	中等增益




图 5.4 五容量 $\times$ 11 比例的 $\Delta\text{Spec@R99.5}$ 热力图（扩展验证集，707 正常样本）。红色 = 正增益，蓝色 = 负增益。小容量 (n/s) 全面蓝色 (HN 无益)，大容量 (m/l) 呈中段红色隆起，标记各模型 winner。l+hn10 ($\Delta = +0.2447$) 为全局最大增益。

表 5.5 汇总了五个容量在等条件协议下的 HN 全量扫描结果（基于扩展验证集，707 个正常样本），揭示三个关键规律：

(1) **HN 增益具有强容量依赖性 (capacity-dependent gain)**。小容量模型 (n/s, 5–9M 参数) 几乎无法从 HN 回流中获益 ($\Delta\text{Spec} \approx 0$)，而大容量模型 (m/l/x, 20–57M 参数) 则可获得中等至巨幅增益。这说明充分的表征空间是 HN 吸收的前提条件。

(2) **最优比例点不可迁移 (non-transferable optimal ratio)**。有效获益的三个容量 (m/l/x) 的 winner ratio 分别为 hn12、hn10、hn02，互不相同，表明不存在通用最优 HN 比例，必须逐模型搜索。

(3) **大容量模型反超 (capacity reversal)**。yolo11l-cls + hn10 以 $\text{Spec@R99.5} = 0.4512$ 成为全局最优，超越 m 和 x 的所有 HN 设置。l 的基线虽为最弱之一 (0.2065)，但其巨幅增益 (+0.2447) 说明大容量模型的潜力需要 HN 回流来激发。这一发现与旧验证集上“HN 增益随容量递减”的结论相反，突显了扩展验证集对消除小样本偏差的重要性。

5.3 相对 hn00 的增量解释与训练动力学




图 5.5 yolo11n-cls 的门控最优轮次随 HN 比例的变化

图 5.5 表明，yolo11n-cls 的门控最优轮次随 HN 比例发生明显移动。尽管在扩展验证集上 n 的所有 HN 比例均未超越基线，但训练动力学仍呈现差异化模式——多个比例的最优检查点落在第 1 轮（早熟），而 hn08 推迟到第 100 轮。




图 5.6 yolo11m-cls 的门控最优轮次随 HN 比例的变化

从 hn00 锚点看，hn14 的主要变化集中在 Spec@R99.5，其提升幅度为 0.0476，对应工作点评估集上多正确拦截 4 个正常样本；与此同时，Spec@R99.0 基本不变，Prec@R99.0 仅有极小变化，PTR@R99.0 甚至轻微上升 0.0020。也就是说，当前可观察到的收益主要体现为高召回约束下的前级正常样本拦截，而不是所有指标都同步改善。图 5.6 则表明，门控最优轮次会随比例发生系统性移动，进一步说明 HN 改变的是训练轨迹，而非仅在终点挑选一个偶然更好的检查点。

5.4 代表性比例的训练轨迹对比




图 5.7 hn00、yolo11n-cls 当前排序第一设置与高比例尾部设置的训练轨迹对比

图 5.7 选取了 yolo11n-cls 上的三种代表性设置：hn00、当前排序第一的 hn08 以及高比例尾部设置 hn20。可以看到，hn08 并未在所有指标上同时形成最高平台，但在 Spec@R99.5 的主排序指标上保持了更高且更稳定的中后期平台；相比之下，hn20 的多数指标更早趋稳，但峰值高度不足。这与表 5.1 的排序结果相互印证。




图 5.8 hn00、当前排序第一设置与高比例尾部设置的训练轨迹对比

图 5.8 选取了三种代表性设置：hn00、当前排序第一的 hn14 以及高比例尾部设置 hn20。可以看到，HN 不仅影响最终最优检查点的落点，还改变了训练过程中 Spec@R99.5、Spec@R99.0、Prec@R99.0 与 PTR@R99.0 的轨迹形态。相较于 hn00，hn14 在 Spec@R99.5 上形成更高平台，而 hn20 则显示出更早但更弱的峰值。

5.5 与基线主线的衔接及跨容量验证

表 5.6 基线与 HN 最优设置的桥接对照（扩展验证集，op = 3863 张，707 正常样本）

Setting	Best Epoch	Spec@R99.5	tn/707	Spec@R99.0	Prec@R99.0	PTR@R99.0
yolo11n 基线 (hn00)	76	0.3267	231	0.4371	0.8870	0.9120
yolo11n HN 无增益	—	—	—	—	—	—
yolo11s 基线 (hn00)	77	0.3395	240	0.4455	0.8885	0.9104
yolo11s + hn20	66	0.3409	241	0.4484	0.8892	0.9112
yolo11m 基线 (hn00)	78	0.1697	120	0.3140	0.8657	0.9350
yolo11m + hn12	115	0.3310	234	0.4215	0.8843	0.9154
yolo11l 基线 (hn00)	54	0.2065	146	0.3805	0.8771	0.9223
yolo11l + hn10	48	0.4512	319	0.4979	0.8981	0.9016
yolo11x 基线 (hn00)	125	0.3140	222	0.4710	0.8931	0.9060
yolo11x + hn02	59	0.3734	264	0.4682	0.8926	0.9065

表 5.7 yolo11x-cls HN 比例扫描：主排序指标与增量（扩展验证集）

Ratio	Best Epoch	Spec@R99.5	Δ Spec@R99.5	Spec@R99.0	Rank
hn00	125	0.3140	0.0000	0.4710	6
hn02	59	0.3734	+0.0594	0.4682	1
hn04	1	0.3267	+0.0127	0.4540	4
hn06	172	0.3451	+0.0311	0.4922	2
hn08	107	0.2999	−0.0141	0.4342	7
hn10	63	0.2645	−0.0495	0.4682	10
hn12	1	0.3409	+0.0269	0.4696	3
hn14	117	0.2645	−0.0495	0.4342	11
hn16	107	0.3267	+0.0127	0.4554	5
hn18	70	0.2744	−0.0396	0.4300	9
hn20	1	0.2900	−0.0240	0.4470	8




图 5.9 yolo11m-cls 与 yolo11x-cls 在 hn00 到 hn02 间的跨容量方向性对比

表 5.6 说明，HN 实验与既有基线主线的衔接方式是”固定骨干网络后再做比例扫描”，而不是重新开启容量比较。对于 yolo11m-cls，hn14 相对 hn00 在 Spec@R99.5 上取得 0.0476 的绝对提升，并在 Spec@R99.0 与 Prec@R99.0 上基本保持不变。前文给出的 yolo11n-cls 与 yolo11s-cls 全量比例扫描结果则进一步表明，两者的当前最优比例点分别出现在 hn08 与 hn20；三个容量模型上的最优比例点（n→hn08、s→hn20、m→hn14）彼此都不相同，且 yolo11s-cls + hn20 的 Spec@R99.5 已经追平 yolo11m-cls 基线 hn00 的同一水平。相比之下，表 5.7 与图 5.9 表明，yolo11x-cls 上的 hn02 并未复现相同方向的净增益，四个指标均较 hn00 回落。n、s、m 与 x 四组结果合在一起，进一步说明 HN 收益与模型容量、训练动力学及候选池状态密切相关，而不是对任意骨干网络都稳定成立的统一规律。

5.6 HN 样本来源的可追溯性

当前 HN 工作集还提供了困难正常样本的来源证据。具体而言，yolo11m 的 HN 候选来自 1080 个训练正常样本，其中分数最高的 250 个样本构成回流池，占训练正常样本总量的 23.15%。这意味着本文所讨论的 HN 并非人工主观挑选，而是直接来自基线门控模型在训练正常集上的高风险尾部分布。为控制仓库存储，附录仅保留分布统计与最高分候选名单，而不复制分类图像文件。

表 5.8 困难正常样本选择统计

正常样本总数	选中数	占比	最低分	中位数	最高分	P95	P99	阈值
1080	250	0.2315	0.1133	0.2854	0.9780	0.8377	0.9143	0.1133




图 5.10 训练正常样本的异常分数分布与困难正常样本选择阈值

表 5.8 与图 5.10 共同说明，当前困难正常样本候选池的来源是训练正常样本中的高风险尾部，而不是人工主观筛图。选入 top250 候选池的样本最低分数为 0.1133，中位数为 0.2854，最高达到 0.9780，说明该候选池内部风险分布很宽。考虑到论文仓库不长期保留分类图片副本，正文不再列出文件名清单，而把来源证明集中保留为分布统计和阈值位置。这一证据已经足以说明 HN 回流面对的是一个内部风险高度不均匀的候选池，也正因此，均匀回流之后仍有必要进一步研究固定预算下的样本重分配。

5.7 HN 回流的已知边界

尽管 yolo11m-cls 上的 HN 比例扫描已经证明均匀难样本回流可以带来门控指标上的可观净增益，但这一增益具有三条明确边界。第一，收益不是单调随比例增加而增长，而是存在窄的最优比例点。第二，收益不具备骨干网络无关性，yolo11x-cls 的轻量验证已经表明小比例 HN 并不必然复现相同方向的净增益。第三，均匀回流只能说明候选池作为整体具有训练价值，并不能说明池内部样本价值近似同质；这恰恰构成了后续高价值困难样本直接评估问题的直接动机。

从均匀回流最优比例点到候选池内部异质性的问题转移




图 5.11 从容量扫描、HN 最优比例点到固定预算样本重分配的问题收缩链

图 5.11 所表达的核心逻辑是：第 5 章已经基本扫透了 HN 的“数量维度”，而尚未解释的是困难正常样本候选池的“组成维度”。更具体地说，hn14 说明在当前主模型与均匀回流规则下，额外回流预算存在一个最优比例点；但 HN 收益的非单调性、在 yolo11x-cls 上未复现以及 top250 候选池本身较宽这三点，又共同说明候选池内部样本并不能被近似看成同质整体。于是，下一步自然不再是继续扫描更多比例，而是在固定 hn14 预算的条件下研究“哪些该加、哪些不该加”。这也正是第 6 章的起点。

第 6 章 高价值困难样本的信号分解与 Goldilocks 效应验证

第 5 章的 HN 比例全量扫描揭示了三个关键观察：（1）HN 增益呈非单调双峰形态，说明候选池中混有高价值与低价值样本；（2）不同容量模型的最优比例点互不相同，说明样本价值具有模型相关性；（3）较高比例（hn16–hn20）的性能急剧下降，说明过量注入低价值样本会干扰训练。这三个观察共同指向一个核心问题：在固定回流预算下，候选池内部哪些样本真正对门控性能有正向贡献？

6.1 从 HN 非单调性到样本价值信号假设

均匀回流将 hn14 的 $B = 151$ 张预算等概率地分配给候选池中的所有样本，隐含了“候选池内部样本同质”的假设。但 HN 曲线的双峰形态直接否定了该假设——如果所有候选样本价值相同，增加比例应产生单调递增而非双峰。

基于第 2 章的理论分析，本文从卷积网络的训练动力学出发，提出四条可观测的样本价值信号假设：

1. 校准后边界风险 R (boundary risk)：样本是否靠近门控工作阈值 $\tau_{99.5}$ 。从式 (1.1) 的约束优化目标直接推导——距离决策边界越近的样本，对 specificity 的边际影响越大 [22, 23]。
2. 特征空间结构支撑 D (density)：样本在 representation space 中是否具有相似邻居。有邻域支撑的高风险样本更可能对应系统性困难模式（如管壁水膜与裂缝的视觉混淆），而孤立高风险样本更可能是采集噪声 [28]。
3. 扰动预测稳定性 C (consistency)：样本在轻量 TTA 下的预测是否稳定。真正的系统性困难模式应在微小扰动下保持高异常概率，而偶发反光/脏帧引起的高分往往对扰动极度敏感 [26]。
4. 训练轨迹持续性 T (trajectory)：样本在跨 epoch 训练过程中是否持续处于门控边界附近。Dataset Cartography [30] 表明，在不同 epoch 间反复摇摆的 ambiguous 样本具有最高训练价值，而持续被正确分类的 easy 样本和持续被错分的 hard-to-learn 样本价值较低。

这四条信号构成两对正交镜像： $R \leftrightarrow C$ （空间位置 vs 扰动稳定性）和 $D \leftrightarrow T$ （邻域结构 vs 时间轨迹）。本章首先对已实现的 $R/C/D$ 三条信号执行分位数分层消融（quintile-stratified ablation），验证各信号的独立排序力与非单调价值–信号响应（Goldilocks pattern）。

6.2 候选池构建

候选池固定为基线门控模型 `yolo11m-cls + hn00` (epoch 78) 在 1080 个训练正常样本上的 top-250 高风险样本。`hn14` 的最优回流预算为 151 张，但最优比例点附近的非单调性表明候选池边界可能遗漏有价值样本，因此将候选池扩展至 top-250 (训练正常样本的前 23.15%)，确保潜在的 Goldilocks zone 完整落入候选范围。

6.3 分位数分层消融与 Goldilocks 效应验证

上述四条信号假设需要在当前门控任务上逐信号独立验证。直接将多个信号组合为单一评分函数存在隐含单调假设 (implicit monotonic assumption) 的风险——即默认信号值越高则样本越有价值。为避免这一假设偏差，本节采用分位数分层消融 (quintile-stratified ablation) 设计，将各信号的排序力解耦，逐信号验证其排序力与价值-信号响应的单调性。

6.3.1 实验设计

将候选池 250 个样本按 R 、 C 、 D 三个信号各自降序排列后均分为 5 个分位桶 (quintile bucket): Q1 (rank 1–50, 信号值最高) 至 Q5 (rank 201–250, 信号值最低)，每桶 50 个 unique 样本。各桶内 50 个样本以等概率 replay 至训练预算 $B = 151$ 张。另设均匀基线 G0: 从 250 池中不放回随机抽取 151 张，不使用任何信号排序。3 个信号 $\times$ 5 个分位桶 + 1 个 G0 = **16** 组独立训练 run，全部在第 3.2 节的等条件共享协议下执行，评估遵循第 3.3 节。

6.3.2 主结果

表 6.1 三信号分位数分层消融主结果: **Spec@R99.5**。加粗为各信号的 peak bucket, Δ 为相对 G0 的增量。三个信号的 peak 均不在 Q1 (最高信号值)，而分别落在 Q2 (R)、Q4 (C) 和 Q3 (D)，呈现非单调价值-信号响应 (Goldilocks pattern)。注: 本表数据待在扩展验证集 (**707** 正常样本) 上重新评估。

Signal	Q1	Q2	Q3	Q4	Q5	G0	Peak	Δ_{peak}
R (boundary risk)	0.5238	0.6190	0.5119	0.5357	0.5833	0.5476	Q2	+0.0714
C (TTA consistency)	0.5595	0.5595	0.5357	0.6071	0.5833	0.5476	Q4	+0.0595
D (kNN density)	0.5952	0.5476	0.6071	0.5595	0.5476	0.5476	Q3	+0.0595

6.3.3 Goldilocks 效应分析

表 6.1 揭示了三个关键发现。

(1) 三个信号均具有独立排序力。每个信号的 peak bucket 均显著优于 G0

均匀基线： R -Q2 以 +0.0714（6 个正常样本）打赢 G0， C -Q4 和 D -Q3 各以 +0.0595（5 个正常样本）打赢 G0。这是 $R/C/D$ 三个信号在门控任务上排序力存在性（signal sorting power）的首个直接实证。

（2）三个信号均呈非单调价值—信号响应。没有任何一个信号的 Q1（最高信号值样本）是该信号的 peak。 R 信号的 Q1（最靠近门控边界的 50 个样本）的 $\text{Spec@R99.5} = 0.5238$ ，低于 G0 基线 0.0238（2 个正常样本）。这一结果表明，极端信号值样本不等于高价值样本：靠近边界的最外层（”皮层”）中混入采集噪声与孤立异常，中等信号值层（”Goldilocks zone”）才是真正具有系统性训练价值的中间层（moderate-signal stratum）。

（3）**Goldilocks pattern** 在三个正交信号上独立复现。 R （空间静态边界风险）、 C （扰动动态 TTA 稳定性）和 D （邻域空间 kNN 密度）测量的是三个正交维度的样本属性，但三者均呈现相同的非单调模式。单个信号出现非单调可能是偶然；三个正交信号独立复现则构成结构性规律。这一交叉验证（cross-signal cross-validation）使 Goldilocks pattern 的实证基础不依赖于 multi-seed 重复。

6.3.4 单调加权假设的反证

Goldilocks pattern 直接否定了单调加权假设（monotonic weighting assumption）——即”信号值越高则样本训练价值越高”。若按该假设设计评分函数（如 $\pi_i \propto R_i^k$ ），采样概率将集中在 Q1 附近。然而，表 6.1 证明 R -Q1 恰好是排序力最低的分位桶，其 gate 性能甚至低于 G0 均匀基线。因此，有效的样本评分函数必须是非单调的——对中间层（Goldilocks zone）赋予高权重，对两端赋予低权重。




图 6.1 单调加权假设的反证。(a) 假设采用 $\pi_i \propto R_i^2$ 的单调评分，84% 以上的采样预算将集中在 Q1（最高 R 值样本）。(b) 分位数消融表明 Q1 的 Spec@R99.5 低于 G0 基线（-0.0238），而 Q2 才是 peak（+0.0714）。单调加权将预算系统性地投向最低价值分位桶。




图 6.2 三信号分位数分层消融的非单调价值-信号响应 (Goldilocks pattern)。R 信号 peak 落在 Q2 (+0.0714, 6 个正常样本), C 信号 peak 落在 Q4 (+0.0595), D 信号 peak 落在 Q3 (+0.0595)。R-Q1 (最高边界风险) 的 Spec@R99.5 反而低于 G0 基线。拟合二次曲线可视化非单调 shape。

第 7 章 综合讨论与工程启示

本章对第 4–6 章的实验结果进行综合讨论，围绕三个层面展开：等条件容量扫描与 HN 全量扫描建立的跨容量规律、分位数分层消融揭示的 Goldilocks 效应及其理论意义、当前方法边界与后续方向。

7.1 已建立的第一阶段证据链

表 7.1 第一阶段已建立证据链总表

证据环节	回答的问题	当前结论	状态
容量扫描	谁是第一阶段主模型	yolo11m-cls 为主模型，已完成 yolo11x-cls 为第二对照	
检查点错位	训练器指标能否直接选模	5 个模型的训练器最优轮次均与门控最优轮次不一致	已完成
跨视图错位	六类视图能否替代门控视图	六类源域视图仅为辅助参考，不能替代门控选模	已完成
HN 比例扫描	HN 是否存在最优比例点	五个容量最优点互不相同：l+hn10（全局最优）、m+hn12、x+hn02；n/s 无增益	已完成
高价值样本直接评估	固定预算下能否直接评估并优先利用高价值困难样本	已提出 lite 版实现；已完成 Goldilocks Campaign R-W02 验证甜点区效应	

表 7.1 汇总了五条相互衔接的证据环节。所有排序均为当前数据划分与当前随机种子下的点估计（具体不确定性见表 4.2）。其中 lite 路线的贡献不是给出胜出策略，而是把“固定预算下高价值困难样本的直接评估”建立为一个可审计、带清晰边界的研究问题。

7.2 HN 增益的容量依赖性

表 5.5 的跨容量对比（基于扩展验证集，707 个正常样本）揭示了 HN 增益的强容量依赖性：小容量模型（n/s，5–9M 参数）几乎无法从 HN 回流中获益（ $\Delta\text{Spec} \approx 0$ ），而大容量模型则获得显著增益——l+hn10 以 $\Delta\text{Spec}@R99.5 =$

+0.2447 (拦截 319/707 个正常样本) 成为 55 个数据点的全局最优, $m+hn12$ 增益 +0.1612, $x+hn02$ 增益 +0.0594。

五个容量的 winner ratio 互不相同 ($n \rightarrow hn00$, $s \rightarrow hn20$, $m \rightarrow hn12$, $l \rightarrow hn10$, $x \rightarrow hn02$), 表明不存在通用最优 HN 比例, 必须逐模型搜索。这些差异不能由单一超参数解释, 而是反映了不同容量模型对 HN 注入的不同训练动力学响应。

值得注意的是, 旧验证集 (84 个正常样本) 曾给出“HN 增益随容量递减至零”的结论, 扩展验证集将其推翻: 1 从旧评估中表现最弱的模型反转为全局冠军。这一反转突显了充分验证集规模对消除小样本偏差的重要性, 也说明在安全关键场景下, 84 个正常样本不足以支撑可靠的模型选择结论。

7.3 Goldilocks 效应的理论意义

第 6.3 节的分位数分层消融揭示了样本价值建模中的一个核心发现: 三个正交信号均呈非单调价值-信号响应。这一 Goldilocks pattern 与 Swayamdipta 等人在 Dataset Cartography^[30] 中报告的“ambiguous 样本训练价值高于 hard-to-learn 样本”高度一致, 但本文在两个方面扩展了原有发现: (1) Dataset Cartography 的分类基于训练轨迹的时变性 (跨 epoch 方差), 本文的 $R/C/D$ 三个信号均为静态一次性打分, 表明 Goldilocks 效应在静态评估框架下同样成立; (2) Goldilocks pattern 在三个测量不同物理量的正交信号上独立复现, 构成跨信号交叉验证 (cross-signal cross-validation), 而非依赖单一信号的观察。

该发现对后续样本效用评分函数的设计施加了一个硬约束: 评分函数不能对任何单一信号采用单调加权 (如纯 top- k 选样或 R^α 放大)。有效的评分策略必须识别并优先选择中间层 (Goldilocks zone) 样本, 而非极端值样本。

7.4 当前方法边界与后续方向

表 7.2 本文已解决问题与未解决问题对照表

问题类型	当前结论	是否已闭合
第一阶段选模	已通过二分类门控协议闭合	是
HN 最优比例点	全局最优为 yolo111-cls + hn10; m 最优为 hn12	是
HN 跨容量稳定性	n/s/m/l/x 五模型全量扫描已完成, 增益呈容量依赖性 (小容量无增益, 大容量巨幅增益)	是
Goldilocks 效应	三信号分位数分层消融均呈非单调价值-信号响应	是
高价值困难样本直接评估	lite 版 A0-A4 负结果; Goldilocks 归因已定位失败主因	部分
完整两阶段系统优于单阶段检测器	当前不作结论	否

本文存在以下已知局限性: (1) 单随机种子: 所有排序均为单一 seed 下的点估计, 未补做 multi-seed 重复; 但三信号交叉验证和四模型跨容量复现提供了替代性的鲁棒性证据。(2) 单数据集: 所有实验基于 Sewer-ML 的子集, 未在其他管道或工业检测数据集上验证泛化性。(3) 评估集规模有限: 84 个 op normal 对应 Wilson 步长 0.0119, 相邻排序的置信区间存在重叠。(4) 跨容量结论的 **scope** 限定: 容量阶梯假说与 HN 增益递减规律严格限定在等条件共享协议下, 不代表 model-specific 调参下的最优表现。

后续研究应优先推进以下方向: (1) 闭环验证 (closed-loop retraining validation): 基于 Goldilocks 效应设计非单调评分函数, 选样后重训练并与 G0 均匀基线比较, 完成从”发现规律”到”利用规律”的闭环。(2) 教师选择消融: 对比 gate-best 教师与 top1-best 教师在 $R/C/D$ 评分上的排序力差异。(3) 跨容量 **Goldilocks** 验证: 在 n/s/l 容量上重复分位数分层消融, 验证 Goldilocks zone 是数据属性而非模型属性。

附录 A 第一阶段协议与符号表

表 A.1 第一阶段协议摘要

项目	说明
主选模视图	直接二分类门控
辅助参考视图	六类源域容量扫描
二分类门控排序规则	$\text{Spec@R99.5} > \text{Spec@R99.0} > \text{Prec@R99.0} > \text{PTR@R99.0}$
六类视图排序规则	先比较准确率，再比较 AUROC 与 AUPRC
统一训练协议	批量大小 24，训练轮数 200，每轮保存检查点
检查点策略	每轮检查点均由外部评估器评估；训练器 <code>top1</code> 不决定最终检查点选择
校准协议	先在校准集（val-cal）上拟合温度，再在工作点评估集（val-op）上搜索工作阈值
HN 协议	在骨干网络固定后继续沿用同一套校准后的门控排序规则
当前稿件范围	仅报告已经完成的第一阶段证据

附录 B 容量扫描补充材料

B.1 五模型检查点关键索引

表 B.1 五模型门控最优检查点与训练器最优轮次索引

模型	门控最优轮次	训练器最优轮次	轮次差	二分类门控排序
yolo11n-cls	76	120	44	5
yolo11s-cls	77	88	11	4
yolo11m-cls	78	197	119	1
yolo11l-cls	54	103	49	3
yolo11x-cls	125	120	-5	2

B.2 容量扫描补充说明

容量扫描的完整主表、主图与附录图表均已在 `research/results/stage1_formal/capacity_` 下留档。正文只保留最直接支撑结论的主表与主图，而本附录的作用是提供更明确的检查点索引、错位量级与溯源路径，便于后续复核与复现。

附录 C HN 比例扫描与困难正常样本来源补充材料

C.1 HN 检查点与材料覆盖

表 C.1 五模型 HN 最优检查点汇总（扩展验证集，707 正常样本）。仅列出各模型基线与排序第一设置。

模型	比例	最优轮次	Spec@R99.5	tn/707	Spec@R99.0	Prec@R99.0	PTR@R99.0
yolo11n-cls	hn00	76	0.3267	231	0.4371	0.8870	0.9120
yolo11s-cls	hn00	77	0.3395	240	0.4455	0.8885	0.9104
yolo11s-cls	hn20	66	0.3409	241	0.4484	0.8892	0.9112
yolo11m-cls	hn00	78	0.1697	120	0.3140	0.8657	0.9350
yolo11m-cls	hn12	115	0.3310	234	0.4215	0.8843	0.9154
yolo11l-cls	hn00	54	0.2065	146	0.3805	0.8771	0.9223
yolo11l-cls	hn10	48	0.4512	319	0.4979	0.8981	0.9016
yolo11x-cls	hn00	125	0.3140	222	0.4710	0.8931	0.9060
yolo11x-cls	hn02	59	0.3734	264	0.4682	0.8926	0.9065

表 C.2 yolo11n-cls 的全量 HN 比例扫描结果（扩展验证集，707 正常样本）

比例	最优轮次	Spec@R99.5	Spec@R99.0	Prec@R99.0	PTR@R99.0	备注
hn00	76	0.3267	0.4371	0.8870	0.9120	基线（排序第一）
hn02	43	0.1485	0.2334	0.8523	0.9498	
hn04	72	0.1768	0.3678	0.8749	0.9252	
hn06	1	0.2871	0.3904	0.8788	0.9205	
hn08	100	0.2843	0.4130	0.8828	0.9164	
hn10	1	0.3168	0.4201	0.8840	0.9151	
hn12	1	0.2956	0.4272	0.8853	0.9141	
hn14	87	0.2008	0.3550	0.8727	0.9270	
hn16	1	0.2447	0.3621	0.8739	0.9260	
hn18	1	0.2857	0.4215	0.8843	0.9154	
hn20	1	0.2900	0.4031	0.8810	0.9182	

表 C.2 为扩展验证集上的完整评估结果。yolo11n-cls 的基线 hn00 即为排序第一，所有 HN 比例均导致 Spec@R99.5 下降，表明小容量模型无法从 HN 回流中获益。

表 C.3 yolo11s-cls 的全量 HN 比例扫描结果（扩展验证集，707 正常样本）

比例	最优轮次	Spec@R99.5	Spec@R99.0	Prec@R99.0	PTR@R99.0	备注
hn00	77	0.3395	0.4455	0.8885	0.9104	基线
hn02	8	0.3182	0.4201	0.8841	0.9154	
hn04	28	0.3126	0.4356	0.8868	0.9128	
hn06	54	0.3310	0.4399	0.8875	0.9115	
hn08	1	0.2857	0.4243	0.8848	0.9143	
hn10	36	0.2192	0.3479	0.8714	0.9283	
hn12	1	0.2744	0.4116	0.8826	0.9172	
hn14	75	0.3083	0.4045	0.8813	0.9179	
hn16	1	0.2928	0.4484	0.8890	0.9099	
hn18	1	0.3013	0.4427	0.8880	0.9110	
hn20	66	0.3409	0.4484	0.8892	0.9112	排序第一 ($\Delta+0.0014$)

表 C.3 显示 yolo11s-cls 的 hn20 仅以 $\Delta = +0.0014$ 微弱领先基线，在统计上不具备显著性，与 n 共同支持小容量模型无法从 HN 获益的结论。

全部 HN 比例扫描的逐轮评估汇总（epoch_gate_summary）、最优轮次清单（best_epoch_manifest）与检查点索引（all_checkpoints_index）均以 CSV / JSON / Markdown 三格式归档于 research/materials/stage1_formal/gate_hn_{n,s,m,l,x}_s 各比例子目录中。

C.2 yolo11l-cls 完整 HN 比例扫描

表 C.4 yolo11l-cls HN 比例扫描完整四指标表（扩展验证集，707 正常样本）

Ratio	Best Epoch	Spec@R99.5	Spec@R99.0	Prec@R99.0	PTR@R99.0	Δ Spec@R99.5
hn00	54	0.2065	0.3805	0.8771	0.9223	0
hn02	64	0.2984	0.4045	0.8813	0.9182	+0.0919
hn04	115	0.2617	0.3890	0.8785	0.9208	+0.0552
hn06	16	0.1825	0.3140	0.8657	0.9347	-0.0240
hn08	14	0.3522	0.4272	0.8853	0.9138	+0.1457
hn10	48	0.4512	0.4979	0.8981	0.9016	+0.2447
hn12	5	0.3352	0.4187	0.8838	0.9154	+0.1287
hn14	86	0.3098	0.4130	0.8828	0.9164	+0.1033
hn16	54	0.2772	0.3960	0.8799	0.9195	+0.0707
hn18	1	0.2390	0.4045	0.8814	0.9187	+0.0325
hn20	5	0.3083	0.4116	0.8825	0.9166	+0.1018

C.3 分位数分层消融完整结果

表 C.5 $R/C/D$ 三信号分位数分层消融完整四指标表 (16 组 run, G0 = 均匀基线)

Signal	Bucket	Unique	Best Epoch	Spec@R99.5	Spec@R99.0	Prec@R99.0	PTR@R99.0
R	Q1	50	112	0.5238	0.5357	0.9143	0.9028
R	Q2	50	100	0.6190	0.6429	0.9329	0.8869
R	Q3	50	108	0.5119	0.5357	0.9143	0.9028
R	Q4	50	25	0.5357	0.5833	0.9227	0.8968
R	Q5	50	76	0.5833	0.6071	0.9267	0.8929
C	Q1	50	109	0.5595	0.5595	0.9187	0.9028
C	Q2	50	2	0.5595	0.5714	0.9205	0.8988
C	Q3	50	78	0.5357	0.5714	0.9204	0.8968
C	Q4	50	82	0.6071	0.6310	0.9306	0.8869
C	Q5	50	161	0.5833	0.6071	0.9265	0.8909
D	Q1	50	57	0.5952	0.6429	0.9329	0.8869
D	Q2	50	46	0.5476	0.5952	0.9244	0.8929
D	Q3	50	72	0.6071	0.6190	0.9287	0.8909
D	Q4	50	41	0.5595	0.5833	0.9224	0.8948
D	Q5	50	81	0.5476	0.5833	0.9224	0.8948
baseline	G0	151	79	0.5476	0.5952	0.9244	0.8929

C.4 HN sweep 的整体形态




图 C.1 各 HN ratio 相对 hn00 的增量热力图

C.5 HN 样本来源证明

表 C.6 困难正常样本选择统计

正常样本总数	选中数	占比	最低分	中位数	最高分	阈值
1080	250	0.2315	0.1133	0.2854	0.9780	0.1133




图 C.2 训练正常样本的异常分数分布与困难正常样本选择阈值

C.6 关于比例级 top1 与门控最优检查点的说明

当前 HN 材料层级并不包含可靠的训练器侧比例级 top1 轨迹字段；因此，本文不构造“比例级 top1 与门控最优检查点错位”这一类缺乏直接证据的结论，

而仅在附录溯源档案中登记该限制。

附录 D 有效信息量评分函数、消融接口与样本清单

D.1 lite 版评分函数摘要

为便于后续复现实验，本文将门控导向有效信息量评分 lite 版的最终表达统一记为

$$S_i^{(A2)} = R_i, \quad S_i^{(A3)} = (R_i C_i)^{1/2}, \quad S_i^{(A4)} = (R_i C_i D_i)^{1/3}, \quad (\text{D.1})$$

其中风险项 R_i 、一致性项 C_i 与结构支撑项 D_i 的定义见第 6 章。三组实验共享同一困难正常样本候选池、同一 **hn14** 预算锚点以及同一外部评估器，不改变骨干网络、批量大小、训练轮数或检查点策略。

D.2 样本清单与固定预算接口

对于 lite 版重加权实验，本文保留的最小可复现工作集包括候选池评分清单、采样概率清单、加权回流清单与套件级汇总，而不要求在论文仓库内长期保留全量中间张量或分类图片副本。更具体地说，`candidate_pool_scores.csv`、`score_stats.json/md`、`weighted_replay_summary.json` 以及相应清单文件共同构成了从固定候选池到固定预算回流分配的可追溯接口。

附录 E 复现实验入口、目录结构与溯源清单

E.1 训练脚本与运行入口

当前 lite 版重加权实验的训练入口统一挂接在 `main.py` 的 `stage1_formal_gate_info_sampl` 任务下。整个流程可概括为四步：先生成固定候选池的一次性评分、采样概率与统计汇总；再在固定 `hn14` 预算下构建加权回流数据集视图；随后组织预检、冒烟测试、完整运行和套件级汇总；最后生成表格、图像、汇总文件与清单文件。对应脚本分别为 `stage1_prepare_info_sampling_lite_scores.py`、`stage1_build_info_sampling_lite_dataset.py`、`stage1_formal_gate_info_sampling_lite.py` 与 `stage1_build_info_sampling_lite_paper_assets.py`。为避免误用，教师模型固定为 `yolo11m-cls + hn00` 的门控最优检查点，困难正常样本候选池固定为既有 `top_false_positive_normals.csv`，预算固定为 151。若预检或冒烟测试未通过，本文不建议直接启动完整运行。

E.2 目录结构与溯源清单

与 lite 版实验直接相关的目录可概括为三层：第一层是 `research/materials/stage1_formal`，用于保留候选池评分、数据集清单与运行清单；第二层是 `research/results/stage1_formal/gate`，用于保留预检、冒烟测试、结果汇总、复现说明与产物说明等汇总文件；第三层是 `YOL0v11/datasets/stage1_formal_gate_info_sampling_lite` 与 `YOL0v11/runs/stage1_forma`，分别保存加权数据集视图和训练运行目录。三层目录之间通过清单文件与路径指针关联，而不依赖人工整理。

表 E.1 lite 版 PNG 产物重建清单与用途说明

文件	层级	用途
<code>stage1_info_sampling_lite_png_manifest.csv</code>	材料层/清单目录	登记当前 lite 工作流中所有 PNG 产物的文件级清单，便于核查哪些图表已经被实际生成。
<code>stage1_info_sampling_lite_png_rebuild_map.csv</code>	材料层/清单目录	建立 PNG 文件与重建来源之间的映射关系，用于后续按脚本和溯源路径重画图表。
<code>stage1_info_sampling_lite_png_manifest_usage.md</code>	材料层/清单目录	对上述两份 CSV 的字段、用途与使用方式给出文字说明。

截至本文当前版本，lite 路线已经同时包含 A0–A4 的结果表、主图、附录材料以及上述 PNG 重建清单。后者的作用是补强图表可追溯性与重建路径，而不是替代性能结果本身。因此，第 6 章的 lite 结论应以结果表和图像为主，以清单文件作为溯源辅助。

E.3 产物保留与清理规则

考虑到训练侧工作流会产生大量中间文件，本文对 lite 版产物的保留规则作如下约定：保留 `candidate_pool_scores.csv`、`score_stats.json`、`md`、`dataset_manifest.json`、`run_manifest.json`、`epoch_gate_summary.*`、`best_epoch_manifest.json` 与套件级主表主图；不将全量检查点复制到 `research/materials`，也不默认复制分类图片副本。若临时生成特征张量、测试时增强原始数组或样本画廊中间件，使用后即清理，并在相应清单文件中登记“已清理”状态。

参考文献

- [1] Goodfellow I, Bengio Y, Courville A. Deep Learning[M]. Cambridge: MIT Press, 2016.
- [2] LeCun Y, Bottou L, Bengio Y, Haffner P. Gradient-Based Learning Applied to Document Recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278–2324.
- [3] Krizhevsky A, Sutskever I, Hinton G E. ImageNet Classification with Deep Convolutional Neural Networks[C]//Advances in Neural Information Processing Systems. 2012: 1097–1105.
- [4] Simonyan K, Zisserman A. Very Deep Convolutional Networks for Large-Scale Image Recognition[C]//International Conference on Learning Representations. 2015.
- [5] He K, Zhang X, Ren S, Sun J. Deep Residual Learning for Image Recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770–778.
- [6] Nair V, Hinton G E. Rectified Linear Units Improve Restricted Boltzmann Machines[C]//Proceedings of the 27th International Conference on Machine Learning. 2010: 807–814.
- [7] Ioffe S, Szegedy C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift[C]//Proceedings of the 32nd International Conference on Machine Learning. 2015: 448–456.
- [8] Redmon J, Farhadi A. YOLO9000: Better, Faster, Stronger[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 6517–6525.
- [9] Redmon J, Farhadi A. YOLOv3: An Incremental Improvement[J]. arXiv preprint arXiv:1804.02767, 2018.
- [10] Bochkovskiy A, Wang C Y, Liao H Y M. YOLOv4: Optimal Speed and Accuracy of Object Detection[J]. arXiv preprint arXiv:2004.10934, 2020.

- [11] Jocher G, Chaurasia A, Qiu J. Ultralytics YOLO[EB/OL]. <https://github.com/ultralytics/ultralytics>, 2023.
- [12] Pan S J, Yang Q. A Survey on Transfer Learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2010, 22(10): 1345–1359.
- [13] Yosinski J, Clune J, Bengio Y, Lipson H. How Transferable Are Features in Deep Neural Networks?[C]//Advances in Neural Information Processing Systems. 2014: 3320–3328.
- [14] Moradi S, Zayed T, Golkhoo F. Review on Computer Aided Sewer Pipeline Defect Detection and Condition Assessment[J]. Infrastructures, 2019, 4(1): 10.
- [15] Haurum J B, Moeslund T B. A Survey on Image-Based Automation of CCTV and SSET Sewer Inspections[J]. Automation in Construction, 2020, 111: 103061.
- [16] Ma D, Fang H, Wang N, et al. The State-of-the-Art in Pipe Defect Inspection with Computer Vision-Based Methods[J]. Measurement, 2026, 257: 118431.
- [17] Halfawy M R, Hengmeechai J. Automated Defect Detection in Sewer Closed Circuit Television Images Using Histograms of Oriented Gradients and Support Vector Machine[J]. Automation in Construction, 2014, 38: 1–13.
- [18] Kumar S S, Abraham D M, Jahanshahi M R, et al. Automated Defect Classification in Sewer Closed Circuit Television Inspections Using Deep Convolutional Neural Networks[J]. Automation in Construction, 2018, 91: 273–283.
- [19] Cheng J C P, Wang M. Automated Detection of Sewer Pipe Defects in CCTV Images Using Deep Learning Techniques[J]. Automation in Construction, 2018, 95: 155–171.
- [20] Haurum J B, Moeslund T B. Sewer-ML: A Multi-Label Sewer Defect Classification Dataset and Benchmark[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 13456–13467.
- [21] Redmon J, Divvala S, Girshick R, Farhadi A. You Only Look Once: Unified, Real-Time Object Detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 779–788.

- [22] Guo C, Pleiss G, Sun Y, Weinberger K Q. On Calibration of Modern Neural Networks[C]//Proceedings of the 34th International Conference on Machine Learning. 2017: 1321–1330.
- [23] Kumar A, Narasimhan H, Cotter A, Gupta M. Optimizing Specificity at a High Sensitivity[C]//Proceedings of the 38th International Conference on Machine Learning. 2021: 11415–11424.
- [24] Koh P W, Liang P. Understanding Black-box Predictions via Influence Functions[C]//Proceedings of the 34th International Conference on Machine Learning. 2017: 1885–1894.
- [25] Ash J T, Zhang C, Krishnamurthy A, Langford J, Agarwal A. Deep Batch Active Learning by Diverse, Uncertain Gradient Lower Bounds[C]//International Conference on Learning Representations. 2020.
- [26] Wu J, Zhang T, Zhai Y, et al. Entropy-Based Active Learning for Object Detection With Progressive Diversity Constraint[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 9397–9406.
- [27] Yang Y, Wu Z, Wang J, et al. Plug-and-Play Active Learning for Object Detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 25163–25172.
- [28] Kim M, Hwang J, Kim S, et al. Learning With Structural Labels for Learning With Noisy Labels[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 17639–17649.
- [29] Zhang Y, Li X, Zhou Y, et al. Spanning Training Progress: Temporal Dual-Depth Scoring (TDDS) for Enhanced Dataset Pruning in Object Detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 17665–17675.
- [30] Swayamdipta S, Schwartz R, Lourie N, et al. Dataset Cartography: Mapping and Diagnosing Datasets with Training Dynamics[C]//Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing. 2020: 9275–9293.

- [31] Situ Z, Teng S, Feng W, et al. A Transfer Learning-Based YOLO Network for Sewer Defect Detection in Comparison to Classic Object Detection Methods[J]. *Developments in the Built Environment*, 2023, 15: 100191.
- [32] Wang T, Li Y, Zhai Y, et al. A Sewer Pipeline Defect Detection Method Based on Improved YOLOv5[J]. *Processes*, 2023, 11(8): 2508.
- [33] Zhao X, Xiao N, Cai Z, et al. YOLOv5-Sewer: Lightweight Sewer Defect Detection Model[J]. *Applied Sciences*, 2024, 14(5): 1869.
- [34] Meijer D, Scholten L, Clemens F, Knobbe A. A Defect Classification Methodology for Sewer Image Sets with Convolutional Neural Networks[J]. *Automation in Construction*, 2019, 104: 281–298.
- [35] Xie Q, Li D, Xu J, Yu Z, Wang J. Automatic Detection and Classification of Sewer Defects via Hierarchical Deep Learning[J]. *IEEE Transactions on Automation Science and Engineering*, 2019, 16(4): 1836–1847.
- [36] Chen K, Hu H, Chen C, Chen L, He C. An Intelligent Sewer Defect Detection Method Based on Convolutional Neural Network[C]//*IEEE International Conference on Information and Automation*. 2018: 1301–1306.
- [37] Shamsolmoali P, Sadka A H, Savvas I K, et al. Automated Defect Classification and Localization in Sewer Pipelines Using Hybrid ResNet50–Swin Transformer and Modified YOLOv8[J]. *Scientific Reports*, 2025, 15: 6143.
- [38] Myrans J, Everson R, Maybury R. Automated Detection of Faults in Sewers Using CCTV Image Sequences[J]. *Automation in Construction*, 2019, 95: 64–71.
- [39] Li Y, Xie Q, Yu Z, et al. Sewer Pipe Defect Detection via Deep Learning with Local and Global Feature Fusion[J]. *Automation in Construction*, 2021, 129: 103823.